10.11.20

Einführung in Data Science und maschinelles Lernen mit RStudio

Einführung

OPENCAMPUS.sh

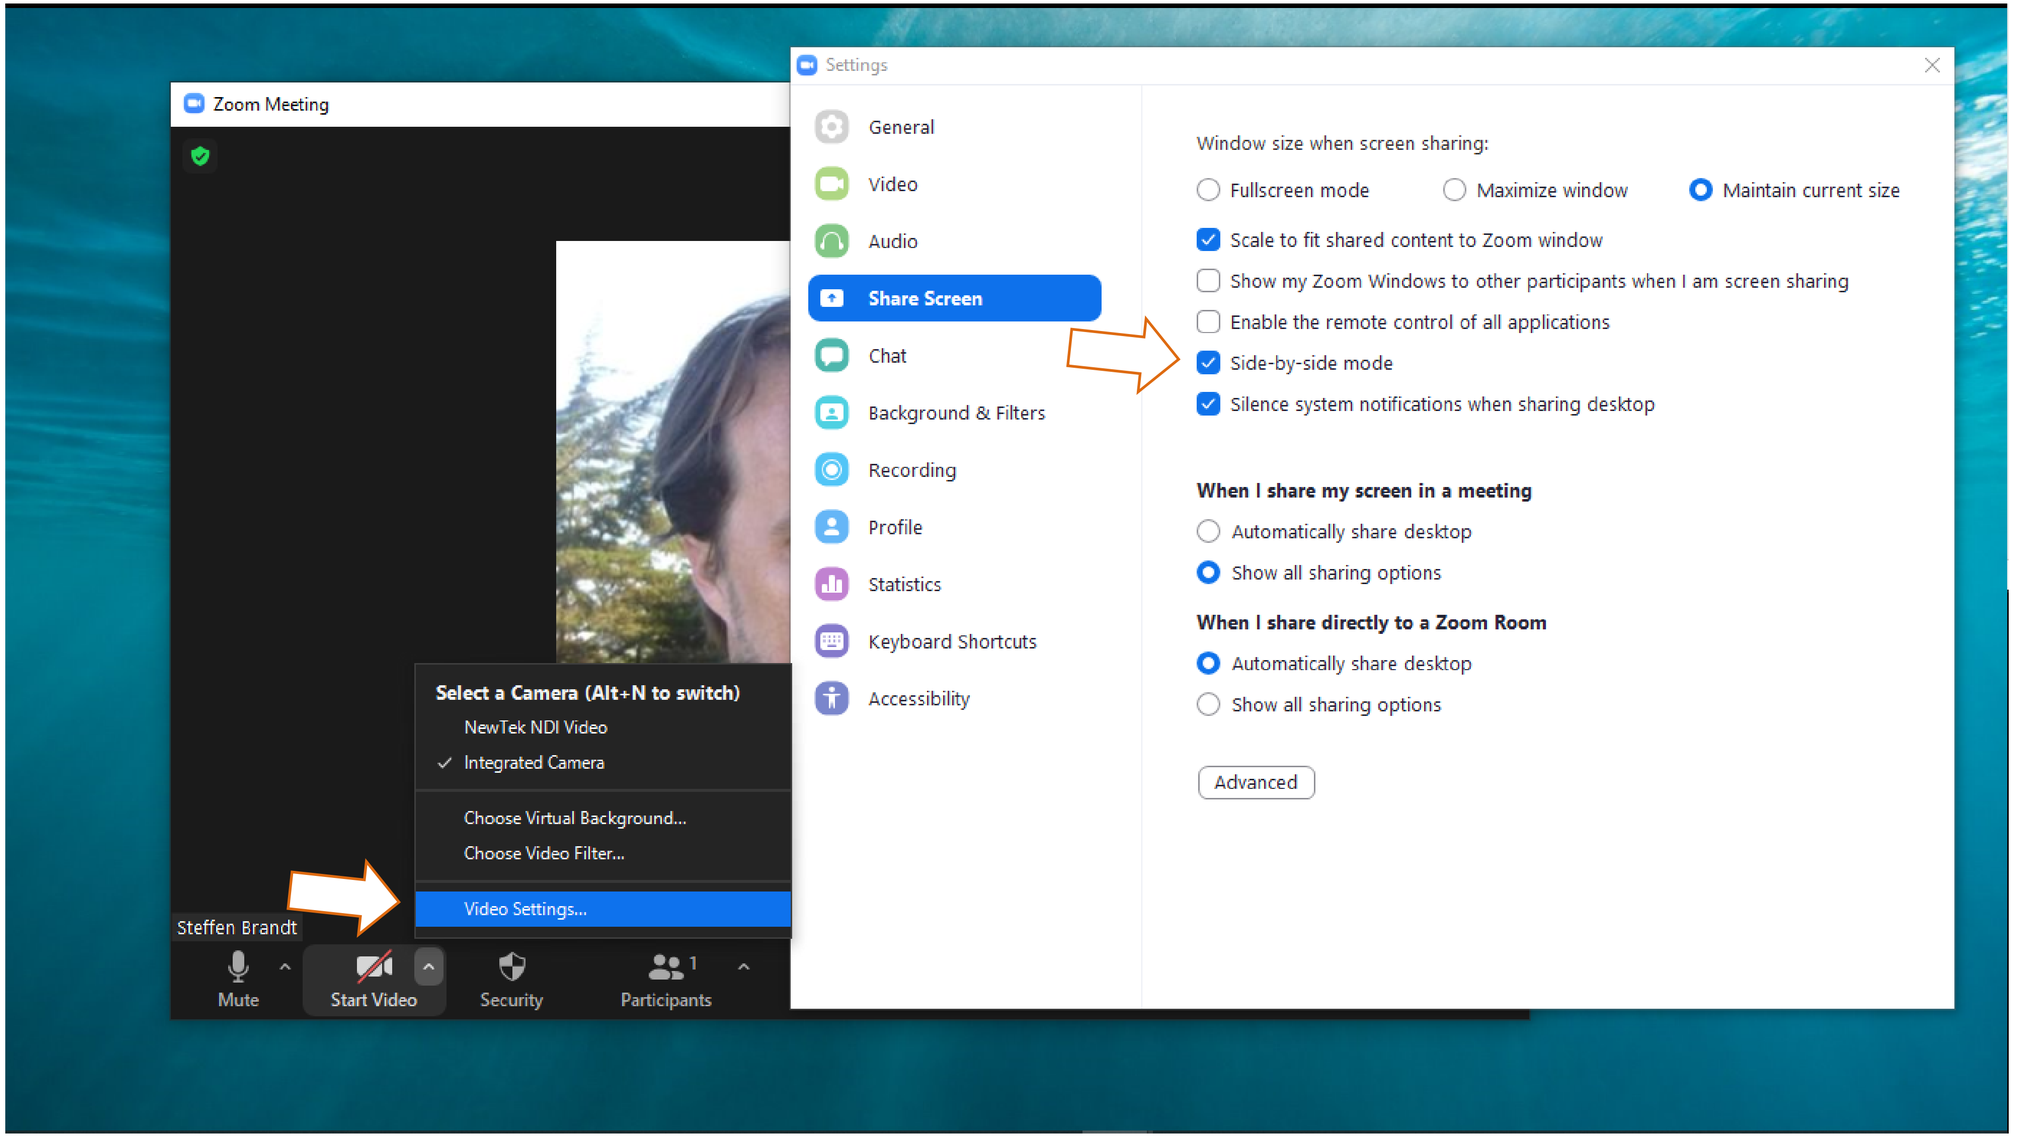
- **Zoom/ Mattermost/ Gitbook**
- **Aufbau des Kurses**
- **Was ist Data Science?**
- **R vs. Python vs. SPSS vs. …**
- **Wozu RStudio?**
- **Datenstrukturen in R**

- **Benutzt Eure tatsächlichen Namen in den Zoom-Meetings!**

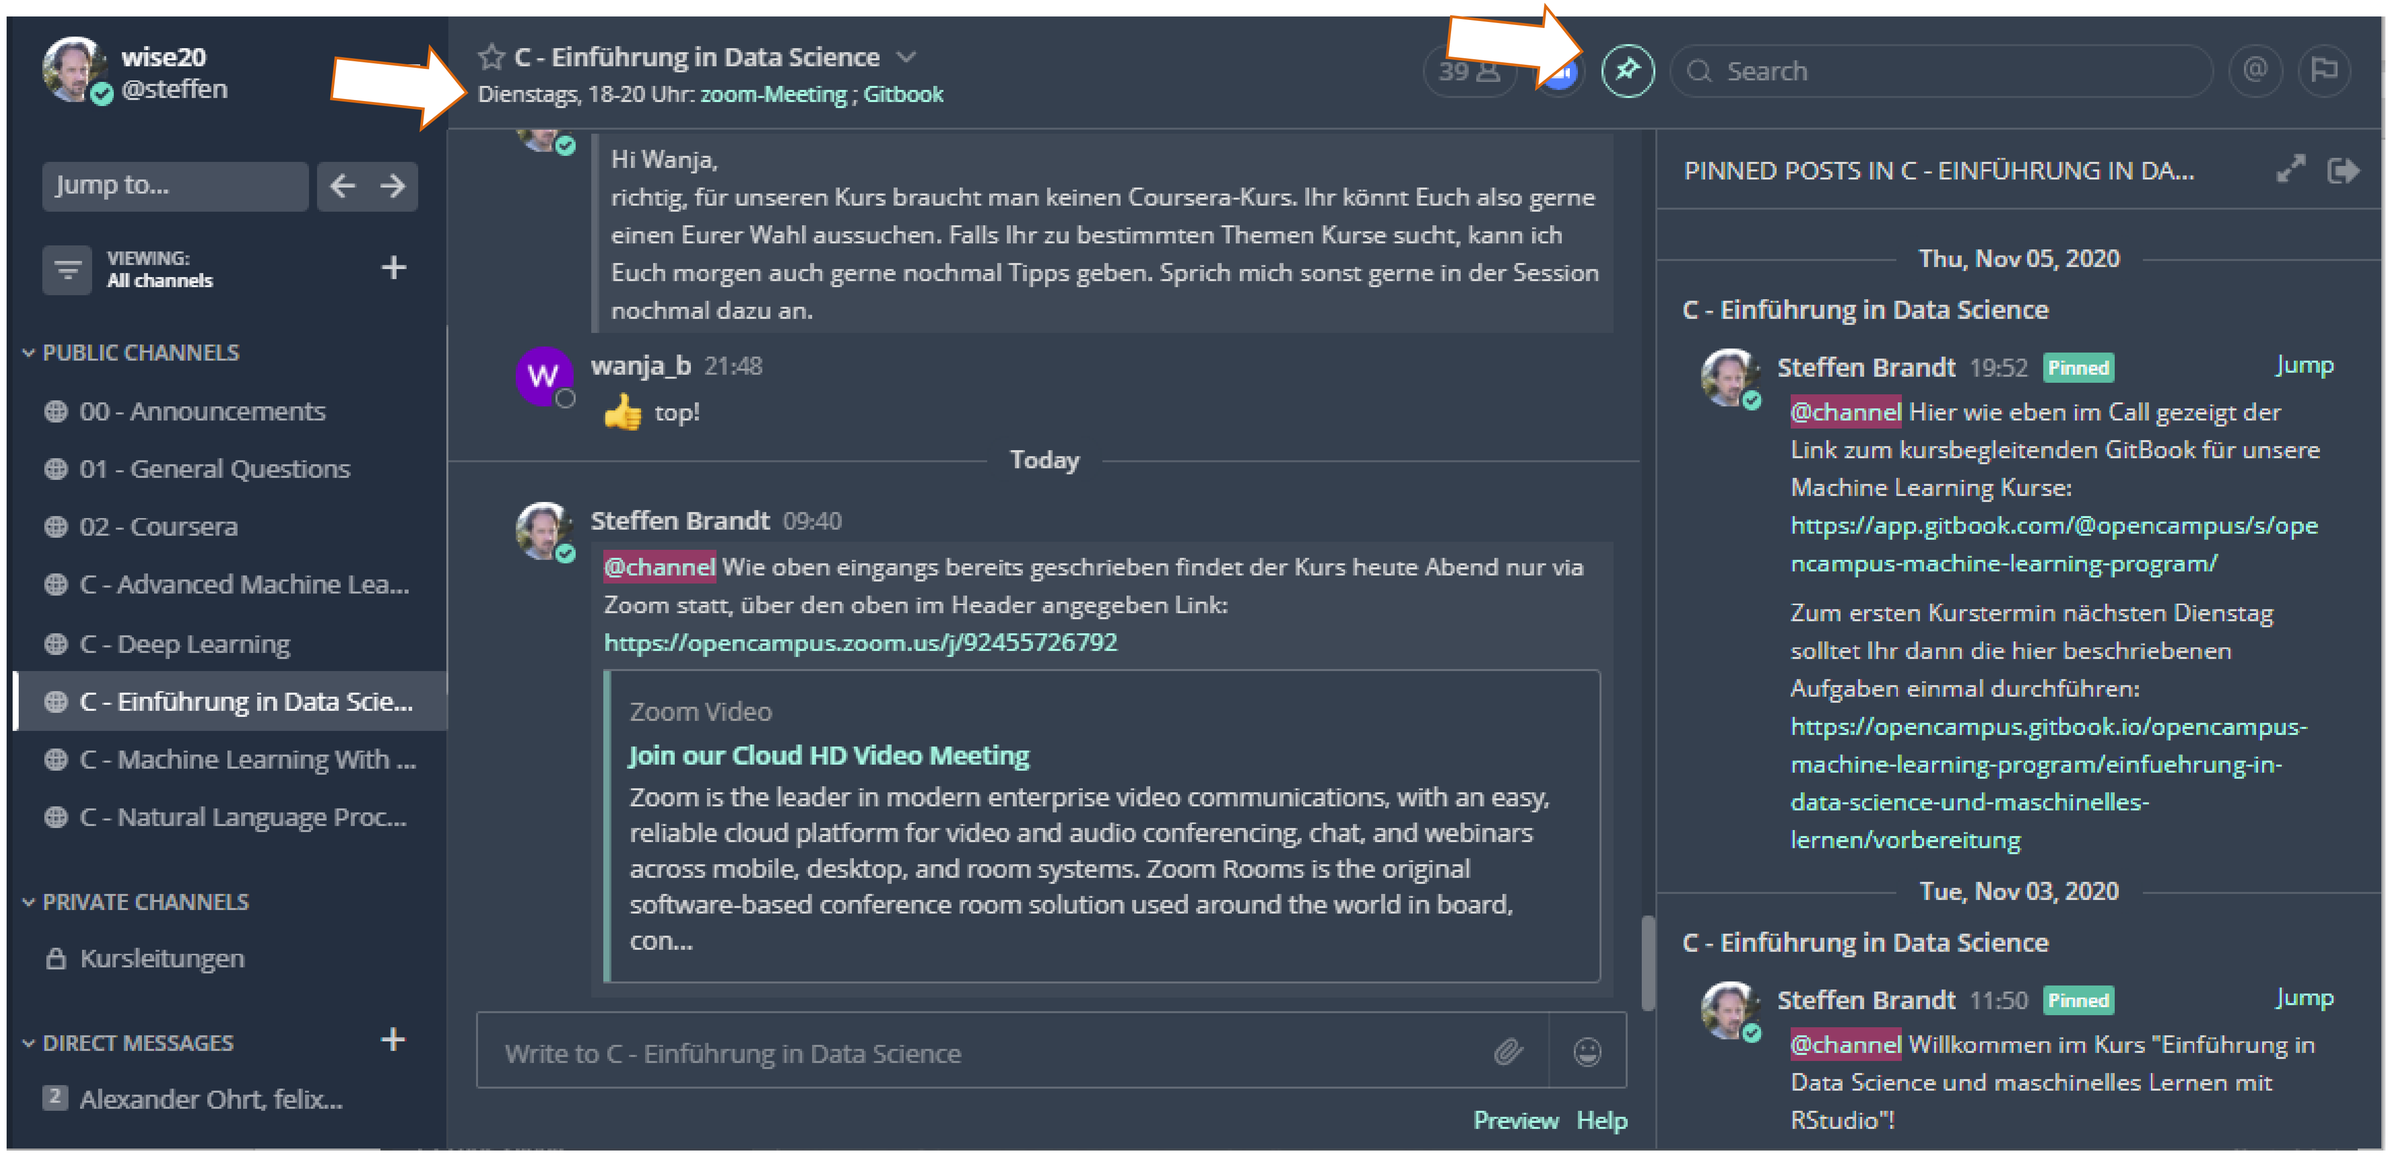
- **Vervollständigt Eure Namen im Mattermost-Profil und fügt, wenn möglich auch ein Foto hinzu.**

- **Bitte schreibt mit, wenn Ihr den Kurs abbrecht!**

- **Zoom**
- **Mattermost**
- **Gitbook**



OPENCAMPUS.sh


wise20
@steffen
C - Einführung in Data Science
Dienstags, 18-20 Uhr: zoom-Meeting ; Gitbook
39
Search
Jump to...
VIEWING:
All channels
PUBLIC CHANNELS
00 - Announcements
01 - General Questions
02 - Coursera
C - Advanced Machine Lea...
C - Deep Learning
C - Einführung in Data Scie...
C - Machine Learning With ...
C - Natural Language Proc...
PRIVATE CHANNELS
Kursleitungen
DIRECT MESSAGES
Alexander Ohrt, felix...
Hi Wanja,
richtig, für unseren Kurs braucht man keinen Coursera-Kurs. Ihr könnt Euch also gerne einen Eurer Wahl aussuchen. Falls Ihr zu bestimmten Themen Kurse sucht, kann ich Euch morgen auch gerne nochmal Tipps geben. Sprich mich sonst gerne in der Session nochmal dazu an.
wanja_b 21:48
top!
Today
Steffen Brandt 09:40
@channel Wie oben eingangs bereits geschrieben findet der Kurs heute Abend nur via Zoom statt, über den oben im Header angegeben Link:
https://opencampus.zoom.us/j/92455726792
Zoom Video
Join our Cloud HD Video Meeting
Zoom is the leader in modern enterprise video communications, with an easy, reliable cloud platform for video and audio conferencing, chat, and webinars across mobile, desktop, and room systems. Zoom Rooms is the original software-based conference room solution used around the world in board, con...
Write to C - Einführung in Data Science
Preview
Help
PINNED POSTS IN C - EINFÜHRUNG IN DA...
Thu, Nov 05, 2020
C - Einführung in Data Science
Steffen Brandt 19:52 Pinned
Jump
@channel Hier wie eben im Call gezeigt der Link zum kursbegleitenden GitBook für unsere Machine Learning Kurse:
https://app.gitbook.com/@opencampus/s/opencampus-machine-learning-program/
Zum ersten Kurstermin nächsten Dienstag solltet Ihr dann die hier beschriebenen Aufgaben einmal durchführen:
https://opencampus.gitbook.io/opencampus-machine-learning-program/einfuehrung-in-data-science-und-maschinelles-lernen/vorbereitung
Tue, Nov 03, 2020
C - Einführung in Data Science
Steffen Brandt 11:50 Pinned
Jump
@channel Willkommen im Kurs "Einführung in Data Science und maschinelles Lernen mit RStudio"!

opencampus.sh Machine Learning Program

Semester Opening

About this Site

How do I choose a course?

FAQ

COURSES

Einführung in Data Science und maschinelles Lernen mit RStudio

Vorbereitung

Woche 1 - Einführung in Data Science

Woche 2 - Grafische Darstellung von Daten

Woche 3 - R-Projekte und Versionierung mit Git und GitHub

Woche 4 - Datenaufbereitung mit Tidyverse

Woche 5 - Einführung in das maschinelle Lernen

Woche 6 - Support Vector Maschinen

Powered by GitBook

Einführung in Data Science und maschinelles Lernen mit RStudio

Here are the articles in this section:

Vorbereitung

Woche 1 - Einführung in Data Science

Woche 2 - Grafische Darstellung von Daten

Woche 3 - R-Projekte und Versionierung mit Git und GitHub

Woche 4 - Datenaufbereitung mit Tidyverse

Woche 5 - Einführung in das maschinelle Lernen

Woche 6 - Support Vector Maschinen

Woche 7 - Neuronale Netze und Deep Learning

Woche 8 - Zeitreihenanalysen

Woche 9 - Projektpräsentationen

OPENCAMPUS.sh

opencampus.sh Machine Learning Program

Semester Opening

About this Site

How do I choose a course?

FAQ

COURSES

Einführung in Data Science und maschinelles Lernen mit RStudio

Vorbereitung

Woche 1 - Einführung in Data Science

Woche 2 - Grafische Darstellung von Daten

Woche 3 - R-Projekte und Versionierung mit Git und GitHub

Woche 4 - Datenaufbereitung mit Tidyverse

Woche 5 - Einführung in das maschinelle Lernen

Woche 6 - Support Vector Maschinen

Powered by GitBook

Woche 1 - Einführung in Data Science

CONTENTS

Diese Woche werdet Ihr...

Lernressourcen

Bis zur nächsten Woche sollt...

Diese Woche werdet Ihr...

eine Einführung zu den folgenden Themen bekommen:

- Was ist Data Science?
- R vs. Python vs. SPSS vs. ...
- Wozu RStudio?
- Datenstrukturen in R

Lernressourcen

- Präsentation des Kurses dieser Woche (wird nach Kursdurchführung hier zum Download verlinkt)
- Einführungsvideo zu RStudio (5 Minuten)

Bis zur nächsten Woche solltet Ihr...

- [x] Insbesondere falls Ihr noch nie mit RStudio gearbeitet habt, schaut Euch das oben verlinkte Einführungsvideo zu RStudio an.
- [x] Versucht die folgenden Aufgaben zu bearbeiten (siehe auch Präsentation):
  - Speichere den Datensatz airquality in der Variable airQuality.
  - Berechne die Gesamtdurchschnittstemperatur.
  - Berechne die Durchschnittstemperatur für den Monat Juli.
  - Vergleiche, ob die Monate Juli und Mai sich signifikant in ihrer Durchschnittstemperatur unterscheiden.

    Denkt daran, dass Ihr eigentlich alles googlen könnt, gerade anhand solcher vergleichsweise leichten Aufgaben kann man gut lernen wie man die Berechnungen bzw. den Programmcode von anderen für sich abändern kann

05.11. **18:00- 20:00**	**SEMESTER OPENING** Online
10.11. **18:00- 20:00**	**EINFÜHRUNG IN DATA SCIENCE** Zoom + Starterkitchen, Kuhnkestraße 6, Wissenschaftspark
17.11. **18:00- 20:00**	**GRAFISCHE DARSTELLUNG VON DATEN** Zoom + Starterkitchen, Kuhnkestraße 6, Wissenschaftspark
24.11. **18:00- 20:00**	**R-PROJEKTE UND VERSIONIERUNG MIT GIT UND GITHUB** Zoom + Starterkitchen, Kuhnkestraße 6, Wissenschaftspark
01.12. **18:00- 20:00**	**DATENAUFBEREITUNG MIT TIDYVERSE** Zoom + Starterkitchen, Kuhnkestraße 6, Wissenschaftspark
08.12. **18:00- 20:00**	**EINFÜHRUNG IN DAS MASCHINELLE LERNEN** Zoom + Starterkitchen, Kuhnkestraße 6, Wissenschaftspark
15.12. **18:00- 20:00**	**SUPPORT VECTOR MASCHINEN** Zoom + Starterkitchen, Kuhnkestraße 6, Wissenschaftspark
22.12. **18:00- 20:00**	**NEURONALE NETZE UND DEEP LEARNING** Zoom + Starterkitchen, Kuhnkestraße 6, Wissenschaftspark
12.01. **18:00- 20:00**	**ZEITREIHENANALYSEN** Zoom + Starterkitchen, Kuhnkestraße 6, Wissenschaftspark
19.01. **18:00- 20:00**	**PROJEKTPRÄSENTATIONEN** Zoom + Starterkitchen, Kuhnkestraße 6, Wissenschaftspark

OPENCAMPUS.sh

Was ist Künstliche Intelligenz?

- Vorstellung
- Diskussion
- Präsentation eines Vorschlags

“What's the difference between data science, machine learning, and artificial intelligence?”

(http://varianceexplained.org/r/ds-ml-ai)

Data science produces insights.

Machine learning produces predictions.

Artificial intelligence produces actions.

DATA SCIENCE

**Anwendung statistischer Auswertungsverfahren
mit deren Hilfe Ergebnisse für einen Bericht oder Artikel erzeugt werden.**

- **Deskriptive Statistiken**
- **Statistische Schlussfolgerungen**
- **Visualisierung von Daten**
- **Design von Experimenten**

MASCHINELLES LERNEN

**Anwendung eines statistisches Auswertungsverfahren
zur Schätzung von Modellparametern (validiert mit „ungesehenen“ Daten)**

**mit deren Hilfe eine Funktion erstellt wird, die Prognosen liefert,
Wobei (häufig) gleichzeitig die Modellparameterschätzung durch
Hinzufügen neuer Daten ständig verbessert wird.**

- **Prognose zukünftiger Zustände**
- **Prognose unbeobachteter Zustände**
- **Prognose aktueller Zustände**

OPENCAMPUS.sh

KÜNSTLICHE INTELLIGENZ

„an autonomous agent executes or recommends actions“

(Poole, Mackworth, & Goebel, 1998)

„Systeme mit einem ‚intelligenten‘ Verhalten, die ihre Umgebung analysieren und mit einem gewissen Grad an Autonomie handeln, um bestimmte Ziele zu erreichen. “

(Europäische Kommission, 2018)

„Unter Künstlicher Intelligenz verstehen wir hochentwickelte Softwaresysteme, welche lernfähig und trainierbar sind, um komplexe Aufgaben bewältigen können.“

(KI-Strategie des Landes Schleswig-Holstein, 2019)

KÜNSTLICHE INTELLIGENZ

(aufgefasst als maschinelles Lernen)

- Programme zur Optimierung (Google Maps)
- Programme zur Steuerung von Robotern
- Programme zur Verarbeitung natürlicher Sprache (Bots)
- Programme, die Spiele spielen (Deep Blue, AlphaGo)

EIGENSCHAFTEN VON R

- **Von Statistikern entwickelte Auswertungssprache (Python etwa kommt aus dem IT-/Tech-Umfeld)**

- **Interpretersprache (Syntax wird Zeile für Zeile interpretiert, vergleichbar eines Taschenrechners)**

- **Konsolen-Programm ohne grafische Benutzeroberfläche**

```r
#####
# Prepare Environament
#####
setwd("C:/Users/Steffen/Arbeit/opencampus/99_source-code/elearning-statistics/00_functions")
source("02_LimeSurvey-API.R") # import LimeSurvey API
setwd("../../auswertung pre-challenge")

library(inspectdf)
library(dplyr)
library(readr)
library(stringr)


#####
# Import Answer Data
#####
introData <- as_tibble(ls.getResponses(615549, sHeadingType = "code")) # import of the Introductory Questionnaire
closingData <- as_tibble(ls.getResponses(722958, sHeadingType = "code")) # import of the Closing Questionnaire


#####
# Prepare Table for Scoring
#####
# Shrink Datasets to Knowledge Items and join them
introItems <- select(introData , matches("Q2|Q3"))
closingItems <- select(closingData , matches("Q2|Q3"))
# shorten name to exclude questioannire ID
names(introItems) <- substr(names(introItems),3, 10)
names(closingItems) <- substr(names(closingItems),3, 10)
# join items according to question IDs
items <- full_join(introItems, closingItems)

# contruct table including all given anwers, how often they occured (percentage and count) and include corresponding score categories if provided
scoreTable <- get.scoreTable(items)
write.csv2(file="ScoringGuide_new.csv", scoreTable, row.names = F, na="")
scoreTable <- read_csv2(file="ScoringGuide_new.csv")

```

NACHTEILE VON R

- Man muss programmieren
- Im Bereich des maschinellen Lernens weniger verbreitet als Python
- Weniger Schnittstellen (APIs) als Python zu Anwendungen im produktiven Umfeld

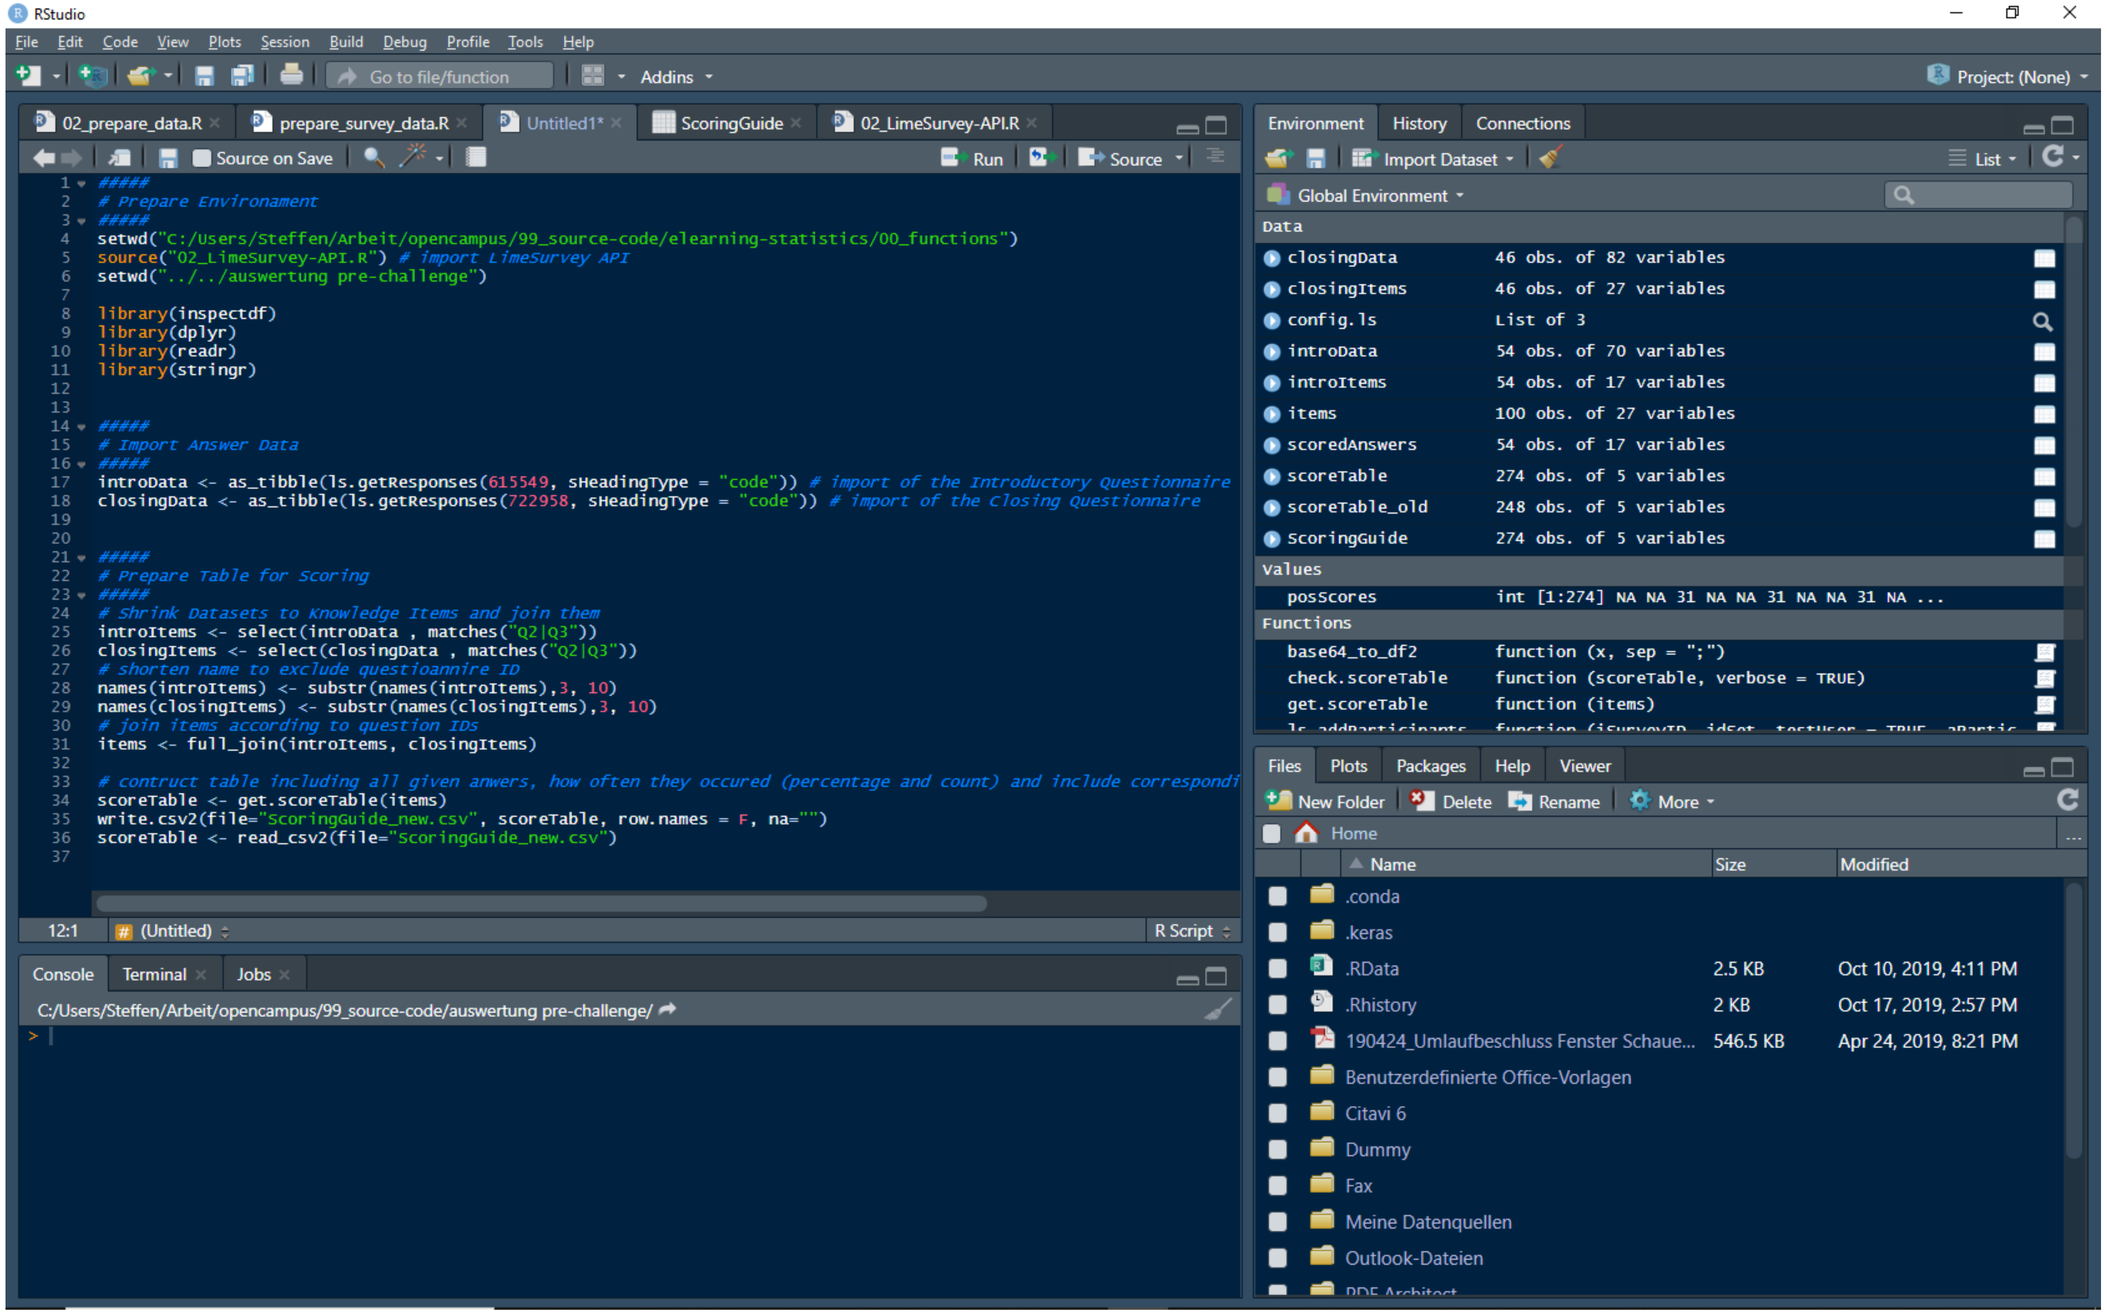
VORTEILE VON R

- Open Source
- Sehr große Community
- Im wissenschaftlichen Bereich zunehmend Standard für statistische Auswertungen
- Umfangreichste Funktionssammlung im Bereich Data Science / Statistik
- Leichte Integration von anderen Programmiersprachen

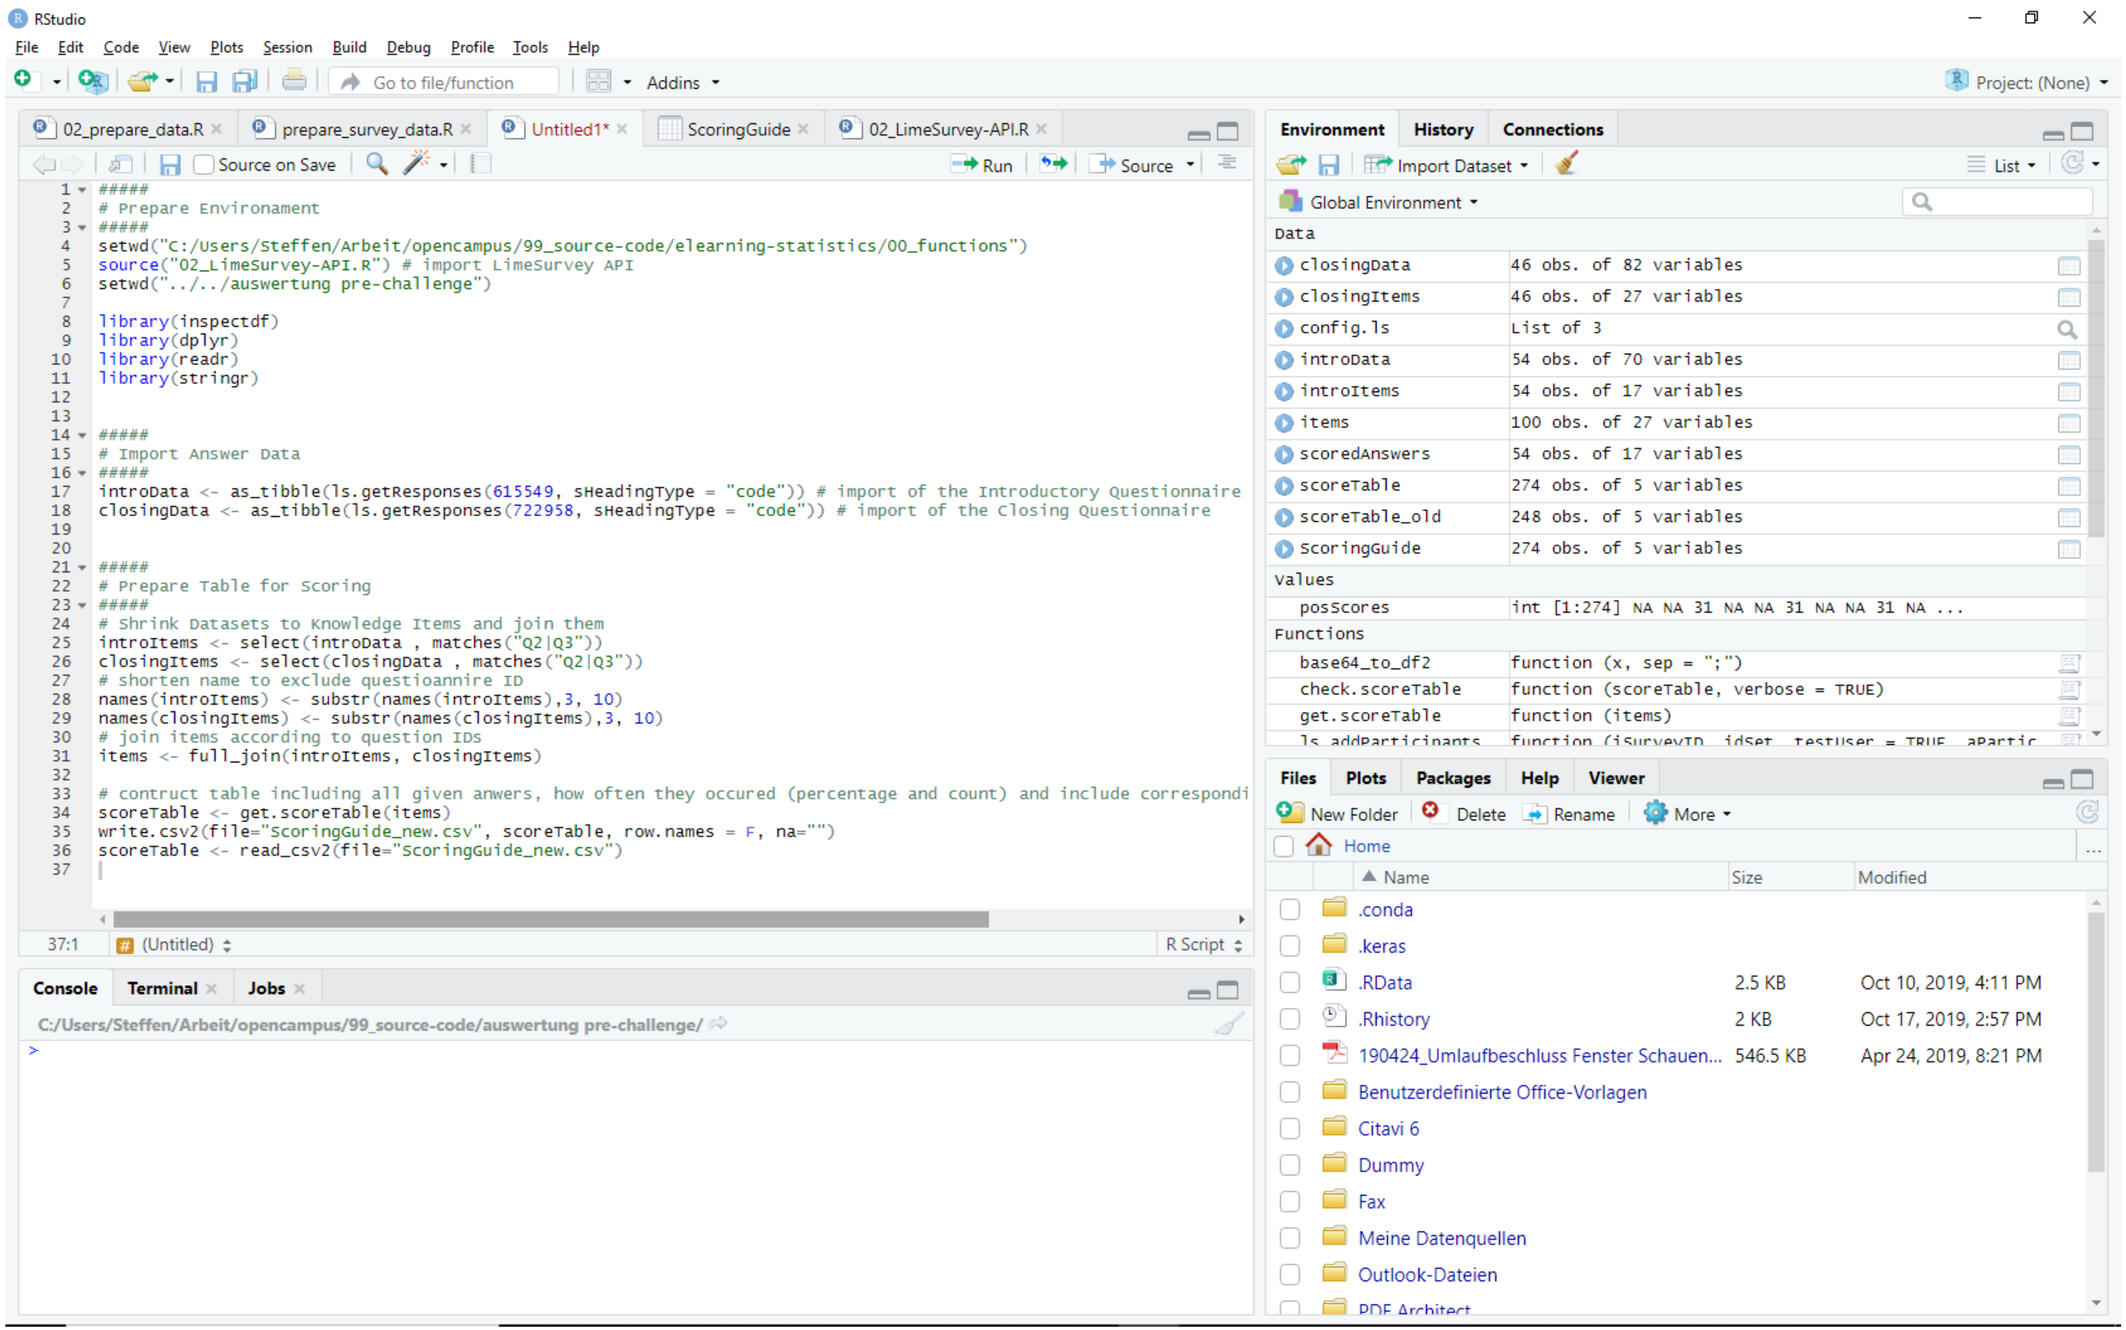
RSTUDIO

(Beliebteste) Umgebung zur Erstellung und Ausführung von R-Programmen

- **Komfortable Bearbeitung und Ausführung der Syntax,**
- **Zugriff auf Hilfe-Dateien,**
- **Anzeige aktuell im Speicher geladener Daten und Funktionen,**
- **Anzeige grafischer Ausgaben,**
- **Installation zusätzlicher Funktionspakete („Packages“)**
- **und vieles mehr…**

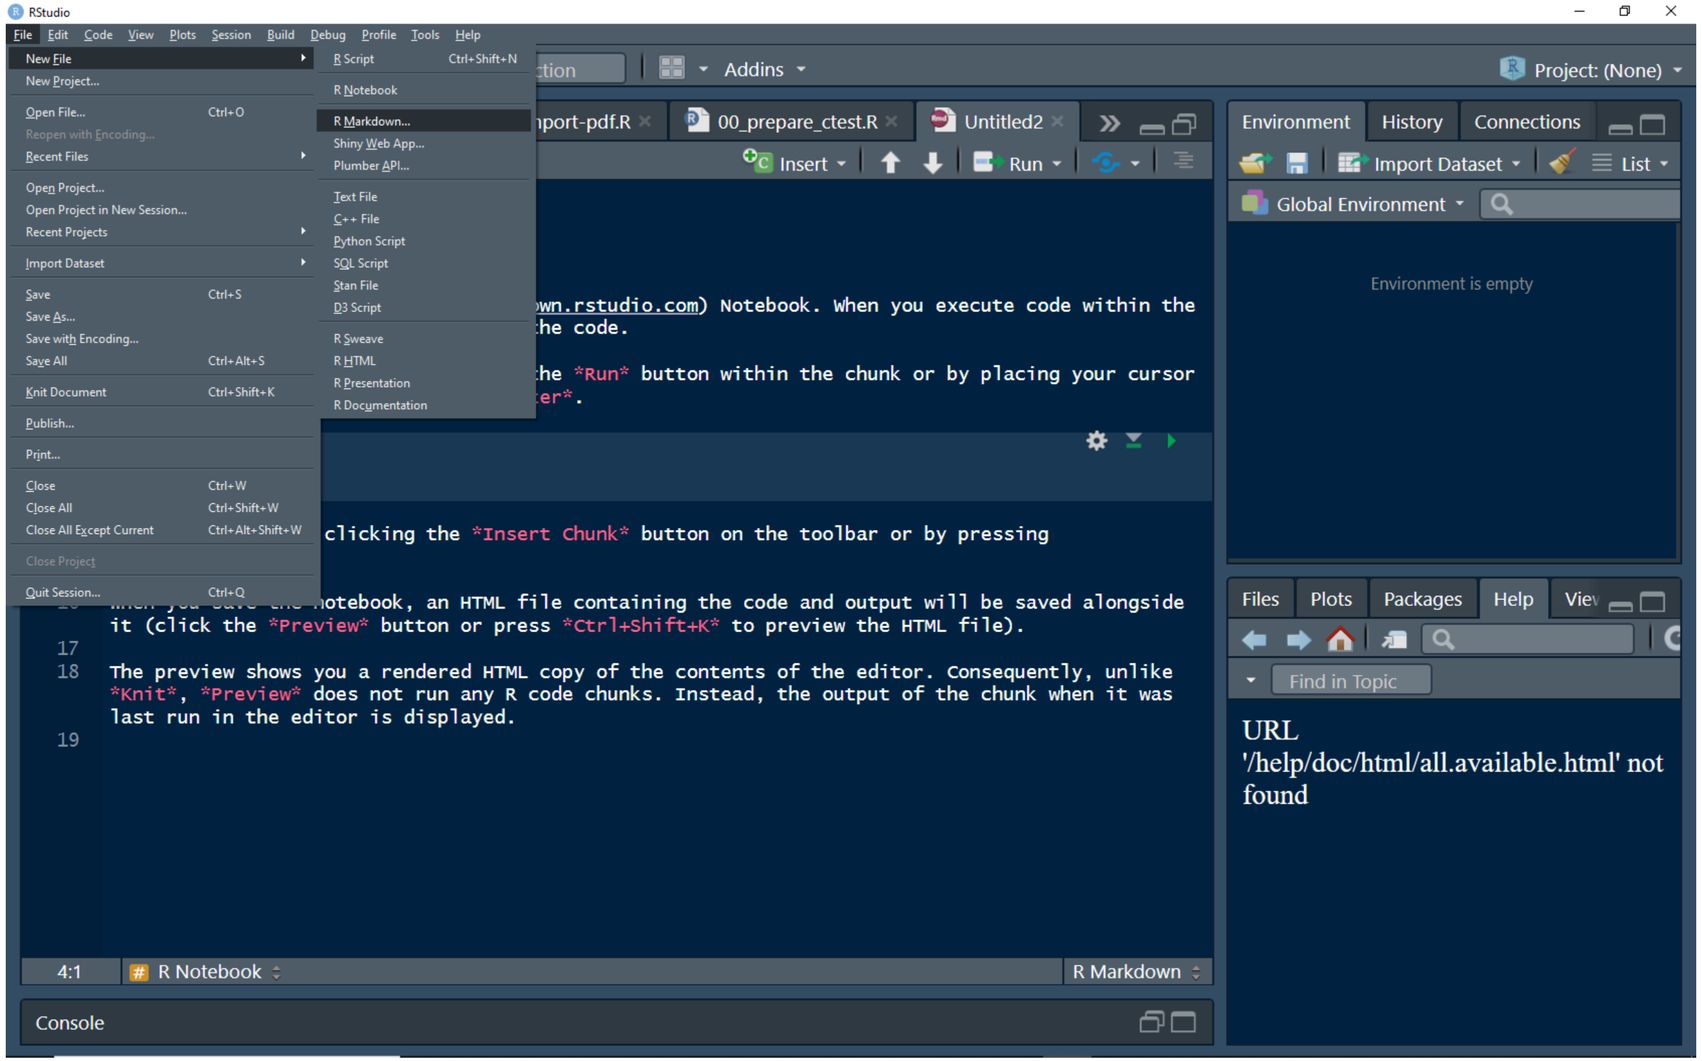


OPENCAMPUS.sh



OPENCAMPUS.sh

R MARKDOWN



OPENCAMPUS.sh

HILFEN

- Google!
- Stackoverflow
- Cheatsheets
- Dokumentation der Funktionen in R

OPENCAMPUS.sh

AUFGABEN

Löst folgende Aufgaben in 3er Teams:

- **Installiert das Package „fortunes“**
- **Diskutiert, was es macht.**
- **Berechnet mit Hilfe von R den Mittelwert der folgenden beiden Zahlen:**
  $9,87654321$ **und** $1,23456789$

DATENSTRUKTUREN

Es gibt drei Grundtypen für ein Datum

- **Boolean** (`TRUE / FALSE`)
- **Numeric** (`1.1392`)
- **String** (`"Text"`)

und zusätzlich abgeleitete, speziellere Typen (integer, date, ...)

- **Integer** (**Untertyp von Numeric;** `12`)
- **Date** (**Untertyp von Numeric;** `"2019-04-11"`)
- **Factor** (**Untertyp von String;** `"female"/"male"`)

VEKTOREN

Alle Elemente eines Vektors haben den gleichen Typ

→ Jeder Vektor hat einen eindeutigen Typ

- `v1 <- c(FALSE, TRUE, TRUE)`
- `ort <- c("kiel", "hamburg", "berlin")`
- `v2 <- c(112, 343, 235)`
- `alter <- 12`

MATRIZEN

Bestehen aus Vektoren gleicher Länge und gleichen Typs

→ Jede Matrix hat einen eindeutigen Typ.

- `m <- matrix(c(1,2,3,4), 2, 2)`

  entspricht: $\begin{pmatrix} 1 & 3 \\ 2 & 4 \end{pmatrix}$

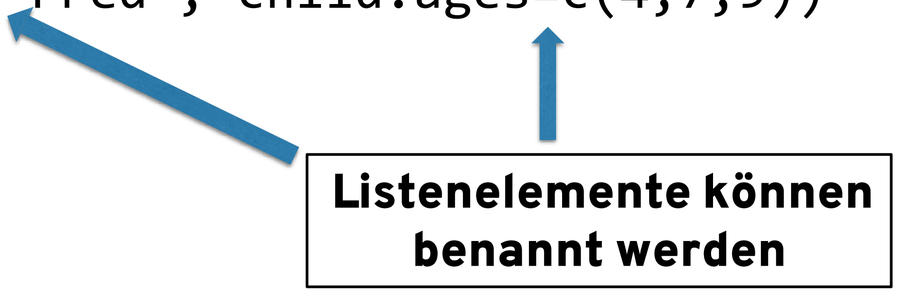
LISTEN

Können beliebige Elemente enthalten:

- Vektoren und Matrizen unterschiedlichen Typs
- sonstige R-Objekte (etwa auch Funktionen)

→ Listen haben keinen eindeutigen Typ

- `l1 <- list(v1, alter, c(4,7,9))`
- `l2 <- list(name="Fred", child.ages=c(4,7,9))`



OPENCAMPUS.sh

SPEZIELLE LISTEN

Datentabellen

bestehen aus Vektoren gleicher Länge
(aber potentiell unterschiedlichen Typs)

→ Datentabellen haben keinen eindeutigen Typ

- ❑ **Data Frame (base Package)**
- ❑ **Tibble (tidyverse Package)**
- ❑ **Data Table (data.table Package)**

SELEKTION VON SPALTEN

Am Beispiel des Data Frames zu `mtcars`

Selektion genau einer Spalte als *Vektor*

- `mtcars$mpg` **oder** `mtcars[["mpg"]]` (**besser nicht:** `mtcars[,"mpg"]`)
- `mtcars[[1]]` (**besser nicht:** `mtcars[,1]`)

Selektion einer oder mehrerer Spalten als *Data Frame*

- `mtcars["mpg"]` **oder** `mtcars[1]`
- `mtcars[c("mpg","cyl")]` **oder** `mtcars[c(1,2)]`

SELEKTION VON ZEILEN

Am Beispiel des Data Frames zu `mtcars`

Selektion einer oder mehrerer Zeilen als *Data Frame*

- `mtcars[1,]`
- `mtcars[c(1,2,3),]` **oder** `mtcars[c(1:3, 5:20),]`

Löschen einer oder mehrerer Zeilen

- `mtcars[-1,]`
- `mtcars[-c(1,3),]`

→ Selektion als Vektor nicht möglich / Keine Selektion über den Namen

OPENCAMPUS.sh

SELEKTION ANHAND VON VEKTOREN DES TYPS BOOLEAN

[1] Konstruktion des Vektors

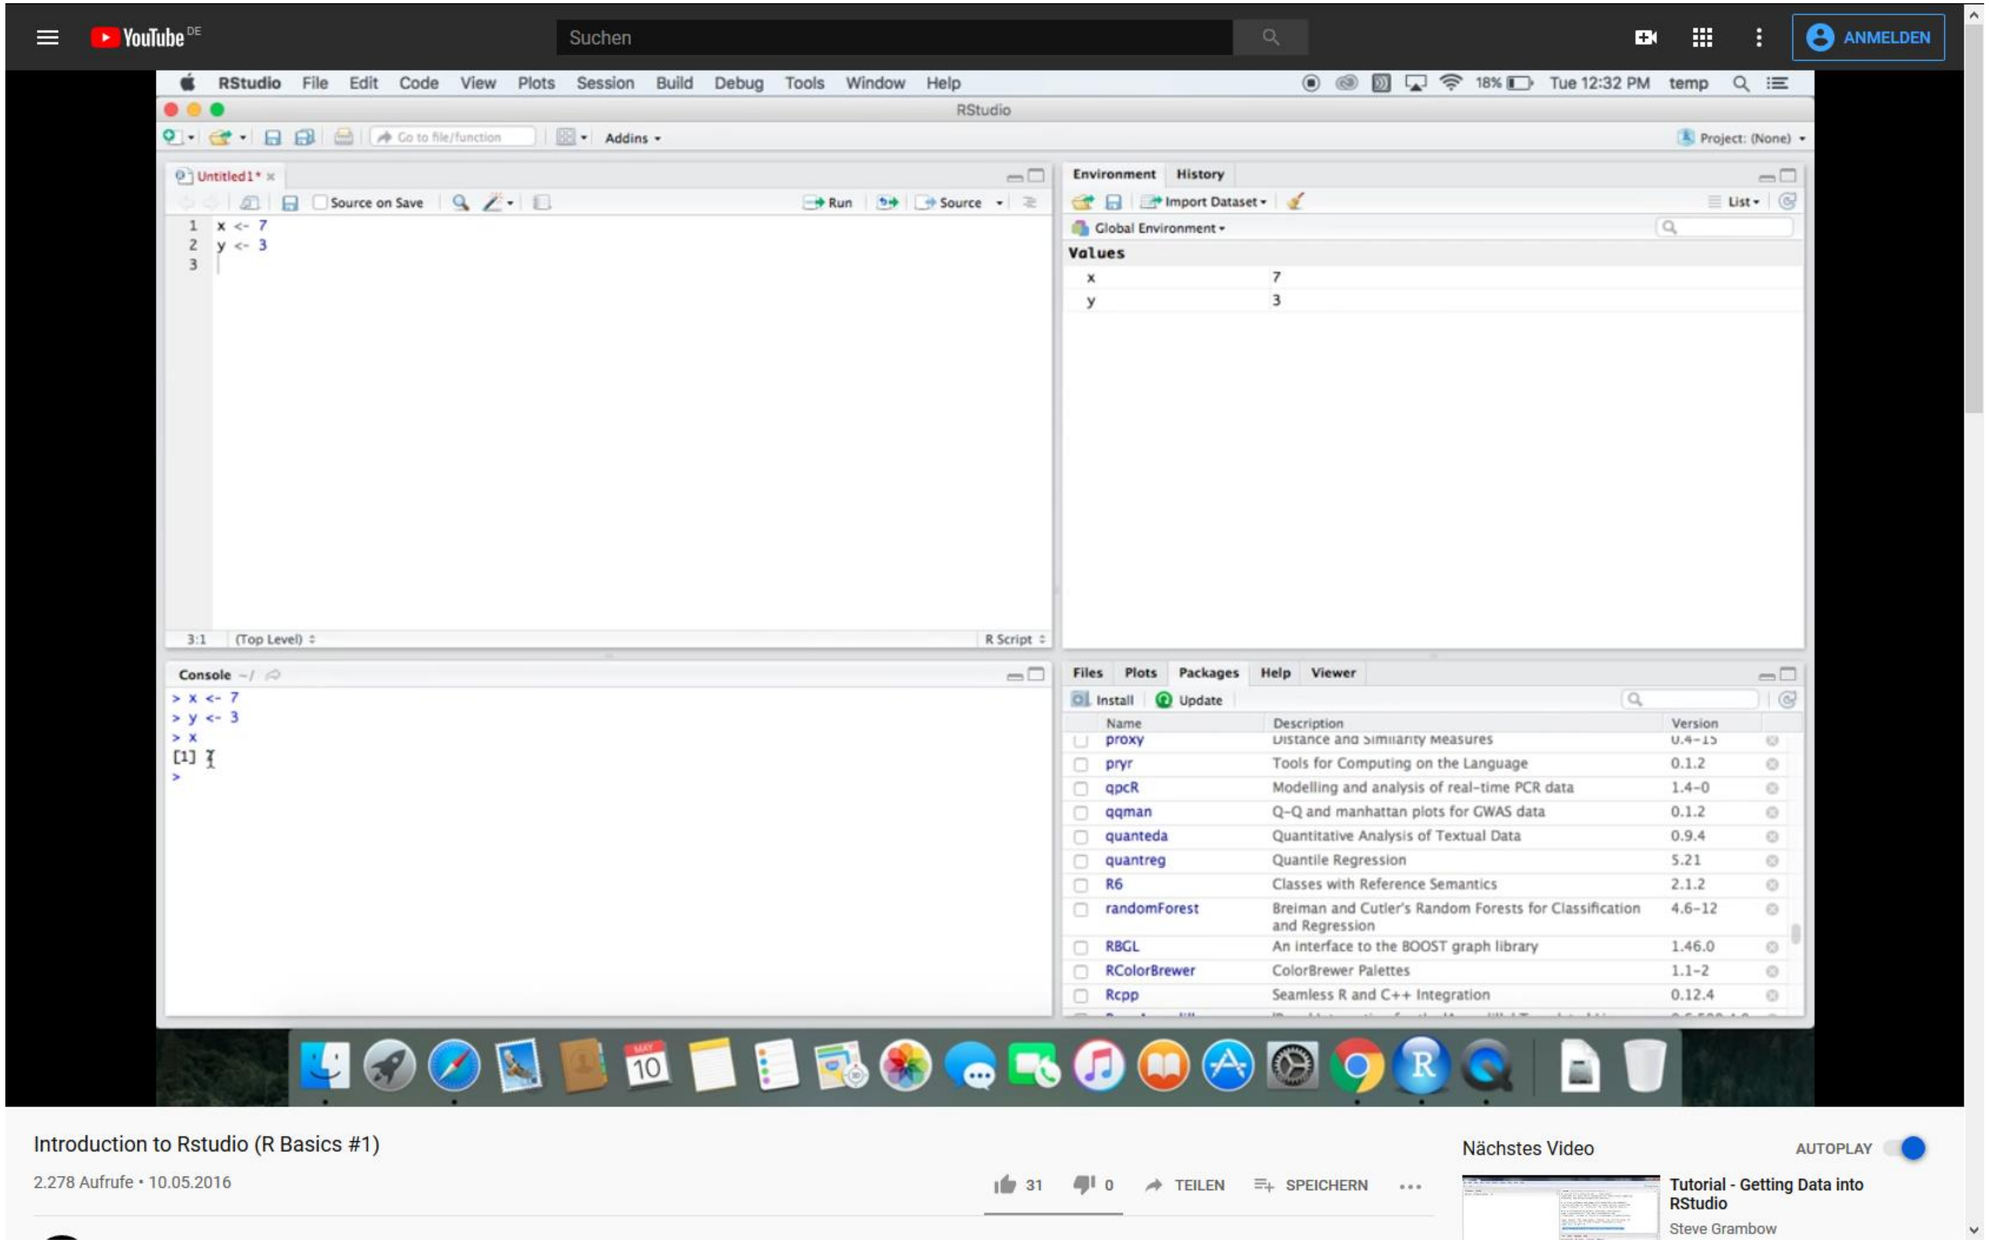
- `mtcars$hp < 100`
- `mtcars$gear == 5`

[2] Selektion der Fälle (Zeilen) mit dem Wert TRUE

- `mtcars[mtcars$hp<100, ]`
- `mtcars[mtcars$gear==5, ]`

AUFGABEN

- **Speichere den Datensatz** `airquality` **in der Variable** `airQuality`**.**
- **Berechne die Gesamtdurchschnittstemperatur.**
- **Berechne die Durchschnittstemperatur für den Monat Juli.**
- **Vergleiche, ob die Monate Juli und Mai sich signifikant in ihrer Durchschnittstemperatur unterscheiden.**



https://www.youtube.com/watch?v=QvBo1RBptvY

OPENCAMPUS.sh

codecademy Course Catalog Pricing For Business

Log in Sign up

Learn R

Start

Earn
Certificate
of completion with PRO

Join
45,000,000+
Codecademy learners

Time to Complete
20 Hours

Prerequisites
None

Overview Syllabus

Why Learn R?

R is a widely used statistical programming language that's beloved by users in academia and industry. R works well with data, making it a great language for anyone interested in data analysis, data visualization, and data science.

Take-Away Skills

In this course, you'll be exposed to fundamental programming concepts in R. After the basics, you'll learn how to organize, modify and clean data frames, a useful data structure in R. Then you'll learn how to create data visualizations to showcase insights in data! Finish up with statistics and hypothesis testing to become a data analysis expert.

Note on Prerequisites:

You do not need to know how to code to enroll in this course!

https://www.codecademy.com/learn/learn-r

OPENCAMPUS.sh

datacamp

Search Catalog

My Account

- My Progress
- My Bookmarks
- For Business
- Career Tracks
- Skill Tracks
- Courses
- Practice
- Projects
- Assessments
- Live Events

Upgrade

INTERACTIVE COURSE

Introduction to R

Continue Course | Bookmark

4 hours | 0 Videos | 62 Exercises | 1,744,033 Participants | 6,200 XP

Course Description

In Introduction to R, you will master the basics of this widely used open source language, including factors, lists, and data frames. With the knowledge gained in this course, you will be ready to undertake your first very own data analysis. Oracle estimated over 2 million R users worldwide in 2012, cementing R as a leading programming language in statistics and data science. Every year, the number of R users grows by about 40%, and an increasing number of organizations are using it in their day-to-day activities. Begin your journey to learn R with us today!

This course is part of these tracks:

- Data Analyst with R
- Data Scientist with R
- R Programming

1 Intro to basics

13%

Take your first steps with R. In this chapter, you will learn how to use the console as a calculator and how to assign variables. You will also get to know the basic data types in R. Let's get started.

VIEW CHAPTER DETAILS

Continue Chapter



Jonathan Cornelissen

Co-founder of DataCamp

Jonathan Cornelissen is one of the co-founders of DataCamp and the initial

https://www.datacamp.com/courses/free-introduction-to-r

OPENCAMPUS.sh