20.04.21

OPENCAMPUS.sh

Einführung in Data Science und maschinelles Lernen mit RStudio

GRAFISCHE DARSTELLUNG VON DATEN



- Wiederholung Datenstrukturen
- Besprechung Aufgaben
- Einlesen von Daten
- Erstellen eines Balkendiagramms
- Struktur der Funktionen in ggplot
- Erstellen eines Balkendigramms mit Schätzfehlern

DATENSTRUKTUREN

Es gibt drei Grundtypen für ein Datum

- **Boolean** (`TRUE / FALSE / NA`)
- **Numeric** (`1.1392 / NA`)
- **String** (`"Text“ / NA`)

und zusätzlich abgeleitete, speziellere Typen (integer, date, …)

- **Integer** **(Untertyp von Numeric;** `12`**)**
- **Date** **(Untertyp von Numeric;** `"2019-04-11"`**)**
- **Factor** **(Untertyp von String;** `"female"/"male"`**)**

VEKTOREN

Alle Elemente eines Vektors haben den gleichen Typ
→ Jeder Vektor hat einen eindeutigen Typ

```
v1 <- c(FALSE, TRUE, NA, TRUE)

ort <- c("kiel", "hamburg", NA, "berlin")

v2 <- c(NA, 112, 343, 235)

alter <- 12
```

MATRIZEN

Bestehen aus Vektoren gleicher Länge und gleichen Typs
→ Jede Matrix hat einen eindeutigen Typ.

```
m <- matrix(c(1,2,3,4), 2, 2)
```

entspricht: $\begin{pmatrix} 1 & 3 \\ 2 & 4 \end{pmatrix}$

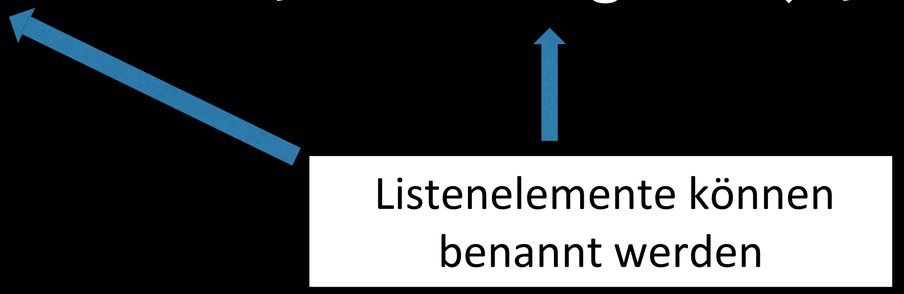
LISTEN

Können beliebige Elemente enthalten:

- **Vektoren und Matrizen unterschiedlichen Typs**
- **sonstige R-Objekte (etwa auch Funktionen)**

→ Listen haben keinen eindeutigen Typ

```
l1 <- list(v1, alter, c(4,7,9))
l2 <- list(name="Fred", child.ages=c(4,7,9), l1)
```



SPEZIELLE LISTEN

DATENTABELLEN

bestehen aus Vektoren gleicher Länge
(aber potentiell unterschiedlichen Typs)

→ Datentabellen haben keinen eindeutigen Typ

- **Data Frame (base Package)**
- **Tibble (tidyverse Package)**
- **Data Table (data.table Package)**

SELEKTION VON SPALTEN (VARIABLEN)

Am Beispiel des Data Frames zu `mtcars`

Selektion genau einer Spalte als *Vektor*

- `mtcars$mpg` **oder** `mtcars[["mpg"]]` (**besser nicht:** `mtcars[,"mpg"]`)
- `mtcars[[1]]` (**besser nicht:** `mtcars[,1]`)

Selektion einer oder mehrerer Spalten als *Data Frame*

- `mtcars["mpg"]` **oder** `mtcars[1]`
- `mtcars[c("mpg","cyl")]` **oder** `mtcars[c(1,2)]`
- **besser nicht:** `mtcars[,c("mpg","cyl")]` **oder** `mtcars[,c(1,2)]`

SELEKTION VON ZEILEN (FÄLLEN)

Selektion einer oder mehrerer Zeilen als Data Frame

- `mtcars[1,]`
- `mtcars[c(1,2,3),]` **oder** `mtcars[c(1:3, 5:20),]`

Löschen einer oder mehrerer Zeilen

- `mtcars[-1,]`
- `mtcars[-c(1,3),]`

→ Selektion als Vektor nicht möglich / Keine Selektion über den Namen

SELEKTION MIT BOOLESCHEN VEKTOREN

- **Konstruktion des Vektors**

```
mtcars$hp < 100
mtcars$gear == 5
```

- **Selektion der Fälle (Zeilen) mit dem Wert TRUE**

```
mtcars[mtcars$hp<100, ]
mtcars[mtcars$gear==5, ]
```

BREAKOUT

- **Speichere den Datensatz** `airquality` **in der Variable** `airQuality`.
- **Berechne die Gesamtdurchschnittstemperatur.**
- **Berechne die Durchschnittstemperatur für den Monat Juli.**
- **Vergleiche, ob die Monate Juli und Mai sich signifikant in ihrer Durchschnittstemperatur unterscheiden.**

ZUWEISUNG VS. VERGLEICH

- **Zuweisung von Datenobjekten:**

  `a <- x` **(besser nicht:** `a = x` **)**

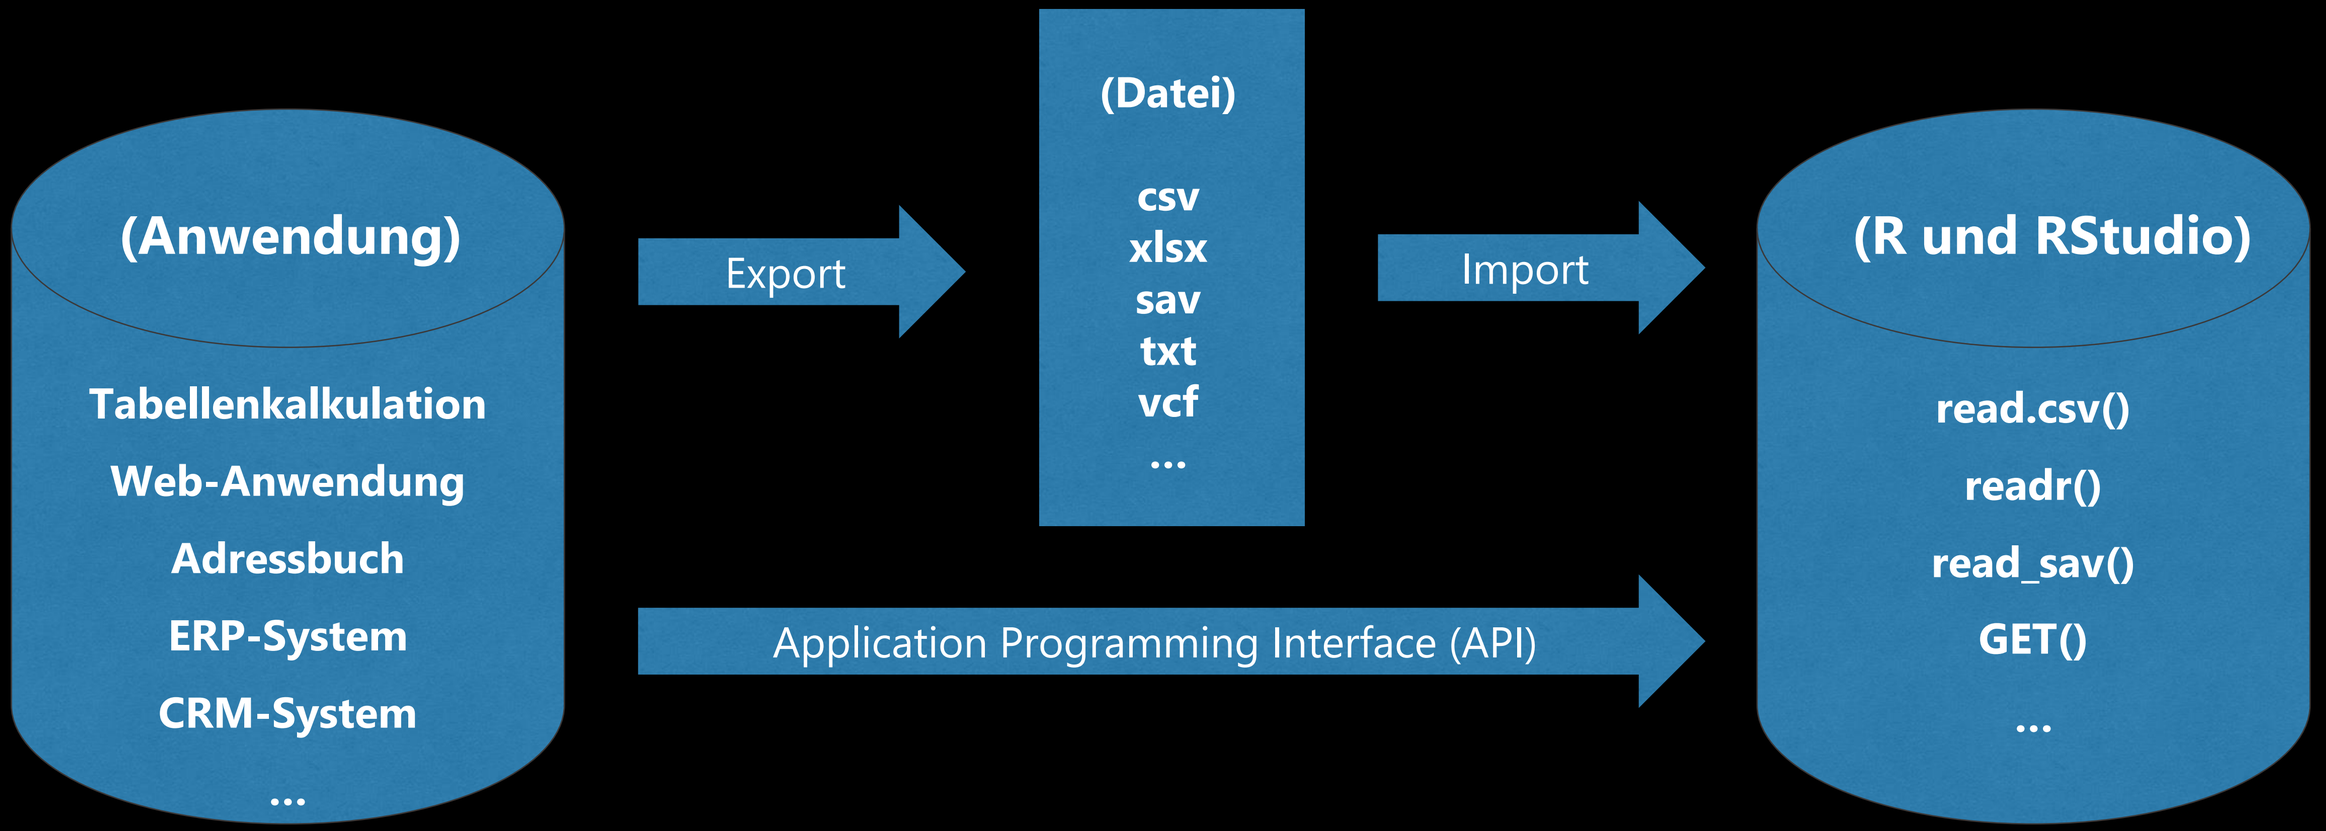
- **Zuweisung von Funktionsargumenten:**

  `mean(x, na.rm = TRUE)`

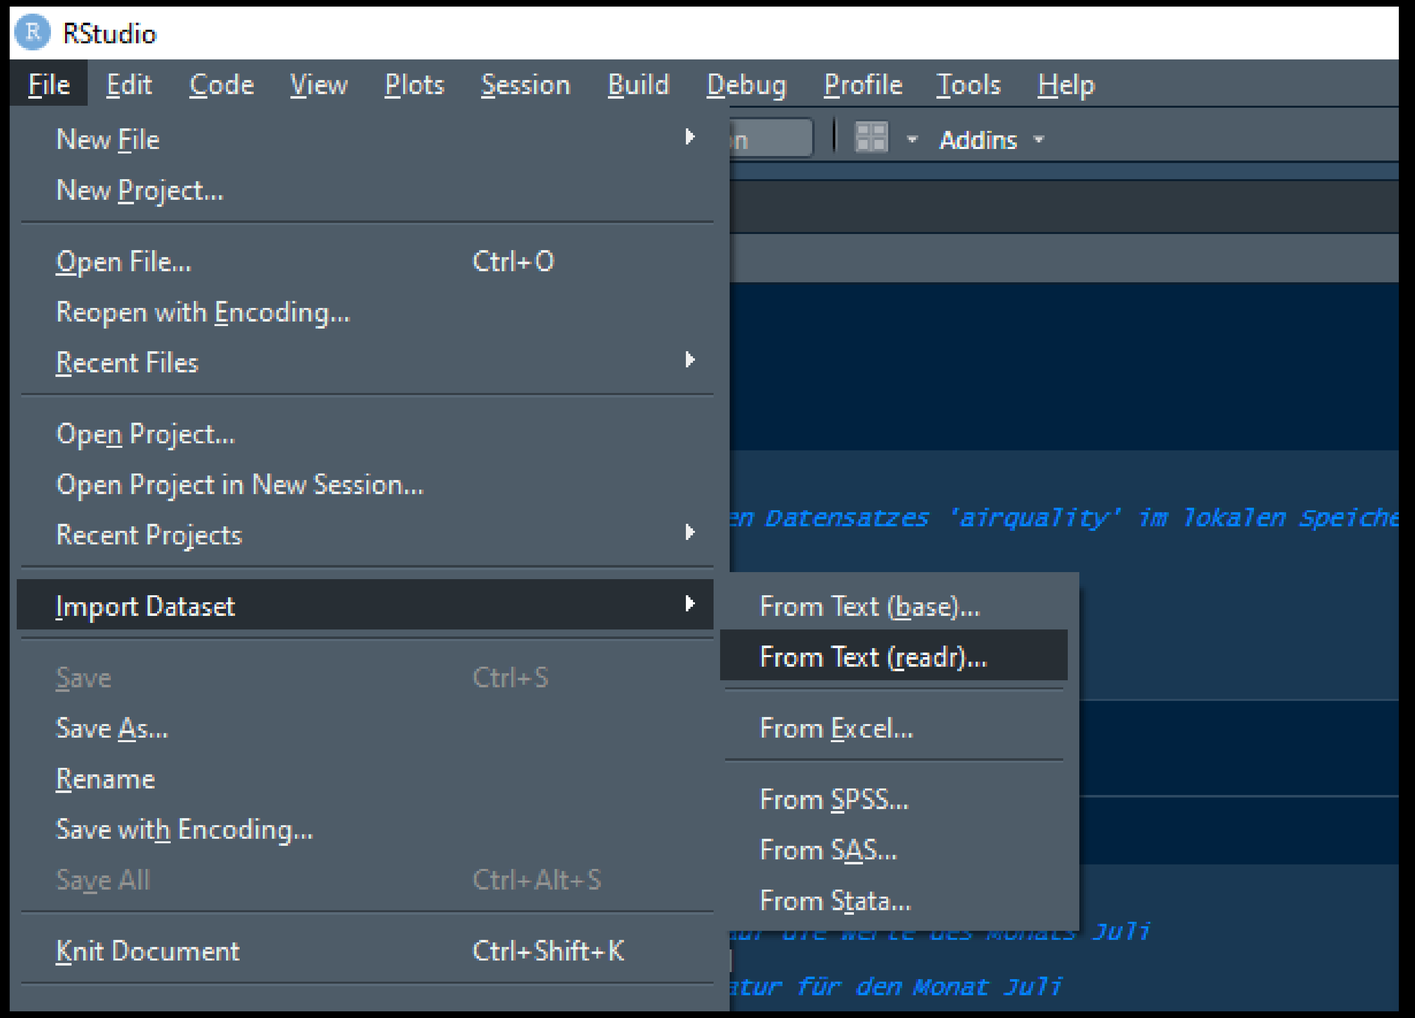
- **Vergleich von Datenobjekten oder Werten:**

  `a == x`

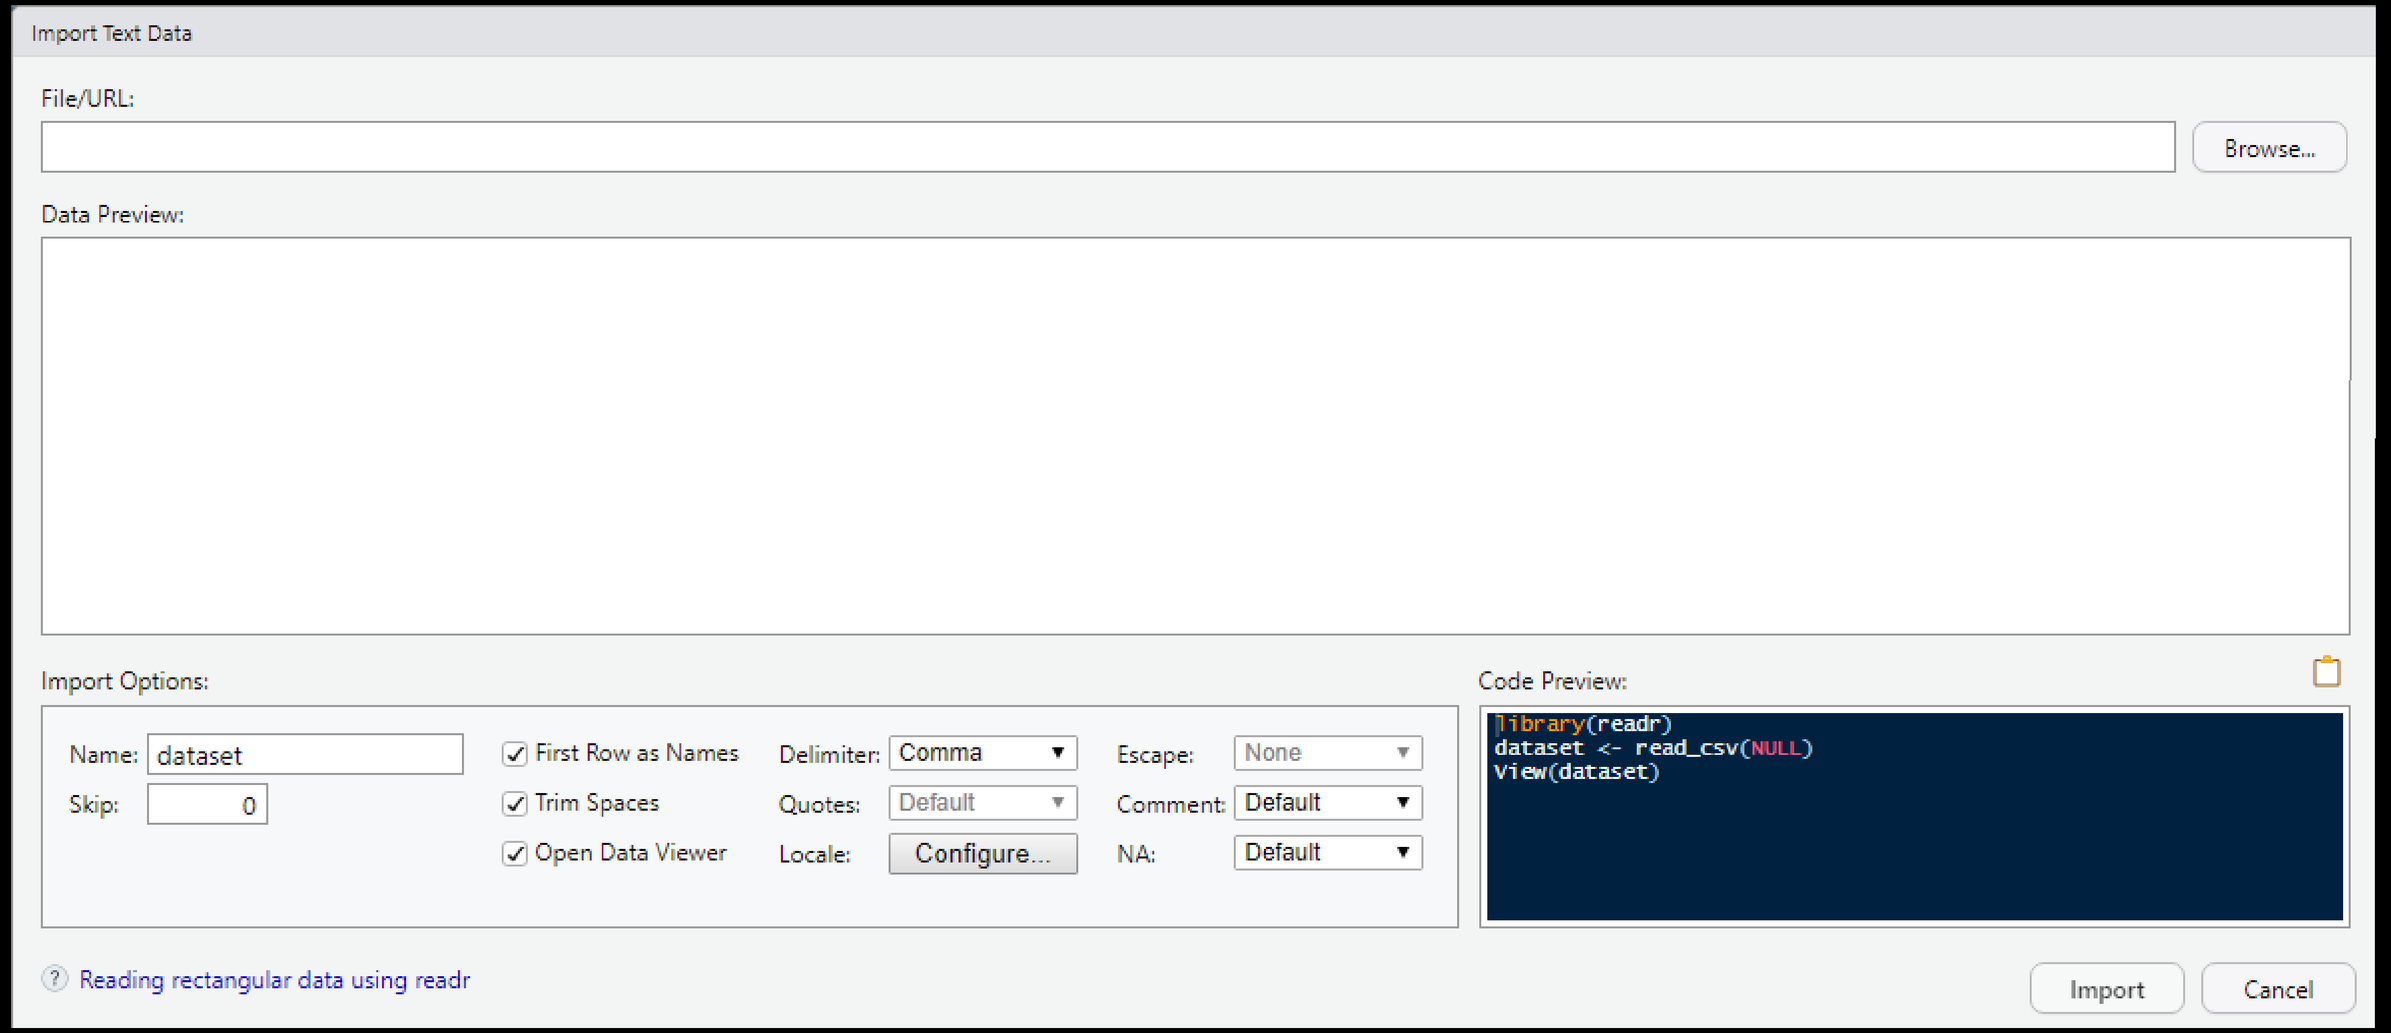
IMPORT VON DATEN



IMPORT MIT HILFE VON RSTUDIO



IMPORT MIT HILFE VON RSTUDIO



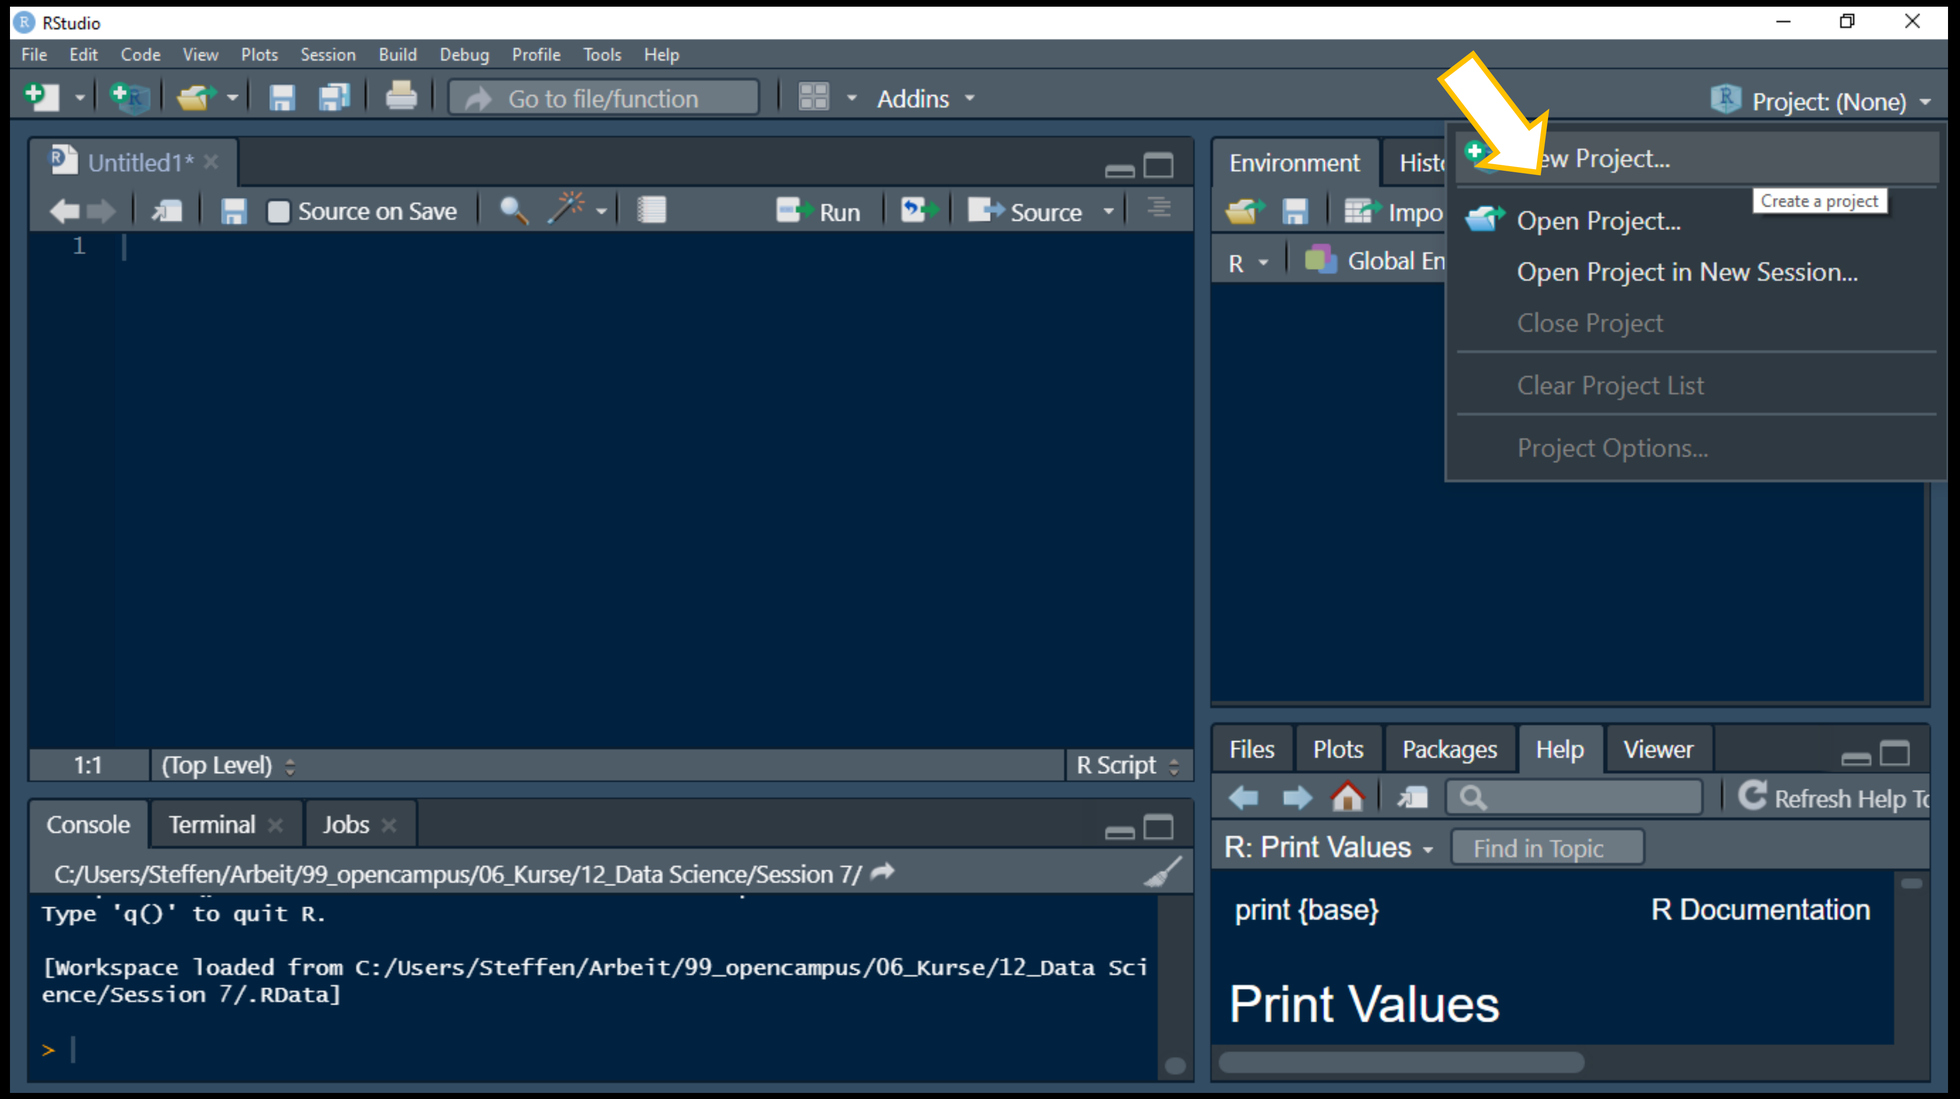
ZUSAMMENFASSUNG IMPORT

- **Nutzen der Vorlage des Programmcodes aus dem RStudio Import-Aufruf**

oder

- **Suche im Internet:**
  „How to import *[Endung der Datendatei]* file into R?“

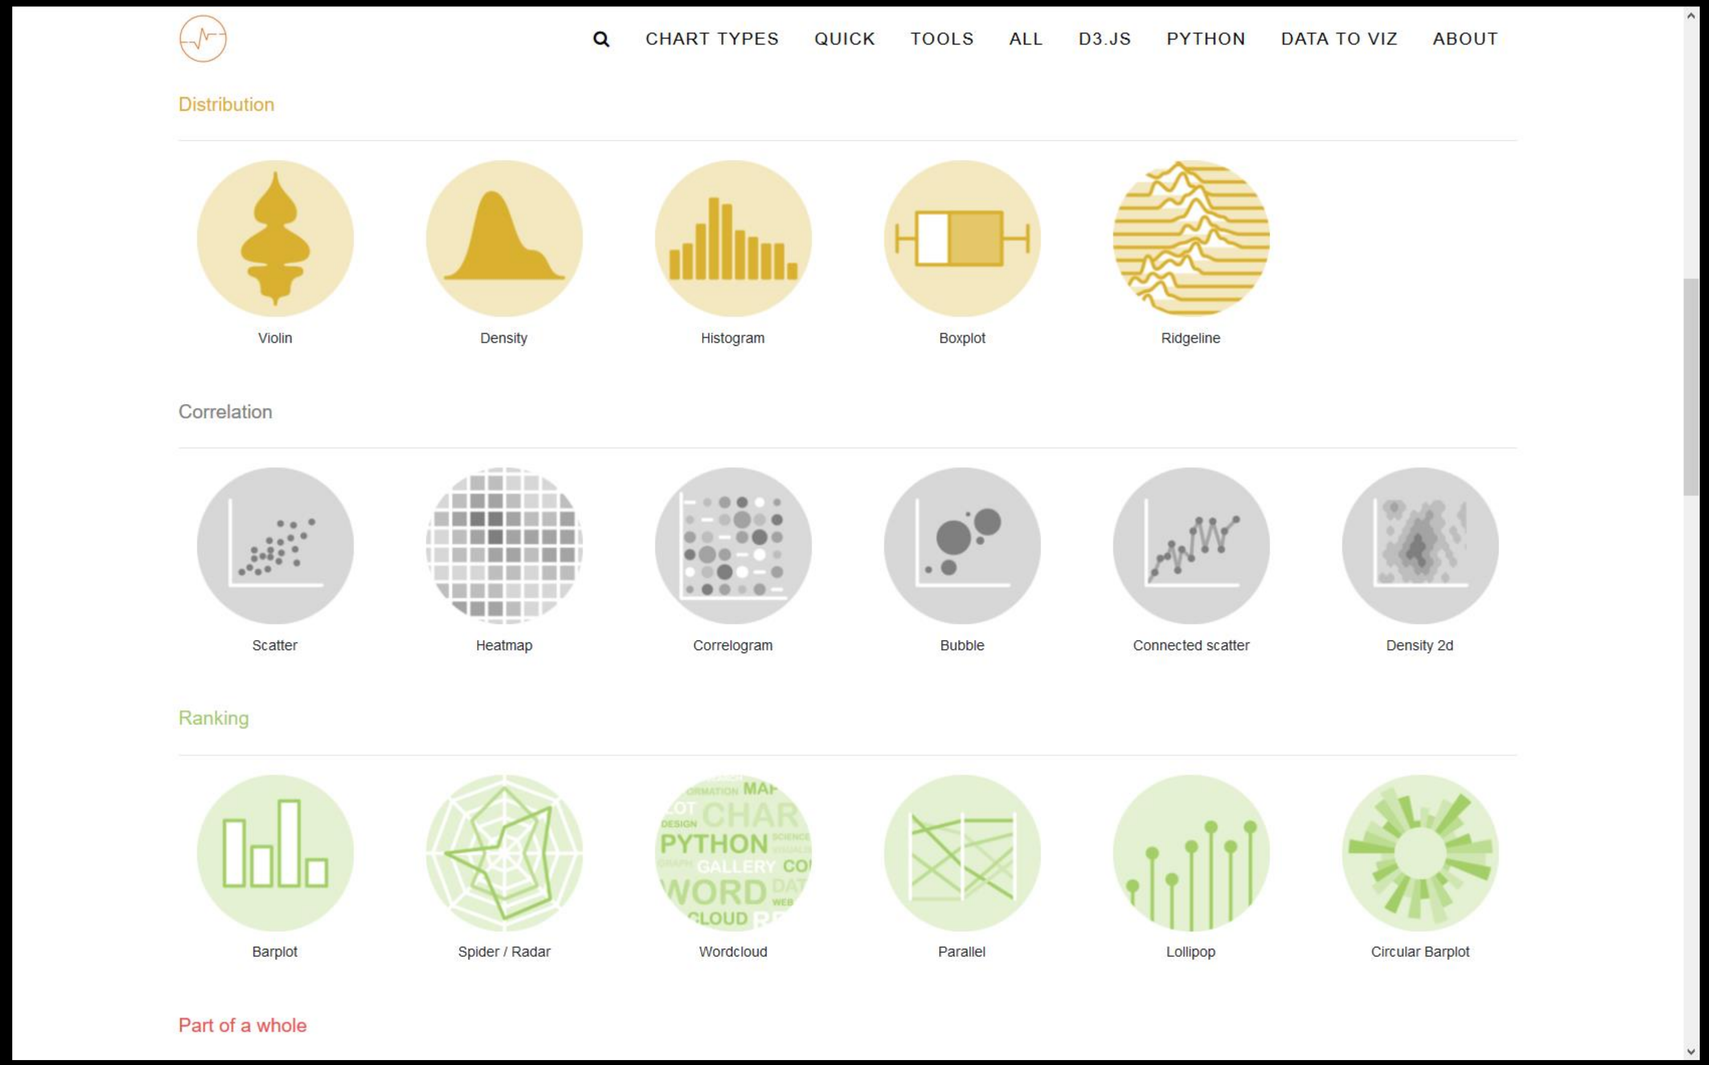
RSTUDIO-PROJEKT



BREAKOUT

- Lege mit Hilfe von RStudio ein Projektverzeichnis an.
- Lade die Dateien „kiwo.csv“, „umsatzdaten_gekuerzt.csv“ und „wetter.csv“ herunter und speichere sie in Deinem Projektverzeichnis.
  Die Dateien befinden sich unter:
  https://github.com/opencampus-sh/einfuehrung-in-data-science-und-ml
- Importiere die Datei „wetter.csv“ in RStudio.
- *Zusatzaufgabe:*
  Wie importiert man eine Datei mit der Endung „.gds“?

DIAGRAMMTYPEN



https://www.r-graph-gallery.com/

SKALENTYPEN

- **Nominalskaliert (kategorial)**
  [Geschlecht, Religionszugehörigkeit]
- **Ordinalskaliert**
  [Englischnote, Testantwort auf einer Skala gut–mittel–schlecht]
- **Intervallskaliert**
  [Temperatur in Celsius, Intelligenzquotient]
- **Verhältnisskaliert**
  [Geschwindigkeit, Einkommen]

GÄNGIGE DIAGRAMMTYPEN

- **Histogramm**
  Darstellung der Verteilung einer numerischen (mind. ordinalen) Variable

- **Scatterplot**
  Darstellung der Beziehung von zwei numerischen (mind. ordinalen) Variablen

- **Balkendiagramm (Barplot)**
  Darstellung zwischen einer numerischen (mind. ordinalen Variable) und einer kategoriellen Variable

GGPLOT BASICS

- **Eine ggplot Abbildung ist ein R-Objekt, das über eine beliebige Anzahl von „Layer“ definiert wird.**
- **Jedes Objekt wird mit** `ggplot()` **erzeugt.**
- **Die wichtigsten Layer sind:**

  Aesthetics – `aes()`
  Zurordnung von Daten zur Abbildung (x-Werte, y-Werte, Label, Farbwerte dargestellter Punkte, ...)

  Geometries – `geoms()`
  Definition der Darstellungsform (Histogramm, Scatterplott, ...)

- **Jeder Layer wird durch ein „+“ hinzugefügt.**

WEITERE GGPLOT LAYER

- **Facets: Layout von mehreren, nebeneinander dargestellten Abbildungen in einer Grafik**
- **Statistics: Durchführung/Darstellung einfacher statistischer Funktionen**
- **Coordinates: Definition/Layout des Raums, in dem die Daten dargestellt werden.**
- **Themes: Selektion von Templates mit unterschiedlichen (datenunabhängigen) Voreinstellungen**
- **Data: Definition eines grundlegenden Datensatzes**

BEISPIEL SCATTERPLOT

Grundlegende Datentabelle wird für alle nachfolgenden Layer definiert.

```
ggplot(mpg) +
     geom_point(aes(x = hwy, y = cty))
```

Aesthetics werden für alle nachfolgenden Layer definiert.

```
ggplot(mpg) +
     aes(x = hwy, y = cty) +
     geom_point()
```

Grundlegende Datentabelle ist nicht definiert, Datentabelle muss also hier angegeben werden.

```
ggplot() +
     aes(x = mpg$hwy, y = mpg$cty) +
     geom_point()
```

WEITERE BEISPIELE

Scatterplot

```
ggplot(mpg)+
      geom_point(aes(x = hwy, y = cty, color = displ))
```

Histogramm

```
ggplot(mpg)+
      geom_histogram(aes(x = cty))
```

Balkendiagramm

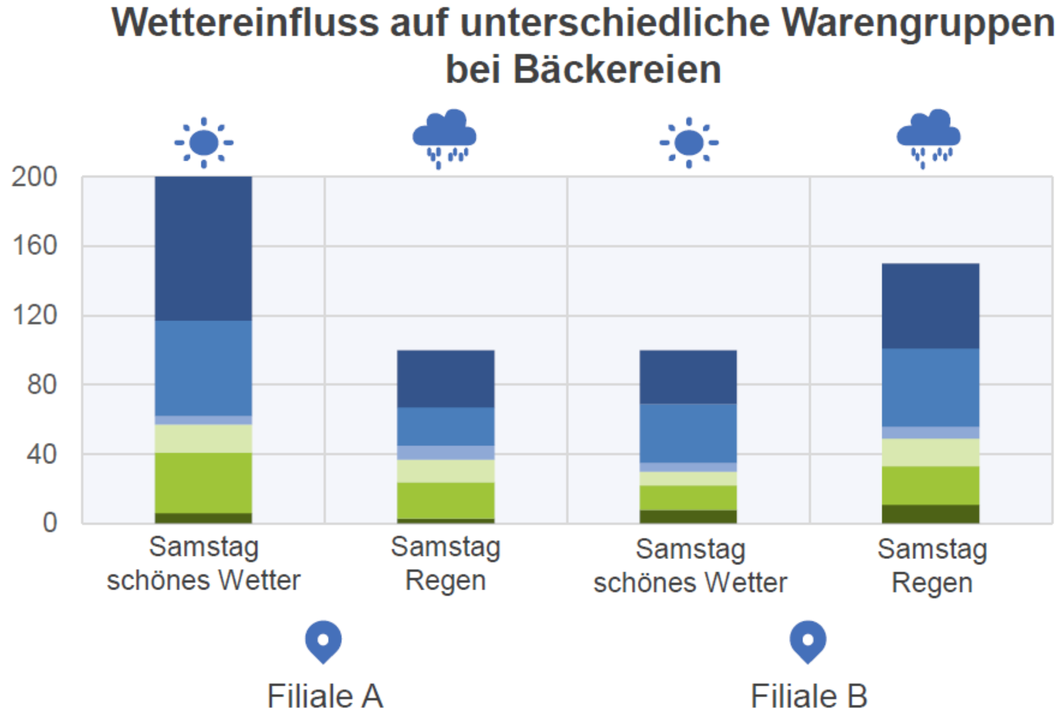
```
ggplot(mtcars)+
      geom_bar(aes(x = as.factor(cyl), y = mpg), stat = "identity")
```

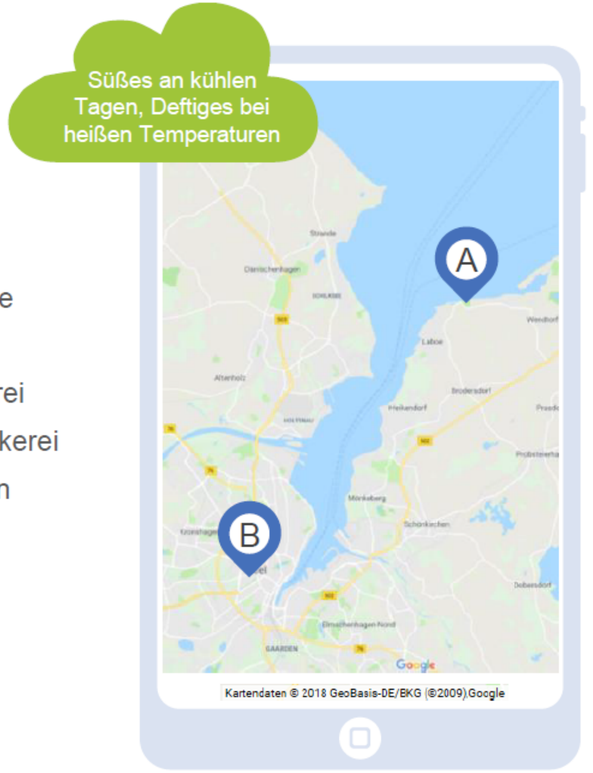
PROJEKTDATENSATZ

- Zur Verfügung gestellt von Meteolytix
- Umsatzdaten von verschiedenen Warengruppen einer Bäckereifiliale für den Zeitraum vom 01.07.2013 bis zum 06.06.2019
- Wetterdaten für den zugehörigen Zeitraum (und darüber hinaus)

Die Stärke des Wettereffekts variiert von Ort zu Ort und wird jeweils filialindividuell berücksichtigt.

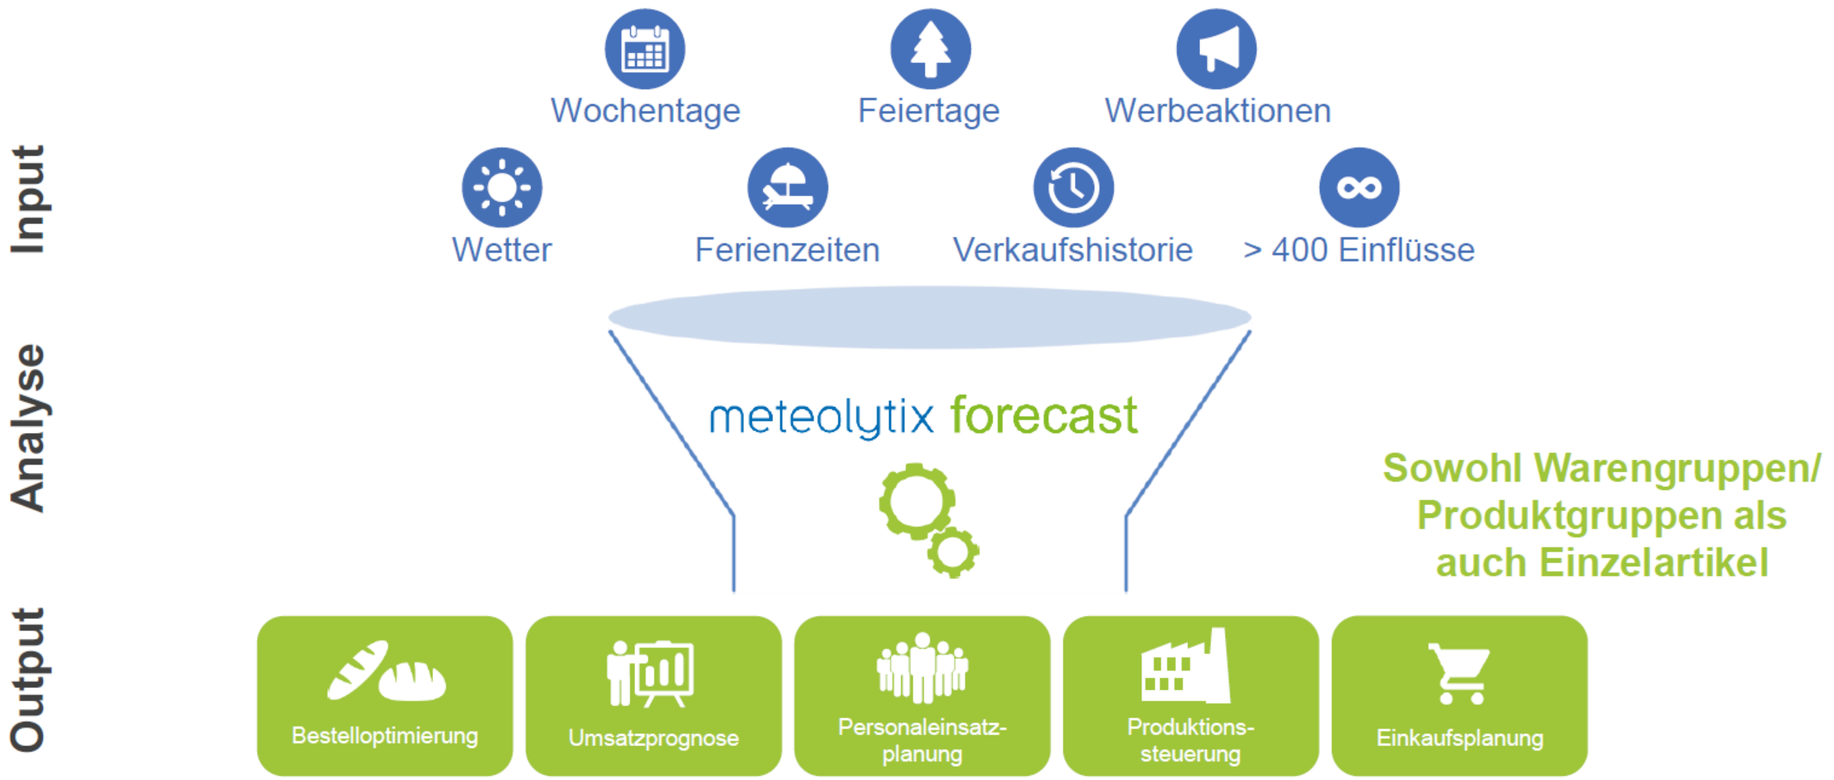
WAS WIR MACHEN





meteolytix forecast analysiert die Datenzusammenhänge von mehr als 400 Einflussfaktoren und liefert Absatzprognosen für viele Einsatzfelder.

WAS WIR MACHEN



© 2019 *meteolytix GmbH*

WARENGRUPPEN

1 Brot

2 Brötchen

3 Croissant

4 Konditorei

5 Kuchen

6 Saisonbrot

WETTERDATEN

- mittlerer Bewölkungsgrad am Tag (0: min bis 8: max)
- mittlere Temperatur in Celsius
- mittlere Windgeschwindigkeit in m/s
- Wettercode
  (eine Liste mit Beschreibungen gibt es z.B. hier: http://www.seewetter-kiel.de/seewetter/daten_symbole.htm)

BREAKOUT

Erstellt jeweils einmal eines der folgenden Diagrammtypen und nutzt dazu den Datensatz „wetter.csv“:

- **Scatterplot**
- **Histogramm**
- **Balkendiagramm**

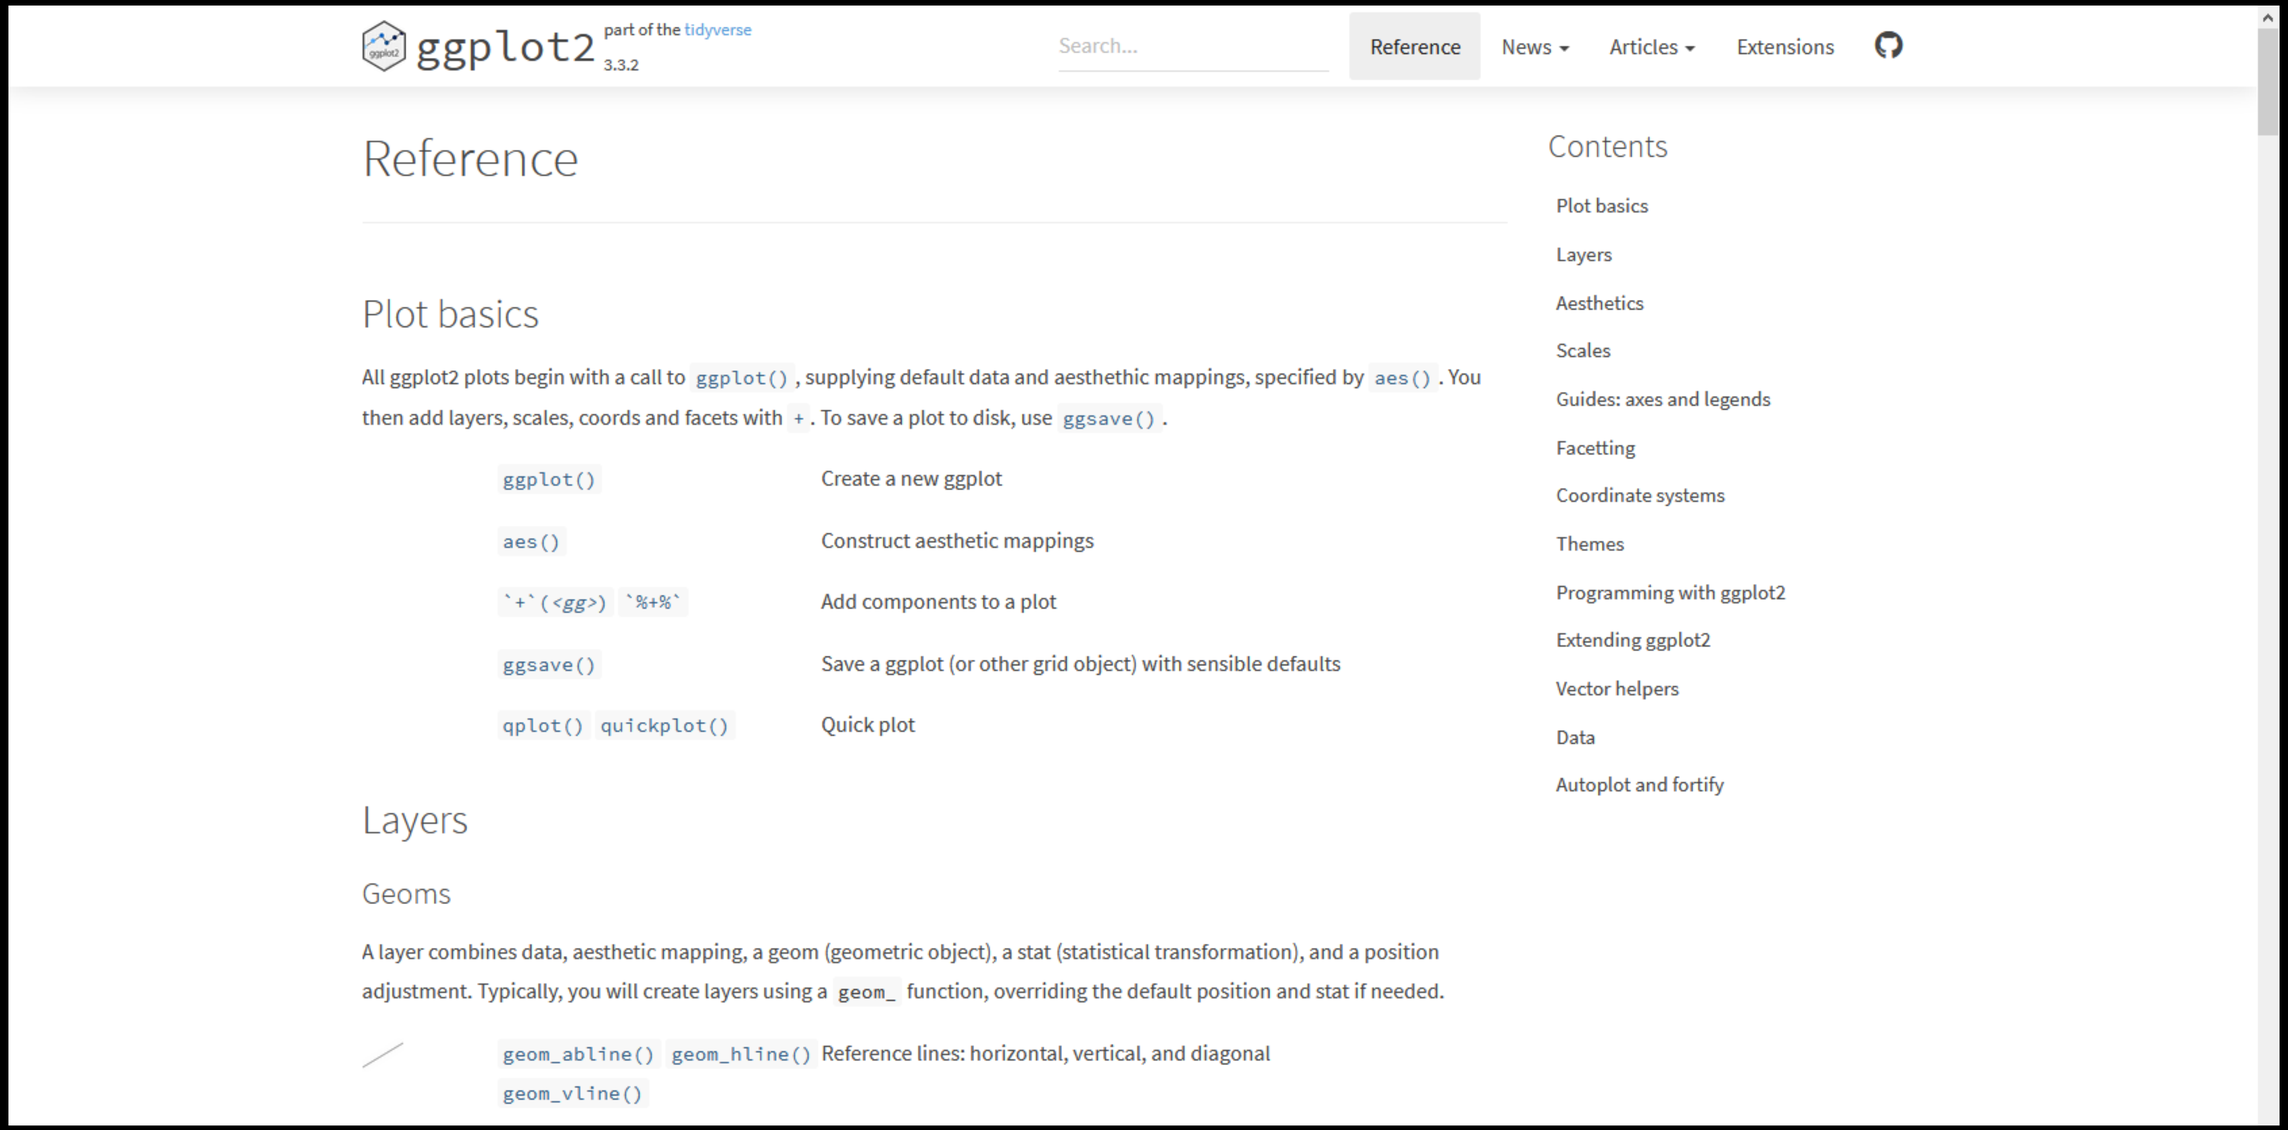
ERSTELLUNG VON GGPLOTS

1) Auswahl eines Diagramms aus R Graph Gallery

2) Ausführen des Beispielcodes

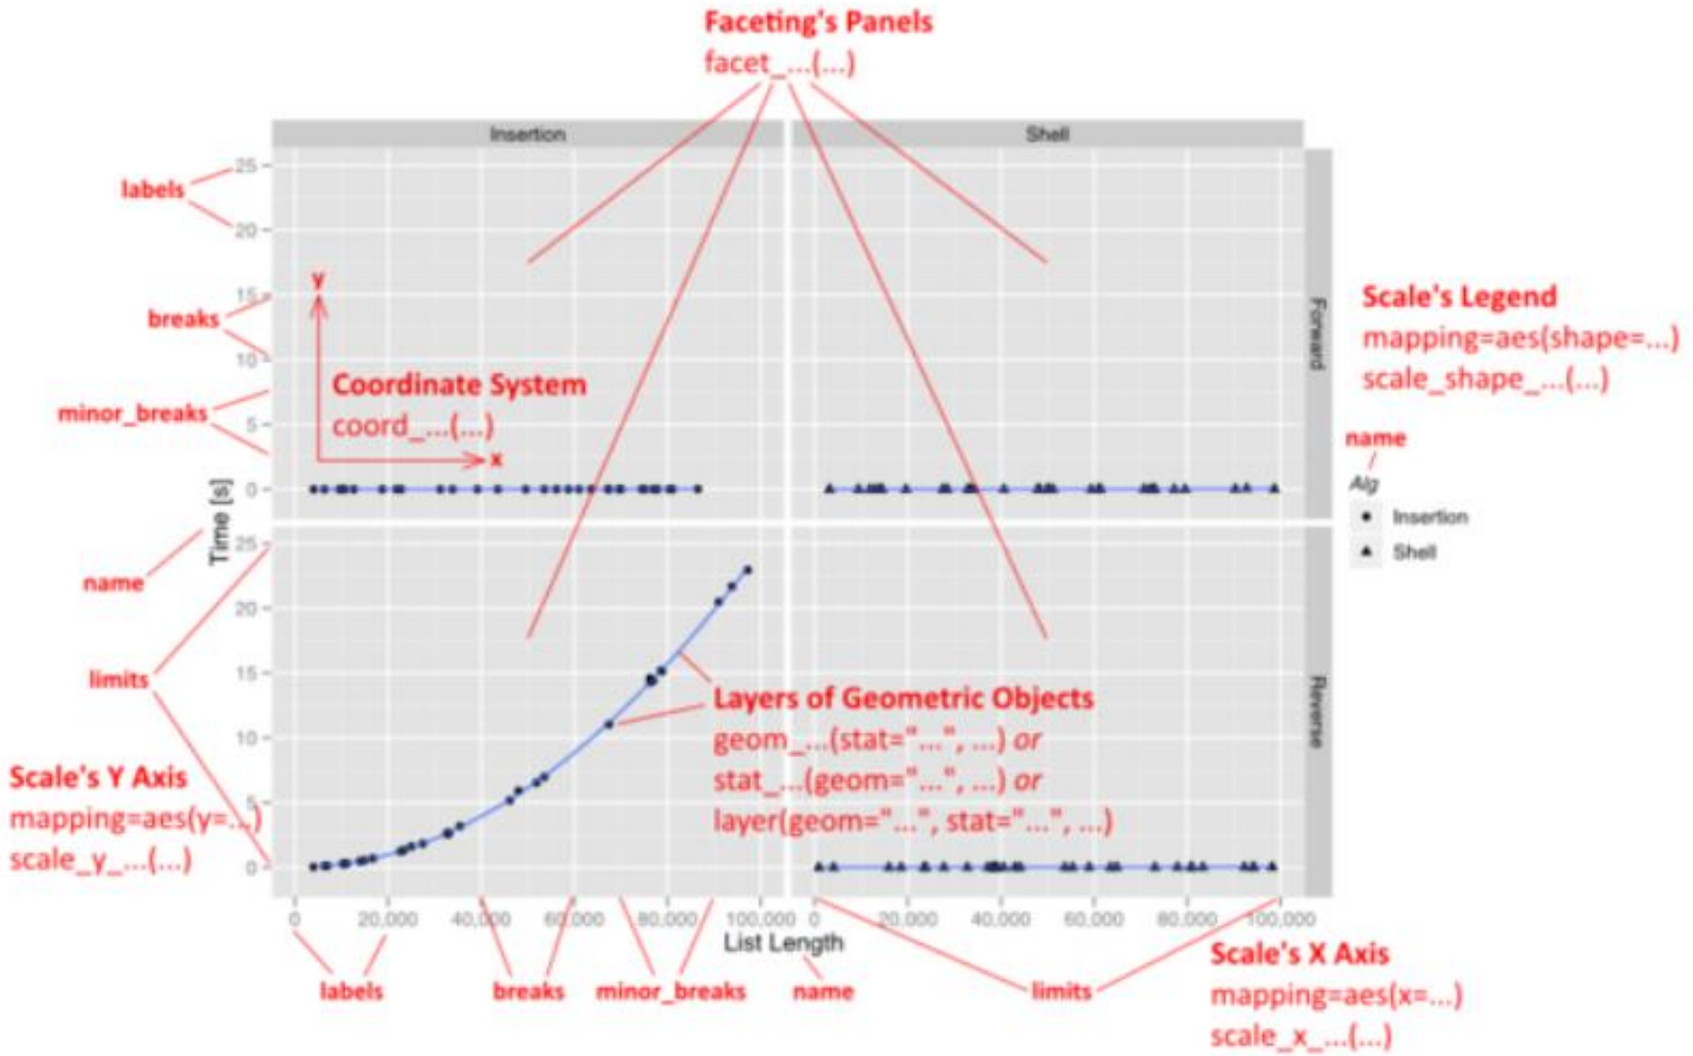
3) Ersetzen der gegeben Beispieldaten durch eigene

4) Anpassen mit weiteren detaillierteren Hilfe-Seiten



Übersicht über existierende Layer und den Funktionen, die existieren.

https://ggplot2.tidyverse.org/reference/



Gute bildliche Darstellung der Elemente einer Abbildung:
http://sape.inf.usi.ch/quick-reference/ggplot2

Articles - R Graphics Essentials

GGPlot Cheat Sheet for Great Customization

kassambara | 17/11/2017 | 36049 | Comments (2) | R Graphics Essentials

This chapter provides a cheat sheet to change the global appearance of a ggplot.

You will learn how to:

- Add title, subtitle, caption and change axis labels
- Change the appearance - color, size and face - of titles
- Set the axis limits
- Set a logarithmic axis scale
- Rotate axis text labels
- Change the legend title and position, as well, as the color and the size
- Change a ggplot theme and modify the background color
- Add a background image to a ggplot
- Use different color palettes: custom color palettess, color-blind friendly palettes, RColorBrewer palettes, viridis color palettes and scientific journal color palettes.
- Change point shapes (plotting symbols) and line types
- Rotate a ggplot
- Annotate a ggplot by adding straight lines, arrows, rectangles and text.

Contents:

- Prerequisites
- Titles and axis labels

How-To‘s mit verschiedenen Beispielen

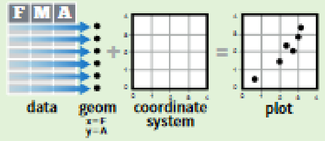
www.sthda.com/english/articles/32-r-graphics-essentials/125-ggplot-cheat-sheet-for-great-customization/

Data Visualization with ggplot2 Cheat Sheet

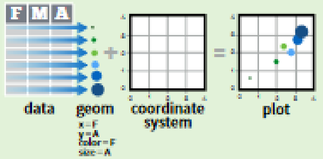
RStudio

Basics

ggplot2 is based on the **grammar of graphics**, the idea that you can build every graph from the same few components: a **data** set, a set of **geoms**—visual marks that represent data points, and a **coordinate system.**



To display data values, map variables in the data set to aesthetic properties of the geom like **size**, **color**, and **x** and **y** locations.



Build a graph with **qplot()** or **ggplot()**

aesthetic mappings · data · geom

qplot(x = cty, y = hwy, color = cyl, data = mpg, geom = "point")

Creates a complete plot with given data, geom, and mappings. Supplies many useful defaults.

Geoms - Use a geom to represent data points, use the geom's aesthetic properties to represent variables. Each function returns a layer.

One Variable

Continuous

a <- ggplot(mpg, aes(hwy))



a + geom_area(stat = "bin")
x, y, alpha, color, fill, linetype, size
b + geom_area(aes(y = ..density..), stat = "bin")



a + geom_density(kernel = "gaussian")
x, y, alpha, color, fill, linetype, size, weight
b + geom_density(aes(y = ..county..))



a + geom_dotplot()
x, y, alpha, color, fill



a + geom_freqpoly()
x, y, alpha, color, linetype, size
b + geom_freqpoly(aes(y = ..density..))



a + geom_histogram(binwidth = 5)
x, y, alpha, color, fill, linetype, size, weight
b + geom_histogram(aes(y = ..density..))

Discrete

b <- ggplot(mpg, aes(fl))



b + geom_bar()
x, alpha, color, fill, linetype, size, weight

Graphical Primitives

c <- ggplot(map, aes(long, lat))



c + geom_polygon(aes(group = group))
x, y, alpha, color, fill, linetype, size

Two Variables

Continuous X, Continuous Y

f <- ggplot(mpg, aes(cty, hwy))



f + geom_blank()



f + geom_jitter()
x, y, alpha, color, fill, shape, size



f + geom_point()
x, y, alpha, color, fill, shape, size



f + geom_quantile()
x, y, alpha, color, linetype, size, weight



f + geom_rug(sides = "bl")
alpha, color, linetype, size



f + geom_smooth(model = lm)
x, y, alpha, color, fill, linetype, size, weight



f + geom_text(aes(label = cty))
x, y, label, alpha, angle, color, family, fontface, hjust, lineheight, size, vjust

Discrete X, Continuous Y

g <- ggplot(mpg, aes(class, hwy))



g + geom_bar(stat = "identity")
x, y, alpha, color, fill, linetype, size, weight



g + geom_boxplot()
lower, middle, upper, x, ymax, ymin, alpha, color, fill, linetype, shape, size, weight



g + geom_dotplot(binaxis = "y",

Continuous Bivariate Distribution

i <- ggplot(movies, aes(year, rating))



i + geom_bin2d(binwidth = c(5, 0.5))
xmax, xmin, ymax, ymin, alpha, color, fill, linetype, size, weight



i + geom_density2d()
x, y, alpha, colour, linetype, size



i + geom_hex()
x, y, alpha, colour, fill size

Continuous Function

j <- ggplot(economics, aes(date, unemploy))



j + geom_area()
x, y, alpha, color, fill, linetype, size



j + geom_line()
x, y, alpha, color, linetype, size



j + geom_step(direction = "hv")
x, y, alpha, color, linetype, size

Visualizing error

df <- data.frame(grp = c("A", "B"), fit = 4:5, se = 1:2)
k <- ggplot(df, aes(grp, fit, ymin = fit-se, ymax = fit+se))



k + geom_crossbar(fatten = 2)
x, y, ymax, ymin, alpha, color, fill, linetype, size



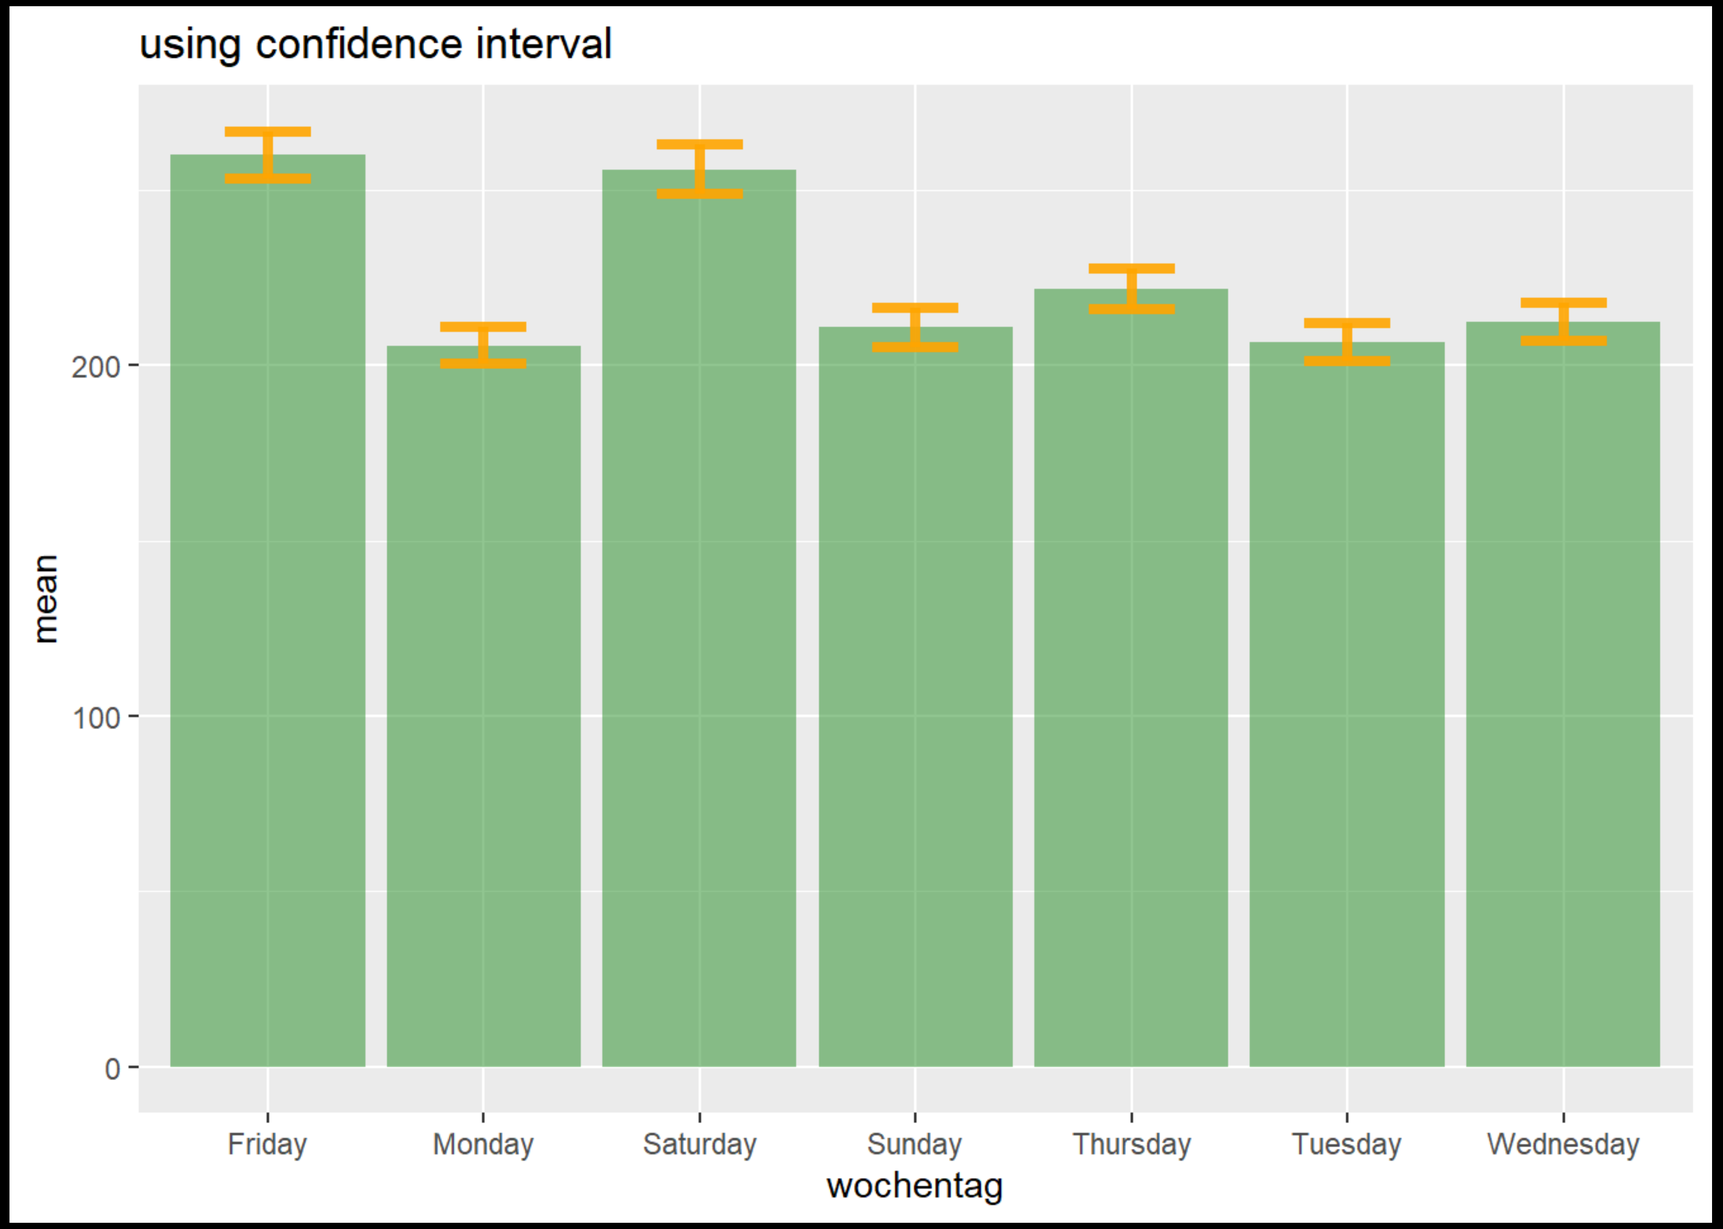
k + geom_errorbar()
x, ymax, ymin, alpha, color, linetype, size, width (also **geom_errorbarh()**)



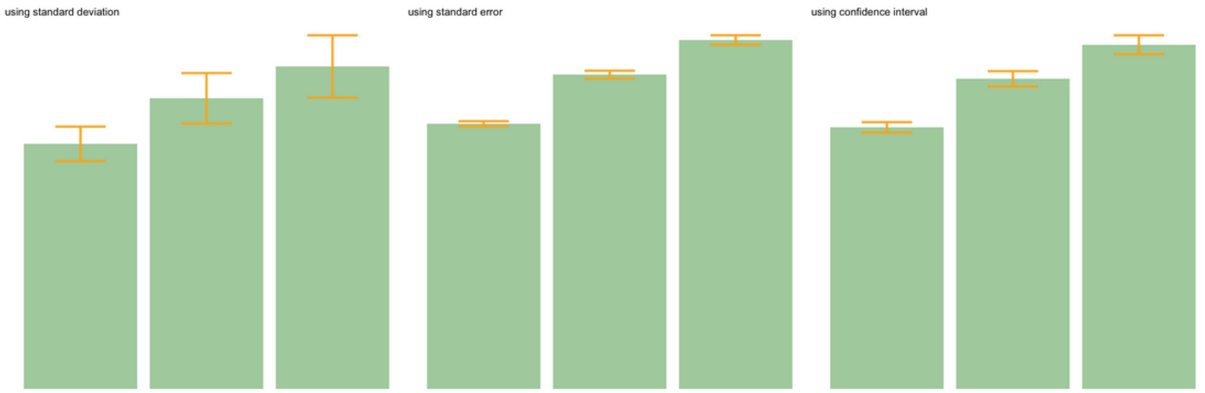
k + geom_linerange()
x, ymin, ymax, alpha, color, linetype, size

Cheat-Sheet von RStudio

https://www.rstudio.com/wp-content/uploads/2015/03/ggplot2-cheatsheet.pdf


using confidence interval
mean
200
100
0
Friday
Monday
Saturday
Sunday
Thursday
Tuesday
Wednesday
wochentag

Standard deviation, Standard error or Confidence Interval?



Three different types of values are commonly used for error bars, sometimes without even specifying which one is used. It is important to understand how they are calculated, since they give very different results (see above). Let's compute them on a simple vector:

```
vec=c(1,3,5,9,38,7,2,4,9,19,19)
```

→ Standard Deviation (SD). wiki

It represents the amount of dispersion of the variable. Calculated as the root square of the variance:

```
sd <- sd(vec)
sd <- sqrt(var(vec))
```

→ Standard Error (SE). wiki

It is the standard deviation of the vector sampling distribution. Calculated as the SD divided by the square root of the sample size. By construction, SE is

https://www.r-graph-gallery.com/4-barplot-with-error-bar.html

AUFGABEN

- **Erstelle ein Balkendiagramm, dass über alle Warengruppen hinweg die durchschnittlichen Umsätze je Wochentag zeigt.**

- **Füge in einem zweiten Schritt zusätzlich Konfidenzintervalle der Umsätze je Wochentag hinzu („barplot with error bars“).**

- ***Freiwillige Zusatzaufgabe:***
  Stelle die Umsätze je Wochentag getrennt nach Warengruppe dar (ein eigenes Balkendiagramm je Warengruppe)

STARTHILFE

```
# Import needed libraries
library(readr)
library(lubridate)
library(ggplot2)
library(dplyr)

# Import turnover data
umsatzdaten <- read_csv("https://raw.githubusercontent.com/opencampus-sh/wise20-datascience/main/umsatzdaten_gekuerzt.csv")

# Create variable weekday
umsatzdaten$wochentag <- weekdays(umsatzdaten$Datum)
```