31.05.22

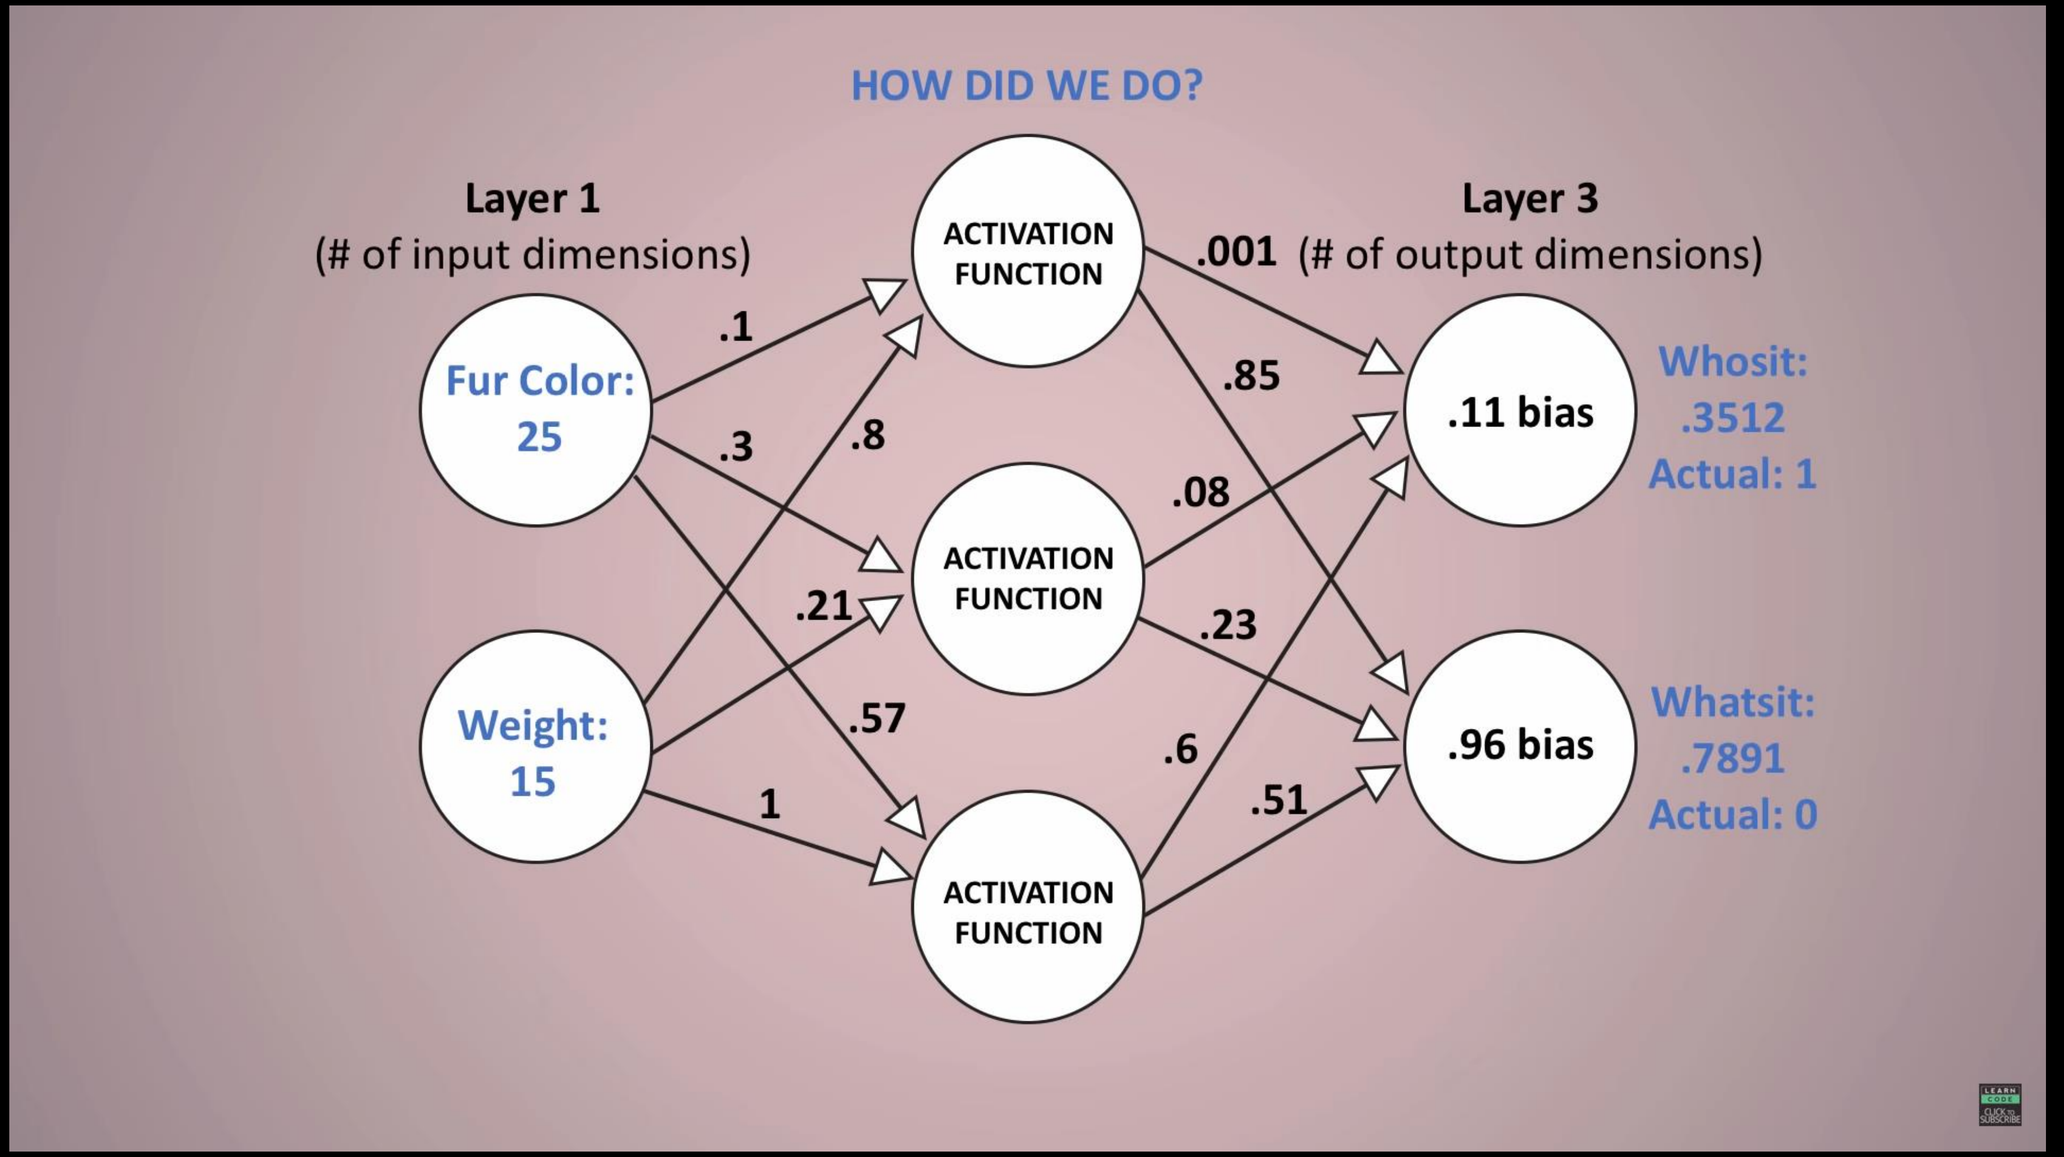
OPENCAMPUS.sh

Einführung in Data Science und maschinelles Lernen

BEHANDLUNG VON FEHLENDEN WERTEN



- Wiederholung wichtiger Konzepte des maschinellen Lernens
- Verschiedene Layer zur Implementierung eines NN
- Behandlung fehlender Werte
- (Support-Vektor-Maschinen)


HOW DID WE DO?
Layer 1
(# of input dimensions)
Layer 3
(# of output dimensions)
Fur Color:
25
Weight:
15
ACTIVATION
FUNCTION
ACTIVATION
FUNCTION
ACTIVATION
FUNCTION
.11 bias
.96 bias
.1
.3
.8
.21
.57
1
.001
.85
.08
.23
.6
.51
Whosit:
.3512
Actual: 1
Whatsit:
.7891
Actual: 0

WICHTIGE KONZEPTE

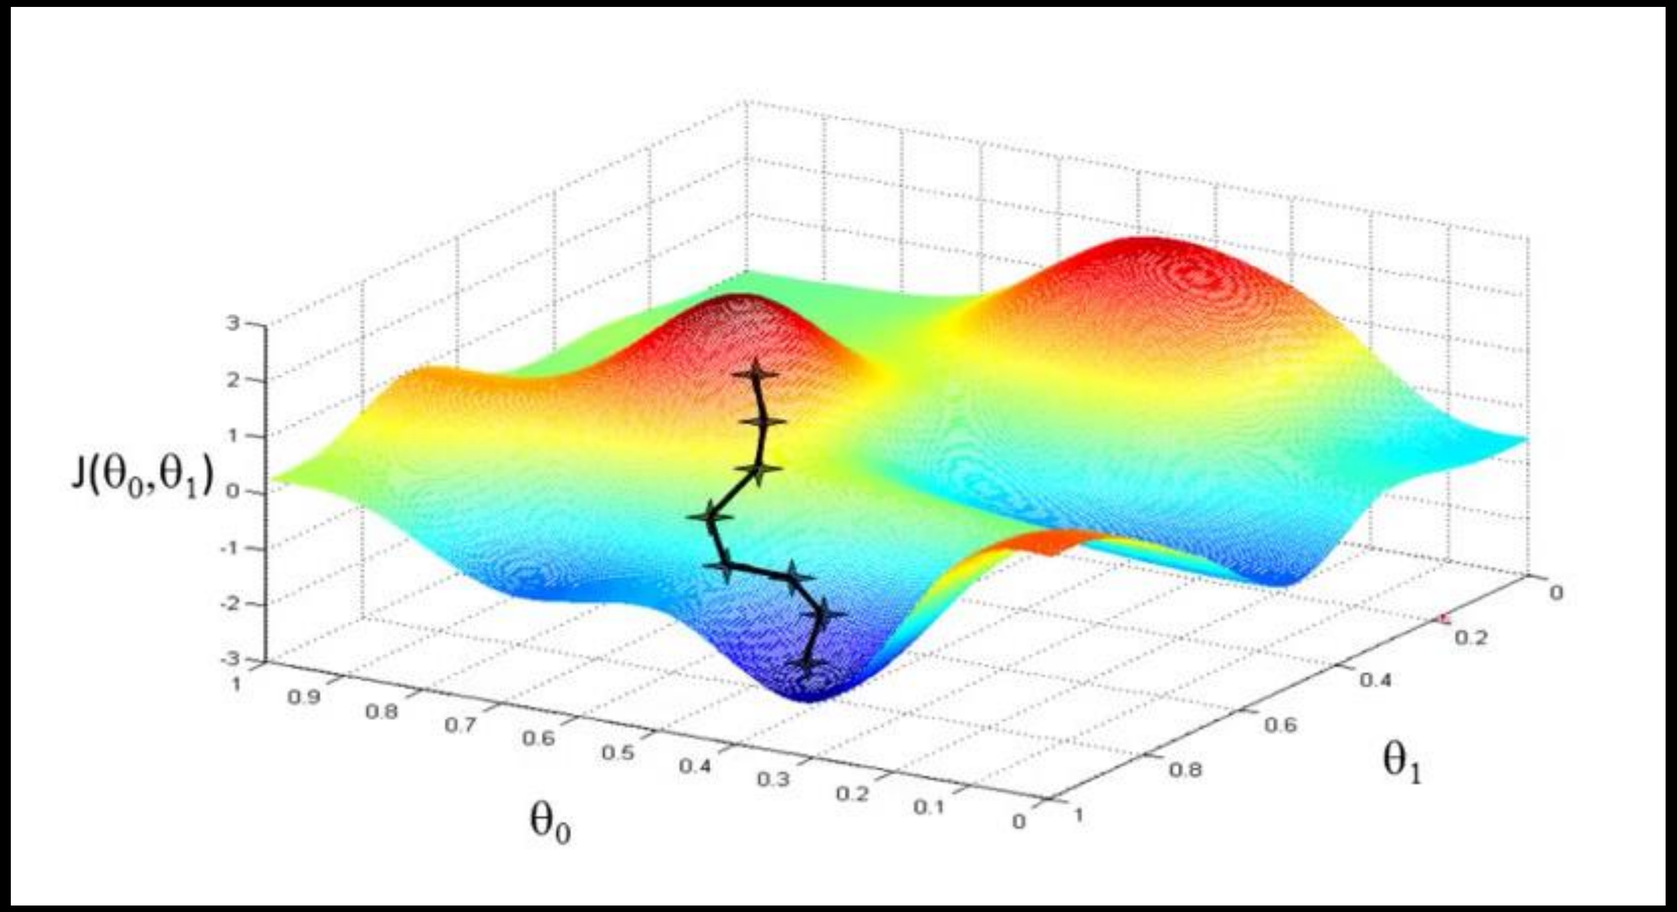
Forward Propagation:

- **Berechnung der Vorhersage basierend auf den aktuellen Parametern und den definierten Aktivierungsfunktionen**

Backward Propagation:

- **Berechnung des Schätzfehlers mit Hilfe der Kostenfunktion**
- **Berechnung neuer, verbesserter Parameter mit Hilfe der Optimierungsfunktion**

MINIMIERUNG DER KOSTENFUNKTION ÜBER EINE OPTIMIERUNGSFUNKTION



- **Minimierung der Kostenfunktion durch ein iteratives Verfahren (Gradient Descent), das sich dem Minimum annähert.**
- **Die Schrittgröße für die Annäherung kann durch die Lernrate („Learning Parameter“) kontrolliert werden.**

Quelle: https://www.coursera.org/learn/machine-learning

BATCH UND EPOCHE

Batch

- **Eine Menge von Fällen, die genutzt wird, um die Gewichte des Modells zu optimieren.**
- **Optimierungsschritte werden anhand der Batches durchgeführt.**

Epoche

- **Optimierung des Modells anhand aller Fälle bzw. aller Batches zu einem Trainingsdatensatz**

Je nach Modell kann es notwendig sein, es über mehrere hundert oder tausend Epochen zu optimieren.

NORMALISIERUNG

Definition:

- **Abziehen des Mittelwerts und Teilen durch die Standardabweichung.**

Erleichtert es dem neuronalen Netz, die benötigten Parameter zu erlernen, indem alle Werte in einem ähnlichen Wertebereich liegen.

BATCH-NORMALISIERUNG

- Durchführung der Normalisierung auf Batch-Ebene

Zusätzliche Optimierung:

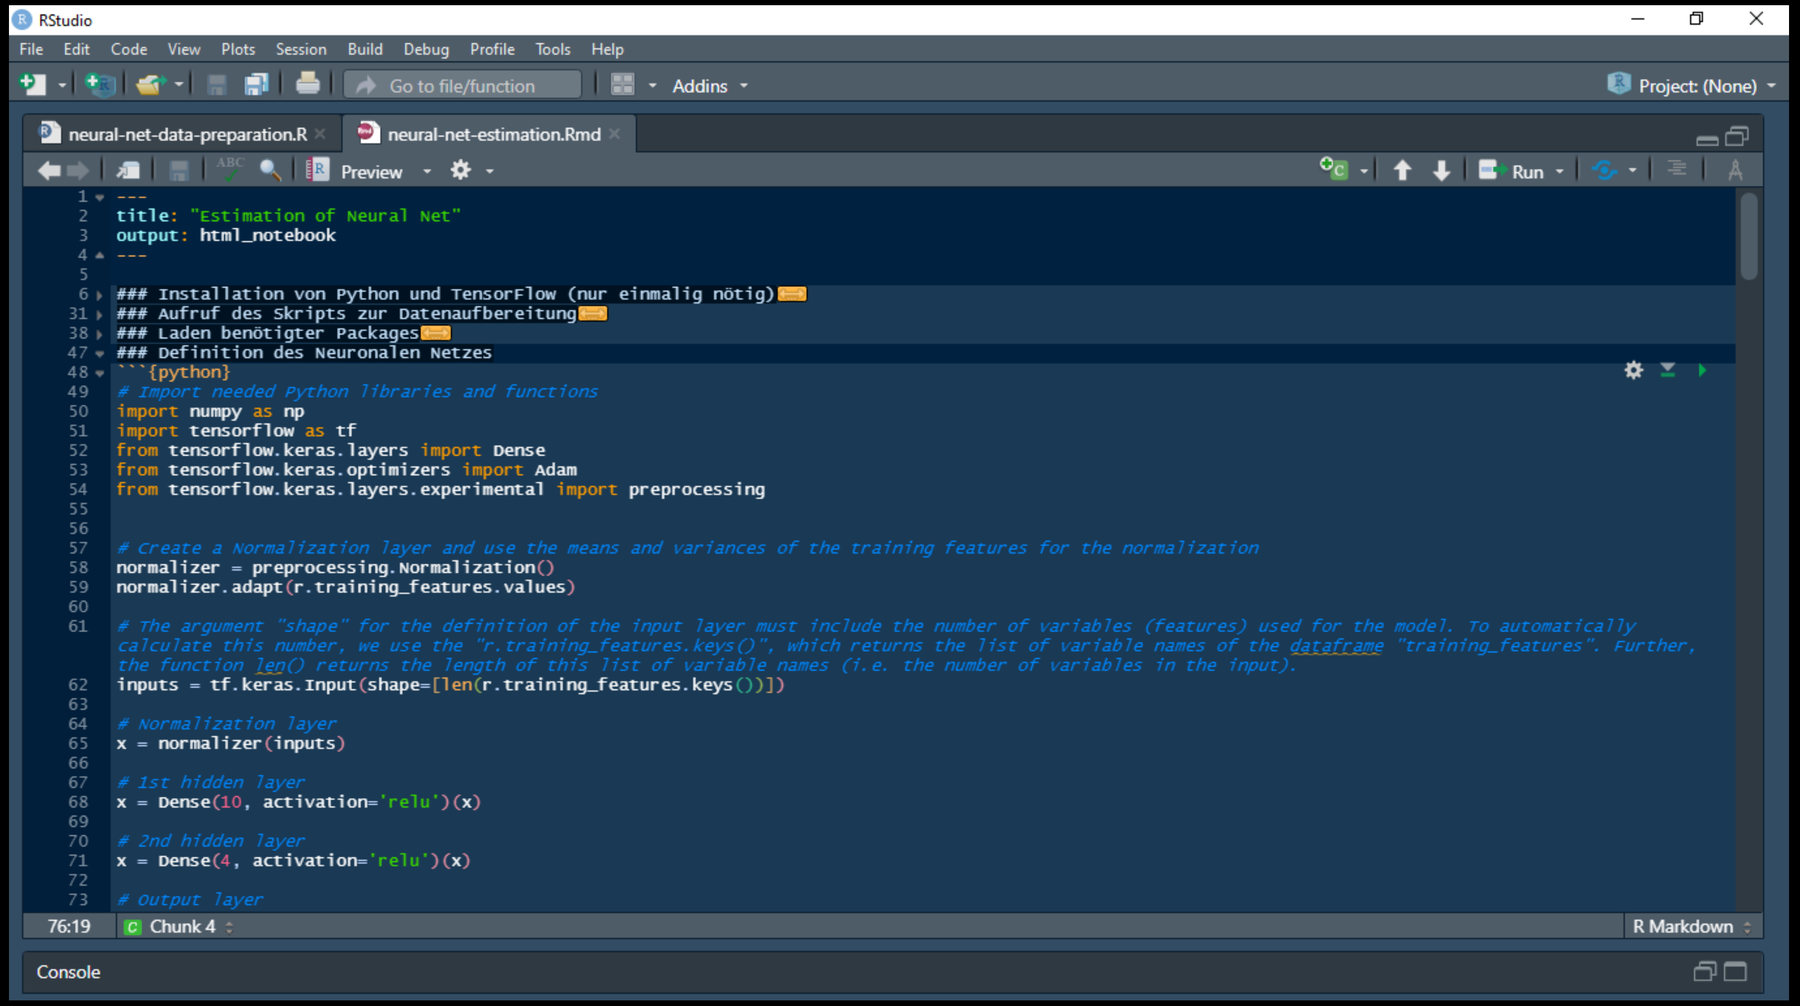
- exakt gleiche Mittelwerte und Standardabweichungen sind nicht notwendigerweise optimal im Sinne der Modellierung

→ Einfügen der Normalisierungsparameter als trainierbare Parameter

DATENAUFBEREITUNG FÜR TENSORFLOW

```
1
2  ##################################################
3  ### Preparation of the Environment 🛋
20 ##################################################
21 ### Data Import 🛋
27 ##################################################
28 ### Data Preparation ####
29
30 # Recoding of the variables into one-hot encoded (dummy) variables
31 dummy_list <- c("view", "condition")
32 house_pricing_dummy = dummy_cols(house_pricing, dummy_list)
33
34 # Definition of lists for each one-hot encoded variable (just to make the handling easier)
35 condition_dummies = c('condition_1', 'condition_2', 'condition_3', 'condition_4', 'condition_5')
36 view_dummies = c('view_0', 'view_1', 'view_2', 'view_3','view_4')
37
38
39 ##################################################
40 ### Selection of the Feature Variables and the Label Variable ####
41
42 # Selection of the features (the independent variables used to predict the dependent)
43 #features <- c('sqft_lot', 'waterfront', 'grade', 'bathrooms', view_dummies, condition_dummies)
44 features <- c('sqft_lot', 'waterfront', 'grade', 'bathrooms', condition_dummies, view_dummies)
45 # Selection of the label (the dependent variable)
46 labels <- 'price'
47
48
49 ##################################################
50 ### Selection of Training, Validation and Test Data ####
51
52 # Look at the data
53 str(house_pricing_dummy)
54
55 # Setting the random counter to a fixed value, so the random initialization stays the same (the ra
56 set.seed(1)
57
```

DEFINITION EINES NEURONALEN NETZES



DROPOUT LAYER ALS FORM DER REGULARISIERUNG

- Setzt die Eingabeeinheiten bei jedem Schritt nach dem Zufallsprinzip mit einer definierten Wahrscheinlichkeit auf 0.

- Hilft Overfitting zu verhindern.

- Wird nur angewendet im Training, für die Inferenz werden keine Werte verworfen.

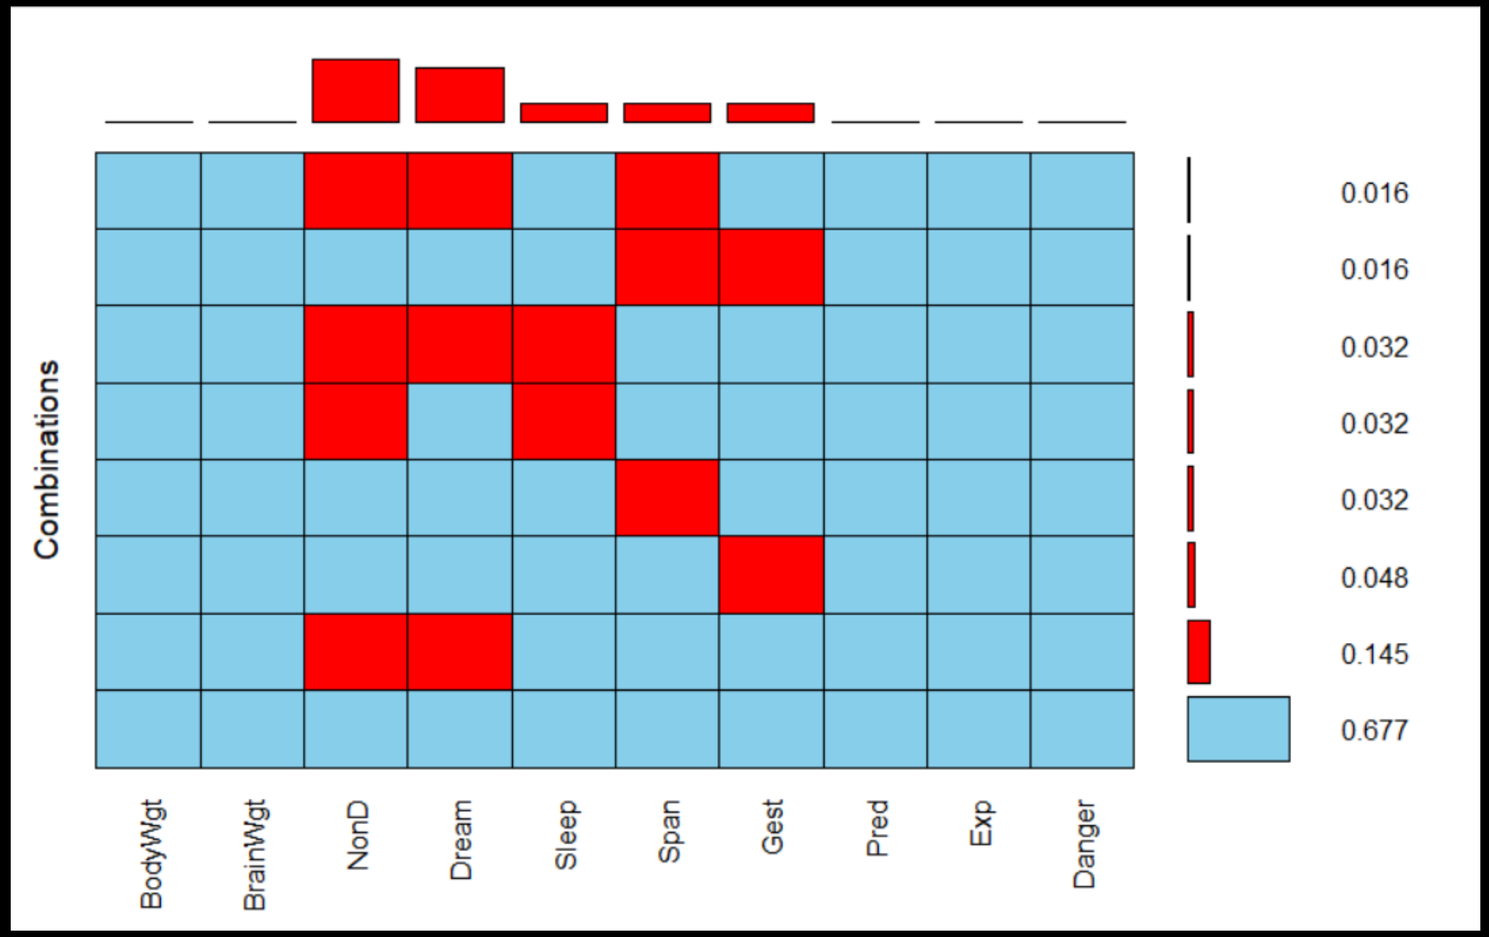
GRÜNDE FÜR FEHLENDE WERTE

- Nicht gegebene Antworten in Umfragen
- Zusammenführung von Daten aus verschiedenen Quellen mit unterschiedlichen Variablen
- Technische Probleme in der Datenerhebung oder Aufzeichnung
- …

TYPEN VON FEHLENDEN WERTEN

- **Missing Completely at Random (MCAR)**
- **Missing at Random (MAR)**
- **Missing not at Random (MNAR)**

VISUALISIERUNG FEHLENDER WERTE



VIM package (Visualization and Imputation of Missing Values)

```
aggr(dataset,
  combined=TRUE,
  numbers=TRUE)
```


Kowarik, A., & Templ, M. (2016). Imputation with the R Package VIM. *Journal of Statistical Software*, *74*, 1–16.

BEHANDLUNG VON FEHLENDEN WERTE

- Zugehörige Fälle löschen (listwise deletion)

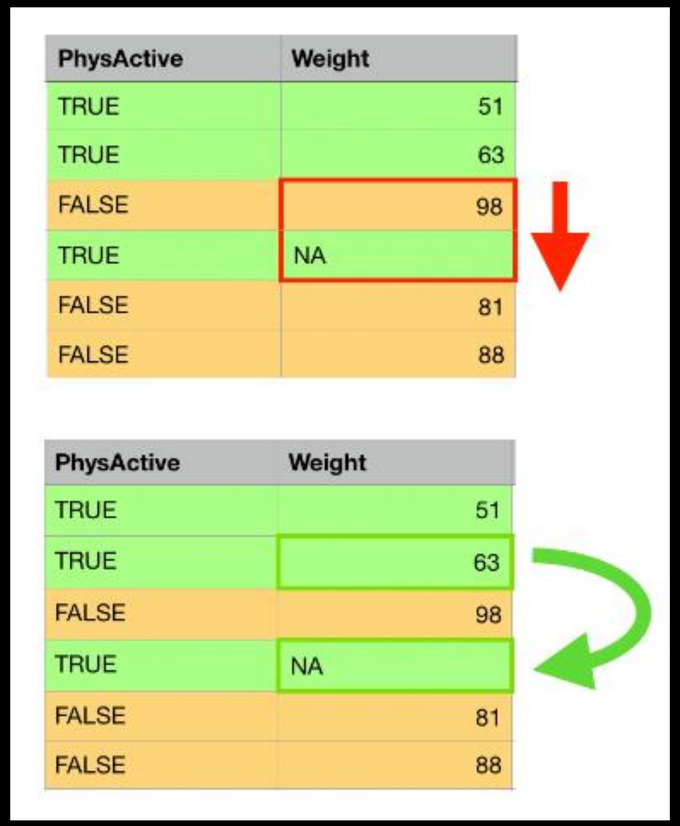
- Einfache „Spender“-basierte Imputation (donor-based)
  - Mittelwertschätzung (bzw. Median oder Mode)
  - nach „Ähnlichkeit“ (Hot-Deck Imputation)
  - durch minimalen Abstand (k Nearest Neighbors)

- Einfache modellbasierte Imputation
  - Iterative Regression

- Multiple Imputation

HOT-DECK IMPUTATION

Nach Domänen



PhysActive	Weight
TRUE	51
TRUE	63
FALSE	98
TRUE	NA
FALSE	81
FALSE	88

PhysActive	Weight
TRUE	51
TRUE	63
FALSE	98
TRUE	NA
FALSE	81
FALSE	88

Nach Korrelation



Height	Weight
150	51
161	63
189	98
155	NA
182	81
184	88

Height	Weight
150	51
155	NA
161	63
182	81
184	88
189	98

Oleszak, M. (2021). Hot-deck imputation | R. Retrieved December 6, 2021, from Datacamp website: https://campus.datacamp.com/courses/handling-missing-data-with-imputations-in-r/donor-based-imputation?ex=5

K-NEAREST NEIGHBORS (KNN)

Suche nach den k Fällen mit minimalem Abstand

- **je nach Variablentyp unterschiedliche Abstandsmessung**
- **Zusammenführung der Abstände über eine Summenfunktion**

Verschiedene Vorgehensweisen zur Berechnung des Imputationswerts:

- **Der Wert mit minimalem Abstand wird genommen (1NN)**
- **Zufällige Ziehung aus den k Fällen**
- **Berechnung aus den k-Fällen über den (gewichteten Mittelwert)**

ITERATIVE REGRESSION

A	B	C	D
5	34	NA	1
1	22	NA	4
NA	65	55	2
4	87	27	2
NA	23	10	1

ITERATIVE REGRESSION

1) Vorhersage fehlender Werte in A

A	B	C	D
5	34	**NA**	1
1	22	**NA**	4
5	65	55	2
4	87	27	2
2	23	10	1

ITERATIVE REGRESSION

2) Vorhersage Fehlender Werte in C mit den imputierten werten von A

A	B	C	D
5	34	**32**	1
1	22	**16**	4
5	65	55	2
4	87	27	2
2	23	10	1

ITERATIVE REGRESSION

3) Vorhersage fehlender Werte in A mit den imputierten Werten von C

A	B	C	D
5	34	**32**	1
1	22	**16**	4
NA	65	55	2
4	87	27	2
NA	23	10	1

→ Wiederholung bis keine Änderung mehr eintritt

ITERATIVE REGRESSION

1) Gehe schrittweise durch alle Variablen des Datensatz
2) Stelle dabei für jede Variable eine Regressionsmodell basierend auf allen anderen Variablen auf
3) Berechne für alle fehlenden Werte eine Vorhersage

- Jetzt wiederhole Schritt 1) bis 3) erneut und schätze die fehlenden Werte erneut - dieses Mal mit den bereits imputierten fehlenden Werten.
- Wiederhole dies, bis sich die imputierten Werte nicht mehr ändern.

IMPUTATION EXAMPLES

```r
library(readr)
library(VIM)
library(dplyr)
library(ggplot2)

sleep <- VIM::sleep

# VIM Aggregation Plot
sleep %>%
  aggr(combined=TRUE, numbers=TRUE)

# Listwise deletion
sleep_deletion <- na.omit(sleep)
sleep_deletion %>%
  aggr(combined=TRUE, numbers=TRUE)

# VIM Hot-Deck Imputation
sleep_hotdeck1 <- sleep %>%
  hotdeck()
sleep_hotdeck1 %>%
  aggr(combined=TRUE, numbers=TRUE)
ggplot(sleep_hotdeck1) +
  geom_point(aes(x=Sleep, y=Dream, color=Sleep_imp))

sleep_hotdeck2 <- sleep %>%
  hotdeck(ord_var = "Dream")
sleep_hotdeck2 %>%
  aggr(combined=TRUE, numbers=TRUE)
ggplot(sleep_hotdeck2) +
  geom_point(aes(x=Sleep, y=Dream, color=Sleep_imp))
```

AUFGABEN

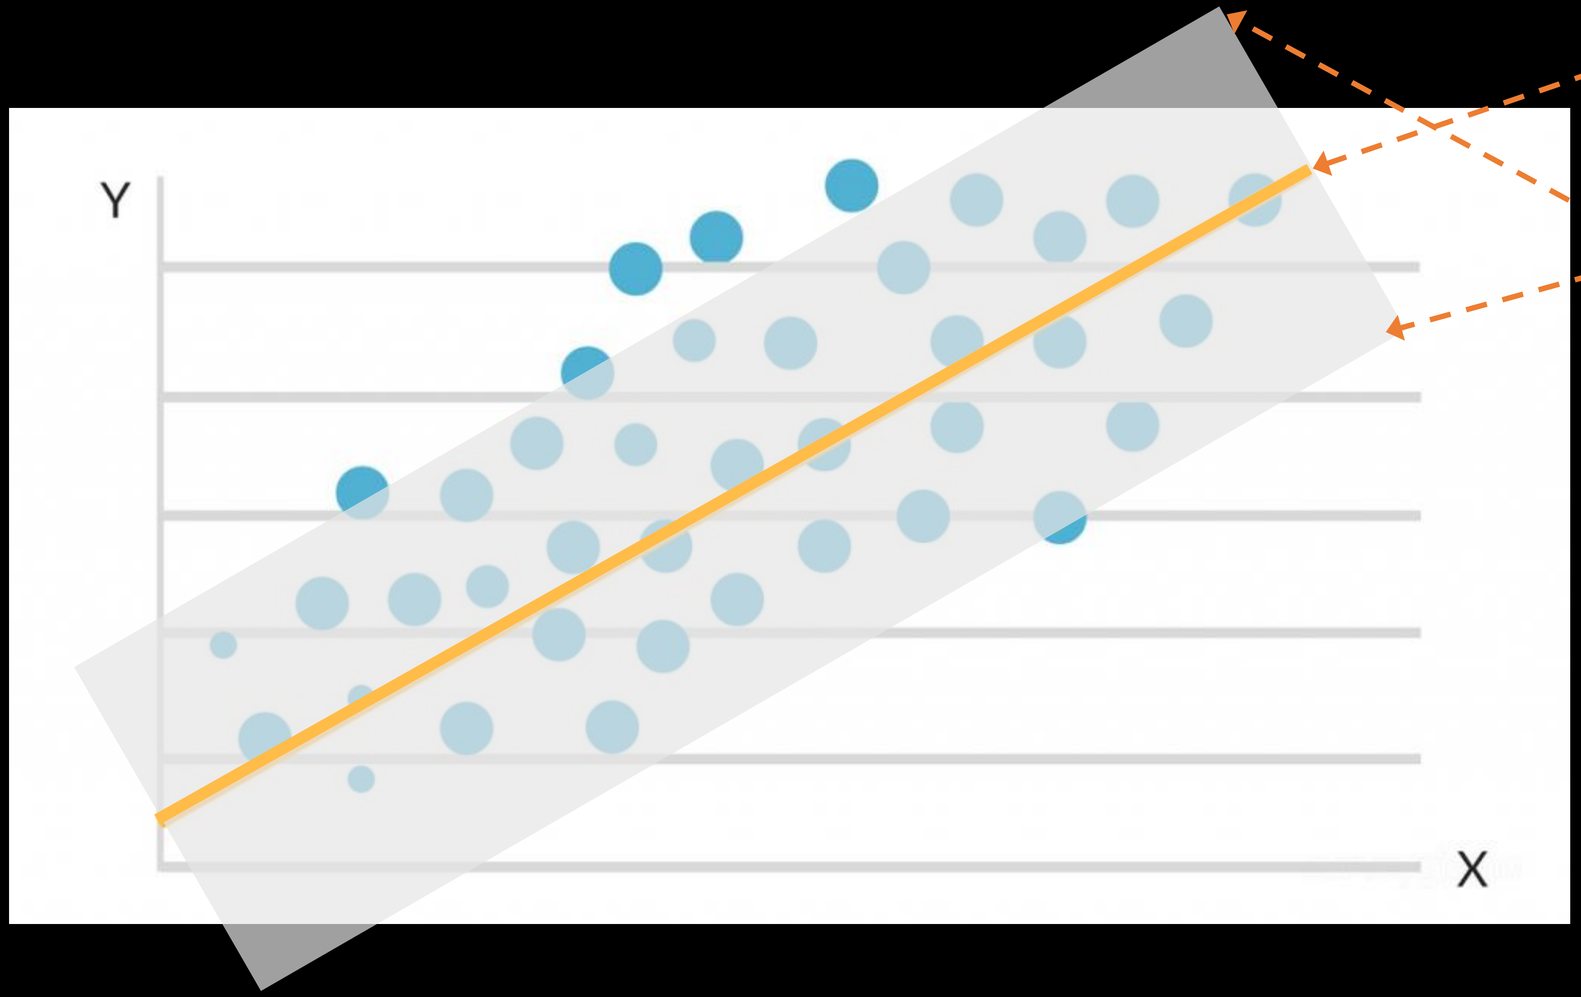
- **Wählt ein (bzw. verschiedene) Verfahren, um fehlenden Werte in Eurem Datensatz zu ersetzen.**

- **Schaut dieses Video (5 Minuten) zu Zeitreihenanalysen an.**

- **Teilt Euch die Aufgaben im Team gut auf:**
  Wer arbeitet an der Datenoptimierung, wer an der Modelloptimierung?

SUPPORT VECTOR MACHINE (SVM)

[SUPPORT VECTOR REGRESSION (SVR)]



Hyper plane

Boundary lines with soft margins

- Der Soft Margin Parameter (auch Cost Paramater) ist ein Regularisierungs-parameter, der die Flexibilität der Grenzlinien steuert bzw. wie stark Punkte außerhalb bestraft werden.

SUPPORT VECTOR MACHINES

Lernressourcen

- **Blog:** https://towardsdatascience.com/an-introduction-to-support-vector-regression-svr-a3ebc1672c2

- **Video:** https://www.youtube.com/watch?v=efR1C6CvhmE

OPTIMIERUNG EINER SVM IN R

R-Package „e1071“

`svm()`	**Optimierung eines SVM Modells**
`tune()`	**Optimierung mehrerer SVM Modelle mit gleichzeitiger Optimierung des C- und Gamma-Parameters**
`predict()`	**Vorhersage auf Basis eines optimierten Modells**

BEISPIELCODE IN R

```
---
title: "Support Vector Machine"
output: html_notebook
---


## Imports
## Splitting Training and Test Data
## Data Preparation
## Training the SVM

```{r}
# Optimization of an SVM with standard hyper parameters
# Typically NOT used; Instead, the function svm_tune() is used in order to also get a model with optimized hyper parameters
model_svm <- svm(price ~ bathrooms, train_dataset)
```

```{r}
# Optimization of various SVM using systematically varied hyper parameters (typically called 'grid search' approach) and
cross validation
# the resulting object includes the optimal model in the element named 'best.model'
svm_tune <- tune(svm, price ~ bedrooms + bathrooms + sqft_living + zipcode, data=train_dataset,
                 ranges = list(epsilon = seq(0.2,1,0.1), cost = 2^(2:3)))
```


Checking the Prediction Quality
```

ZUSAMMENFASSUNG SVM

- Populärer, weil einfach zu optimierender Lernalgorithmus, der schnell gute Ergebnisse bringt.
- Geeignet zur Klassifikation und zur Regression.