18.04.23

OPENCAMPUS.sh

Einführung in Data Science und maschinelles Lernen

EINFÜHRUNG

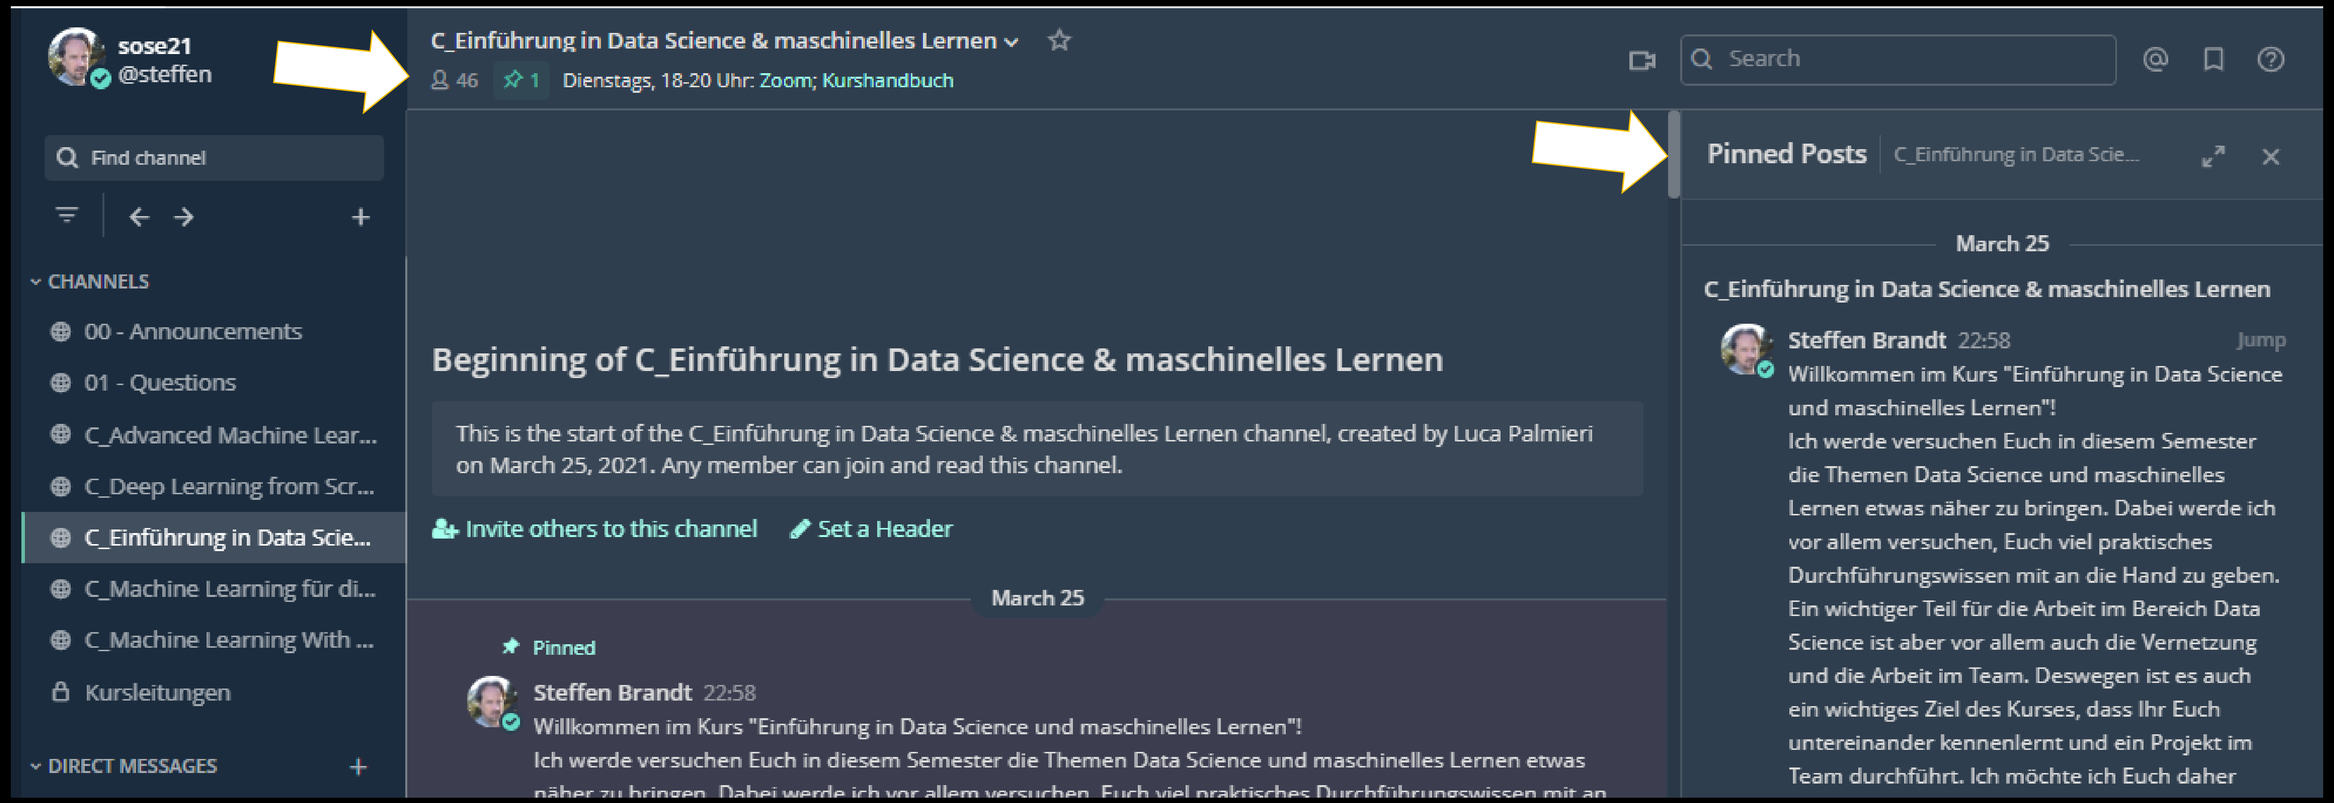
- Vorstellung
- Organisatorisches
- Aufbau des Kurses
- Was ist Data Science?
- R vs. Python vs. SPSS vs. …
- Wozu RStudio?
- Datenstrukturen in R

VORSTELLUNG

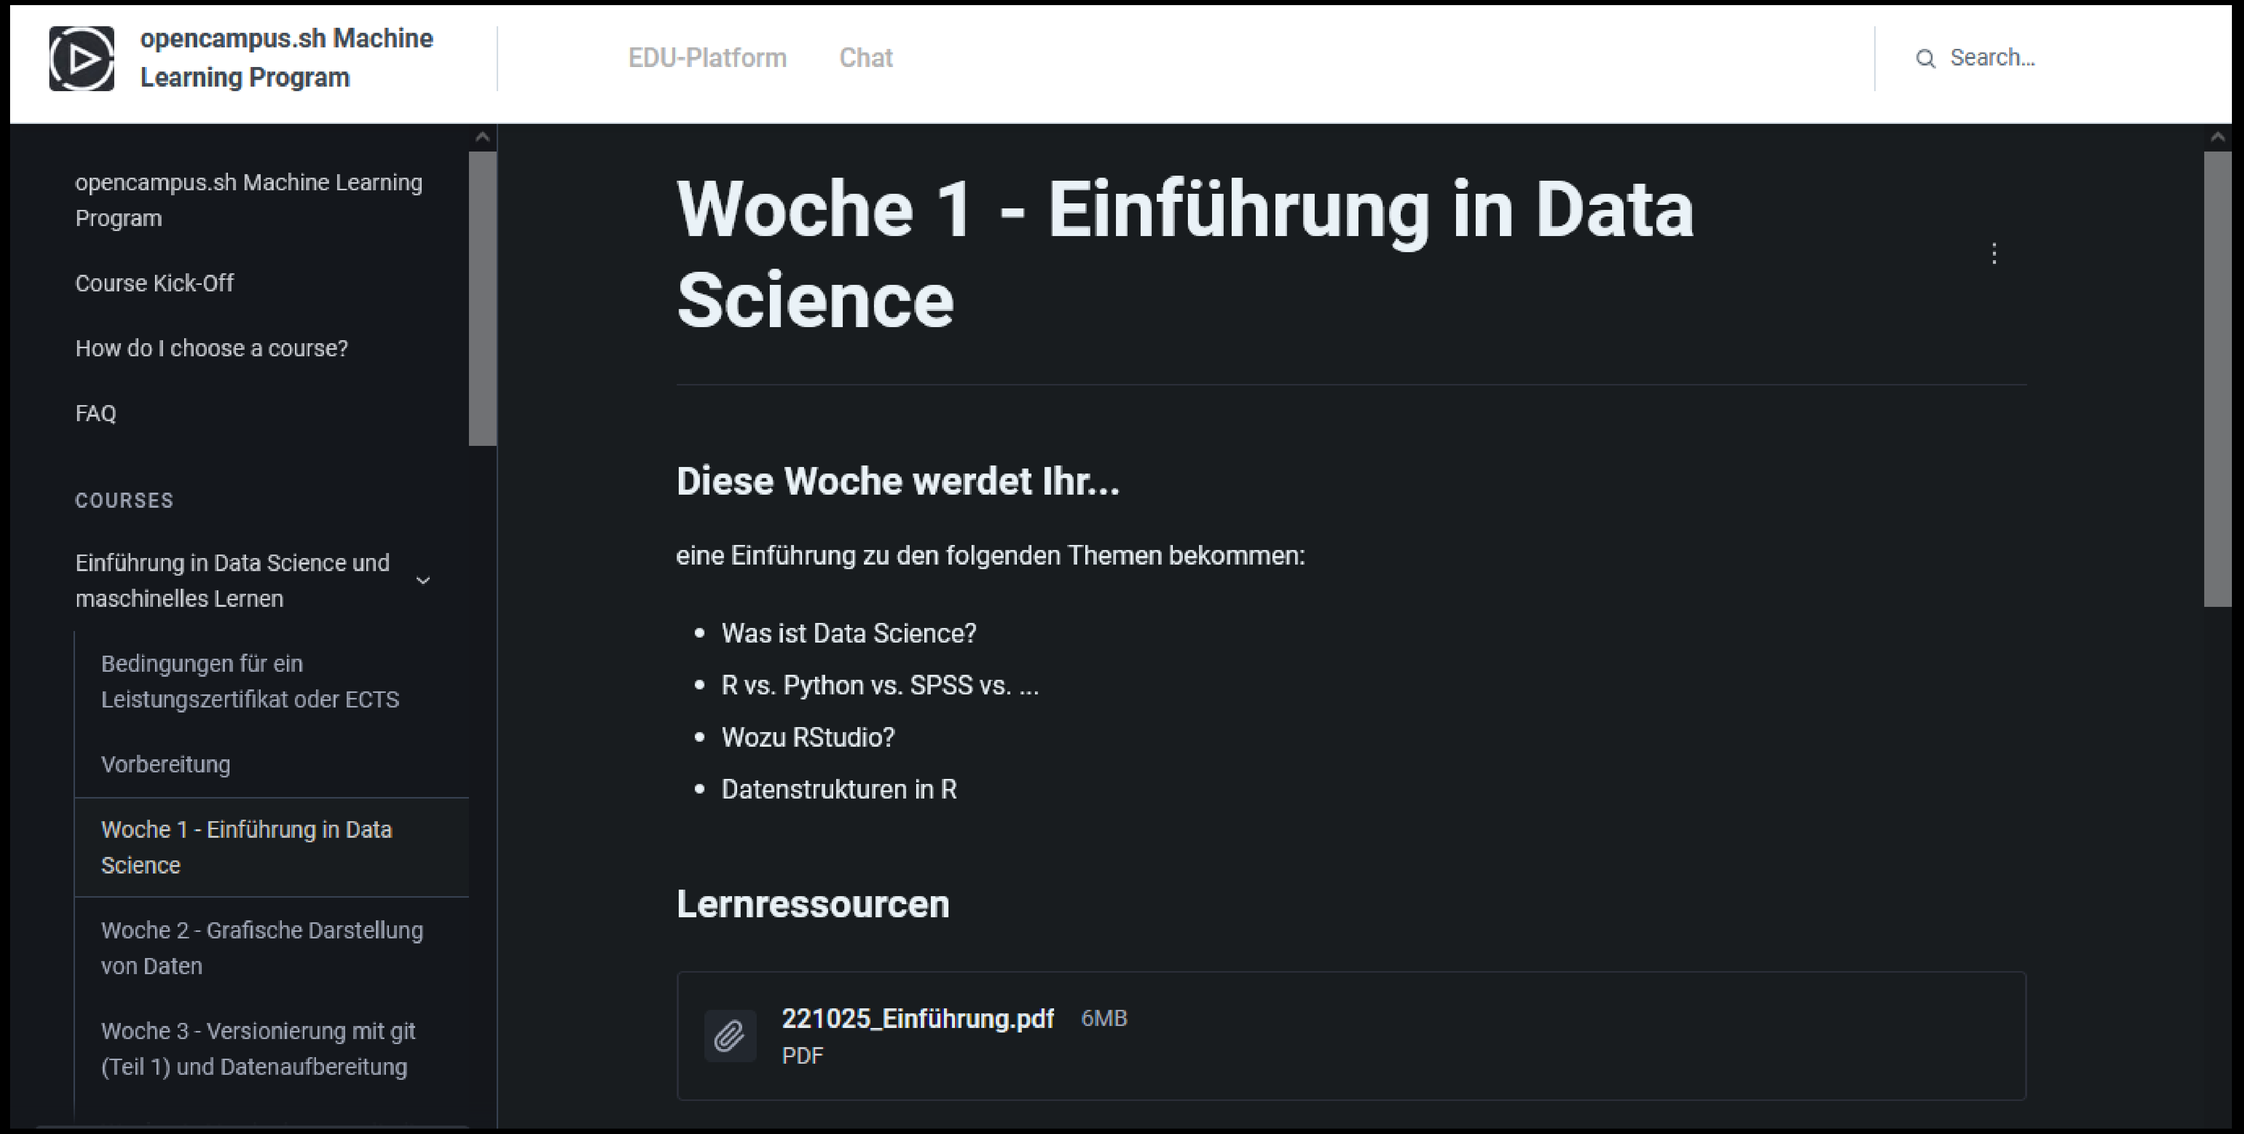
ORGANISATORISCHES

- Benutzt Euren vollständigen Namen in den Zoom-Meetings!
- Scannt den QR-Code, wenn Ihr in Präsenz teilnehmt
- Vervollständigt Euer Profil im Mattermost-Chat mit Eurem Namen und einem Foto.
- Bitte schreibt mir, wenn Ihr den Kurs abbrecht!

CHAT


sose21
@steffen
C_Einführung in Data Science & maschinelles Lernen
46
1
Dienstags, 18-20 Uhr: Zoom; Kurshandbuch
Search
Find channel
CHANNELS
00 - Announcements
01 - Questions
C_Advanced Machine Lear...
C_Deep Learning from Scr...
C_Einführung in Data Scie...
C_Machine Learning für di...
C_Machine Learning With ...
Kursleitungen
DIRECT MESSAGES
Beginning of C_Einführung in Data Science & maschinelles Lernen
This is the start of the C_Einführung in Data Science & maschinelles Lernen channel, created by Luca Palmieri on March 25, 2021. Any member can join and read this channel.
Invite others to this channel
Set a Header
March 25
Pinned
Steffen Brandt 22:58
Willkommen im Kurs "Einführung in Data Science und maschinelles Lernen"!
Ich werde versuchen Euch in diesem Semester die Themen Data Science und maschinelles Lernen etwas
Pinned Posts
C_Einführung in Data Scie...
March 25
C_Einführung in Data Science & maschinelles Lernen
Steffen Brandt 22:58
Jump
Willkommen im Kurs "Einführung in Data Science und maschinelles Lernen"!
Ich werde versuchen Euch in diesem Semester die Themen Data Science und maschinelles Lernen etwas näher zu bringen. Dabei werde ich vor allem versuchen, Euch viel praktisches Durchführungswissen mit an die Hand zu geben. Ein wichtiger Teil für die Arbeit im Bereich Data Science ist aber vor allem auch die Vernetzung und die Arbeit im Team. Deswegen ist es auch ein wichtiges Ziel des Kurses, dass Ihr Euch untereinander kennenlernt und ein Projekt im Team durchführt. Ich möchte ich Euch daher

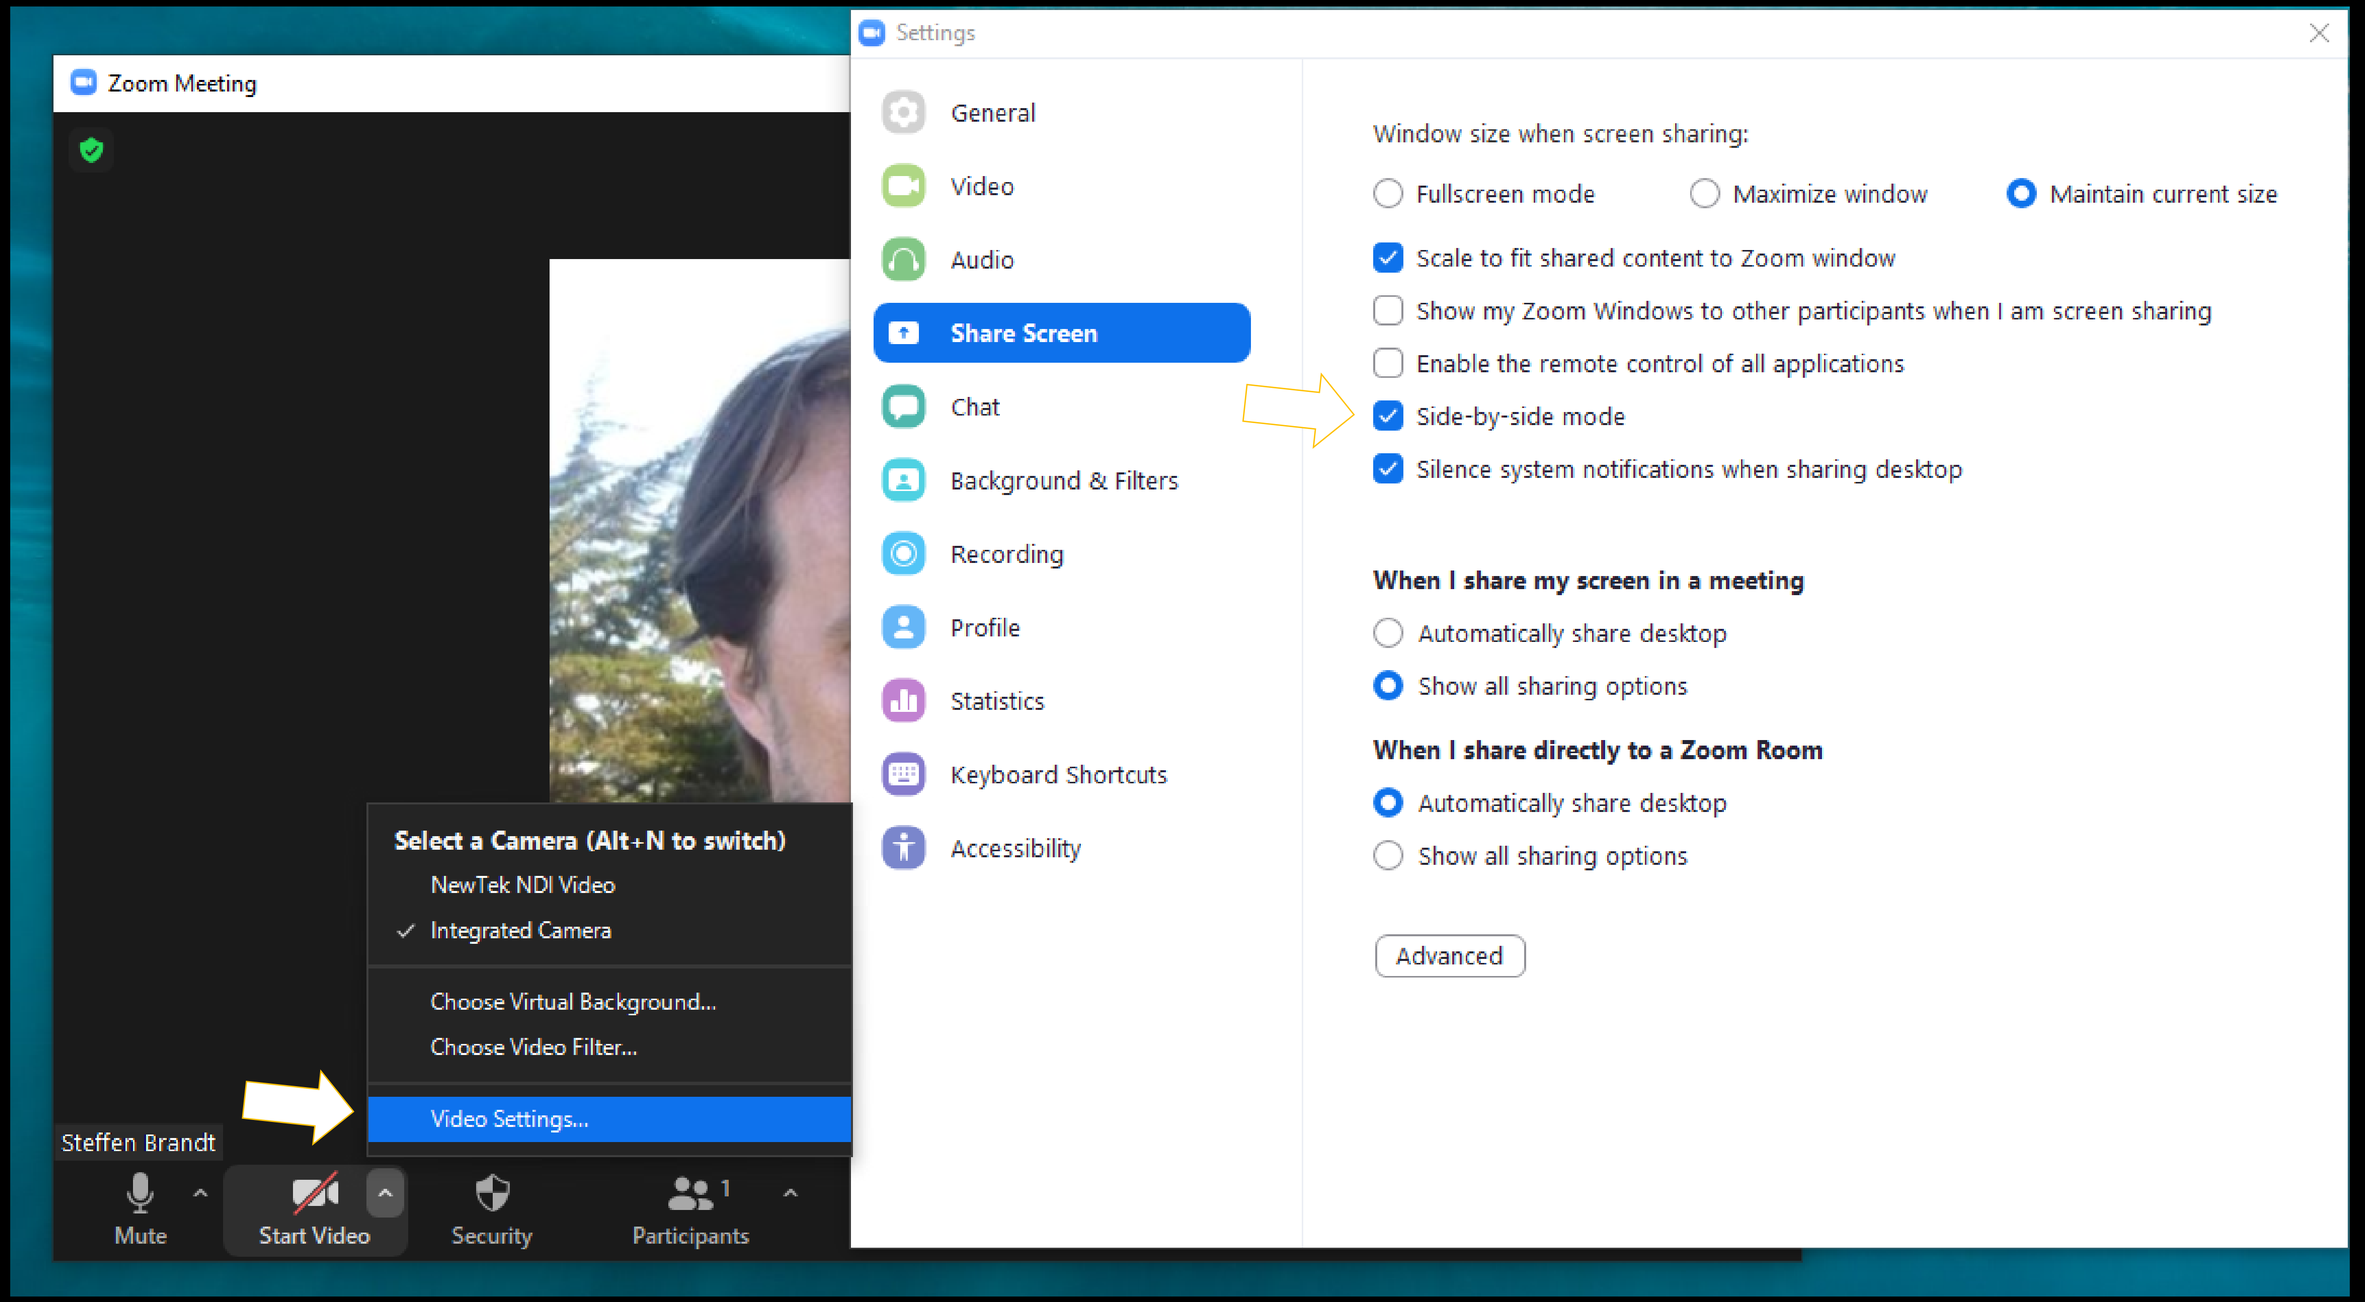
KURSHANDBUCH



ZOOM

- Versucht die unterschiedlichen View Modes:
  - Gallery View/ Active Speaker
  - Split Screen/ Full Screen Mode

- Schaut Euch ggf. dazu dieses Video an:
  https://www.youtube.com/watch?v=v3IPAbpVjd4

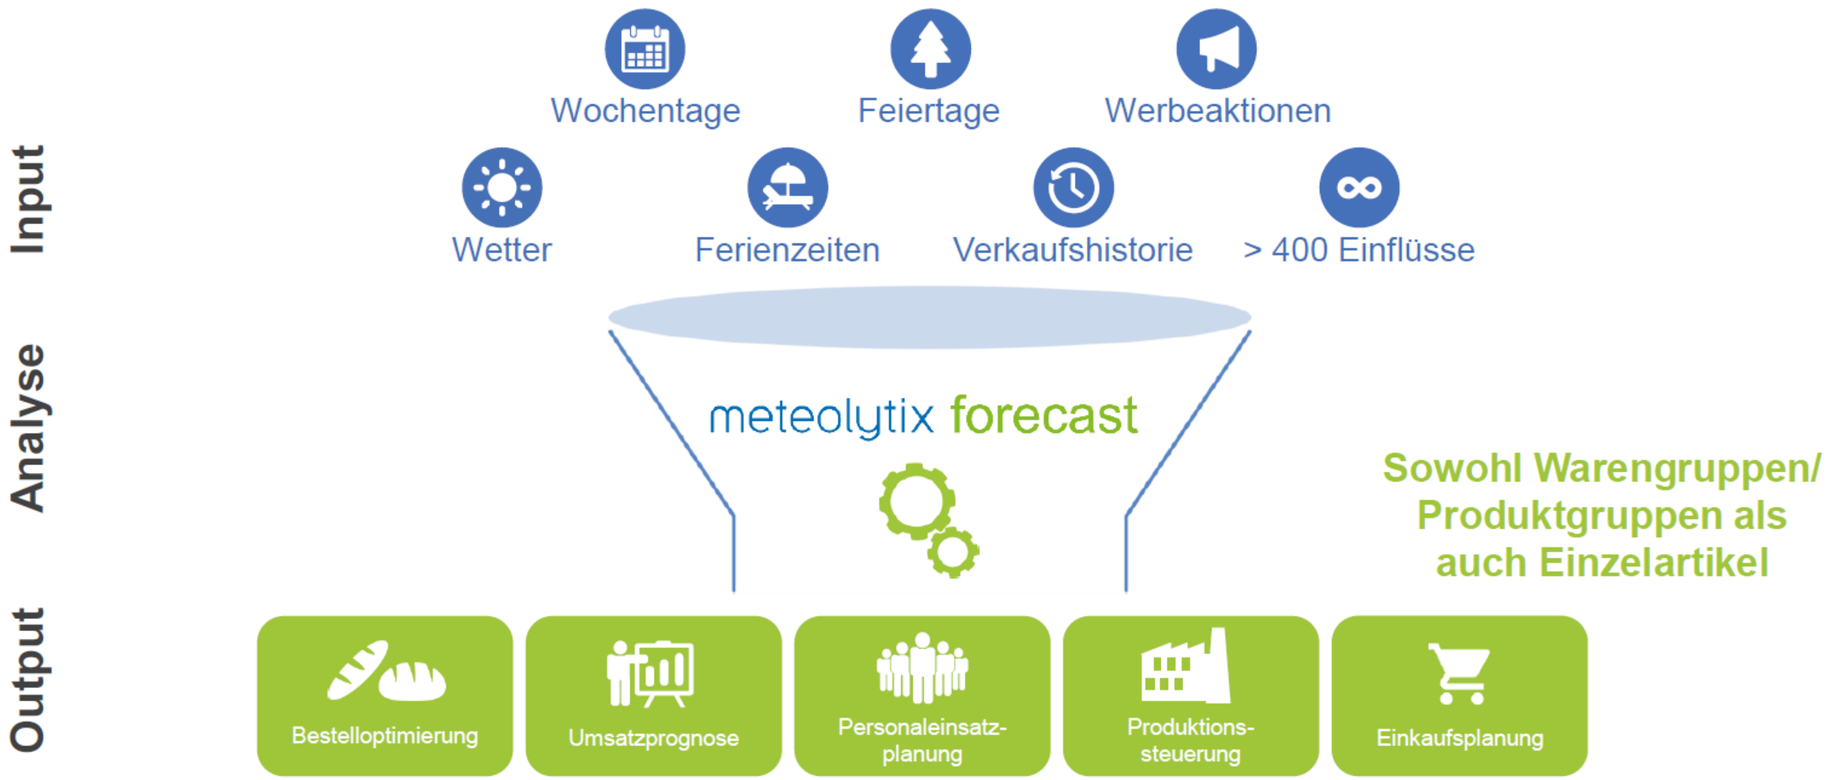

Zoom Meeting
Select a Camera (Alt+N to switch)
NewTek NDI Video
Integrated Camera
Choose Virtual Background...
Choose Video Filter...
Video Settings...
Steffen Brandt
Mute
Start Video
Security
Participants
1
Settings
General
Video
Audio
Share Screen
Chat
Background & Filters
Recording
Profile
Statistics
Keyboard Shortcuts
Accessibility
Window size when screen sharing:
Fullscreen mode
Maximize window
Maintain current size
Scale to fit shared content to Zoom window
Show my Zoom Windows to other participants when I am screen sharing
Enable the remote control of all applications
Side-by-side mode
Silence system notifications when sharing desktop
When I share my screen in a meeting
Automatically share desktop
Show all sharing options
When I share directly to a Zoom Room
Automatically share desktop
Show all sharing options
Advanced

PROJEKT ZUR UMSATZVORHERSAGE

- Datensatz zur Verfügung gestellt von Meteolytix
- Umsatzdaten von verschiedenen Warengruppen einer Bäckereifiliale über einen Zeitraum von ca. 3 Jahren
- Wetterdaten für den zugehörigen Zeitraum (und darüber hinaus)

meteolytix forecast analysiert die Datenzusammenhänge von mehr als 400 Einflussfaktoren und liefert Absatzprognosen für viele Einsatzfelder.

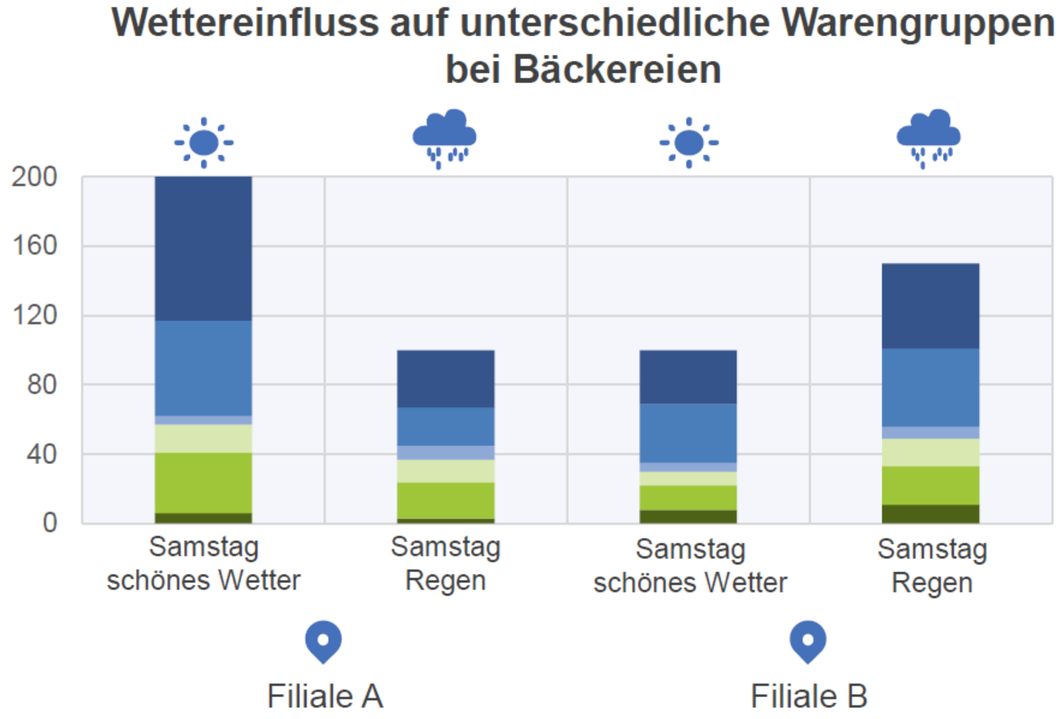
WAS WIR MACHEN

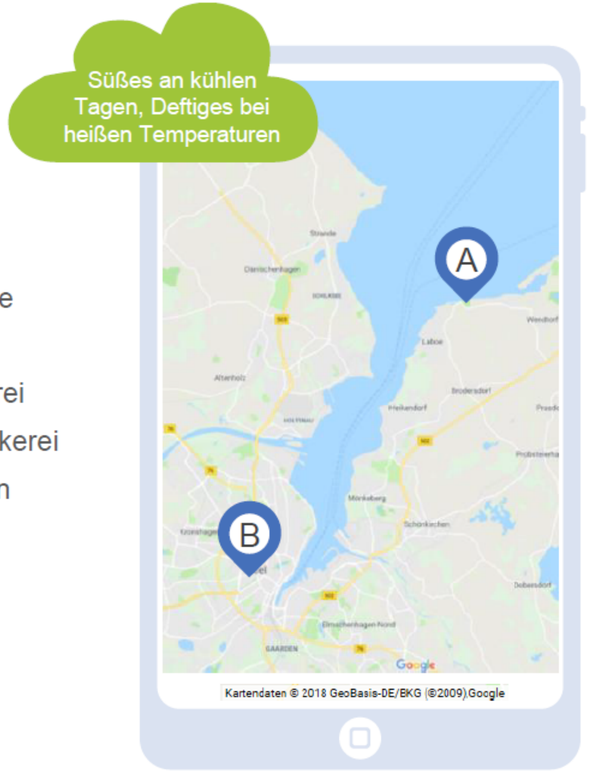


© 2019 *meteolytix GmbH*

Die Stärke des Wettereffekts variiert von Ort zu Ort und wird jeweils filialindividuell berücksichtigt.

WAS WIR MACHEN

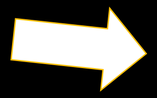




PROJEKTZIELE

- Aufbereitung eigener Variablen zur Vorhersage
- Arbeiten im Team mit Versionierung (Git)
- Nutzung grafischer Darstellungen zur Identifizierung relevanter Variablen (unter anderem über Konfidenzintervalle für Mittelwertsunterschiede)
- Nutzung von Regressionen zur Identifizierung relevanter Variablen
- Behandlung fehlender Werte
- Optimierung eines neuronalen Netzes zur Umsatzvorhersage

Festlegung der Teams



18.04. 18:00	Einführung in Data Science	Zoom + Starterkitchen, Kuhnkestraße 6, Wissenschaftspark
25.04. 18:00	Grafische Darstellung von Daten	Zoom + Starterkitchen, Kuhnkestraße 6, Wissenschaftspark
02.05. 18:00	R-Projekte und Versionierung mit Git und GitHub	Zoom + Starterkitchen, Kuhnkestraße 6, Wissenschaftspark
09.05. 18:00	Datenaufbereitung mit Tidyverse	Zoom + Starterkitchen, Kuhnkestraße 6, Wissenschaftspark
16.05. 18:00	Einführung in das maschinelle Lernen	Zoom + Starterkitchen, Kuhnkestraße 6, Wissenschaftspark
23.05. 18:00	Datenaufbereitung für maschinelles Lernen	Zoom + Starterkitchen, Kuhnkestraße 6, Wissenschaftspark
30.05. 18:00	Neuronale Netze und Deep Learning	Zoom + Starterkitchen, Kuhnkestraße 6, Wissenschaftspark
06.06. 18:00	Behandlung von fehlenden Werten	Zoom + Starterkitchen, Kuhnkestraße 6, Wissenschaftspark
13.06. 18:00	Zeitreihenanalysen	Zoom + Starterkitchen, Kuhnkestraße 6, Wissenschaftspark
20.06. 18:00	Projektpräsentationen	Zoom + Starterkitchen, Kuhnkestraße 6, Wissenschaftspark

„Education is the only thing that humans try to get less out of than what they pay for.“

ERSTER BREAKOUT

- 15 Minuten
- Stellt Euch einander vor
- Frage: Was ist Künstliche Intelligenz?
  - Versucht Euch auf eine Definition zu einigen
  - Teilt diese im Chat

“What's the difference between data science, machine learning, and artificial intelligence?”

http://varianceexplained.org/r/ds-ml-ai

Data science produces insights.

Machine learning produces predictions.

Artificial intelligence produces actions.

DATA SCIENCE

Anwendung statistischer Auswertungsverfahren mit deren Hilfe Ergebnisse für einen Bericht oder Artikel erzeugt werden.

- **Deskriptive Statistiken**
- **Statistische Schlussfolgerungen**
- **Visualisierung von Daten**
- **Design von Experimenten**

MASCHINELLES LERNEN

Anwendung eines statistischen Optimierungsverfahren zur Schätzung von Modellparametern (validiert mit „ungesehenen“ Daten)

mit deren Hilfe eine Funktion erstellt wird, die Prognosen liefert,

Wobei (häufig) gleichzeitig die Modellparameterschätzung durch Hinzufügen neuer Daten ständig verbessert wird.

- **Prognose zukünftiger Zustände**
- **Prognose unbeobachteter Zustände**
- **Prognose aktueller Zustände**

KÜNSTLICHE INTELLIGENZ

„an autonomous agent executes or recommends actions“

(Poole, Mackworth, & Goebel, 1998)

„Systeme mit einem ‚intelligenten‘ Verhalten, die ihre Umgebung analysieren und mit einem gewissen Grad an Autonomie handeln, um bestimmte Ziele zu erreichen. “

(Europäische Kommission, 2018)

„Unter Künstlicher Intelligenz verstehen wir hochentwickelte Softwaresysteme, welche lernfähig und trainierbar sind, um komplexe Aufgaben bewältigen können.“

(KI-Strategie des Landes Schleswig-Holstein, 2019)

EIGENSCHAFTEN VON R

- Von Statistikern entwickelte Auswertungssprache (Python etwa kommt aus dem IT-/Tech-Umfeld)
- Interpretersprache (Syntax wird Zeile für Zeile interpretiert, vergleichbar eines Taschenrechners)
- Konsolen-Programm ohne grafische Benutzeroberfläche

NACHTEILE VON R

- Man muss programmieren
- Im Bereich des maschinellen Lernens weniger verbreitet als Python
- Weniger Schnittstellen (APIs) als Python zu Anwendungen im produktiven Umfeld

VORTEILE VON R (UND RSTUDIO)

- Open Source
- Sehr große Community
- Im wissenschaftlichen Bereich inzwischen Standard für statistische Auswertungen
- Umfangreichste Funktionssammlung im Bereich Data Science / Statistik
- Umfangreiche Möglichkeiten zur Erstellung von Abbildungen und Berichten
- Leichte Integration von anderen Programmiersprachen

RSTUDIO

(Beliebteste) Umgebung zur Erstellung und Ausführung von R-Programmen

- **Komfortable Bearbeitung und Ausführung der Syntax**
- **Zugriff auf Hilfe-Dateien**
- **Anzeige aktuell im Speicher geladener Daten und Funktionen**
- **Anzeige grafischer Ausgaben**
- **Installation zusätzlicher Funktionspakete („Packages“)**
- **…**

```r
#####
# Prepare Environament
#####
setwd("C:/Users/Steffen/Arbeit/opencampus/99_source-code/elearning-statistics/00_functions")
source("02_LimeSurvey-API.R") # import LimeSurvey API
setwd("../../auswertung pre-challenge")

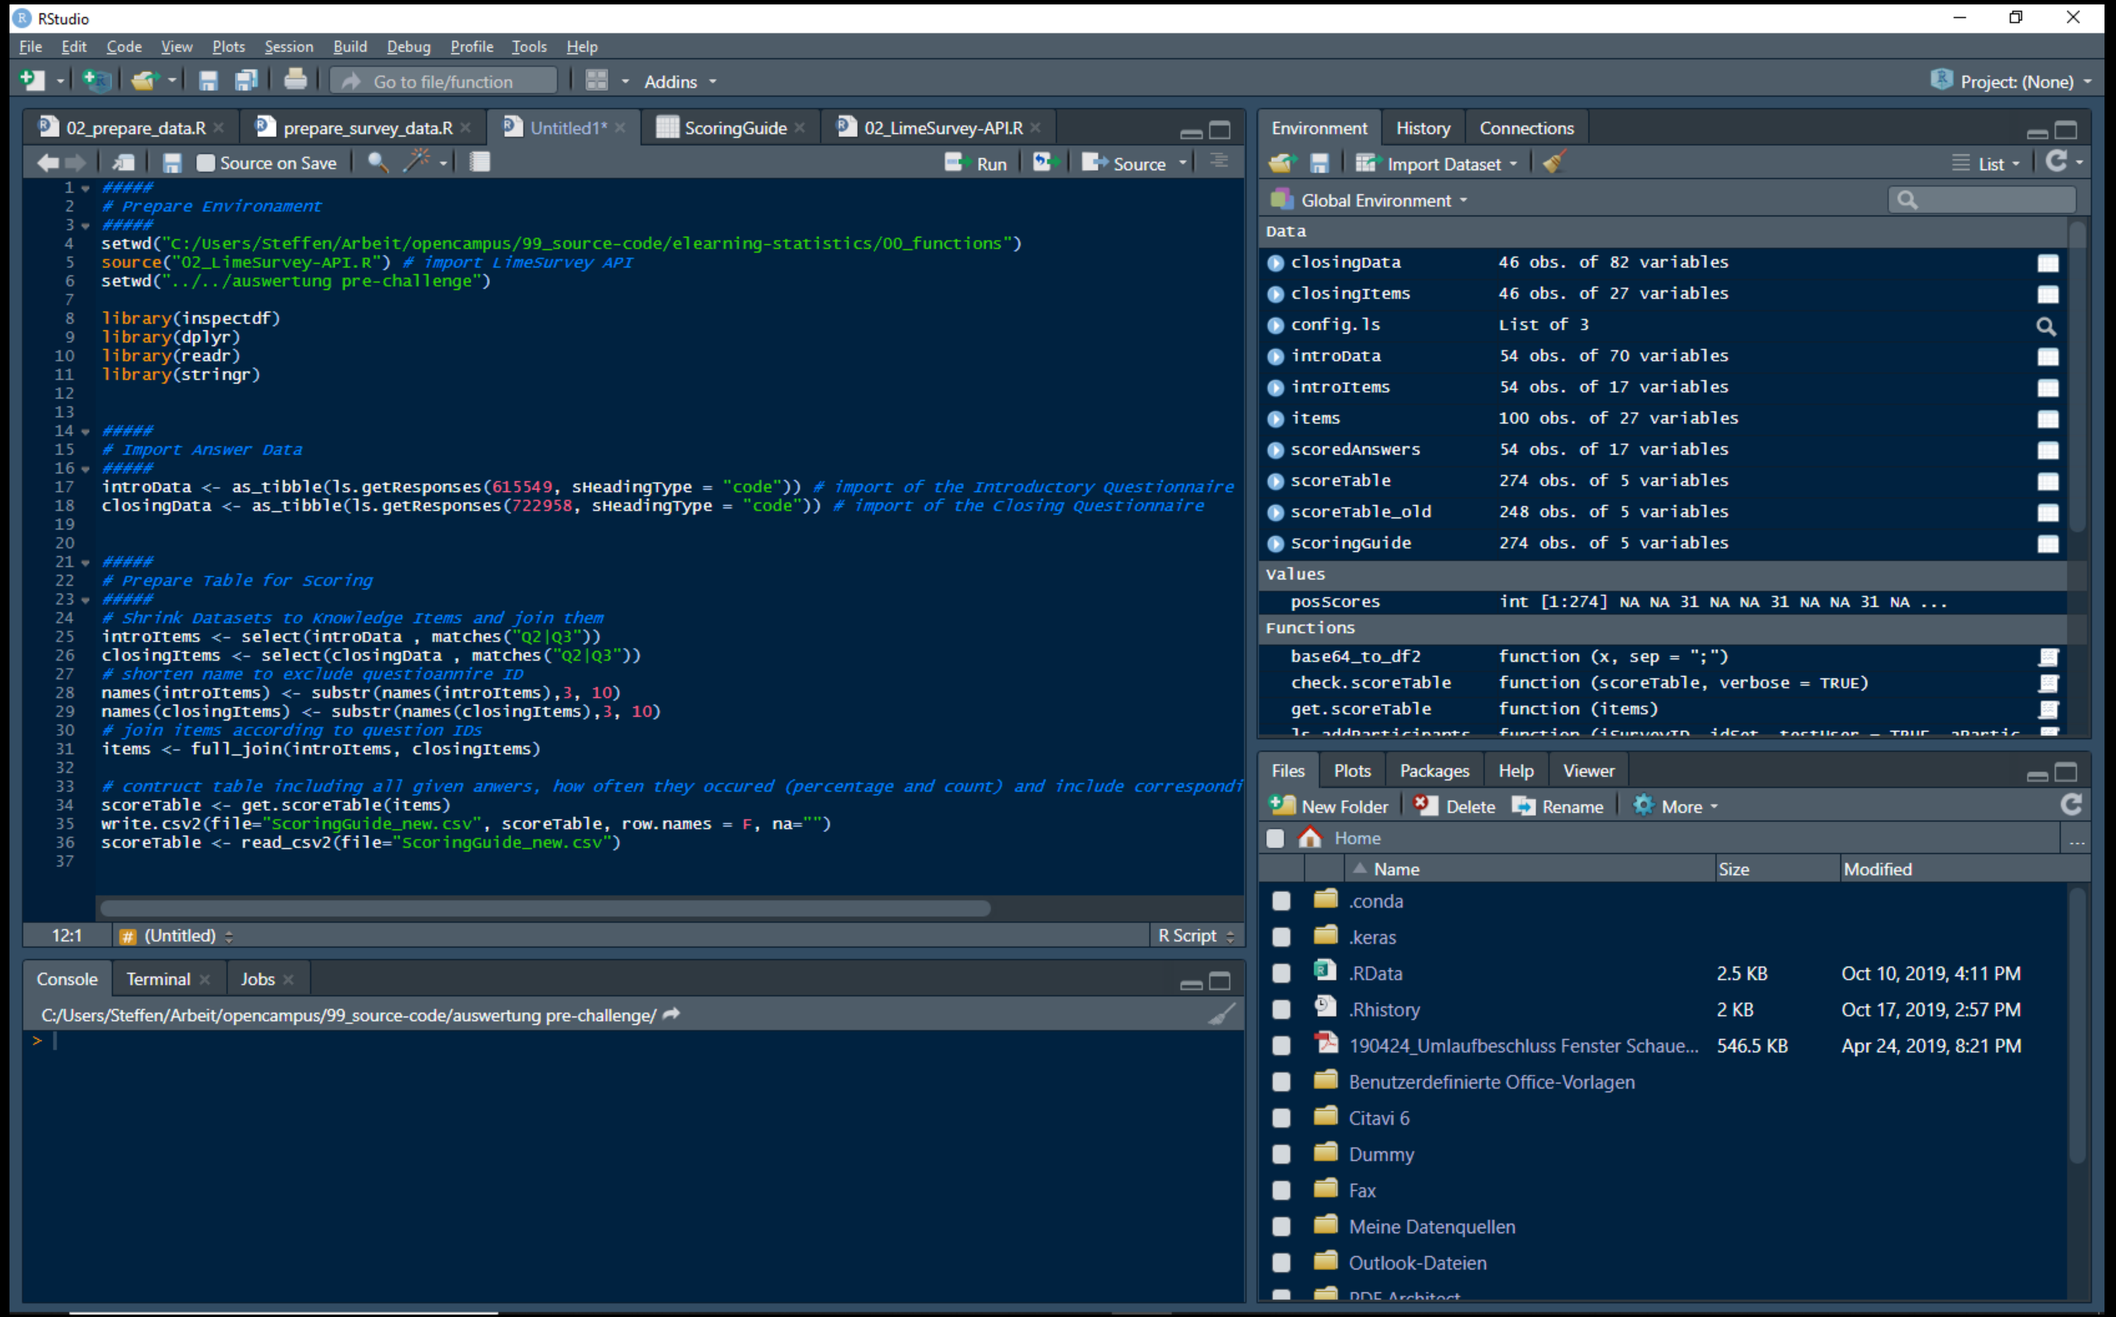
library(inspectdf)
library(dplyr)
library(readr)
library(stringr)

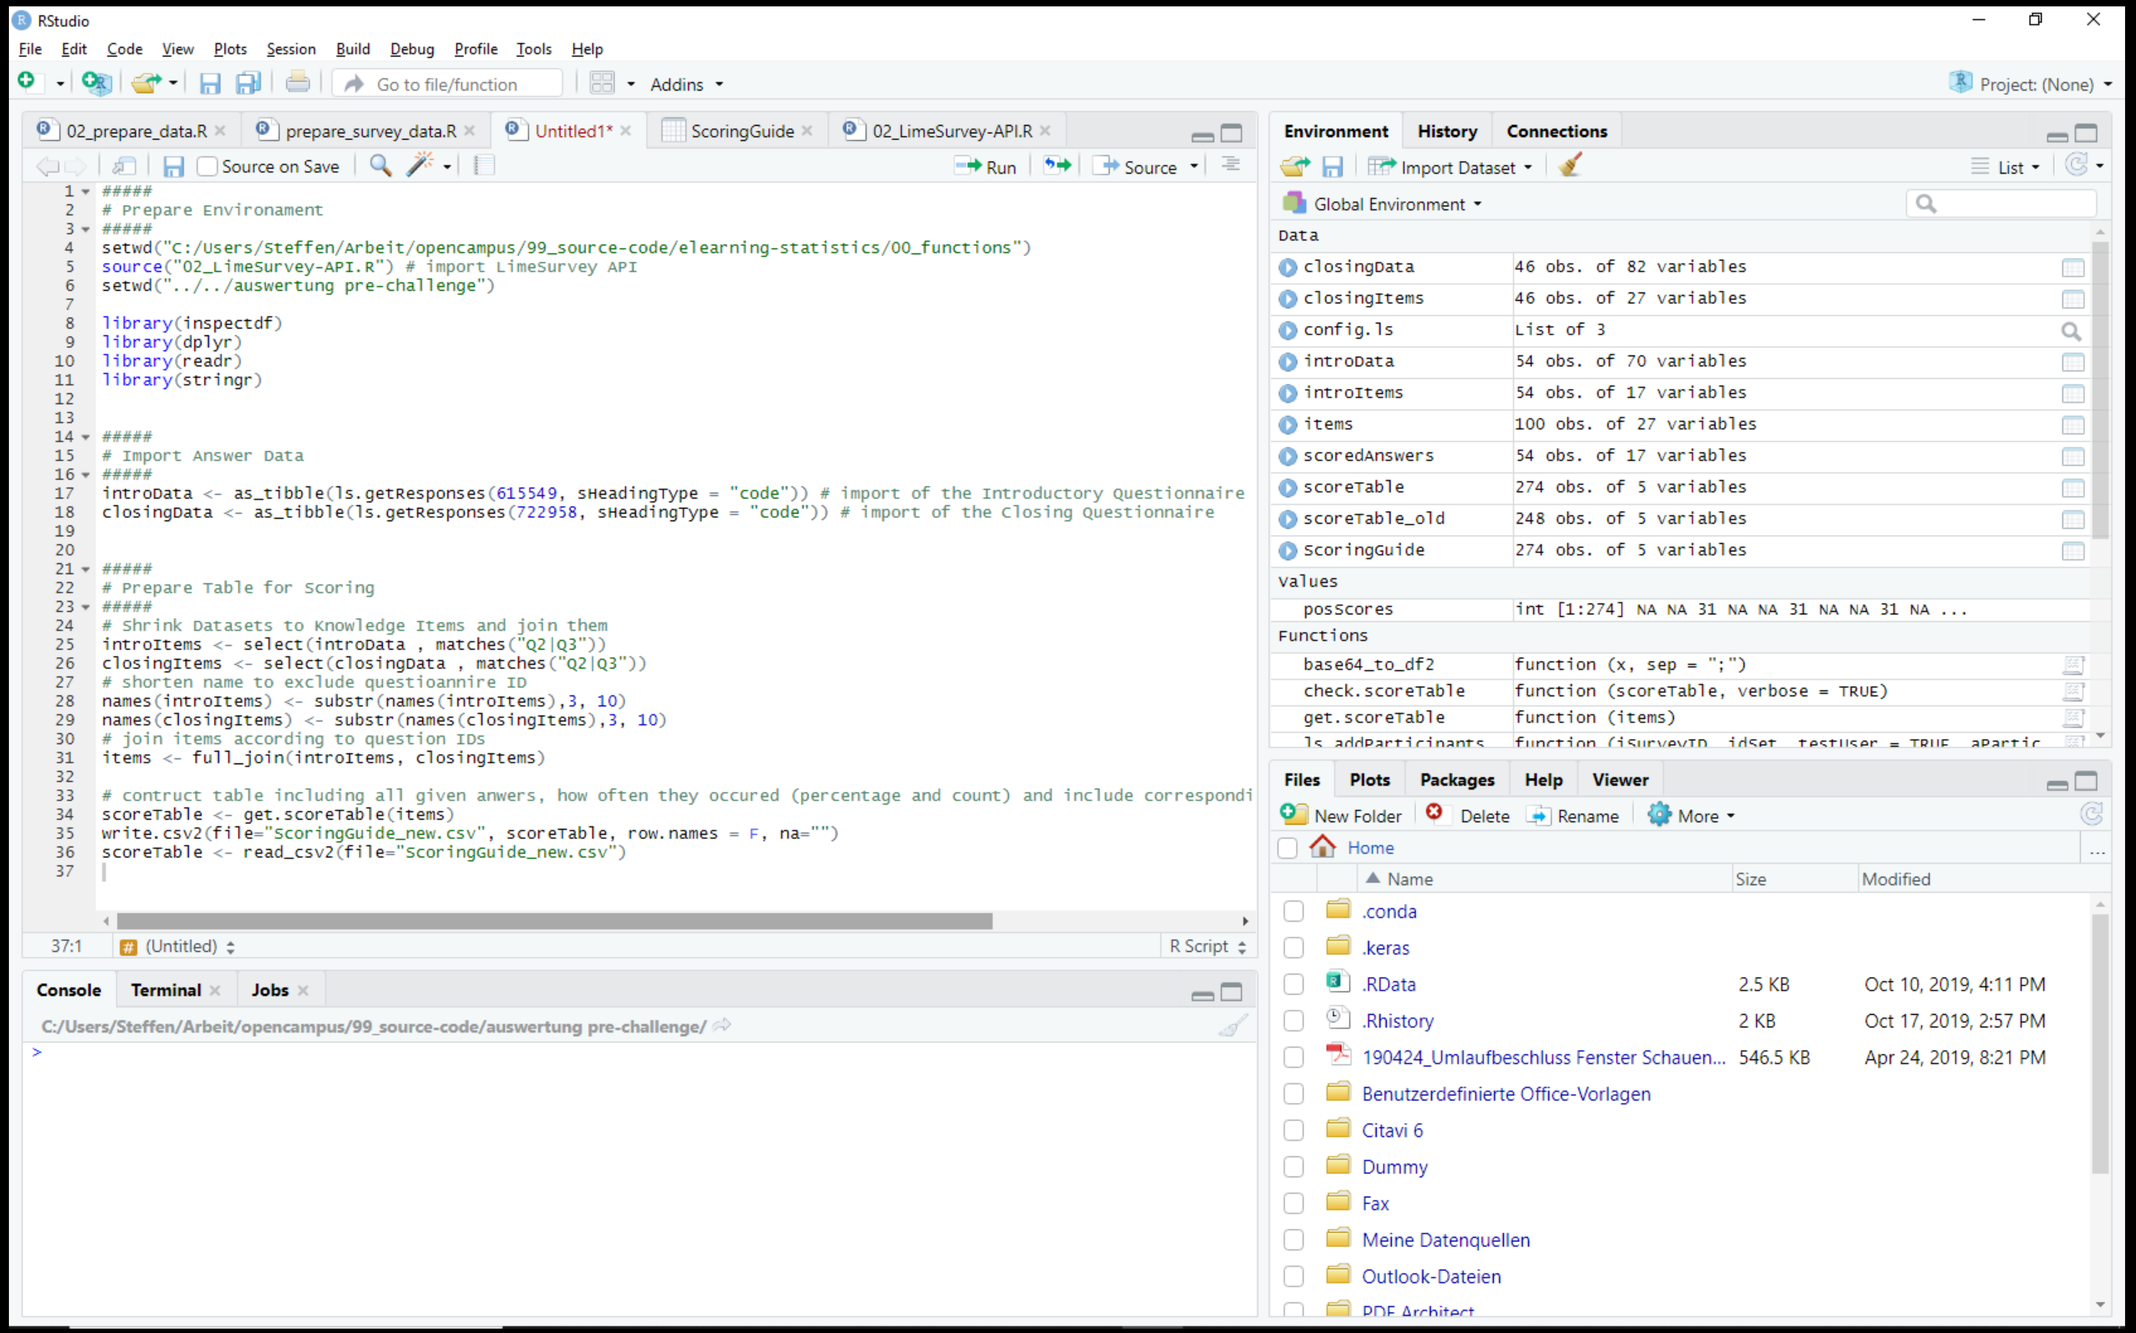

#####
# Import Answer Data
#####
introData <- as_tibble(ls.getResponses(615549, sHeadingType = "code")) # import of the Introductory Questionnaire
closingData <- as_tibble(ls.getResponses(722958, sHeadingType = "code")) # import of the Closing Questionnaire


#####
# Prepare Table for Scoring
#####
# Shrink Datasets to Knowledge Items and join them
introItems <- select(introData , matches("Q2|Q3"))
closingItems <- select(closingData , matches("Q2|Q3"))
# shorten name to exclude questioannire ID
names(introItems) <- substr(names(introItems),3, 10)
names(closingItems) <- substr(names(closingItems),3, 10)
# join items according to question IDs
items <- full_join(introItems, closingItems)

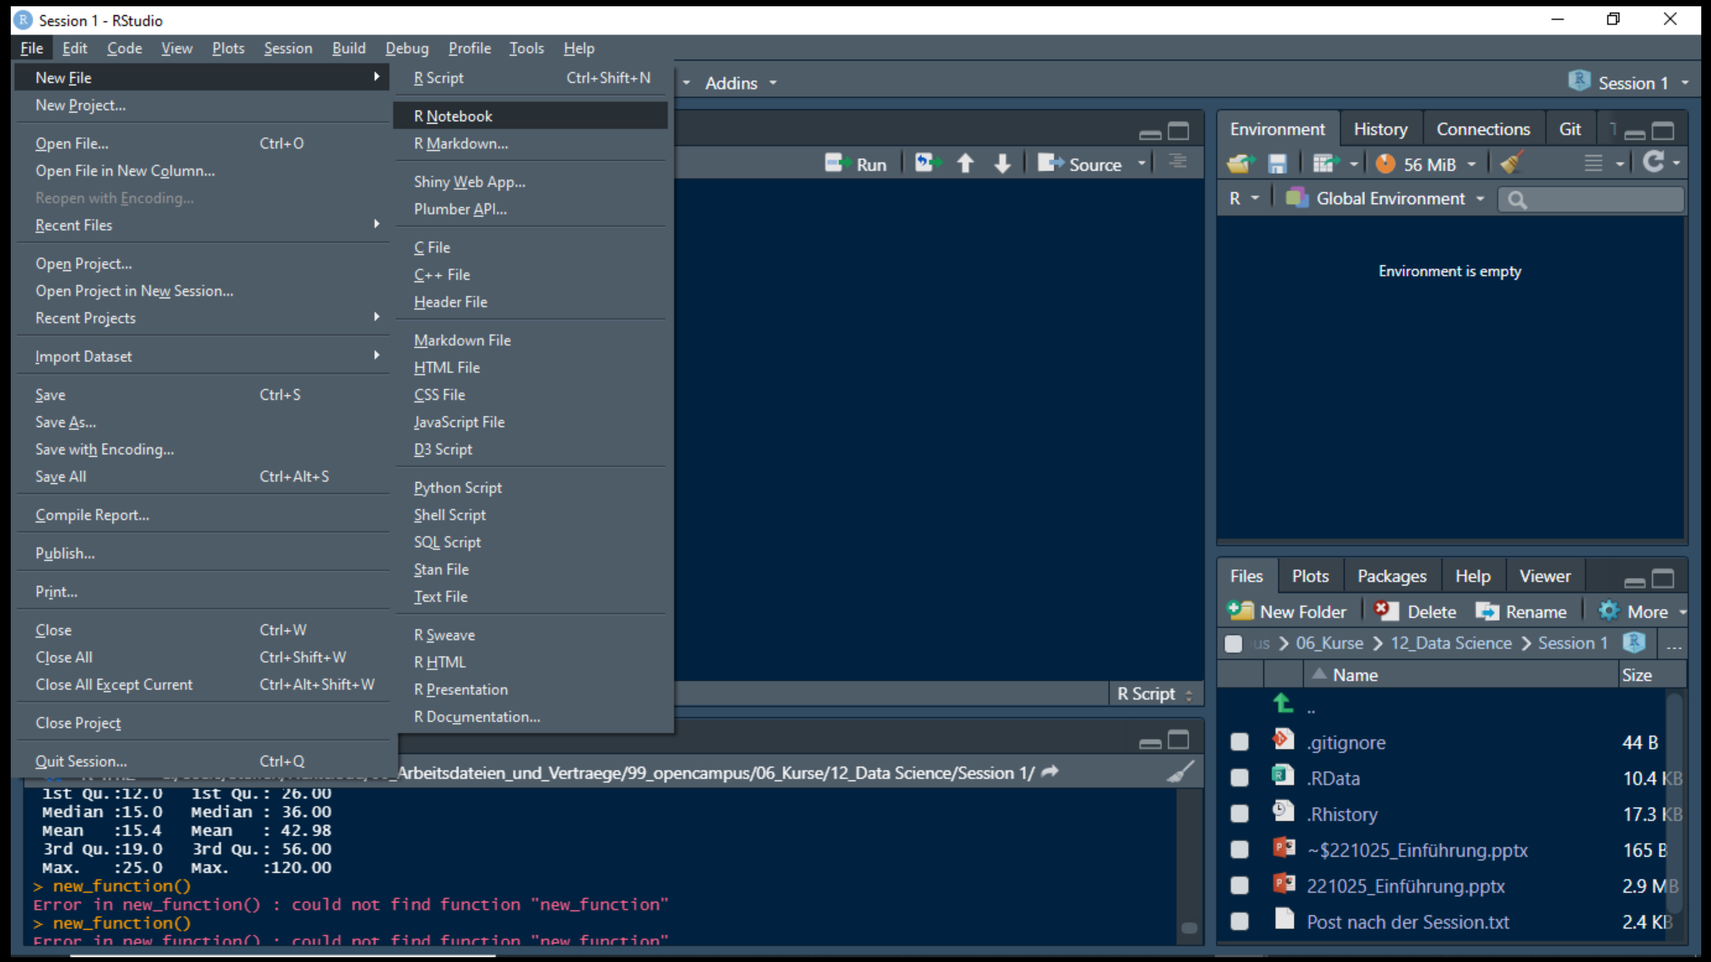
# contruct table including all given anwers, how often they occured (percentage and count) and include corresponding score categories if provided
scoreTable <- get.scoreTable(items)
write.csv2(file="ScoringGuide_new.csv", scoreTable, row.names = F, na="")
scoreTable <- read_csv2(file="ScoringGuide_new.csv")

```


RStudio
File Edit Code View Plots Session Build Debug Profile Tools Help
Go to file/function
Addins
Project: (None)
02_prepare_data.R
prepare_survey_data.R
Untitled1*
ScoringGuide
02_LimeSurvey-API.R
Source on Save
Run
Source
#####
Prepare Environament
#####
setwd("C:/Users/Steffen/Arbeit/opencampus/99_source-code/elearning-statistics/00_functions")
source("02_LimeSurvey-API.R") # import LimeSurvey API
setwd("../../auswertung pre-challenge")
library(inspectdf)
library(dplyr)
library(readr)
library(stringr)
#####
Import Answer Data
#####
introData <- as_tibble(ls.getResponses(615549, sHeadingType = "code")) # import of the Introductory Questionnaire
closingData <- as_tibble(ls.getResponses(722958, sHeadingType = "code")) # import of the Closing Questionnaire
#####
Prepare Table for Scoring
#####
Shrink Datasets to Knowledge Items and join them
introItems <- select(introData , matches("Q2|Q3"))
closingItems <- select(closingData , matches("Q2|Q3"))
shorten name to exclude questioannire ID
names(introItems) <- substr(names(introItems),3, 10)
names(closingItems) <- substr(names(closingItems),3, 10)
join items according to question IDs
items <- full_join(introItems, closingItems)
contruct table including all given anwers, how often they occured (percentage and count) and include correspondi
scoreTable <- get.scoreTable(items)
write.csv2(file="ScoringGuide_new.csv", scoreTable, row.names = F, na="")
scoreTable <- read_csv2(file="ScoringGuide_new.csv")
12:1
(Untitled)
R Script
Console
Terminal
Jobs
C:/Users/Steffen/Arbeit/opencampus/99_source-code/auswertung pre-challenge/
Environment
History
Connections
Import Dataset
List
Global Environment
Data
closingData 46 obs. of 82 variables
closingItems 46 obs. of 27 variables
config.ls List of 3
introData 54 obs. of 70 variables
introItems 54 obs. of 17 variables
items 100 obs. of 27 variables
scoredAnswers 54 obs. of 17 variables
scoreTable 274 obs. of 5 variables
scoreTable_old 248 obs. of 5 variables
ScoringGuide 274 obs. of 5 variables
Values
posScores int [1:274] NA NA 31 NA NA 31 NA NA 31 NA ...
Functions
base64_to_df2 function (x, sep = ";")
check.scoreTable function (scoreTable, verbose = TRUE)
get.scoreTable function (items)
Files
Plots
Packages
Help
Viewer
New Folder
Delete
Rename
More
Home
Name
Size
Modified
.conda
.keras
.RData 2.5 KB Oct 10, 2019, 4:11 PM
.Rhistory 2 KB Oct 17, 2019, 2:57 PM
190424_Umlaufbeschluss Fenster Schaue... 546.5 KB Apr 24, 2019, 8:21 PM
Benutzerdefinierte Office-Vorlagen
Citavi 6
Dummy
Fax
Meine Datenquellen
Outlook-Dateien


RStudio
File Edit Code View Plots Session Build Debug Profile Tools Help
Go to file/function
Addins
Project: (None)
02_prepare_data.R
prepare_survey_data.R
Untitled1*
ScoringGuide
02_LimeSurvey-API.R
Source on Save
Run
Source
#####
Prepare Environament
#####
setwd("C:/Users/Steffen/Arbeit/opencampus/99_source-code/elearning-statistics/00_functions")
source("02_LimeSurvey-API.R") # import LimeSurvey API
setwd("../../auswertung pre-challenge")
library(inspectdf)
library(dplyr)
library(readr)
library(stringr)
#####
Import Answer Data
#####
introData <- as_tibble(ls.getResponses(615549, sHeadingType = "code")) # import of the Introductory Questionnaire
closingData <- as_tibble(ls.getResponses(722958, sHeadingType = "code")) # import of the Closing Questionnaire
#####
Prepare Table for Scoring
#####
Shrink Datasets to Knowledge Items and join them
introItems <- select(introData , matches("Q2|Q3"))
closingItems <- select(closingData , matches("Q2|Q3"))
shorten name to exclude questioannire ID
names(introItems) <- substr(names(introItems),3, 10)
names(closingItems) <- substr(names(closingItems),3, 10)
join items according to question IDs
items <- full_join(introItems, closingItems)
contruct table including all given anwers, how often they occured (percentage and count) and include correspondi
scoreTable <- get.scoreTable(items)
write.csv2(file="ScoringGuide_new.csv", scoreTable, row.names = F, na="")
scoreTable <- read_csv2(file="ScoringGuide_new.csv")
37:1
(Untitled)
R Script
Console
Terminal
Jobs
C:/Users/Steffen/Arbeit/opencampus/99_source-code/auswertung pre-challenge/
Environment
History
Connections
Import Dataset
List
Global Environment
Data
closingData 46 obs. of 82 variables
closingItems 46 obs. of 27 variables
config.ls List of 3
introData 54 obs. of 70 variables
introItems 54 obs. of 17 variables
items 100 obs. of 27 variables
scoredAnswers 54 obs. of 17 variables
scoreTable 274 obs. of 5 variables
scoreTable_old 248 obs. of 5 variables
ScoringGuide 274 obs. of 5 variables
values
posScores int [1:274] NA NA 31 NA NA 31 NA NA 31 NA ...
Functions
base64_to_df2 function (x, sep = ";")
check.scoreTable function (scoreTable, verbose = TRUE)
get.scoreTable function (items)
Files
Plots
Packages
Help
Viewer
New Folder
Delete
Rename
More
Home
Name
Size
Modified
.conda
.keras
.RData 2.5 KB Oct 10, 2019, 4:11 PM
.Rhistory 2 KB Oct 17, 2019, 2:57 PM
190424_Umlaufbeschluss Fenster Schauen... 546.5 KB Apr 24, 2019, 8:21 PM
Benutzerdefinierte Office-Vorlagen
Citavi 6
Dummy
Fax
Meine Datenquellen
Outlook-Dateien

R NOTEBOOK


Session 1 - RStudio
File Edit Code View Plots Session Build Debug Profile Tools Help
New File
New Project...
Open File... Ctrl+O
Open File in New Column...
Reopen with Encoding...
Recent Files
Open Project...
Open Project in New Session...
Recent Projects
Import Dataset
Save Ctrl+S
Save As...
Save with Encoding...
Save All Ctrl+Alt+S
Compile Report...
Publish...
Print...
Close Ctrl+W
Close All Ctrl+Shift+W
Close All Except Current Ctrl+Alt+Shift+W
Close Project
Quit Session... Ctrl+Q
R Script Ctrl+Shift+N
R Notebook
R Markdown...
Shiny Web App...
Plumber API...
C File
C++ File
Header File
Markdown File
HTML File
CSS File
JavaScript File
D3 Script
Python Script
Shell Script
SQL Script
Stan File
Text File
R Sweave
R HTML
R Presentation
R Documentation...
Addins
Session 1
Run
Source
R Script
Environment History Connections Git
56 MiB
R
Global Environment
Environment is empty
Files Plots Packages Help Viewer
New Folder
Delete
Rename
More
06_Kurse
12_Data Science
Session 1
Name
Size
.gitignore 44 B
.RData 10.4 KB
.Rhistory 17.3 KB
~$221025_Einführung.pptx 165 B
221025_Einführung.pptx 2.9 MB
Post nach der Session.txt 2.4 KB
Arbeitsdateien_und_Vertraege/99_opencampus/06_Kurse/12_Data Science/Session 1/
1st Qu.:12.0 1st Qu.: 26.00
Median :15.0 Median : 36.00
Mean :15.4 Mean : 42.98
3rd Qu.:19.0 3rd Qu.: 56.00
Max. :25.0 Max. :120.00
> new_function()
Error in new_function() : could not find function "new_function"
> new_function()

HILFEN

- **ChatGPT!**
- Google
- Stackoverflow
- Cheatsheets
- Dokumentation der Funktionen in R

BREAKOUT

Berechnet mit Hilfe von R den Mittelwert der folgenden sieben Zahlen:

1
2
3
4
5
6
9,87654321

WAS IST EIN R-PROGRAMM?

Eine Sequenz von Definitionen

- `x <- 1`
- `y <- c(2, 15, 39, 24)`

oder Ausdrücken

- `x + y`
- `3^2/2`
- `x == 1`
- `mean(y)`

Alle Namen für Variablen, Funktionen usw. sind case sensitive!

FUNKTIONEN UND PAKETE

- **sind die Motoren jedes R-Programms**
- **Grundlegende Funktionen sind im „base“ Package enthalten, das standardmäßig mit R kommt**
- **Zusätzliche Funktionen kann man nach Installation der Pakete, in denen sie enthalten sind, verwenden.**
- **Funktionen werden über „Argumente“ für den eigenen Anwendungsfall angepasst, zum Beispiel:**

```
mean(x=c(1,3,4,NA), na.rm=TRUE)
```

DATENSTRUKTUREN

Es gibt drei Grundtypen für ein Datum

- **Boolean** (`TRUE / FALSE / NA`)
- **Numeric** (`1.1392 / NA`)
- **String** (`"Text" / NA`)

und zusätzlich abgeleitete, speziellere Typen (integer, date, …)

- **Integer** **(Untertyp von Numeric;** `12`**)**
- **Date** **(Untertyp von Numeric;** `"2019-04-11"`**)**
- **Factor** **(Untertyp von String;** `"red"|"orange"|"green"`**)**

VEKTOREN

Alle Elemente eines Vektors haben den gleichen Typ
→ Jeder Vektor hat einen eindeutigen Typ

```
v1 <- c(FALSE, TRUE, NA, TRUE)

ort <- c("kiel", "hamburg", NA, "berlin")

v2 <- c(NA, 112, 343, 235)

alter <- 12
```

MATRIZEN

Bestehen aus Vektoren gleicher Länge und gleichen Typs
→ Jede Matrix hat einen eindeutigen Typ.

```
m <- matrix(c(1,2,3,4), 2, 2)
```

entspricht: $\begin{pmatrix} 1 & 3 \\ 2 & 4 \end{pmatrix}$

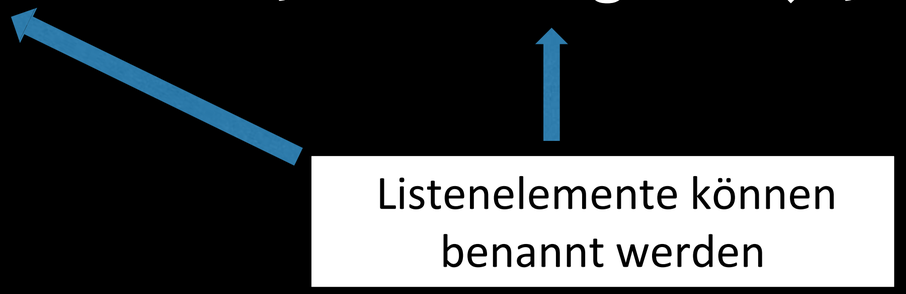
LISTEN

Können beliebige Elemente enthalten:

- **Vektoren und Matrizen unterschiedlichen Typs**
- **sonstige R-Objekte (etwa auch Funktionen)**

→ Listen haben keinen eindeutigen Typ

```
l1 <- list(v1, alter, c(4,7,9))
l2 <- list(name="Fred", child.ages=c(4,7,9), l1)
```



SPEZIELLE LISTEN

DATENTABELLEN

bestehen aus Vektoren gleicher Länge
(aber potentiell unterschiedlichen Typs)

→ Datentabellen haben keinen eindeutigen Typ

- **Data Frame (base Package)**
- **Tibble (tidyverse Package)**
- **Data Table (data.table Package)**

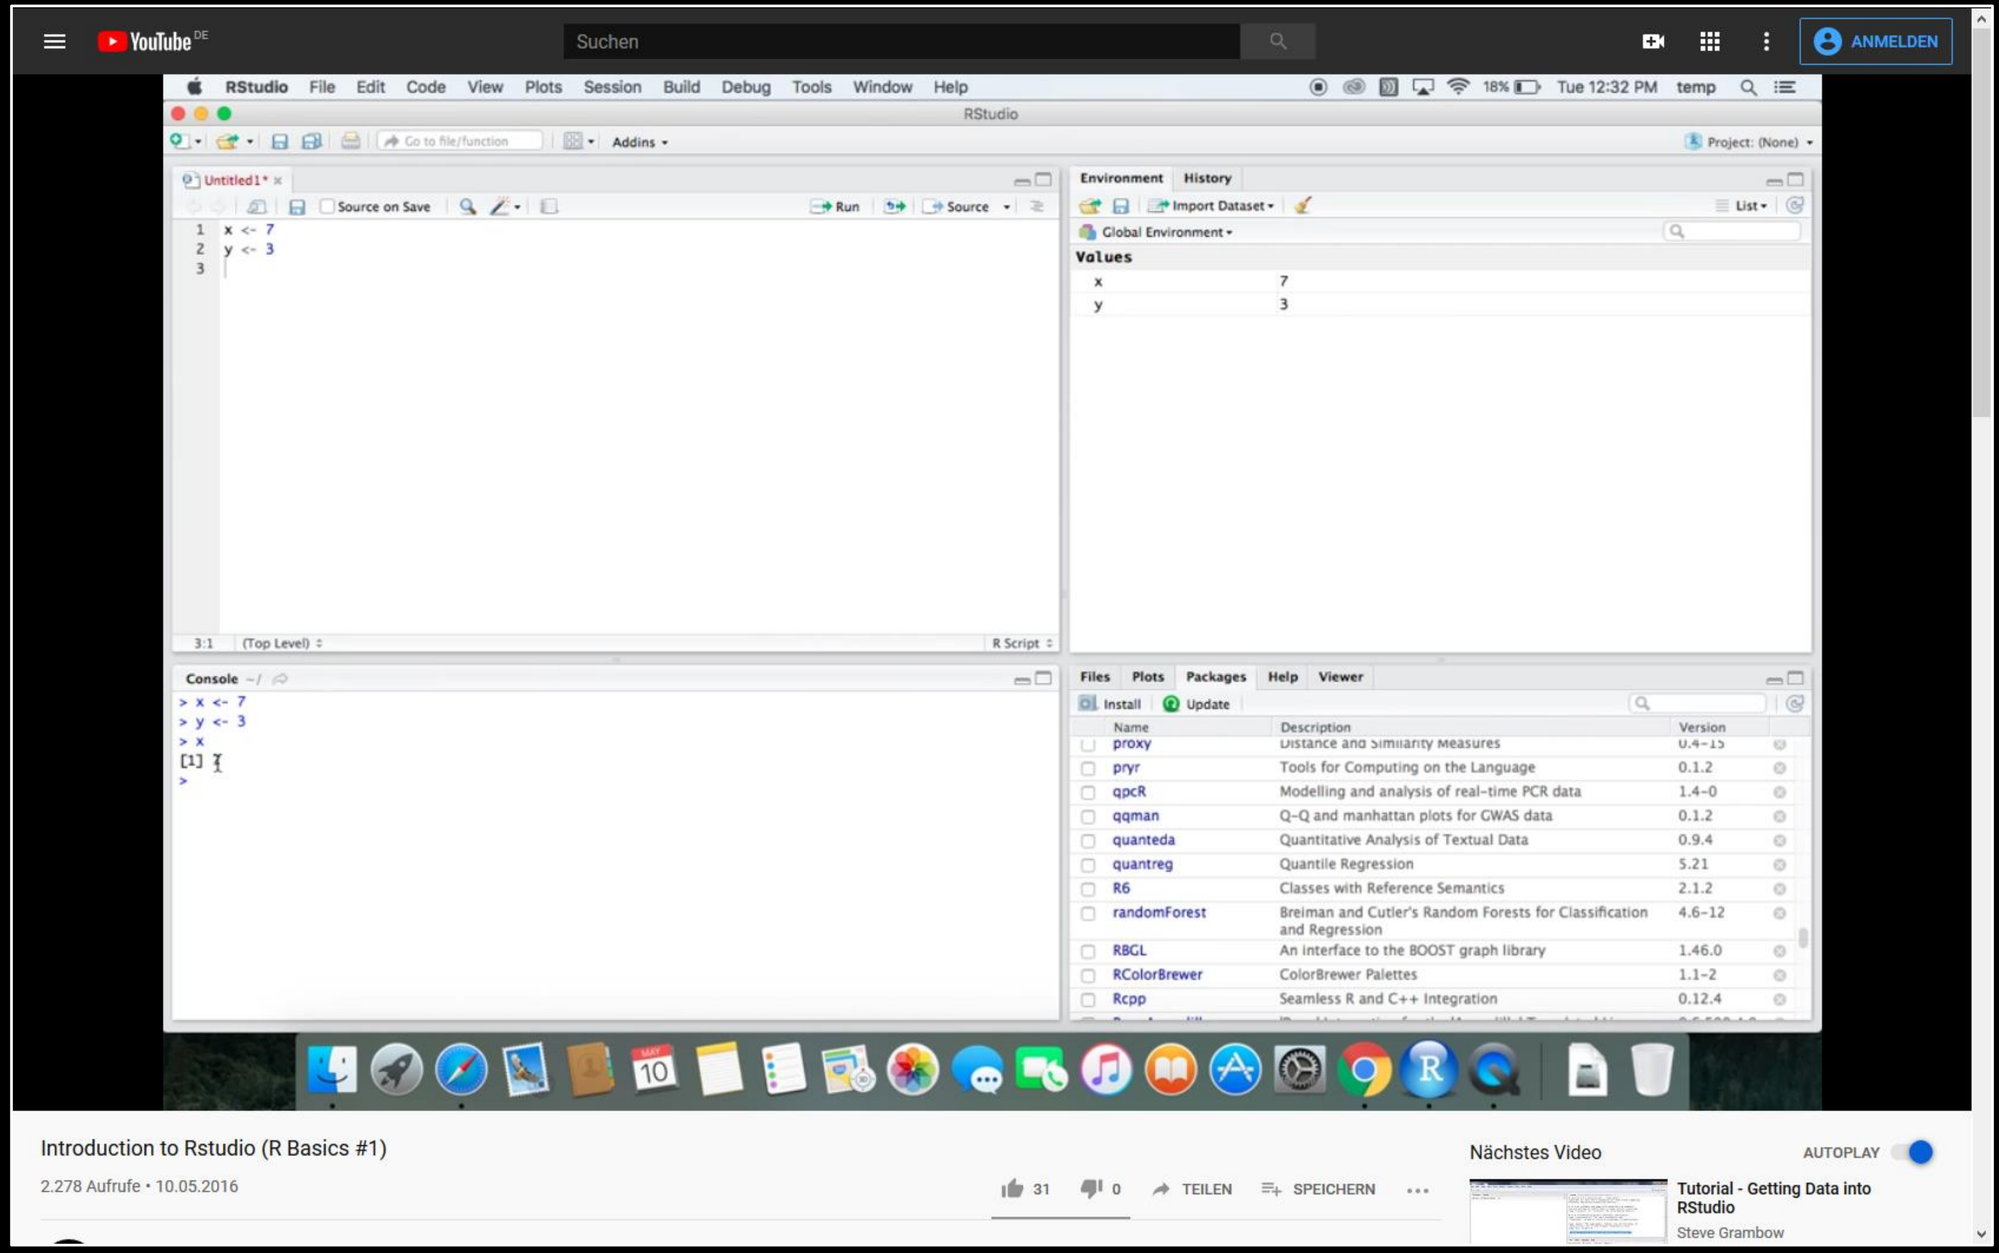
AUFGABEN

- Importiere den Datensatz “umsatzdaten_gekuerzt.csv”, den Du über folgenden Link herunterladen kannst:
  https://raw.githubusercontent.com/opencampus-sh/einfuehrung-in-data-science-und-ml/main/wetter.csv

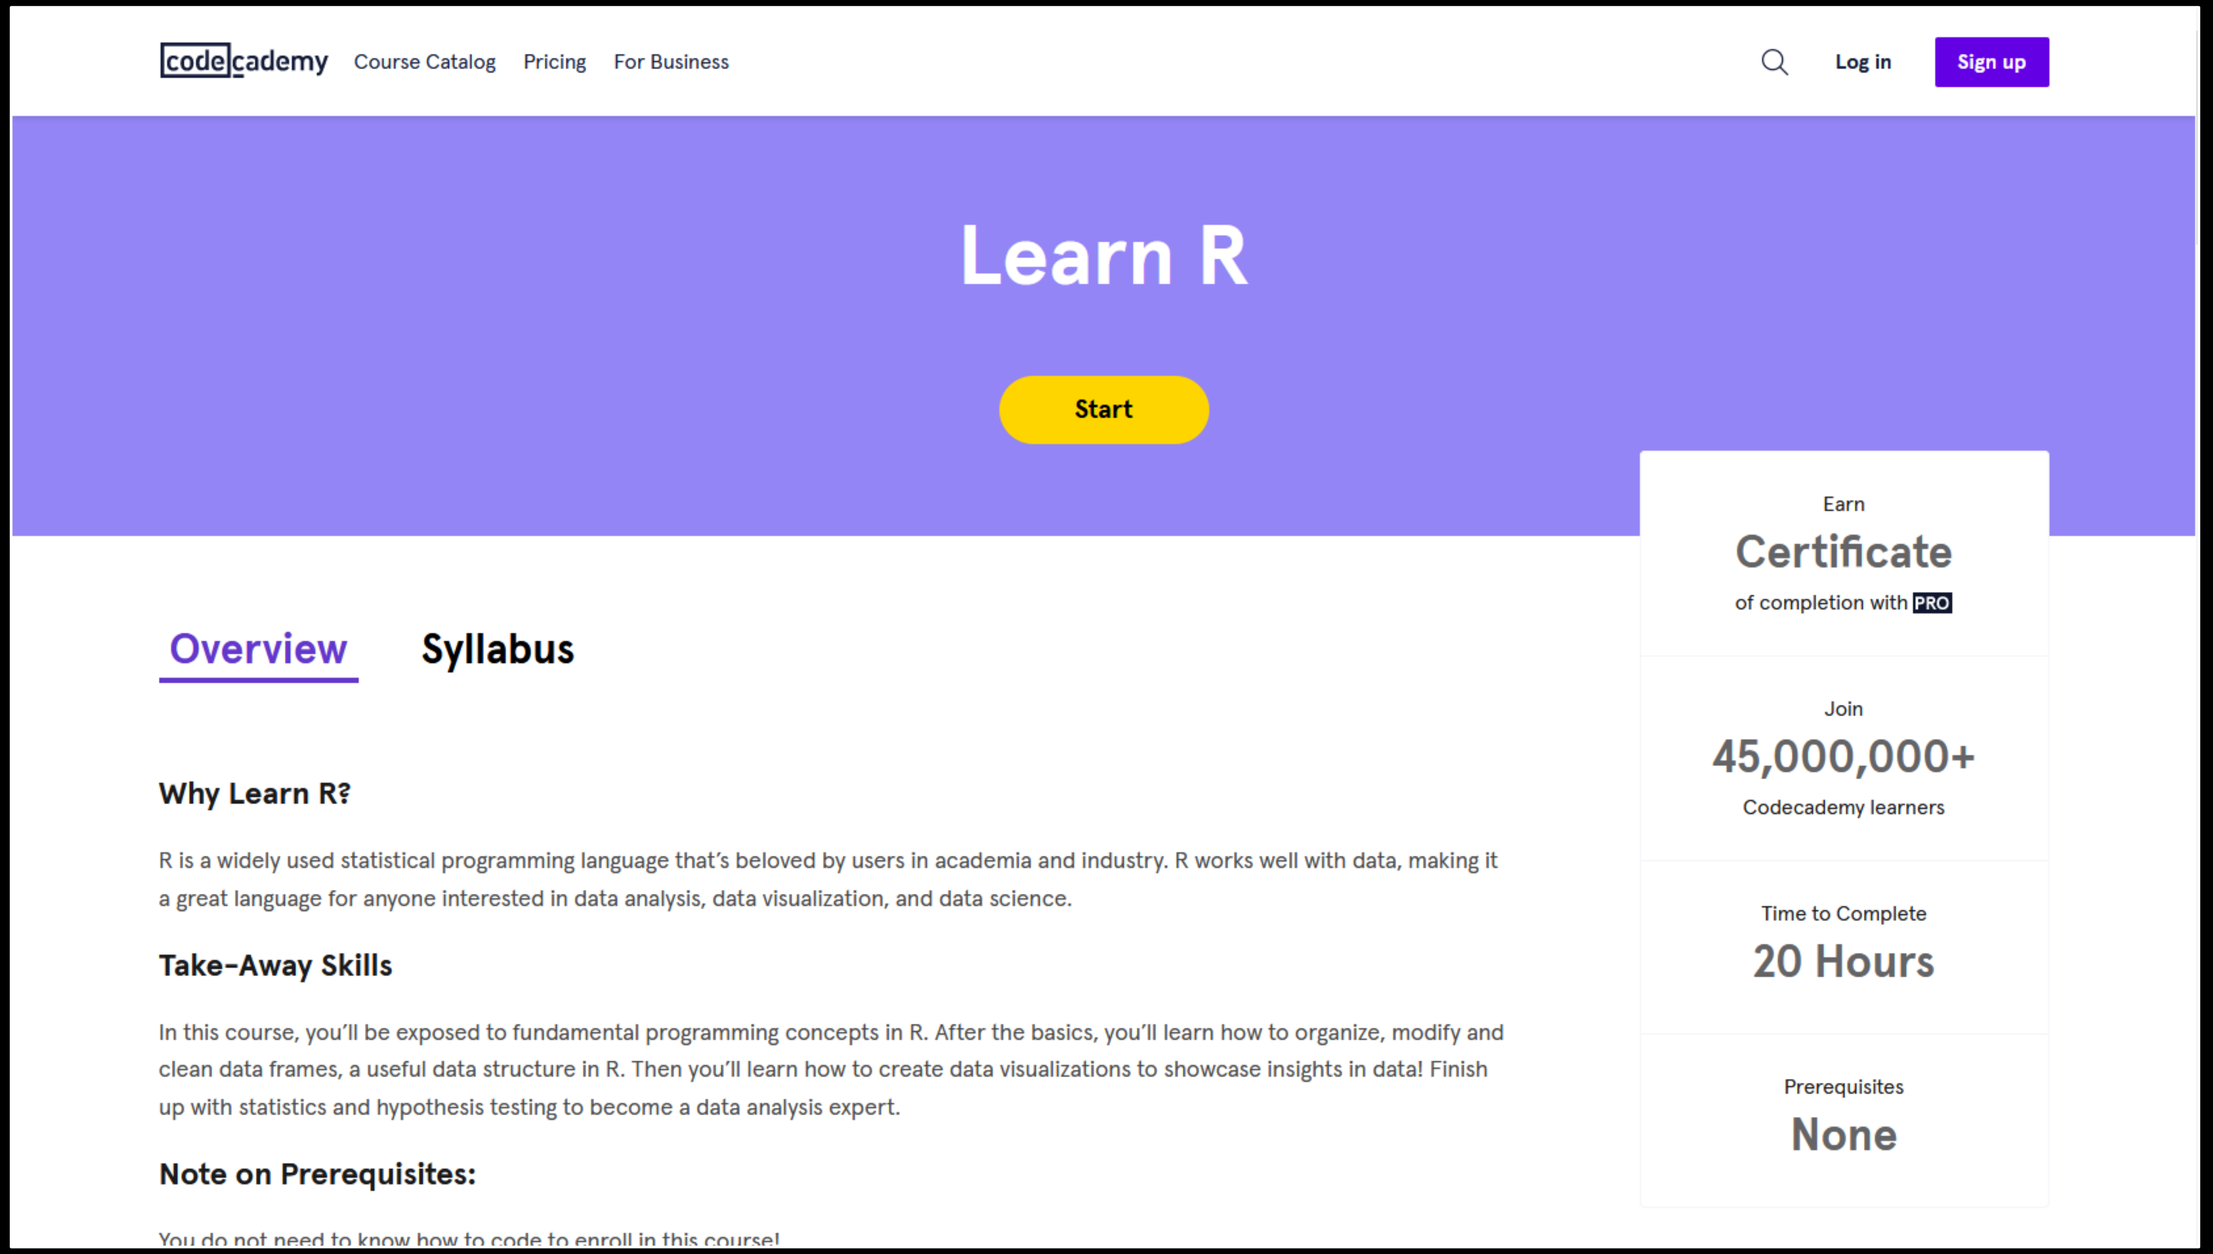
- Berechne die Gesamtdurchschnittstemperatur.

- Berechne die Durchschnittstemperatur für den Monat Juli.

- Vergleiche, ob die Monate Juli und Mai sich in ihrer Durchschnittstemperatur signifikant unterscheiden.



https://www.youtube.com/watch?v=QvBo1RBptvY



https://www.codecademy.com/learn/learn-r

datacamp

Search Catalog

My Account

- My Progress
- My Bookmarks
- For Business
- Career Tracks
- Skill Tracks
- Courses
- Practice
- Projects
- Assessments
- Live Events

Upgrade

INTERACTIVE COURSE

Introduction to R

Continue Course | Bookmark

4 hours | 0 Videos | 62 Exercises | 1,744,033 Participants | 6,200 XP

Course Description

In Introduction to R, you will master the basics of this widely used open source language, including factors, lists, and data frames. With the knowledge gained in this course, you will be ready to undertake your first very own data analysis. Oracle estimated over 2 million R users worldwide in 2012, cementing R as a leading programming language in statistics and data science. Every year, the number of R users grows by about 40%, and an increasing number of organizations are using it in their day-to-day activities. Begin your journey to learn R with us today!

This course is part of these tracks:

- Data Analyst with R
- Data Scientist with R
- R Programming

1 Intro to basics

13%

Take your first steps with R. In this chapter, you will learn how to use the console as a calculator and how to assign variables. You will also get to know the basic data types in R. Let's get started.

VIEW CHAPTER DETAILS

Continue Chapter



Jonathan Cornelissen

Co-founder of DataCamp

Jonathan Cornelissen is one of the co-founders of DataCamp and the initial

https://www.datacamp.com/courses/free-introduction-to-r