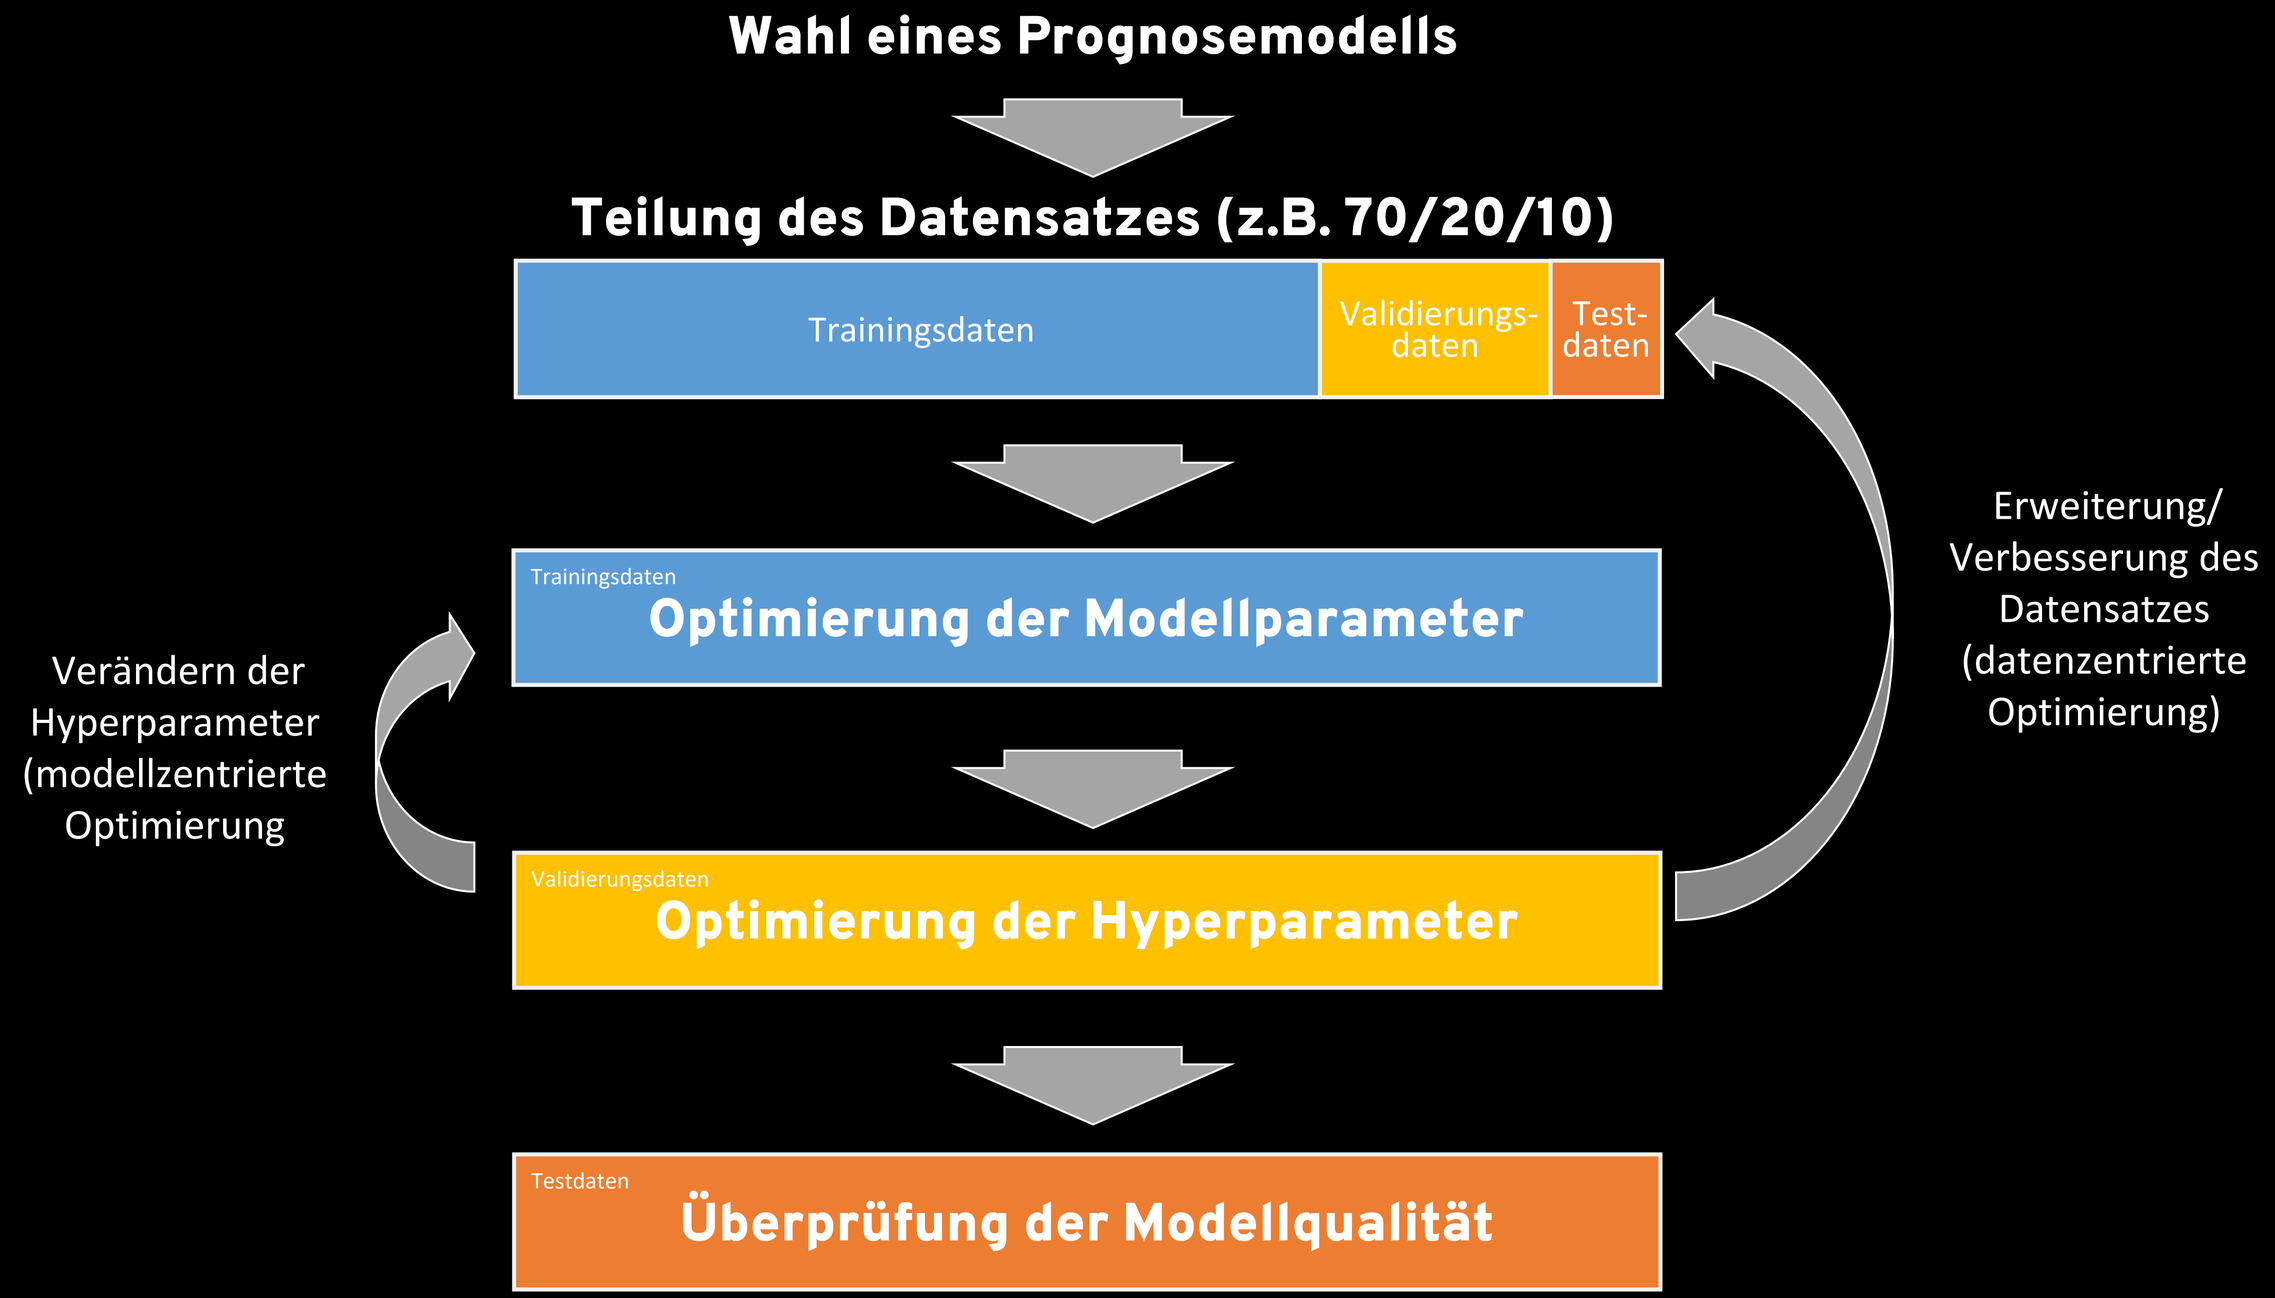
28.11.23

OPENCAMPUS.sh

Einführung in Data Science und maschinelles Lernen

EINFÜHRUNG IN MASCHINELLES LERNEN

- Vorgehen zum Trainieren von maschinellen Lernalgorithmen
- Definition der linearen Regression
- Kostenfunktionen
- Optimierungsfunktionen


Wahl eines Prognosemodells
Teilung des Datensatzes (z.B. 70/20/10)
Trainingsdaten
Validierungs-daten
Test-daten
Trainingsdaten
Optimierung der Modellparameter
Validierungsdaten
Optimierung der Hyperparameter
Testdaten
Überprüfung der Modellqualität
Verändern der Hyperparameter (modellzentrierte Optimierung
Erweiterung/ Verbesserung des Datensatzes (datenzentrierte Optimierung)

TEILUNG EINES DATENSATZES (OHNE ZEITREIHEN!)

(1) Mischung der Reihenfolge (Randomisierung)

(2) Definition der Größen von Trainings-, Validierungs- und Testdatensatz in Prozent

(3) Teilung des Datensatzes

TEILUNG EINES DATENSATZES MIT ZEITREIHEN

(1) Ordnen der Zeitreihe

(2) Definition der Zeitreihenfenster für Validierungs- und Testdatensatz

(3) Teilung des Datensatzes

PROGNOSEMODELLE

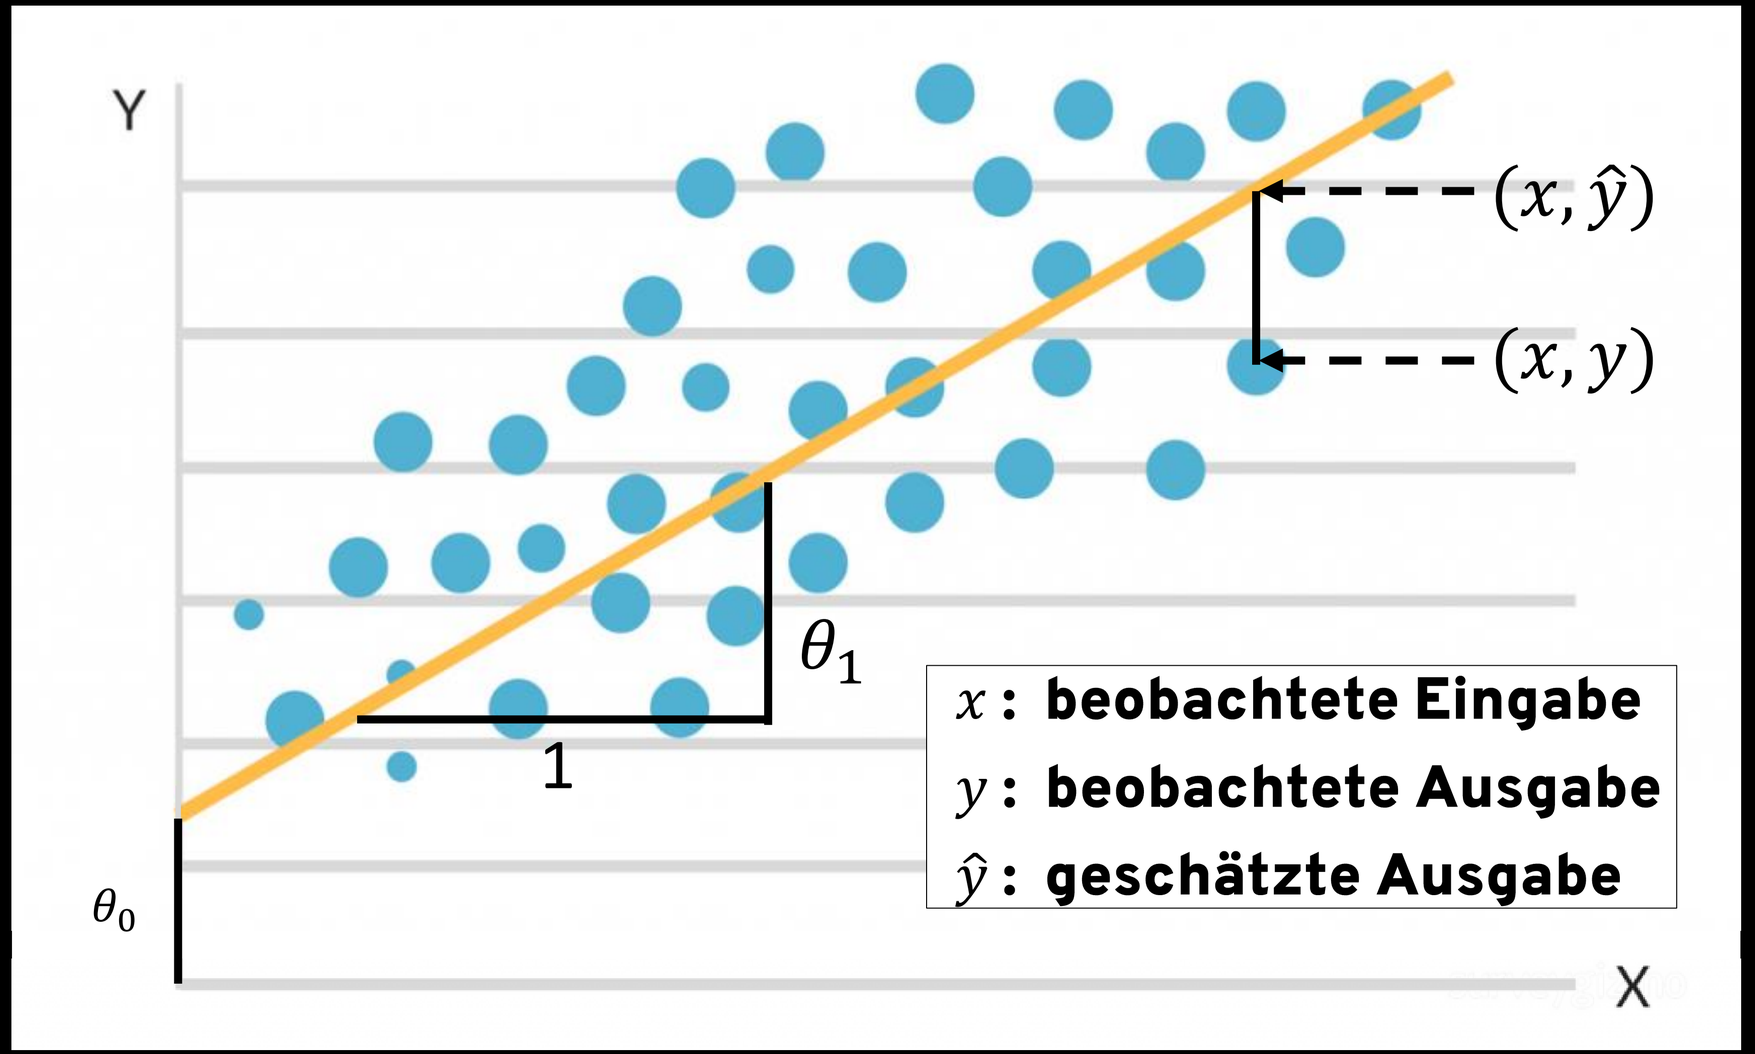
In diesem Kurs behandelte:

- **Lineares Modell**
- **Neuronales Netz**
- **(Support Vektor Maschine)**

LINEARES MODELL

$$\hat{y} = \theta_0 + \theta_1 x$$

$$= h_x\,(\theta_0, \theta_1)$$



KOSTENFUNKTION (LOSS FUNCTION)

Zur Berechnung der Funktion mit den optimalen Parametern θ_0 und θ_1:

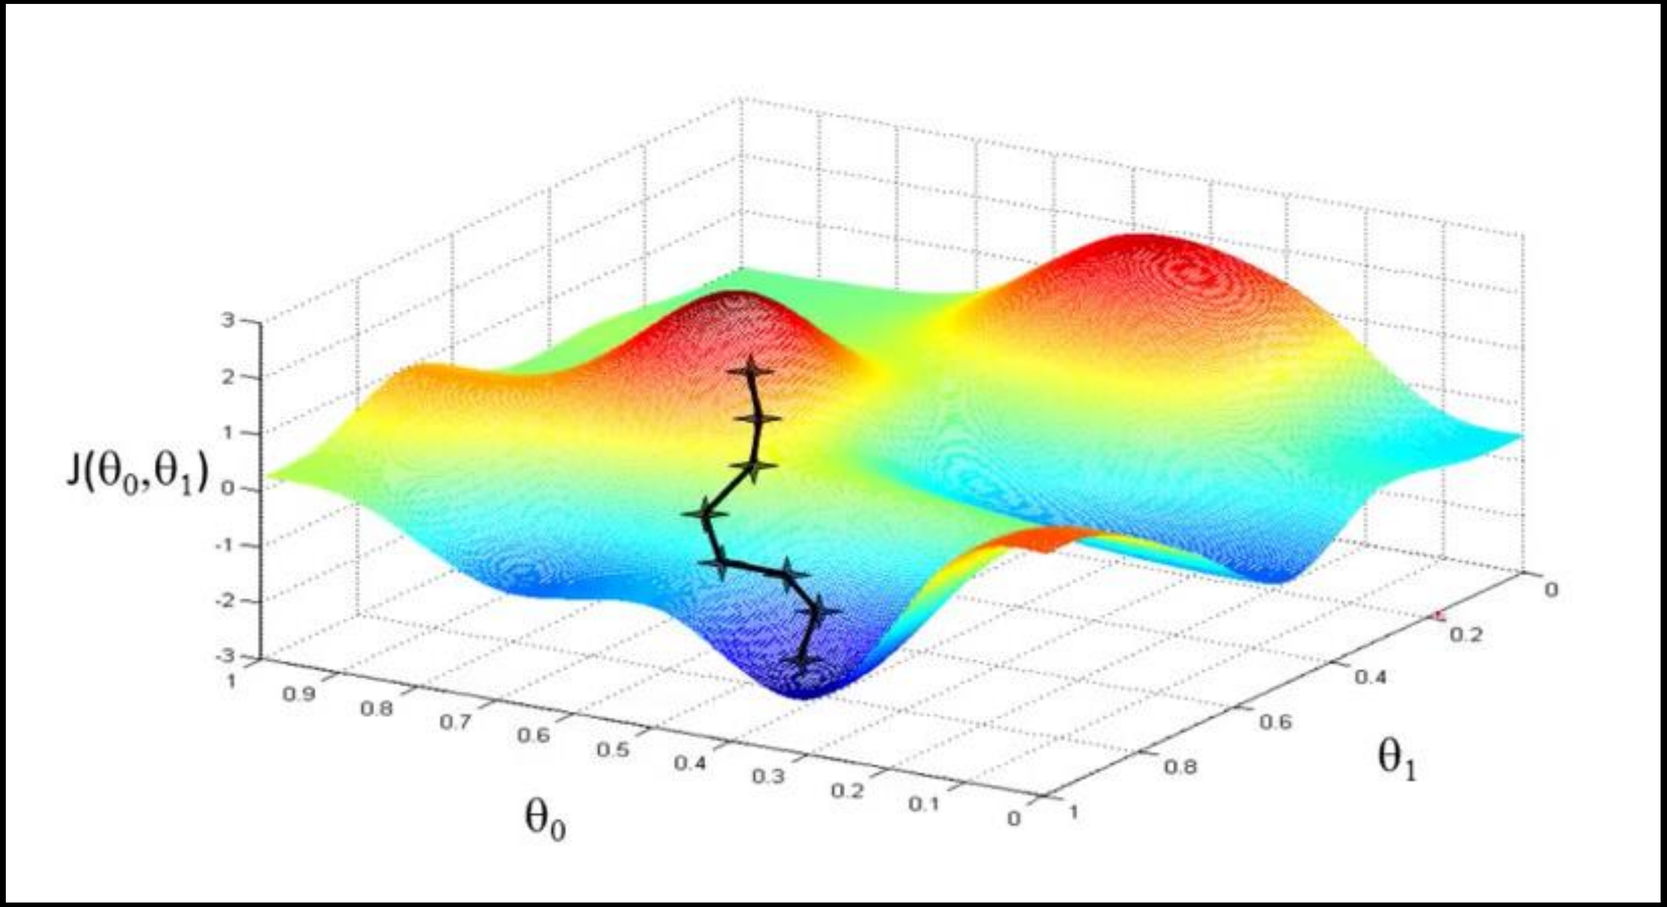
$$J_x(\theta_0, \theta_1) = \qquad h_x(\theta_0, \theta_1) - y$$

Mean Absolute Error (MAE)

$$J_x(\theta_0, \theta_1) = \frac{1}{m} \sum (h_x(\theta_0, \theta_1) - y)^2$$

Mean Squared Error (MSE)

OPTIMIERUNGSFUNKTION (OPTIMIZER)



- **Iteratives Verfahren (Gradient Descent), um das Minimum der Kostenfunktion zu finden.**
- **Die Lernrate („Learning Parameter“) beschreibt die Schrittgröße zur Annäherung an das Minimum.**

Quelle: https://www.coursera.org/learn/machine-learning

OPTIMIERUNG DER MODELLPARAMETER

Forward Propagation

- **Berechnung des vorhergesagten Wertes auf Basis der aktuellen Modellgleichung**
- **Berechnung der Kosten bzw. des Loss**

Backward Propagation

- **Berechnung des Gradienten (d.h. aller partiellen Ableitungen), um die Richtung des Minimums zu bestimmen.**
- **Anpassung der Modellparameter im Ausmaß der definierten Lernrate:**

```
Neuer Wert = Alter Wert - Lernrate × Partieller Gradient
```

MODELLPARAMETER VS. HYPERPARAMETER

Modellparameter

- Teile des Modells, die sich während des Trainingsprozesses automatisch anpassen, wie Gewichte und Biases

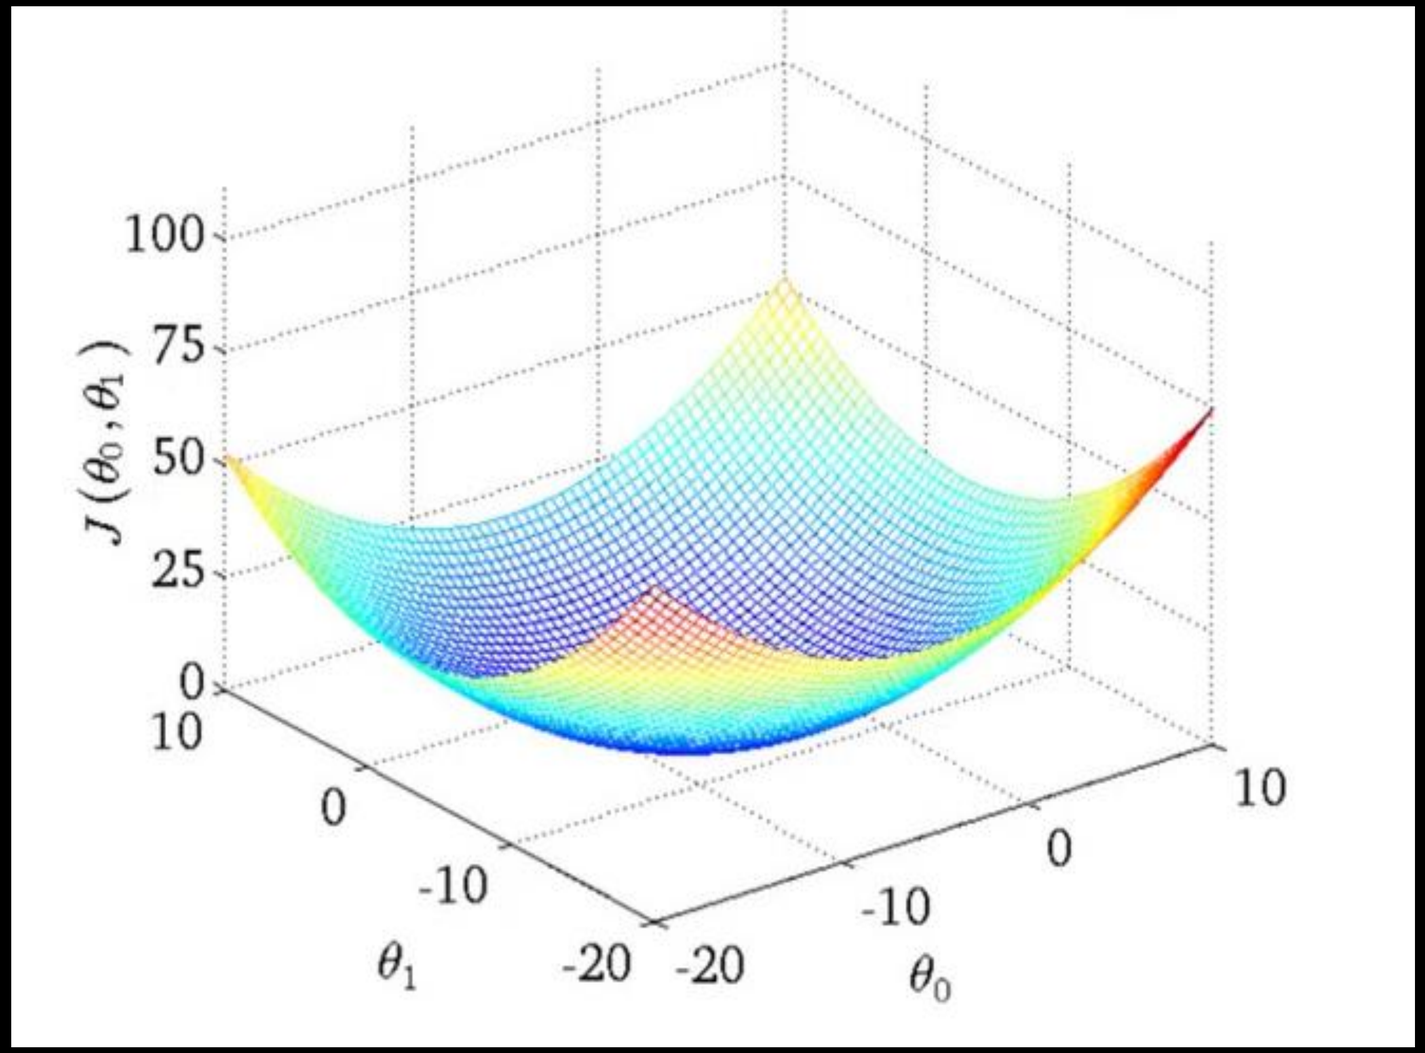
Hyperparameter

- Einstellungen, die du vor dem Training festlegst, wie etwa die Lernrate oder die Anzahl der Modell-Parameter.

FEATURES AND LABELS

Machine Learning	Statistik	Beschreibung
Feature	Unabhängige Variable	Werte, die zur Vorhersage genutzt werden
Label	Abhängige Variable	Vorherzusagende Werte

MINIMIERUNG BEI LINEAREN MODELLEN



Quelle: https://www.coursera.org/learn/machine-learning

- **Für lineare Modelle ist die Kostenfunktion konvex und besitzt keine lokalen Minima.**
- **Hier werden häufig auch andere statistische Verfahren als Gradient Descent genutzt.**

  (Insbesondere wenn das Modell nur wenige Variablen umfasst.)

BEISPIEL EINES LINEAREN MODELLS

```
library(readr)
house_pricing <- read_csv("https://raw.githubusercontent.com/
                          opencampus-sh/einfuehrung-in-data-
                          science-und-ml/main/house_pricing_data/
                          house_pricing_train.csv")


mod <- lm(price ~ sqft_lot15 + as.factor(condition), house_pricing)
summary(mod)
```

ERGEBNIS DES LINEAREN MODELLS

```
Call:
lm(formula = price ~ sqft_lot15 + as.factor(condition), data = house_pricing)

Residuals:
    Min      1Q  Median      3Q     Max
-795388 -214555  -85989  101761 7183941

Coefficients:
                          Estimate Std. Error t value Pr(>|t|)
(Intercept)              3.261e+05  7.049e+04   4.625 3.77e-06 ***
sqft_lot15               1.138e+00  1.035e-01  11.002  < 2e-16 ***
as.factor(condition)2   -2.305e+04  7.690e+04  -0.300 0.764379
as.factor(condition)3    2.031e+05  7.057e+04   2.878 0.004008 **
as.factor(condition)4    1.800e+05  7.070e+04   2.546 0.010915 *
as.factor(condition)5    2.762e+05  7.118e+04   3.880 0.000105 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 366300 on 17284 degrees of freedom
Multiple R-squared:  0.01409,   Adjusted R-squared:  0.0138
F-statistic: 49.39 on 5 and 17284 DF,  p-value: < 2.2e-16
```

KENNWERTE DER REGRESSION

p-Wert

- **Signifikanzwert**
- **Wahrscheinlichkeit, dass der zugehörige Wert in der Regression gleich null ist.**
- **Werte unter 0,05 (entspricht 5%) werden üblicherweise als signifikant betrachtet**

(Adjustiertes) R^2

- **Kennzahl zur Beurteilung der Güte einer Regression**
- **Wert zwischen 0 und 1, der der dem Anteil der erklärten Variation entspricht (1 entspricht 100%):**

$$R^2 = \frac{\text{Erklärte Varianz}}{\text{Gesamtvarianz}}$$

- **Das adjustierte R^2 bestraft das Hinzufügen zusätzlicher Variablen/Parameter**

DataCamp Tutorial zur Linearen Modellierung in R :
https://www.datacamp.com/community/tutorials/linear-regression-R

BEISPIEL DATENSATZTEILUNG (KEINE ZEITREIHE)

Teilen des Datensatzen in Trainings- Validierungs- und Testdatensatz

```{r}
# Load the dplyr library
library(dplyr)

# Set a random seed for reproducibility
set.seed(42)
# Shuffle the data
data_shuffled <- data %>% sample_frac(1)

# Calculate the number of rows for each dataset
n_total <- nrow(data)
n_train <- floor(0.7 * n_total)
n_validation <- floor(0.20 * n_total)

# Split the data into training, validation, and test datasets
train_data <- data_shuffled %>% slice(1:n_train)
validation_data <- data_shuffled %>% slice((n_train + 1):(n_train + n_validation))
test_data <- data_shuffled %>% slice((n_train + n_validation + 1):n_total)

# Check the dimensions of the datasets
cat("Training dataset dimensions:", dim(train_data), "\n")
cat("Validation dataset dimensions:", dim(validation_data), "\n")
cat("Test dataset dimensions:", dim(test_data), "\n")

```

BEISPIEL LINEARE MODELLIERUNG UND VORHERSAGE

````
### Beispiel einer einfachen linearen Regression
```{r}
  mod <- lm(price ~ sqft_lot15 + as.factor(condition), train_data)
  summary(mod)

```

### Nutzung des resultierenden Modells für eine Vohersage
```{r}
# Make predictions using the test data
predicted_values <- predict(mod, newdata = validation_data)

# Compare the predicted values with the actual values
comparison <- data.frame(Actual = test_data$price, Predicted = predicted_values)

# Calculate the mean squared error (RMSE)
rmse <- sqrt(mean((comparison$Actual - comparison$Predicted)^2))

# Display the comparison and RMSE
head(comparison)
cat("Root Mean Squared Error (RMSE):", rmse, "\n")

```
````

BREAKOUT

- Definiert eine lineare Modellgleichung und führt mit Eurem Datensatz eine lineare Regression durch.

- Versucht das adjustierte R^2 des linearen Modells zu maximieren.

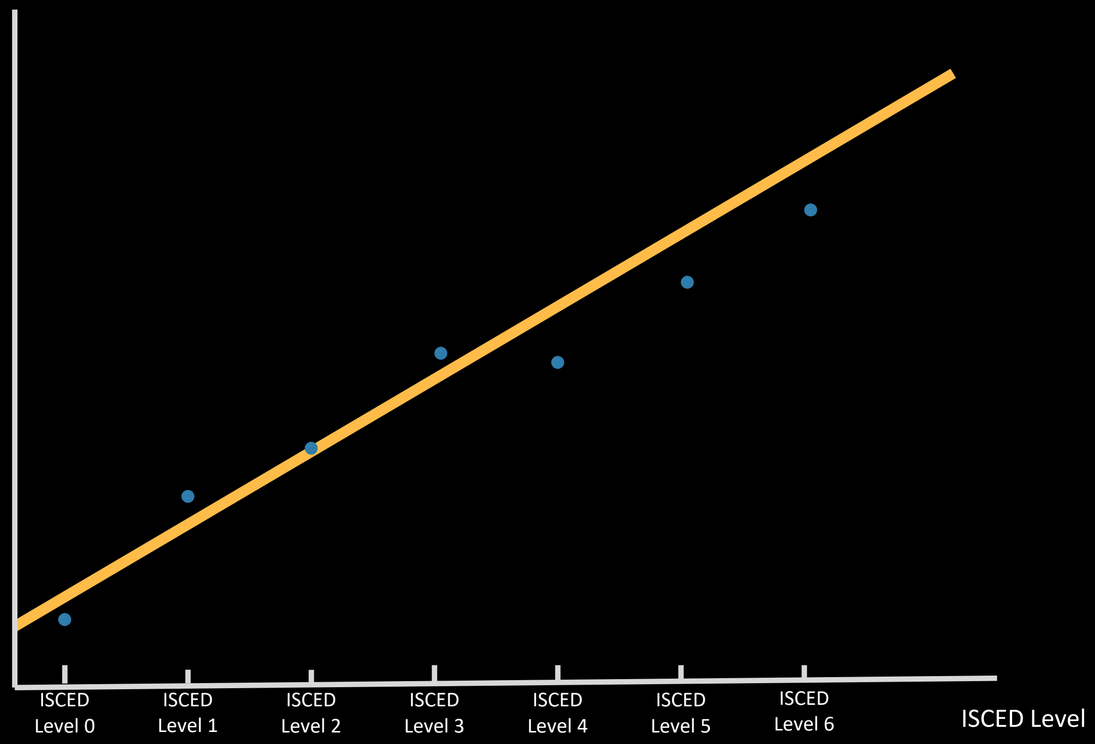
BASELINE MODELL

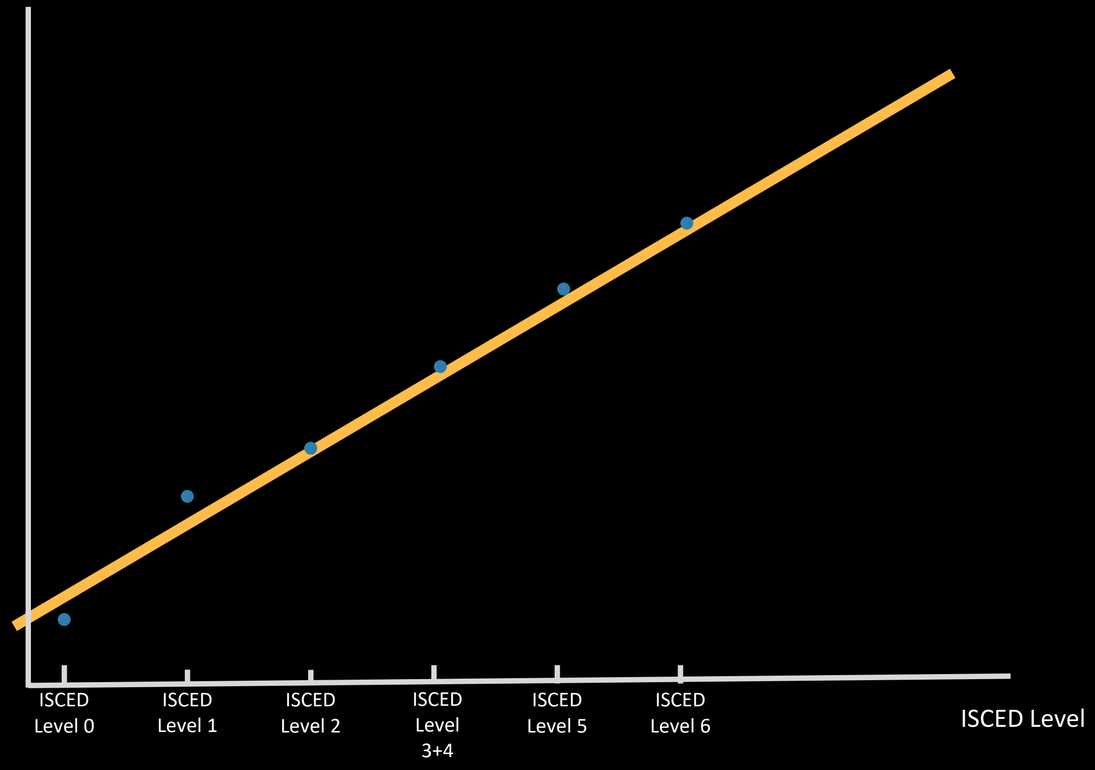
- **Sollte einfach zu implementieren sein, mit einer vernünftigen Chance, anständige Ergebnisse zu liefern und einer sehr geringen Wahrscheinlichkeit des Overfitting.**

- **Sollte interpretierbar sein, um das Verständnis für die Daten zu verbessern und ein besseres „Feature Engineering“ zu ermöglichen.**

Ameisen, E. (2018, March 6). *Always start with a stupid model, no exceptions.* Medium. https://blog.insightdatascience.com/always-start-with-a-stupid-model-no-exceptions-3a22314b9aaa

RELEVANZ VON KATEGORISIERUNGEN





AUFGABEN

- Datensatz weiter um zusätzliche Variablen ergänzen, die für die Schätzung des Umsatzes relevant sein könnten.
- Euren Datensatz teilen in einen Trainingsdatensatz vom 01.07.2013 bis 31.07.2017 und einen Validierungsdatensatz vom 01.08.2017 bis 31.07.2018.
- Eine lineare Modellgleichung aufstellen, die das adjustierte R^2 für Euren Trainingsdatensatz maximiert.
- Im Verzeichnis „Baseline Model“ Eures Team Repositories die Berechnung für die lineare Regression dokumentieren.
- Zum Thema Overfitting dieses Video (9 Minuten) anschauen.
- Einen Account bei Kaggle erstellen.

Level up with the largest AI & ML community

Join over 15M+ machine learners to share, stress test, and stay up-to-date on all the latest ML techniques and technologies. Discover a huge repository of community-published models, data & code for your next project.

Register with Google Register with Email



Who's on Kaggle?

Learners
Dive into Kaggle courses, competitions & forums.



Developers
Leverage Kaggle's models, notebooks & datasets.



Researchers
Advance ML with our pre-trained model hub & competitions.



kaggle

Create

Home

Competitions

Datasets

Models

Code

Discussions

Learn

More

View Active Events

Competitions

Grow your data science skills by competing in our exciting competitions. Find help in the documentation or learn about Community Competitions.

Host a Competition



Search competitions

Filters

All Competitions
Everything, past & present

Featured
Premier challenges with prizes

Getting Started
Approachable ML fundamentals

Research
Scientific and scholarly challenges

Community
Created by fellow Kagglers

Playgr
Fun pra
problem

Get Started

See all

New to Kaggle?

These competitions are perfect for newcomers.



Titanic - Machine Learning from Disaster

Start here! Predict survival on the Ti...

Getting Started

15573 Teams

Knowledge Ongoing



House Prices - Advanced Regression...

Predict sales prices and practice fea...

Getting Started

4911 Teams

Knowledge Ongoing



Spaceship Titanic

Predict which passengers are transp...

Getting Started

2555 Teams

Knowledge Ongoing

kaggle

Search competitions

Filters

Create

Home

Competitions

Datasets

Models

Code

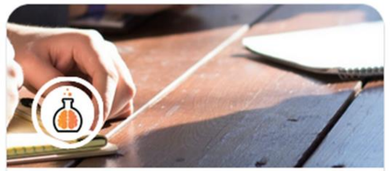
Discussions

Learn

More

View Active Events

All competitions | Featured | Getting Started | Research | Community | Playground | Simulations | Analytics



LLM - Detect AI Generated Text

Identify which essay was written by ...

Featured · Code Competition

1740 Teams

$110,000 2 months to go



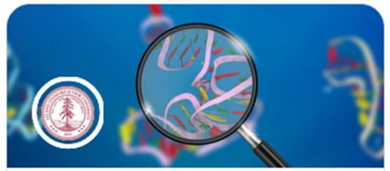
Open Problems – Single-Cell...

Predict how small molecules change...

Featured

1120 Teams

$100,000 3 days to go



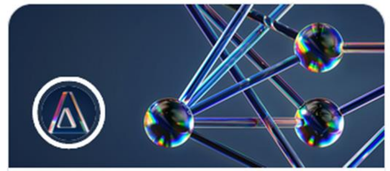
Stanford Ribonanza RNA Folding

Create a model that predicts the str...

Research

676 Teams

$100,000 10 days to go



Optiver - Trading at the Close

Predict US stocks closing movements

Featured · Code Competition

3524 Teams

$100,000 23 days to go

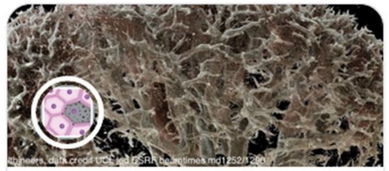


NFL Big Data Bowl 2024

Help evaluate tackling tactics and st...

Analytics

$100,000 a month to go



SenNet + HOA - Hacking the Human...

Segment vasculature in 3D scans of ...

Research · Code Competition

149 Teams

$80,000 2 months to go



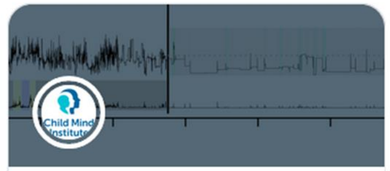
Linking Writing Processes to Writing...

Use typing behavior to predict essa...

Featured · Code Competition

1139 Teams

$55,000 a month to go



Child Mind Institute - Detect Sleep States

Detect sleep onset and wake from w...

Featured · Code Competition

1762 Teams

$50,000 8 days to go

kaggle

Search

Sign In | Register

Create

Home

Competitions

Datasets

Models

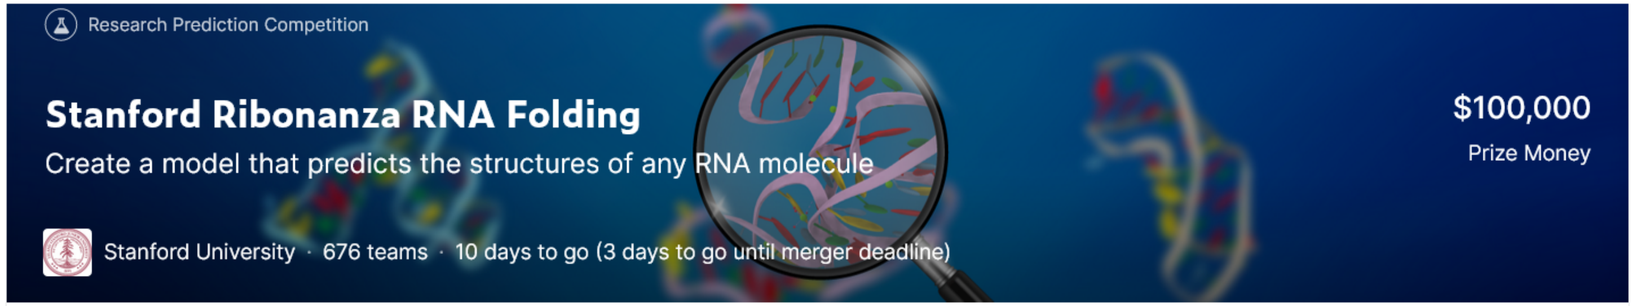
Code

Discussions

Learn

More

View Active Events



Overview | Data | Code | Models | Discussion | Leaderboard | Rules

Join Competition

Leaderboard

Raw Data | Refresh

Search leaderboard

Public | Private

This leaderboard is calculated with approximately 20% of the test data. The final results will be based on the other 80%, so the final standings may be different.

Prize Contenders

#	Team	Members	Score	Entries	Last	Join
1	HandFold		0.13733	85	40m	
2	DI		0.13773	108	3h	