09.01.24

OPENCAMPUS.sh

Einführung in Data Science und maschinelles Lernen

BEHANDLUNG VON FEHLENDEN WERTEN

- Quiz
- Verschiedene Layer zur Implementierung eines NN
- Behandlung fehlender Werte
- (Support-Vektor-Maschinen)

QUIZ

BATCH UND EPOCHE

Batch

- **Eine Teilmenge von Fällen, die genutzt wird, um die Gewichte des Modells zu optimieren.**
- **Optimierungsschritte werden anhand der Batches durchgeführt.**

Epoche

- **Optimierung des Modells anhand aller Fälle bzw. aller Batches zu einem Trainingsdatensatz**

Je nach Modell kann es notwendig sein, es über mehrere hundert oder tausend Epochen zu optimieren.

NORMALISIERUNG

Definition:

- **Abziehen des Mittelwerts und Teilen durch die Standardabweichung.**

Erleichtert es dem neuronalen Netz, die benötigten Parameter zu erlernen, indem alle Werte in einem ähnlichen Wertebereich liegen.

BATCH-NORMALISIERUNG

- Durchführung der Normalisierung auf Batch-Ebene

Zusätzliche Optimierung:

- exakt gleiche Mittelwerte und Standardabweichungen sind nicht notwendigerweise optimal im Sinne der Modellierung

→ Einfügen der Normalisierungsparameter als trainierbare Parameter

DROPOUT LAYER ALS FORM DER REGULARISIERUNG

- Setzt bei jedem Iterationsschritt die Aktivierungen des vorherigen Layers mit der gewählten Wahrscheinlichkeit auf 0.
- Hilft Overfitting zu vermeiden.
- Integriert Redundanz in das Netz.
- Wird nur angewendet im Training, für die Inferenz werden keine Werte verworfen.

NEURONALES NETZ MIT DROPOUT LAYER

```
model = Sequential([
  InputLayer(input_shape=(len(r.training_features.keys()), )),
  BatchNormalization(),
  Dense(10, activation='relu'),
  Dropout(.2),
  Dense(4, activation='relu'),
  Dense(1)
])
```

code - RStudio

File Edit Code View Plots Session Build Debug Profile Tools Help

Go to file/function | Addins | code — Session 8

missing-data.R | neural-net-estimation-with-dropout.Rmd

Knit on Save | Knit | Run

```
### Definition des Neuronalen Netzes
```{python}
# Import needed Python libraries and functions
import numpy as np
import tensorflow as tf
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import InputLayer, Dense, BatchNormalization, Dropout
from tensorflow.keras.optimizers import Adam

# The argument "input_shape" for the definition of the input layer must include the number input variables (features) used for the model. To automatically calculate this
number, we use the  function `r.training_features.keys()`, which returns the list of variable names of the dataframe `training_features`. Then, the function `len()` returns
the length of this list of variable names (i.e. the number of variables in the input).

model = Sequential([
  InputLayer(input_shape=(len(r.training_features.keys()), )),
  BatchNormalization(),
  Dense(10, activation='relu'),
  Dropout(.2),
  Dense(4, activation='relu'),
  Dense(1)
])

# Ausgabe einer Zusammenfassung zur Form des Modells, das geschaetzt wird (nicht notwendig)
model.summary()


```
```

```
Model: "sequential_1"
_________________________________________________________________
Layer (type)                 Output Shape              Param #
=================================================================
batch_normalization_1 (Batch (None, 104)               416
_________________________________________________________________
dense_3 (Dense)              (None, 10)                1050
_________________________________________________________________
dropout (Dropout)            (None, 10)                0
_________________________________________________________________
dense_4 (Dense)              (None, 4)                 44
_________________________________________________________________
dense_5 (Dense)              (None, 1)                 5
=================================================================
Total params: 1,515
Trainable params: 1,307
Non-trainable params: 208
_________________________________________________________________
```

37:16 | Chunk 2 | R Markdown

Console | Terminal | Jobs

Python 3.9.7 · C:/Users/Steffen/Nextcloud/00_Arbeitsdateien_und_Vertraege/99_opencampus/06_Kurse/12_Data Science/Session 8/code/

```
>>>
>>>
>>> # Definition der Kosten-(Loss-)Funktion und der Optimierungsfunktion mit seinen Hyperparametern
>>> model.compile(loss="mse", optimizer=Adam(learning_rate=0.001))
```

Environment | Python | Main

Data
his… <t…
r [R…

Values
Adam <clas…
Bat… <clas…
Den… <clas…

Files | Plots

Python: class D

```
>>> laye
>>> data
>>> prin
[[0. 1.]
 [2. 3.]
 [4. 5.]
 [6. 7.]
 [8. 9.]]
>>> outp
>>> prin
tf.Tenso
[[ 0.
 [ 2.5
 [ 5.
 [ 7.5
 [10.

Args:
  rate:
  noise_
    bina
    For
    `(ba
    you
    you
  seed:

Call arg
  inputs
  traini
    trai
```

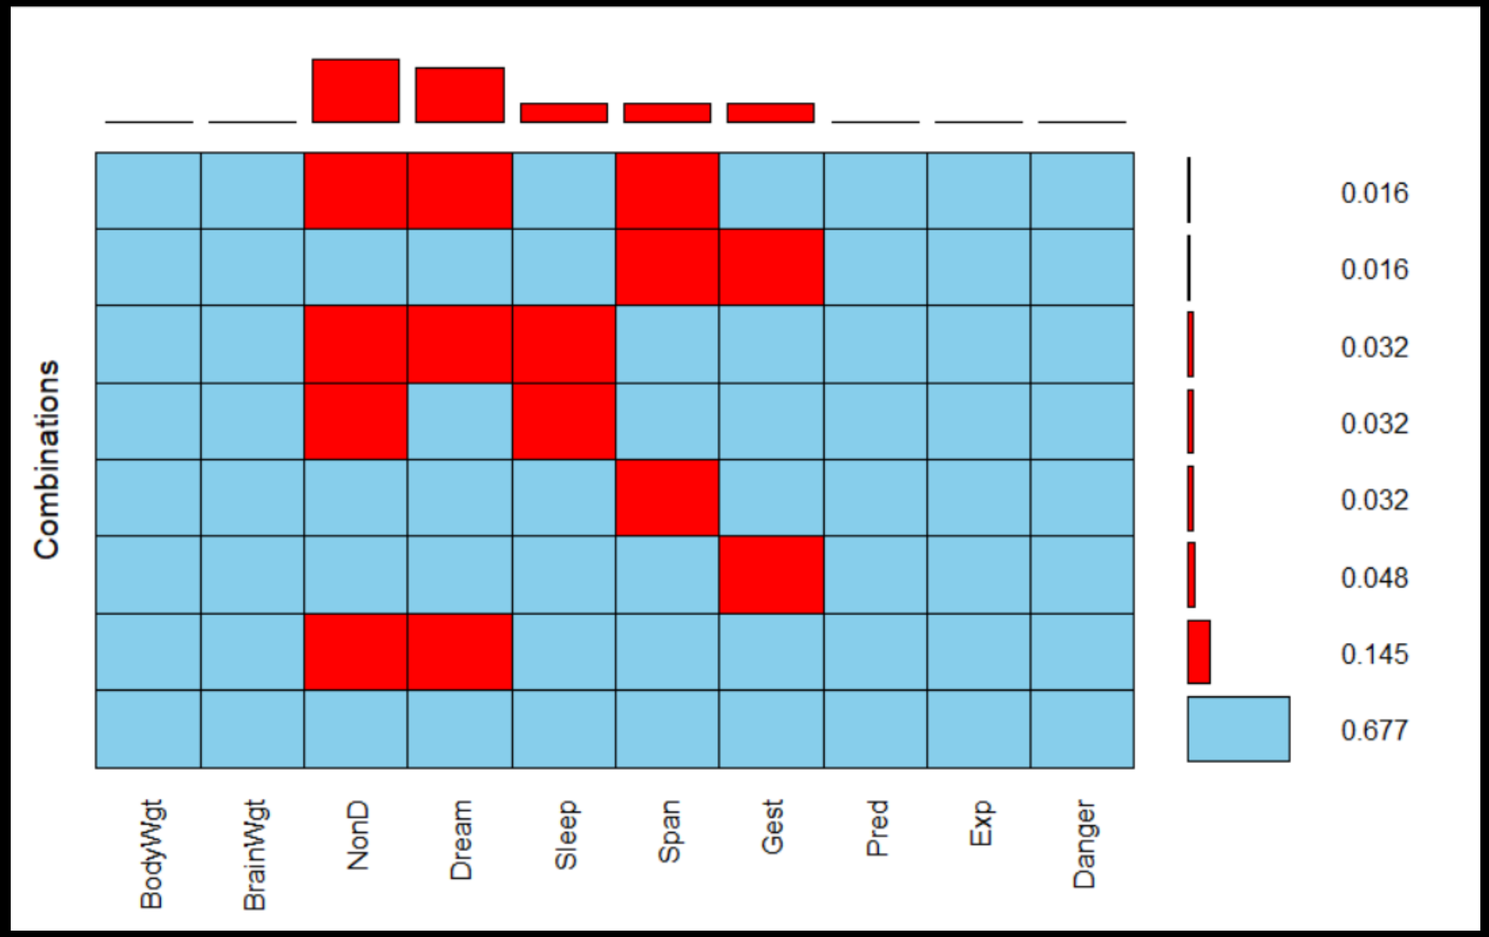
GRÜNDE FÜR FEHLENDE WERTE

- Nicht gegebene Antworten in Umfragen
- Zusammenführung von Daten aus verschiedenen Quellen mit unterschiedlichen Variablen
- Technische Probleme in der Datenerhebung oder Aufzeichnung
- …

TYPEN VON FEHLENDEN WERTEN

- **Missing Completely at Random (MCAR)**
- **Missing at Random (MAR)**
- **Missing not at Random (MNAR)**

VISUALISIERUNG FEHLENDER WERTE



VIM package (Visualization and Imputation of Missing Values)

```
aggr(dataset,
  combined=TRUE,
  numbers=TRUE)
```


Kowarik, A., & Templ, M. (2016). Imputation with the R Package VIM. *Journal of Statistical Software*, *74*, 1–16.

BREAKOUT

Diskutiert Lösungen für folgende mögliche Fälle im Wetterdatensatz:

- **Temperaturdaten für einen Monat mit fehlenden Daten für zwei Tage:**
  `[20, 19, 23, 19, 17, 17, NA, 24, 16, 20, 22, 21, 20, 19, 17, 22, 24, 21, 23, 15, 18, 18, 21, 19, 19, 21, 21, 19, 23, NA]`

- **Temperaturdaten für einen Monat mit fehlenden Daten für ein Woche:**
  `[18, 15, 21, 15, 24, 16, 21, 16, 22, 18, 17, 25, 22, 21, 16, 19, 17, 23, NA, NA, NA, NA, NA, NA, NA, 21, 20, 20, 16, 15]`

- **Wettercode-Daten für 20 Tage mit fehlenden Daten für einen Tag:**
  `[10, 60, NA, 95, 61, 1, 29, 81, 21, 25, 25, 80, 80, 63, 81, 80]`

BEHANDLUNG VON FEHLENDEN WERTE

- Zugehörige Fälle löschen (listwise deletion)

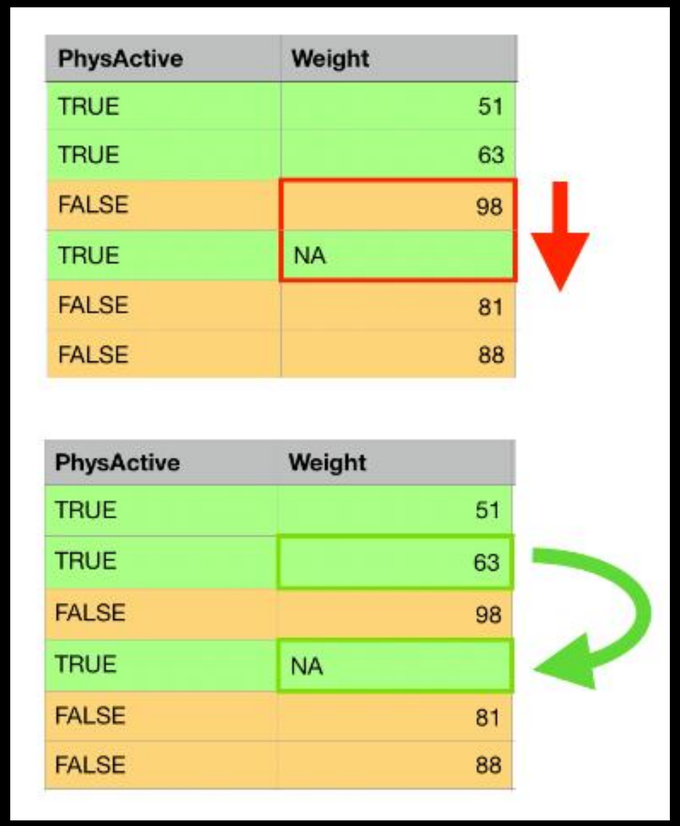
- Einfache „Spender“-basierte Imputation (donor-based)
  - Mittelwertschätzung (bzw. Median oder Mode)
  - nach „Ähnlichkeit“ (Hot-Deck Imputation)
  - durch minimalen Abstand (k Nearest Neighbors)

- Einfache modellbasierte Imputation
  - Iterative Regression

- Multiple Imputation

HOT-DECK IMPUTATION

Nach Domänen



PhysActive	Weight
TRUE	51
TRUE	63
FALSE	98
TRUE	NA
FALSE	81
FALSE	88

PhysActive	Weight
TRUE	51
TRUE	63
FALSE	98
TRUE	NA
FALSE	81
FALSE	88

Nach Korrelation



Height	Weight
150	51
161	63
189	98
155	NA
182	81
184	88

Height	Weight
150	51
155	NA
161	63
182	81
184	88
189	98

Oleszak, M. (2021). Hot-deck imputation | R. Retrieved December 6, 2021, from Datacamp website: https://campus.datacamp.com/courses/handling-missing-data-with-imputations-in-r/donor-based-imputation?ex=5

K-NEAREST NEIGHBORS (KNN)

Suche nach den k Fällen mit minimalem Abstand

- **je nach Variablentyp unterschiedliche Abstandsmessung**
- **Zusammenführung der Abstände über eine Summenfunktion**

Verschiedene Vorgehensweisen zur Berechnung des Imputationswerts:

- **Der Wert mit minimalem Abstand wird genommen (1NN)**
- **Zufällige Ziehung aus den k Fällen**
- **Berechnung aus den k-Fällen über den (gewichteten Mittelwert)**

ITERATIVE REGRESSION

1) Vorhersage fehlender Werte in A

A	B	C	D
5	34	NA	1
1	22	NA	4
NA	65	55	2
4	87	27	2
NA	23	10	1

ITERATIVE REGRESSION

1) Vorhersage fehlender Werte in A

A	B	C	D
5	34	**NA**	1
1	22	**NA**	4
5	65	55	2
4	87	27	2
2	23	10	1

ITERATIVE REGRESSION

2) Vorhersage Fehlender Werte in C mit den imputierten werten von A

A	B	C	D
5	34	**NA**	1
1	22	**NA**	4
5	65	55	2
4	87	27	2
2	23	10	1

ITERATIVE REGRESSION

2) Vorhersage Fehlender Werte in C mit den imputierten werten von A

A	B	C	D
5	34	**32**	1
1	22	**16**	4
5	65	55	2
4	87	27	2
2	23	10	1

ITERATIVE REGRESSION

3) Vorhersage fehlender Werte in A mit den imputierten Werten von C

A	B	C	D
5	34	**32**	1
1	22	**16**	4
NA	65	55	2
4	87	27	2
NA	23	10	1

→ Wiederholung bis keine Änderung mehr eintritt

ITERATIVE REGRESSION

1) Gehe schrittweise durch alle Variablen des Datensatz
2) Stelle dabei für jede Variable eine Regressionsmodell basierend auf allen anderen Variablen auf
3) Berechne für alle fehlenden Werte eine Vorhersage

- Jetzt wiederhole Schritt 1) bis 3) erneut und schätze die fehlenden Werte erneut - dieses Mal mit den bereits imputierten fehlenden Werten.
- Wiederhole dies, bis sich die imputierten Werte nicht mehr ändern.

IMPUTATION EXAMPLES

```
---
title: "Missing Values"
output: html_notebook
---

```{r}
# Prepare Environment
library(readr)
library(VIM)
library(dplyr)
library(ggplot2)

options(datatable.use.index = TRUE)

```

```{r}
# VIM Aggregation Plot
sleep %>%
  aggr(combined=TRUE, numbers=TRUE)

```


```{r}
# Listwise deletion
sleep_deletion <- na.omit(sleep)

sleep_deletion %>%
  aggr(combined=TRUE, numbers=TRUE)

```


```{r}
# VIM Hot-Deck Imputation

sleep_hotdeck1 <- sleep %>%
  hotdeck()
sleep_hotdeck1 %>%
  aggr(combined=TRUE, numbers=TRUE)
ggplot(sleep_hotdeck1) +
  geom_point(aes(x=Sleep, y=Dream, color=Sleep_imp))
```
```

BERECHNUNG DES IMPUTATIONSFEHLERS

1. Erstellen eines vollständigen Datensatz („Referenz-Datensatz“)
2. Zufälliges Entfernen von Daten
3. Imputieren der fehlenden Daten mit der gewählten Methode (ggf. auch mehreren zum Vergleich)
4. Vergleich der imputierten Daten mit den Originaldaten:, z.B. durch Berechnung
   - des mittleren quadratischen Fehlers (MSE) oder
   - des absoluten Fehlers.
5. Bewertung des Fehlers (ggf. Anpassung des Imputationsverfahrens)

BREAKOUT

- **Nutzt das VIM package, um Eure fehlenden Werte darzustellen**
- **Führt eine erste Imputation durch**

AUFGABEN

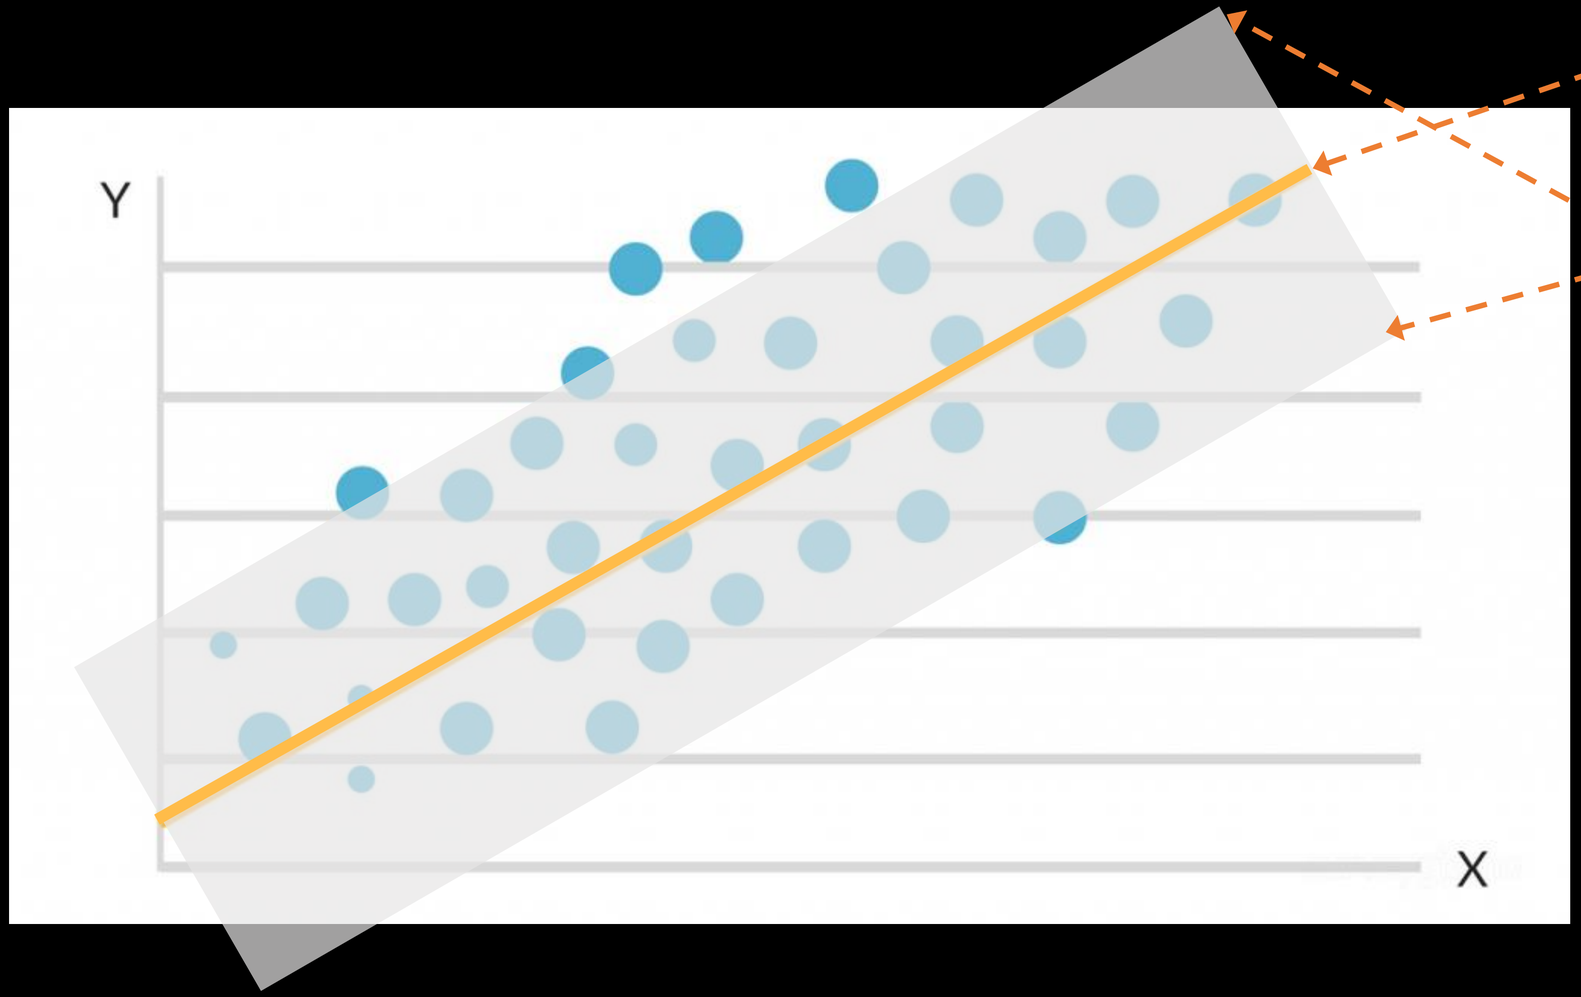
- **Wählt ein (bzw. verschiedene) Verfahren, um die fehlenden Werte in Eurem Datensatz zu ersetzen.**

- **Schaut dieses Video (5 Minuten) zu Zeitreihenanalysen.**

- **Teilt Euch die Aufgaben im Team gut auf:**
  Wer arbeitet an der Datenoptimierung, wer an der Modelloptimierung?

SUPPORT VECTOR MACHINE (SVM)

[SUPPORT VECTOR REGRESSION (SVR)]



Hyper plane

Boundary lines with soft margins

- Der Soft Margin Parameter (auch Cost Paramater) ist ein Regularisierungs-parameter, der die Flexibilität der Grenzlinien steuert bzw. wie stark Punkte außerhalb bestraft werden.

SUPPORT VECTOR MACHINES

Lernressourcen

- **Blog:** https://towardsdatascience.com/an-introduction-to-support-vector-regression-svr-a3ebc1672c2

- **Video:** https://www.youtube.com/watch?v=efR1C6CvhmE

OPTIMIERUNG EINER SVM IN R

R-Package „e1071“

`svm()`	**Optimierung eines SVM Modells**
`tune()`	**Optimierung mehrerer SVM Modelle mit gleichzeitiger Optimierung des C- und Gamma-Parameters**
`predict()`	**Vorhersage auf Basis eines optimierten Modells**

BEISPIELCODE IN R

```
---
title: "Support Vector Machine"
output: html_notebook
---


## Imports
## Splitting Training and Test Data
## Data Preparation
## Training the SVM

```{r}
# Optimization of an SVM with standard hyper parameters
# Typically NOT used; Instead, the function svm_tune() is used in order to also get a model with optimized hyper parameters
model_svm <- svm(price ~ bathrooms, train_dataset)
```

```{r}
# Optimization of various SVM using systematically varied hyper parameters (typically called 'grid search' approach) and
cross validation
# the resulting object includes the optimal model in the element named 'best.model'
svm_tune <- tune(svm, price ~ bedrooms + bathrooms + sqft_living + zipcode, data=train_dataset,
                 ranges = list(epsilon = seq(0.2,1,0.1), cost = 2^(2:3)))
```


Checking the Prediction Quality
```

ZUSAMMENFASSUNG SVM

- Populärer, weil einfach zu optimierender Lernalgorithmus, der schnell gute Ergebnisse bringt.
- Geeignet zur Klassifikation und zur Regression.