18.04.24

OPENCAMPUS.sh

# Einführung in Data Science und maschinelles Lernen

## EINFÜHRUNG

- Vorstellung
- Organisatorisches
- Aufbau des Kurses
- Was ist Data Science?
- Python vs. R vs. SPSS vs. ...
- Jupyter Notebook

# VORSTELLUNG

# OPENCAMPUS.sh

- Nonprofit organization which oversees a variety of initiatives
- Offering a wide range of educational opportunities, support, and networking for entrepreneurs, creatives, and anyone curious, regardless of age, educational background, or origin
- The services are open to everyone and mostly free.
- The goal is to support the entrepreneurial landscape, promote creative change processes, and contribute to innovative and sustainable future development.










starter kitchen.de




# COBL

**COZY WORKING, CULTURE & EVENTS**





KOSMOS
by opencampus.sh





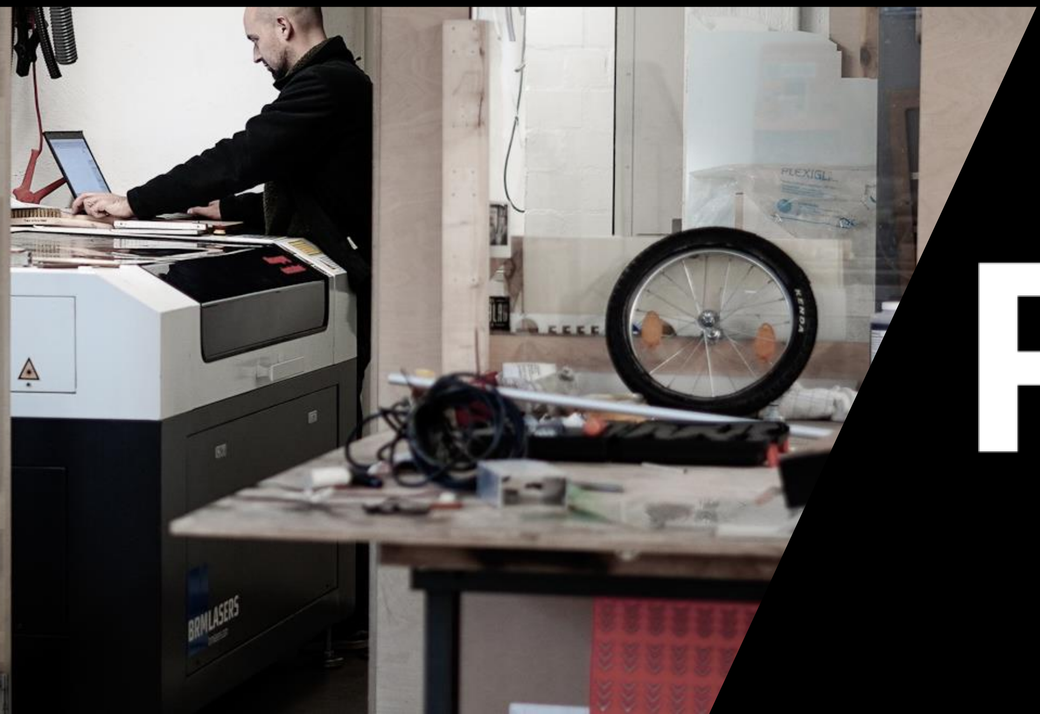













# FABLAB KIEL

SEEd | Social Entrepreneurship Education

#seed17









Design Thinking

Business/
Project Modelling

Pitching/
Präsentationen






MFG 5 KIEL WE CONNECT. 13.–14. JUNI 2024

# WATERKANT FESTIVAL

WATERKANT.SH











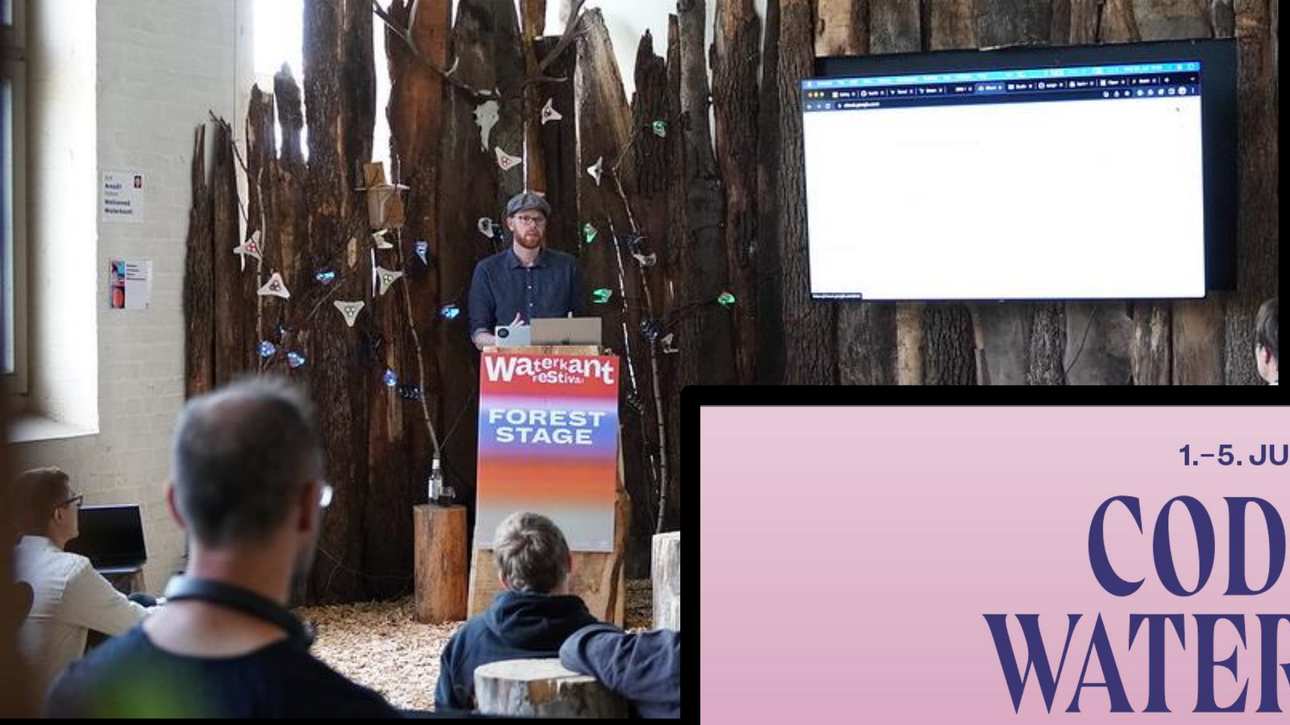






# WATERKANT EXHIBITION 2024

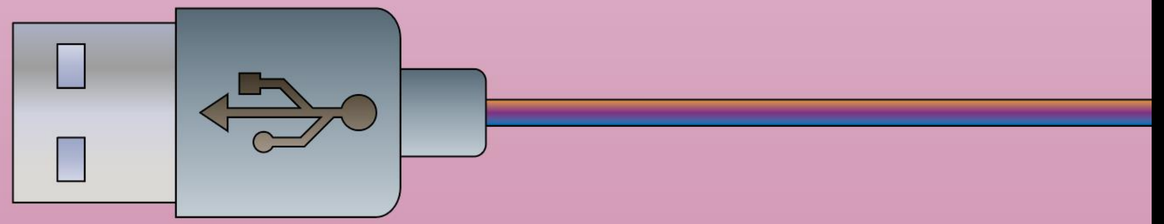




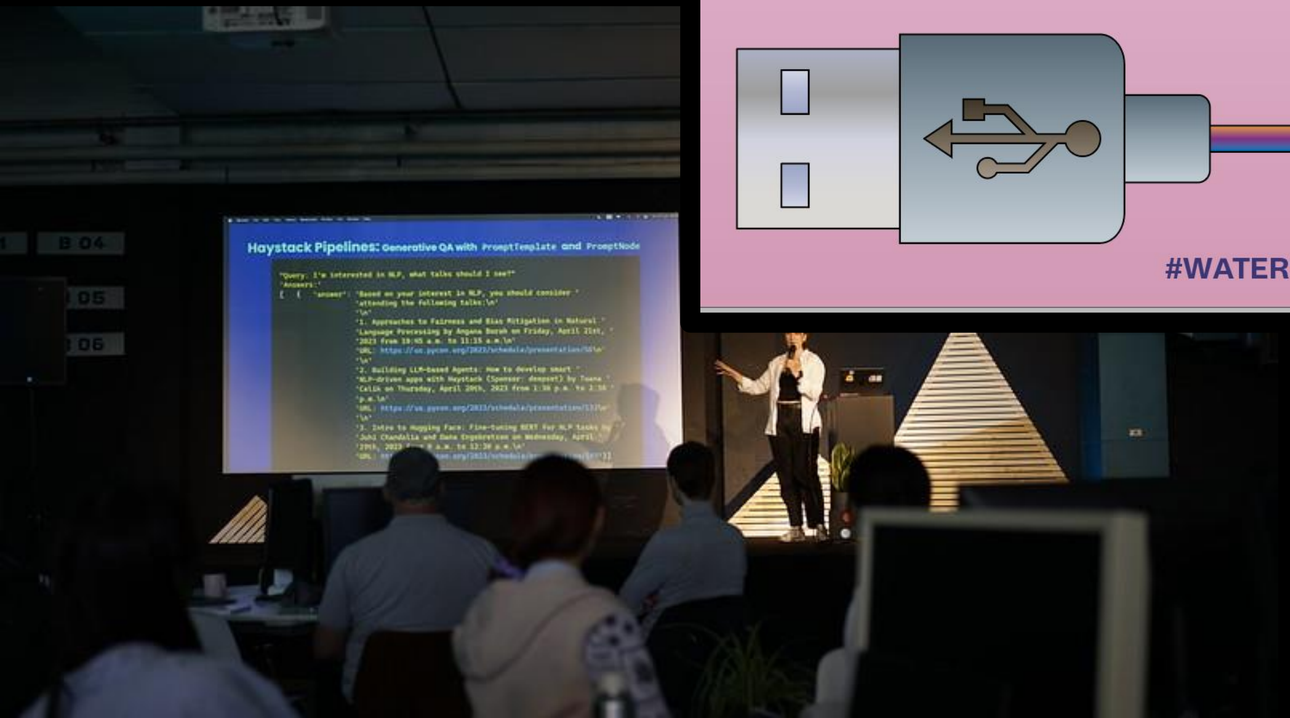



1.–5. JULI 2024

# CODING. WATERKANT



#WATERKANT24






1.–5. JULI 2024

# CODING. WATERKANT

- Work for four consecutive days:
  - on your own machine learning project or
  - support others in their project
- Take part in workshops

- Get input and feedback by invited experts
- Present your work to a larger audience.
- Take educational leave
- Get accommodation on site

https://coding.waterkant.sh

# https://kiel.ai

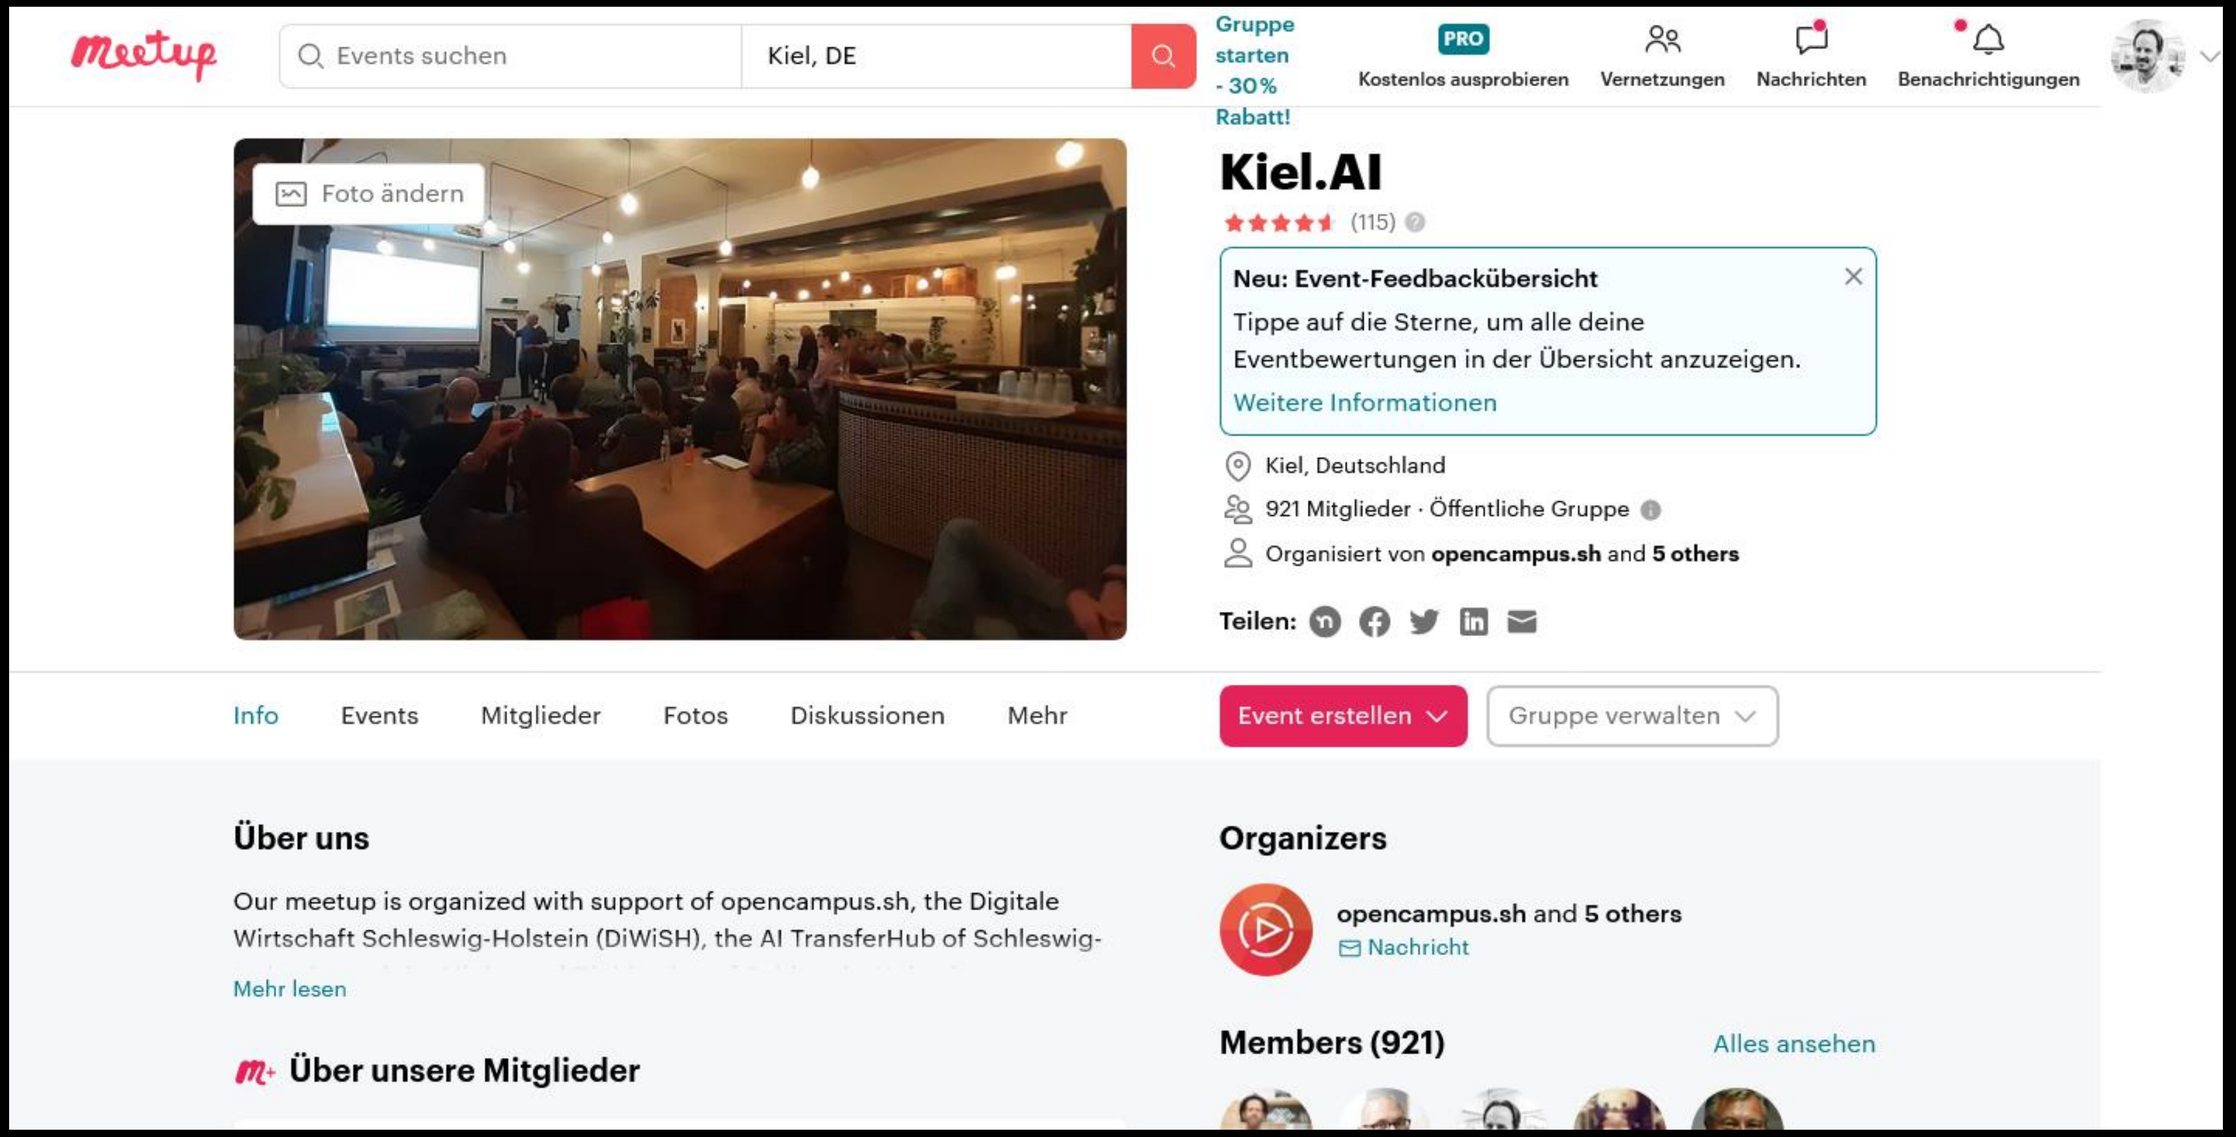
ML Degree Meetup Coding.Waterkant Chat



**Kiel.AI**

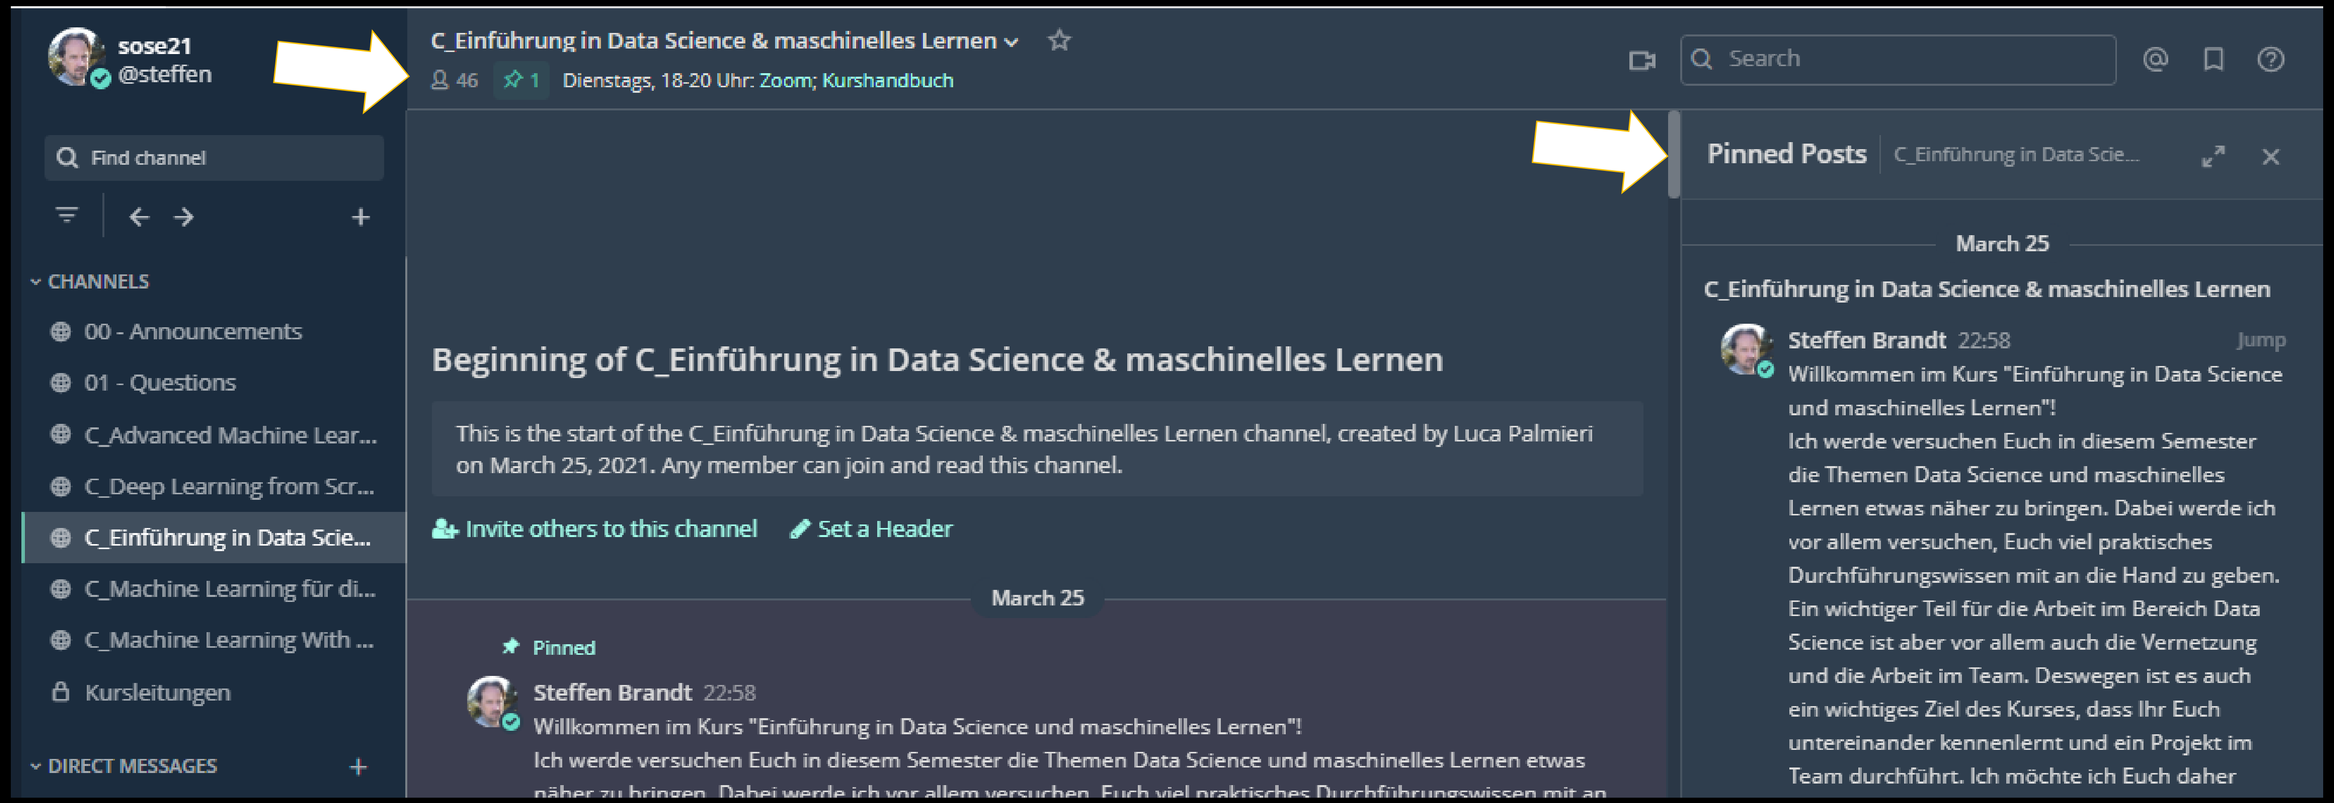
OPENCAMPUS.sh

DiWiSH
DIGITALE WIRTSCHAFT
SCHLESWIG-HOLSTEIN
CLUSTERMANAGEMENT

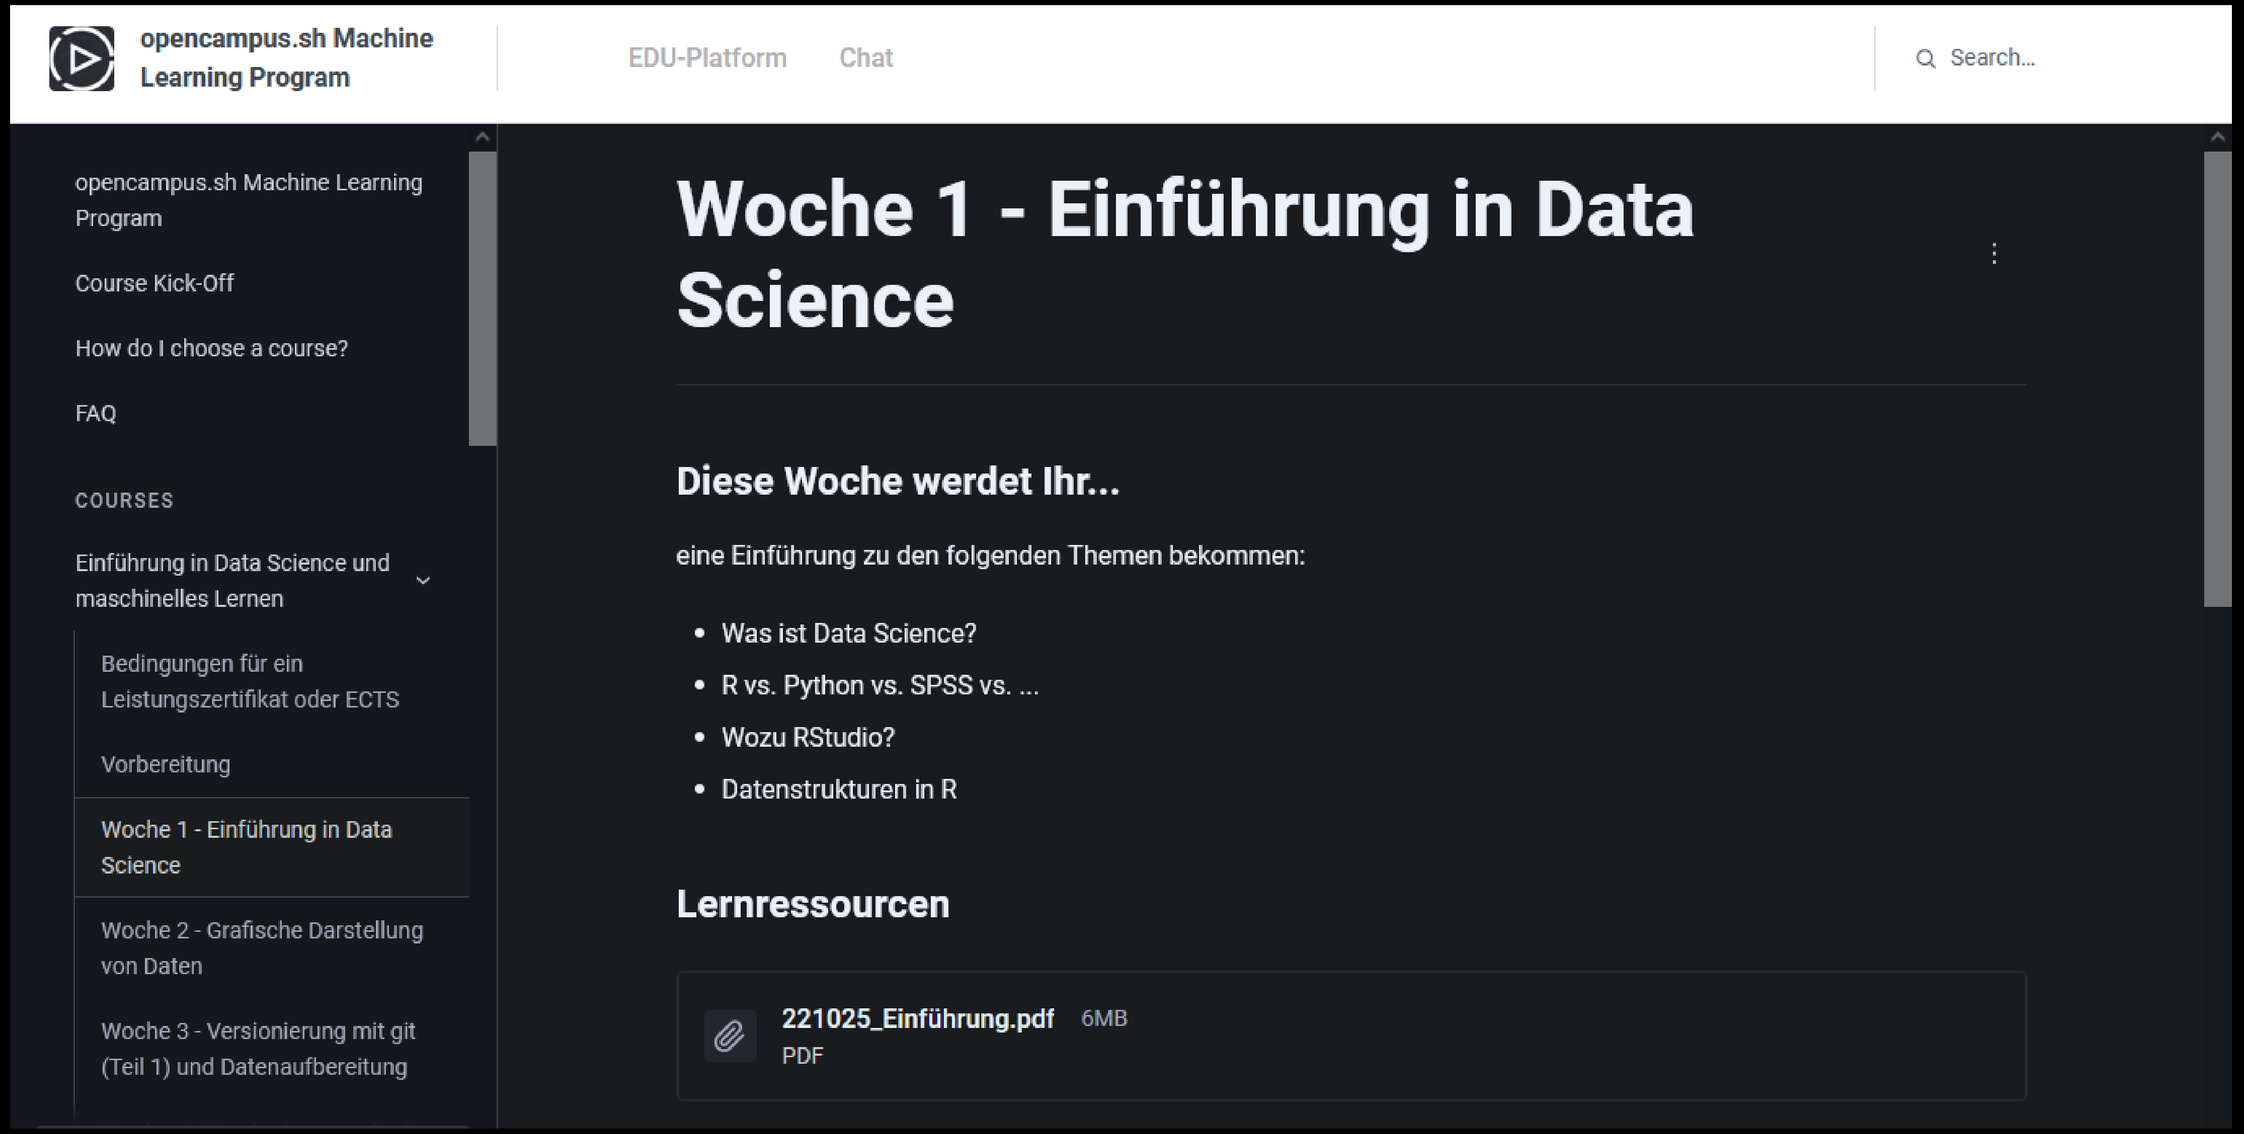



https://www.meetup.com/kiel-ai/

# CHAT


sose21
@steffen
C_Einführung in Data Science & maschinelles Lernen
46
1
Dienstags, 18-20 Uhr: Zoom; Kurshandbuch
Search
Find channel
CHANNELS
00 - Announcements
01 - Questions
C_Advanced Machine Lear...
C_Deep Learning from Scr...
C_Einführung in Data Scie...
C_Machine Learning für di...
C_Machine Learning With ...
Kursleitungen
DIRECT MESSAGES
Beginning of C_Einführung in Data Science & maschinelles Lernen
This is the start of the C_Einführung in Data Science & maschinelles Lernen channel, created by Luca Palmieri on March 25, 2021. Any member can join and read this channel.
Invite others to this channel
Set a Header
March 25
Pinned
Steffen Brandt 22:58
Willkommen im Kurs "Einführung in Data Science und maschinelles Lernen"!
Ich werde versuchen Euch in diesem Semester die Themen Data Science und maschinelles Lernen etwas
Pinned Posts
C_Einführung in Data Scie...
March 25
C_Einführung in Data Science & maschinelles Lernen
Steffen Brandt 22:58
Jump
Willkommen im Kurs "Einführung in Data Science und maschinelles Lernen"!
Ich werde versuchen Euch in diesem Semester die Themen Data Science und maschinelles Lernen etwas näher zu bringen. Dabei werde ich vor allem versuchen, Euch viel praktisches Durchführungswissen mit an die Hand zu geben. Ein wichtiger Teil für die Arbeit im Bereich Data Science ist aber vor allem auch die Vernetzung und die Arbeit im Team. Deswegen ist es auch ein wichtiges Ziel des Kurses, dass Ihr Euch untereinander kennenlernt und ein Projekt im Team durchführt. Ich möchte ich Euch daher

# KURSHANDBUCH



# ORGANISATORISCHES

- Vervollständigt Euer Profil im Mattermost-Chat mit Eurem Namen und einem Foto.

- Bitte schreibt mir, wenn Ihr den Kurs abbrecht!

**Online-Teilnahme:**

- Benutzt Euren vollständigen Namen in den Zoom-Meetings!
- Kamera an

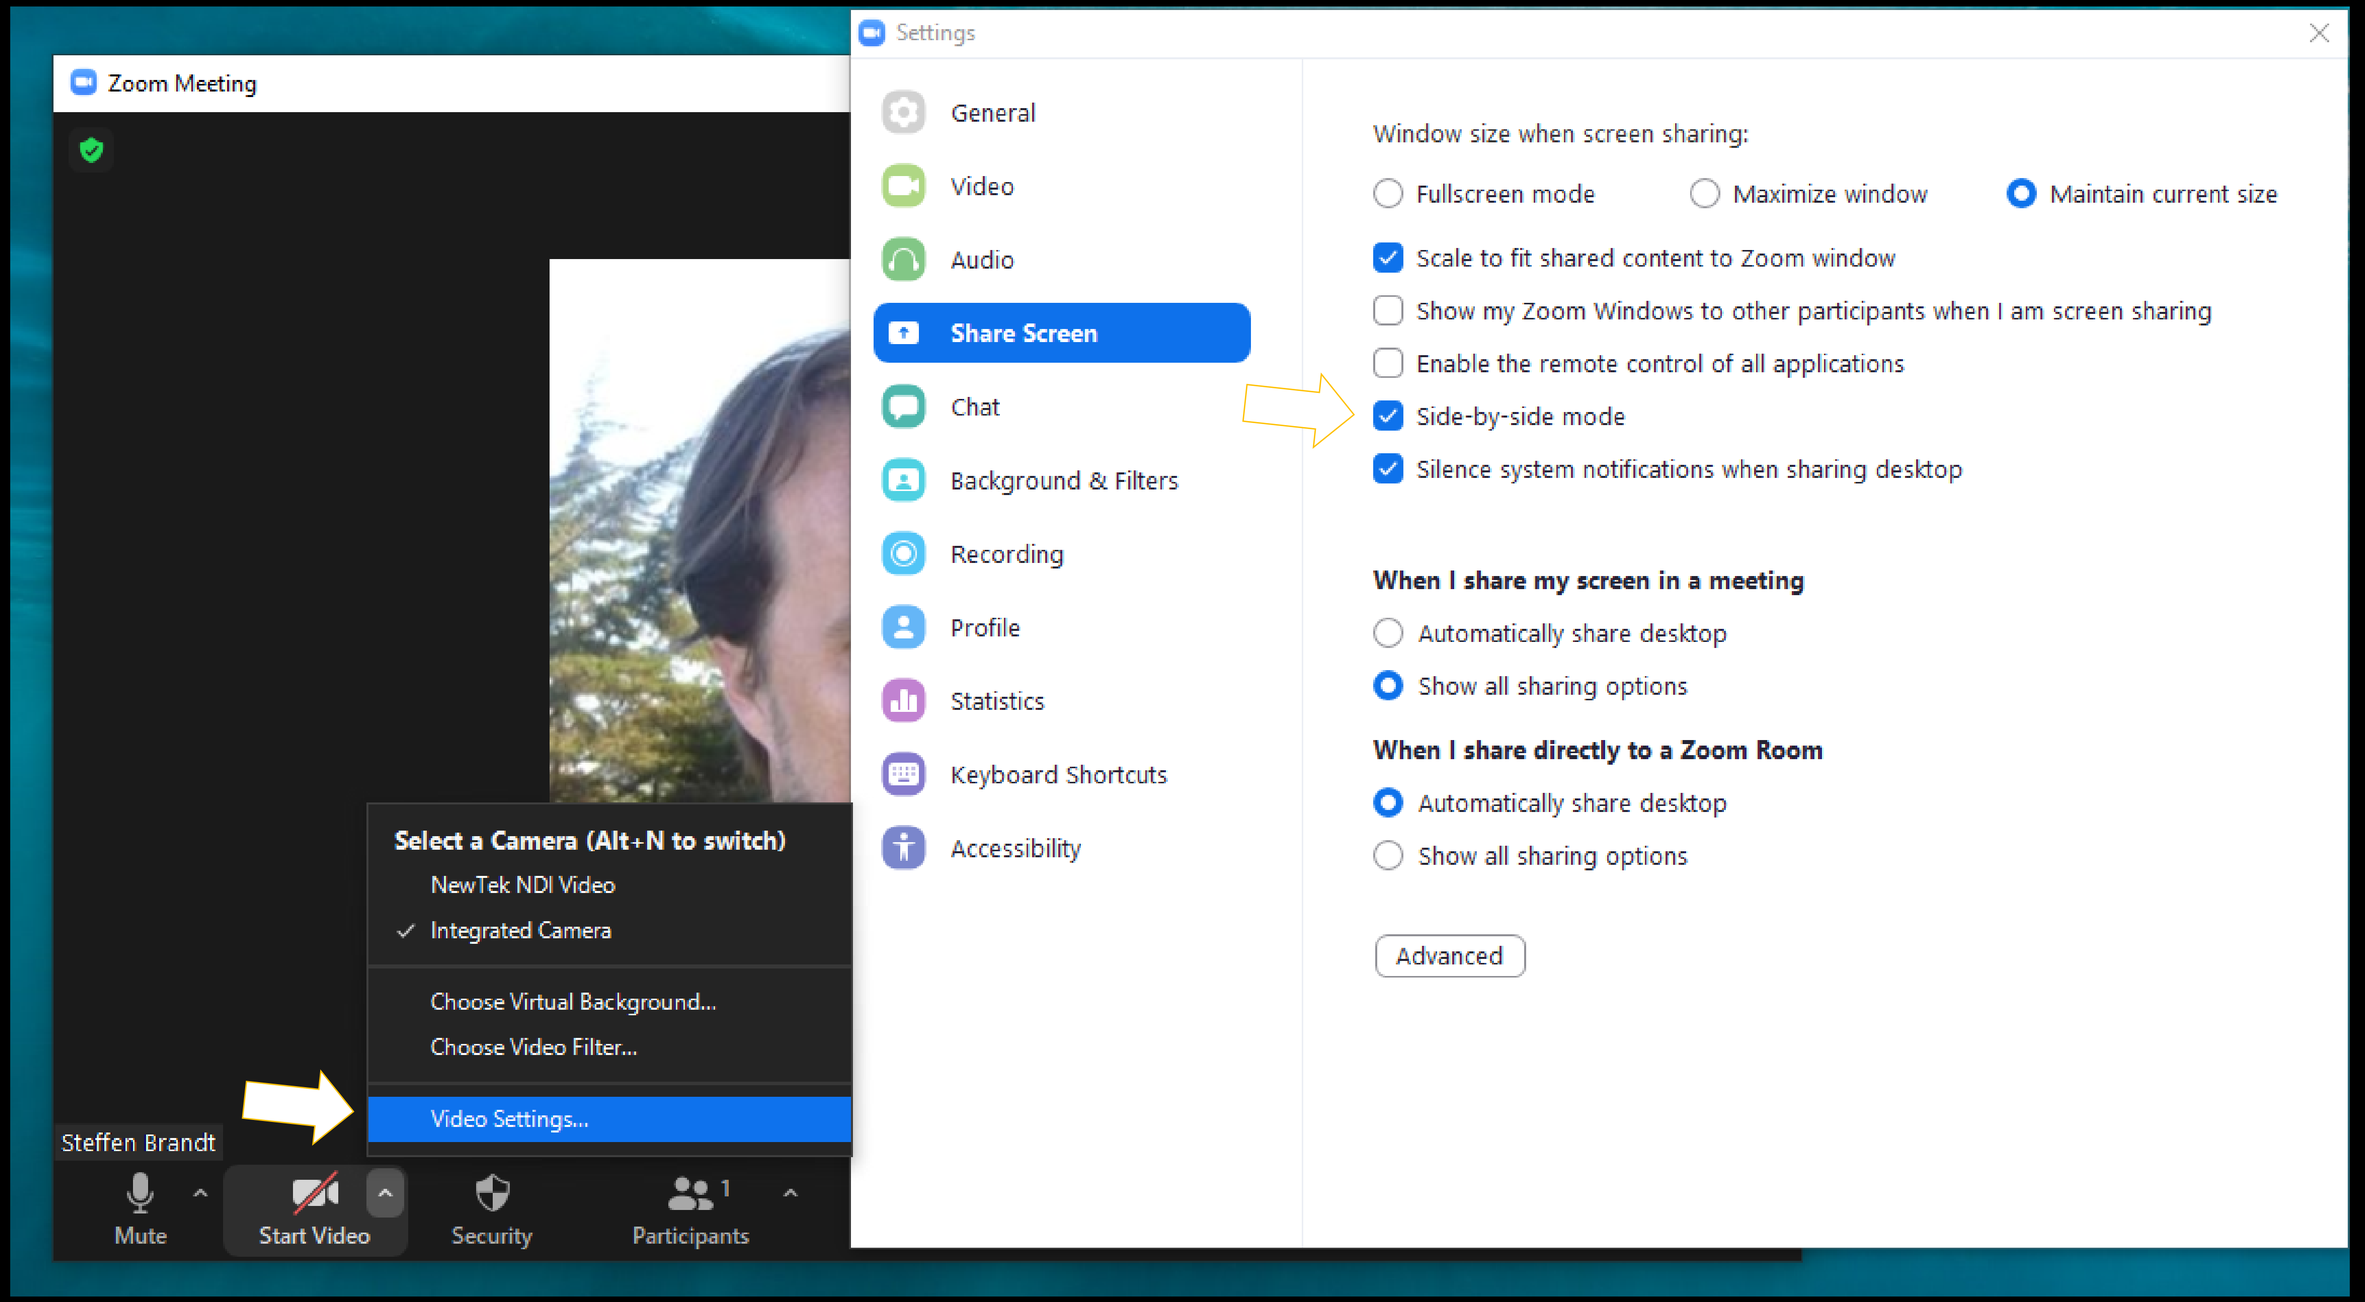
**Präsenzteilnahme:**

- Scannt den QR-Code, wenn Ihr in Präsenz teilnehmt

# ZOOM

- Versucht die unterschiedlichen View Modes:
  - Gallery View/ Active Speaker
  - Split Screen/ Full Screen Mode

- Schaut Euch ggf. dazu dieses Video an:
  https://www.youtube.com/watch?v=v3IPAbpVjd4


Zoom Meeting
Select a Camera (Alt+N to switch)
NewTek NDI Video
Integrated Camera
Choose Virtual Background...
Choose Video Filter...
Video Settings...
Steffen Brandt
Mute
Start Video
Security
Participants
1
Settings
General
Video
Audio
Share Screen
Chat
Background & Filters
Recording
Profile
Statistics
Keyboard Shortcuts
Accessibility
Window size when screen sharing:
Fullscreen mode
Maximize window
Maintain current size
Scale to fit shared content to Zoom window
Show my Zoom Windows to other participants when I am screen sharing
Enable the remote control of all applications
Side-by-side mode
Silence system notifications when sharing desktop
When I share my screen in a meeting
Automatically share desktop
Show all sharing options
When I share directly to a Zoom Room
Automatically share desktop
Show all sharing options
Advanced

# BREAKOUTS

*Bei Online-Teilnahme:*

**Macht einen Screenshot von der Aufgabe, bevor es in die Breakout-Räume geht!**

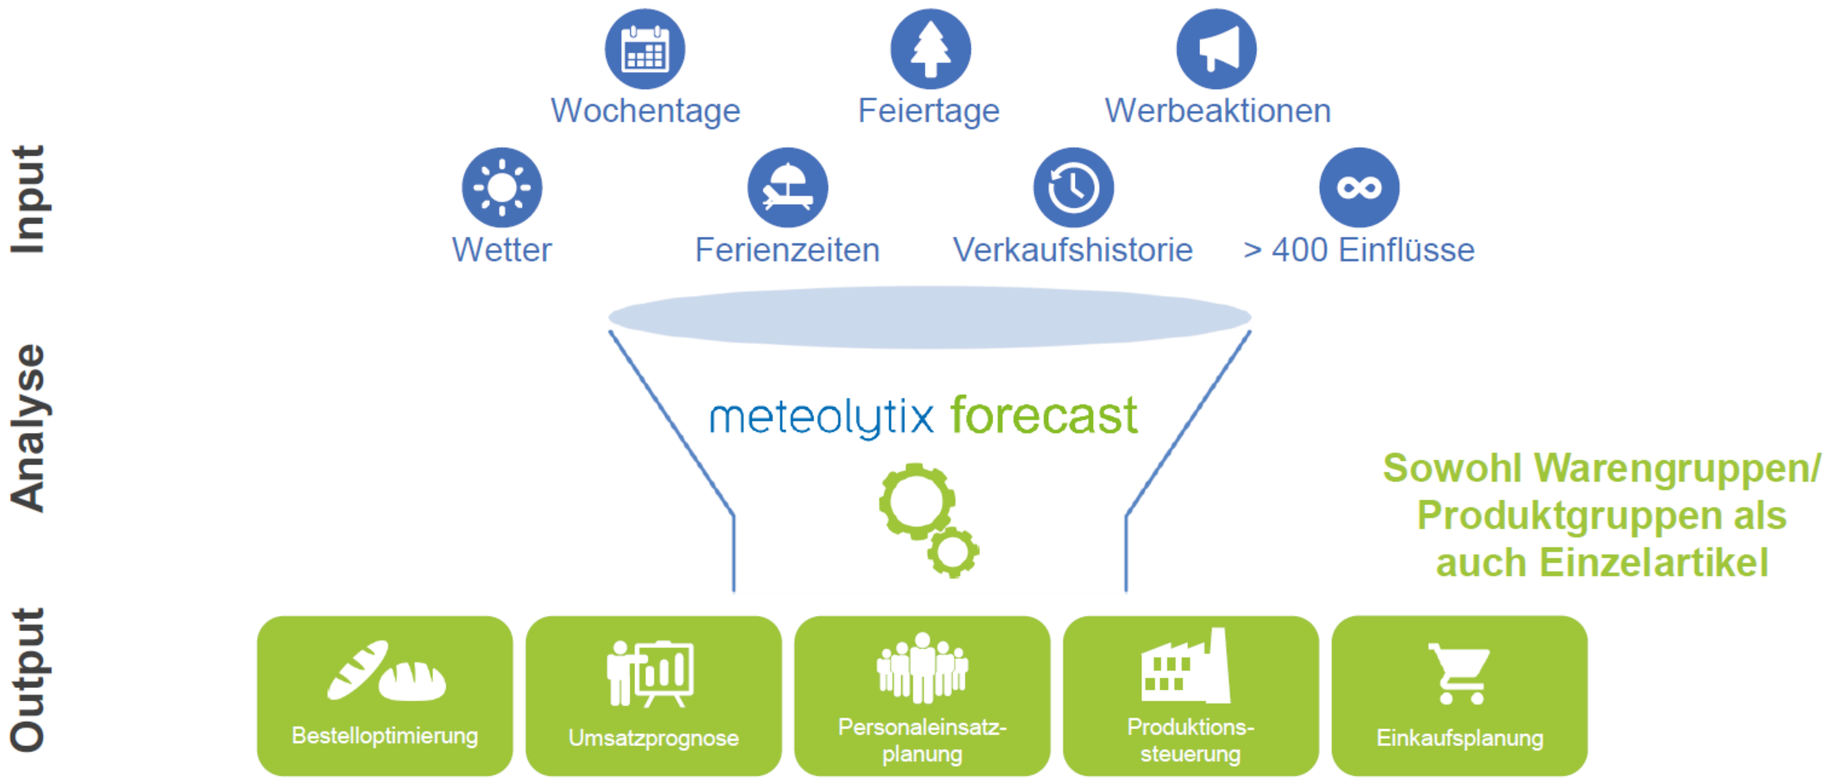
# PROJEKT ZUR UMSATZVORHERSAGE

- **Echte Umsatzdaten von verschiedenen Warengruppen einer Bäckereifiliale über einen Zeitraum von ca. 3 Jahren**

- **Wetterdaten für den zugehörigen Zeitraum (und darüber hinaus)**

# *meteolytix forecast* analysiert die Datenzusammenhänge von mehr als 400 Einflussfaktoren und liefert Absatzprognosen für viele Einsatzfelder.

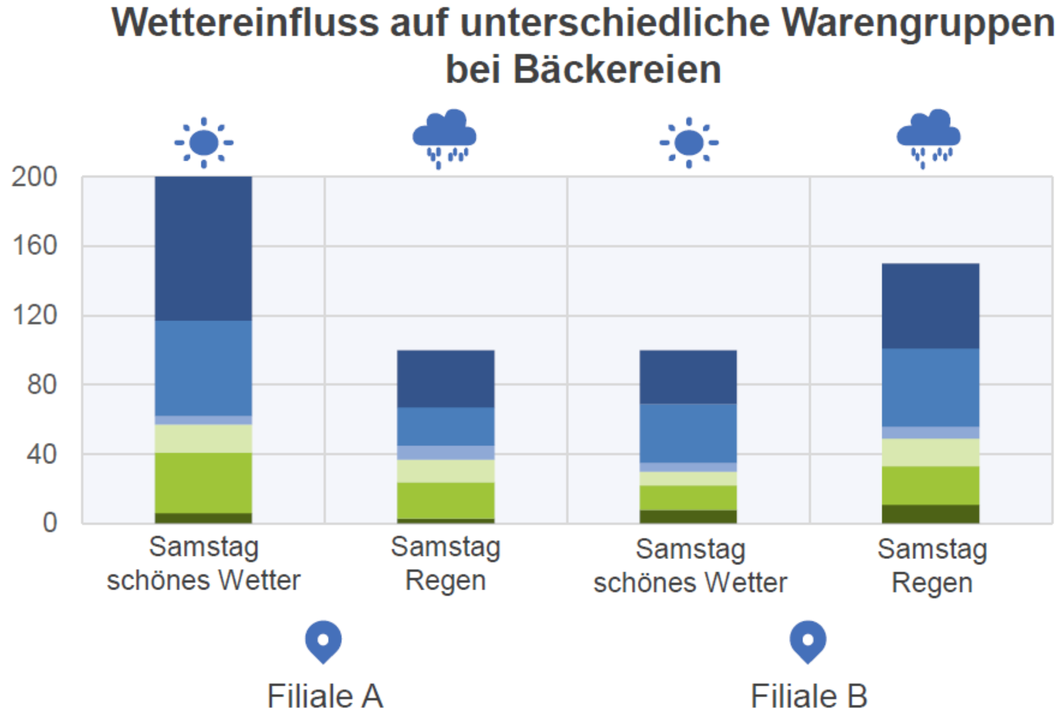
WAS WIR MACHEN

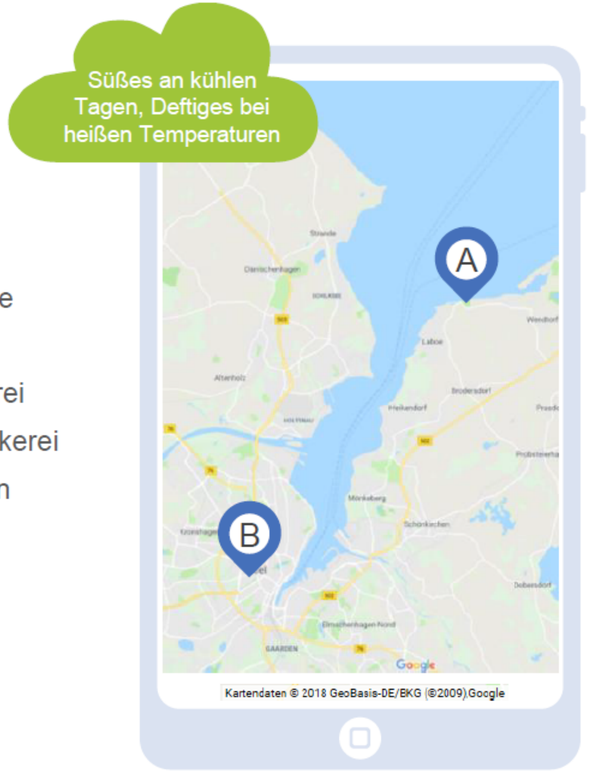



© 2019 *meteolytix GmbH*

# Die Stärke des Wettereffekts variiert von Ort zu Ort und wird jeweils filialindividuell berücksichtigt.

WAS WIR MACHEN

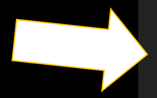


# PROJEKTZIELE

- Programmieren mit KI-Unterstützung
- Arbeiten im Team mit Versionierung (Git)
- Aufbereitung von Variablen
- Nutzung grafischer Darstellungen
- Nutzung von Regressionen zur Identifizierung relevanter Variablen
- Behandlung fehlender Werte
- Optimierung eines neuronalen Netzes

**Festlegung der Teams**



| | | |
|---|---|---|
| 18.04.2024 | 16:00 - 18:00 | Einführung in Data Science<br>Starterkitchen, Kuhnkestr. 6, 24118 Kiel + ONLINE |
| 25.04.2024 | 16:00 - 18:00 | Grafische Darstellung von Daten<br>Starterkitchen, Kuhnkestr. 6, 24118 Kiel + ONLINE |
| 02.05.2024 | 16:00 - 18:00 | Versionierung mit Git und GitHub<br>Starterkitchen, Kuhnkestr. 6, 24118 Kiel + ONLINE |
| 09.05.2024 | 16:00 - 18:00 | Datenaufbereitung<br>Starterkitchen, Kuhnkestr. 6, 24118 Kiel + ONLINE |
| 16.05.2024 | 16:00 - 18:00 | Einführung in das maschinelle Lernen<br>Starterkitchen, Kuhnkestr. 6, 24118 Kiel + ONLINE |
| 23.05.2024 | 16:00 - 18:00 | Overfitting und Modell-Evaluation<br>Starterkitchen, Kuhnkestr. 6, 24118 Kiel + ONLINE |
| 30.05.2024 | 16:00 - 18:00 | Project Work<br>Starterkitchen, Kuhnkestr. 6, 24118 Kiel + ONLINE |
| 06.06.2024 | 16:00 - 18:00 | Neuronale Netze<br>Starterkitchen, Kuhnkestr. 6, 24118 Kiel + ONLINE |
| 13.06.2024 | 16:00 - 18:00 | Behandlung von fehlenden Werten<br>Starterkitchen, Kuhnkestr. 6, 24118 Kiel + ONLINE |
| 20.06.2024 | 16:00 - 18:00 | Zeitreihenanalysen<br>Starterkitchen, Kuhnkestr. 6, 24118 Kiel + ONLINE |
| 27.06.2024 | 16:00 - 18:00 | Projektpräsentationen<br>Starterkitchen, Kuhnkestr. 6, 24118 Kiel + ONLINE |

„Education is the only thing that humans try to get less out of than what they pay for.“

# ERSTER BREAKOUT

- 15 Minuten
- Stellt Euch einander vor
- Frage: Was ist Künstliche Intelligenz?
  - Versucht Euch auf eine Definition zu einigen
  - Teilt diese im Chat

# WAS DAVON IST KI?

- Schachcomputer
- Google Maps
- ChatGPT

“What's the difference between data science, machine learning, and artificial intelligence?”

http://varianceexplained.org/r/ds-ml-ai

Data science produces insights.

Machine learning produces predictions.

Artificial intelligence produces actions.

# DATA SCIENCE

**Anwendung statistischer Auswertungsverfahren mit deren Hilfe Ergebnisse für einen Bericht oder Artikel erzeugt werden.**

- **Deskriptive Statistiken**
- **Statistische Schlussfolgerungen**
- **Visualisierung von Daten**
- **Design von Experimenten**

# MASCHINELLES LERNEN

**Anwendung eines statistischen Optimierungsverfahren zur Schätzung von Modellparametern (validiert mit „ungesehenen“ Daten)**

**mit deren Hilfe eine Funktion erstellt wird, die Prognosen liefert,**

**Wobei (häufig) gleichzeitig die Modellparameterschätzung durch Hinzufügen neuer Daten ständig verbessert wird.**

- **Prognose zukünftiger Zustände**
- **Prognose unbeobachteter Zustände**
- **Prognose aktueller Zustände**

# KÜNSTLICHE INTELLIGENZ

„an autonomous agent executes or recommends actions“

(Poole, Mackworth, & Goebel, 1998)

„Systeme mit einem ‚intelligenten‘ Verhalten, die ihre Umgebung analysieren und mit einem gewissen Grad an Autonomie handeln, um bestimmte Ziele zu erreichen. “

(Europäische Kommission, 2018)

„Unter Künstlicher Intelligenz verstehen wir hochentwickelte Softwaresysteme, welche lernfähig und trainierbar sind, um komplexe Aufgaben bewältigen können.“

(KI-Strategie des Landes Schleswig-Holstein, 2019)

# EIGENSCHAFTEN VON PYTHON

- Aus der Softwareentwicklung kommende Auswertungssprache
  (R wurde von Statistikern entwickelt)
- Interpretersprache
  (Syntax wird Zeile für Zeile interpretiert, vergleichbar eines Taschenrechners)
- Konsolen-Programm ohne grafische Benutzeroberfläche
- Aktuell am schnellsten wachsende Programmiersprache

# NACHTEILE VON PYTHON

- Man muss Programmieren.
- Starke Ausrichtung auf den produktiven Einsatz, wodurch die Installation komplizierter ist als z.B. für R.
- In manchen statistiknahen Forschungs- und Anwendungsbereichen nicht so verbreitet wie R.

# VORTEILE VON PYTHON

- Open Source
- Sehr große Community
- In der Wirtschaft und zunehmend auch im wissenschaftlichen Bereich die Standardsprache für datenbasierte Auswertungen
- Die Standardsprache im Bereich des maschinellen Lernens
- Umfangreichste Funktionsbibliotheken zur Erstellung von
  - Web-Anwendungen (z.B. Django und Flask)
  - Datenauswertungen (z.B. NumPy und Pandas)
  - Abbildungen (z.B. Matplotlib und Seaborn)
  - Neuronalen Netzen (z.B. TensorFlow und PyTorch)
- Umfangreicher Beispiel-Code für Schnittstellen (APIs) zu anderen Anwendungen
- Breite Unterstützung zum Einsatz im produktiven Bereich

# JUPYTER NOTEBOOK

## Beliebte Anwendung zur Erstellung und Ausführung von Python-Programmen

- Open Source-Webanwendung, die im Browser aufgerufen wird
- Komfortable Bearbeitung und Ausführung des Codes
- Ermöglicht einfügen von formatierten Kommentierungen und Erklärungen in „Markdown“
- Anzeige des Ergebnisses des aktuell ausgeführten Codes, auch von grafischen Ausgaben

IP[y]: Notebook spectrogram Last Checkpoint: a few seconds ago (autosaved)

IPython (Python 3)

File Edit View Insert Cell Kernel Help

Code Cell Toolbar: None

# Simple spectral analysis

An illustration of the Discrete Fourier Transform using windowing, to reveal the frequency content of a sound signal.

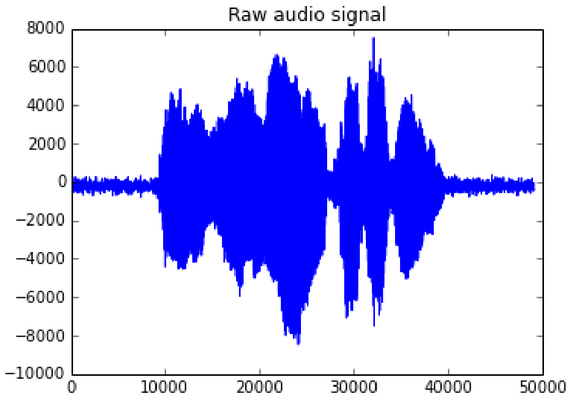
$$X_k = \sum_{n=0}^{N-1} x_n e^{-\frac{2\pi i}{N} kn} \qquad k = 0, \ldots, N-1$$

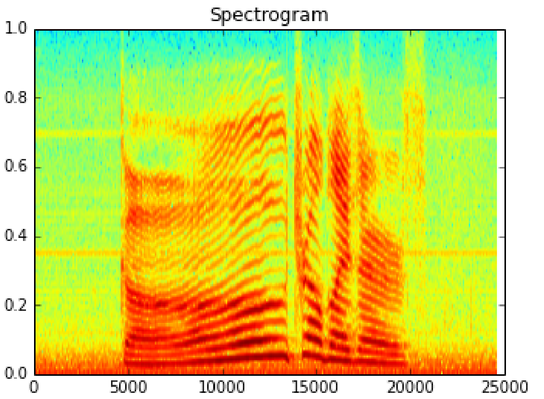
We begin by loading a datafile using SciPy's audio file support:

In [1]:
```
from scipy.io import wavfile
rate, x = wavfile.read('test_mono.wav')
```

And we can easily view its spectral structure using matplotlib's builtin `specgram` routine:

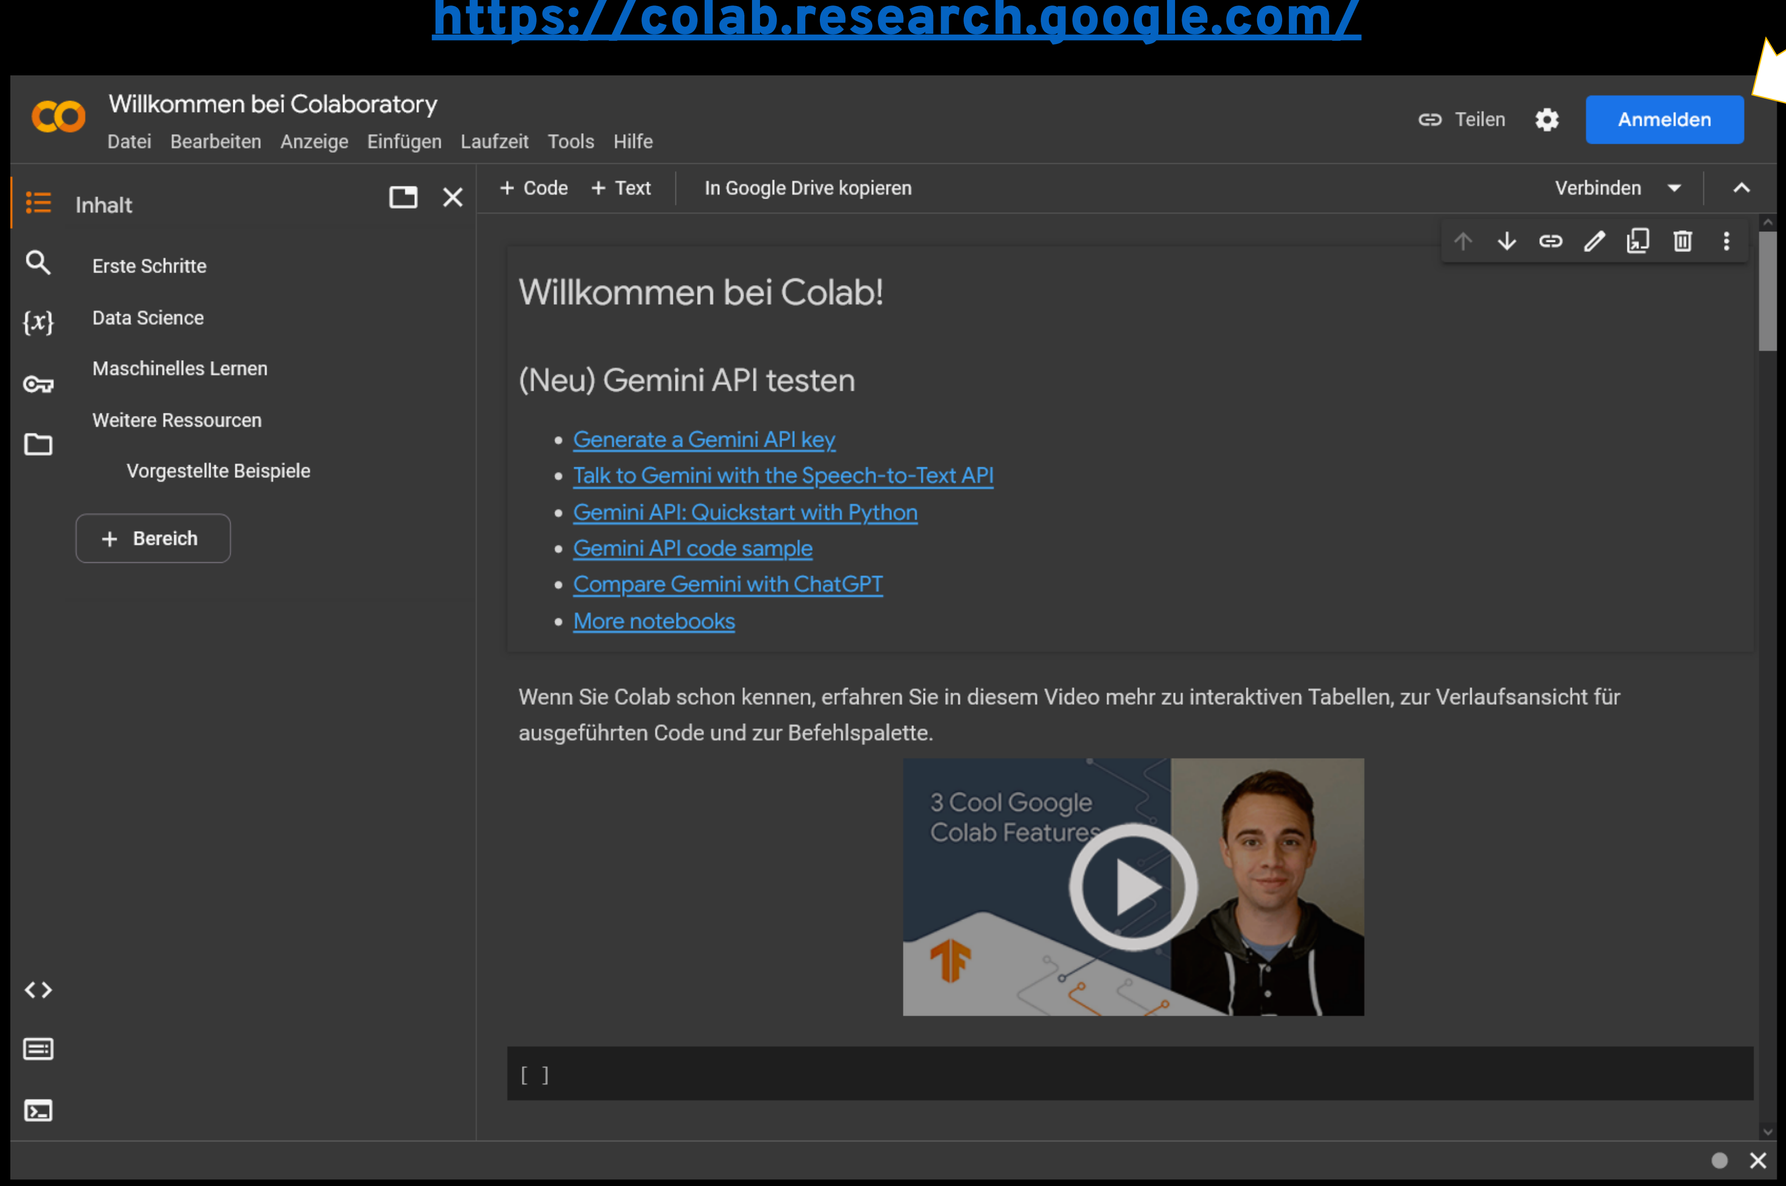
In [2]:
```
%matplotlib inline
from matplotlib import pyplot as plt
fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(12, 4))
ax1.plot(x); ax1.set_title('Raw audio signal')
ax2.specgram(x); ax2.set_title('Spectrogram');
```



# VERWENDUNG IN COLAB

https://colab.research.google.com/



# BREAKOUT

- Probiert aus wie man Zellen für Code und Markdown einfügt

- Führt einfache Beispiele von Python Code aus, so wie ihr sie aus dem Einführungskapitel von datacamp kennt

# WAS IST MARKDOWN?

| Markdown | Preview |
| --- | --- |
| `**bold text**` | **bold text** |
| `*italicized text*` or `_italicized text_` | *italicized text* |
| `` `Monospace` `` | `Monospace` |
| `~~strikethrough~~` | ~~strikethrough~~ |
| `[A link](https://www.google.com)` | A link |
| `![An image](https://www.google.com/images/rss.png)` |  |

# JUPYTERLAB UND COLAB

- Kombiniert Jupyter Notebook mit Funktionen eines Dateimanagers, Terminal und weiteren benutzerdefinierten Komponenten

- JupyterLab:
  - Open Source
  - lokal installiert oder Cloud-basiert, z.B. von Uni-Rechenzentren

- Colab (Google Colaboratory):
  - Cloud-basierte Software von Google (keine lokale Installation von Python, Jupyter Notebook oder anderem notwendig)
  - Integriert mit Google Drive
  - Bietet kostenlosen Zugang zur Rechenressourcen, einschließlich von Grafikkarten (GPUs)
  - Integrierte Kollaborationsfunktion, die es mehreren Nutzern ermöglicht, gleichzeitig an demselben Notebook zu arbeiten.

# BREAKOUT

**Berechnet mit Hilfe von Python den Mittelwert der folgenden sieben Zahlen:**

1
2
3
4
5
6
9,87654321

# HILFEN

- **ChatGPT!**
- **Google**
- **Stackoverflow**
- **Dokumentation der Funktionen**

# BEISPIELHAFTE PROGRAMMIERUNG MIT KI-UNTERSTÜTZUNG

# LERNMATERIAL

- Dieses Video zum Arbeiten mit Strings ansehen (16 Minuten).
- Diesen Video-Ausschnitt zum Arbeiten mit Zahlen ("Numbers" und "Working With Numbers") ansehen (5 Minuten).
- Die ersten vier Kapitel dieses Videos zu Funktionen ansehen (12 Minuten).
- Dieses Video zum Arbeiten mit Listen in Python ansehen (18 Minuten).
- *Optional:*
  Falls Euch die Aufbereitung im Kurs von datacamp gefallen hat, könnt Ihr alternativ (oder zusätzlich) auch die übrigen drei Kapitel gratis im Audit-Modus durchgehen (ihr dürft nur keine Übungen abschicken).

# AUFGABEN

- Importiere den Datensatz “umsatzdaten_gekuerzt.csv”, den Du über folgenden Link herunterladen kannst:
  https://raw.githubusercontent.com/opencampus-sh/einfuehrung-in-data-science-und-ml/main/wetter.csv

- Berechne die Gesamtdurchschnittstemperatur.

- Berechne die Durchschnittstemperatur für den Monat Juli.

- Vergleiche, ob die Monate Juli und Mai sich in ihrer Durchschnittstemperatur signifikant unterscheiden.

# REGISTRIERUNG GITHUB COPILOT

- ***Optional:***

  **Euch wie hier beschrieben für GitHub Copilot anmelden und das 30-Tage-Probe-Abo nutzen, das gratis ist.**

  **Wenn Ihr *Schüler:in, Student:in oder Lehrkraft* seid, könnt Ihr Euch wie hier beschrieben gratis für GitHub Co-Pilot registrieren, das Ihr dann ggf. in VSCode, das wir uns in der nächsten Woche anschauen, integrieren könnt.**

  **Die Bezahlversion kostet aktuell 10 US-Dollar pro Monat.**