25.04.24

OPENCAMPUS.sh

Einführung in Data Science und maschinelles Lernen

IMPORT UND GRAFISCHE DARSTELLUNG VON DATEN

- Besprechung Aufgaben
- VSCode und GitHub Code Spaces
- KI-Gestützte Programmierung
- Einlesen von Daten aus externen Quellen
- Diagramm- und Skalentypen

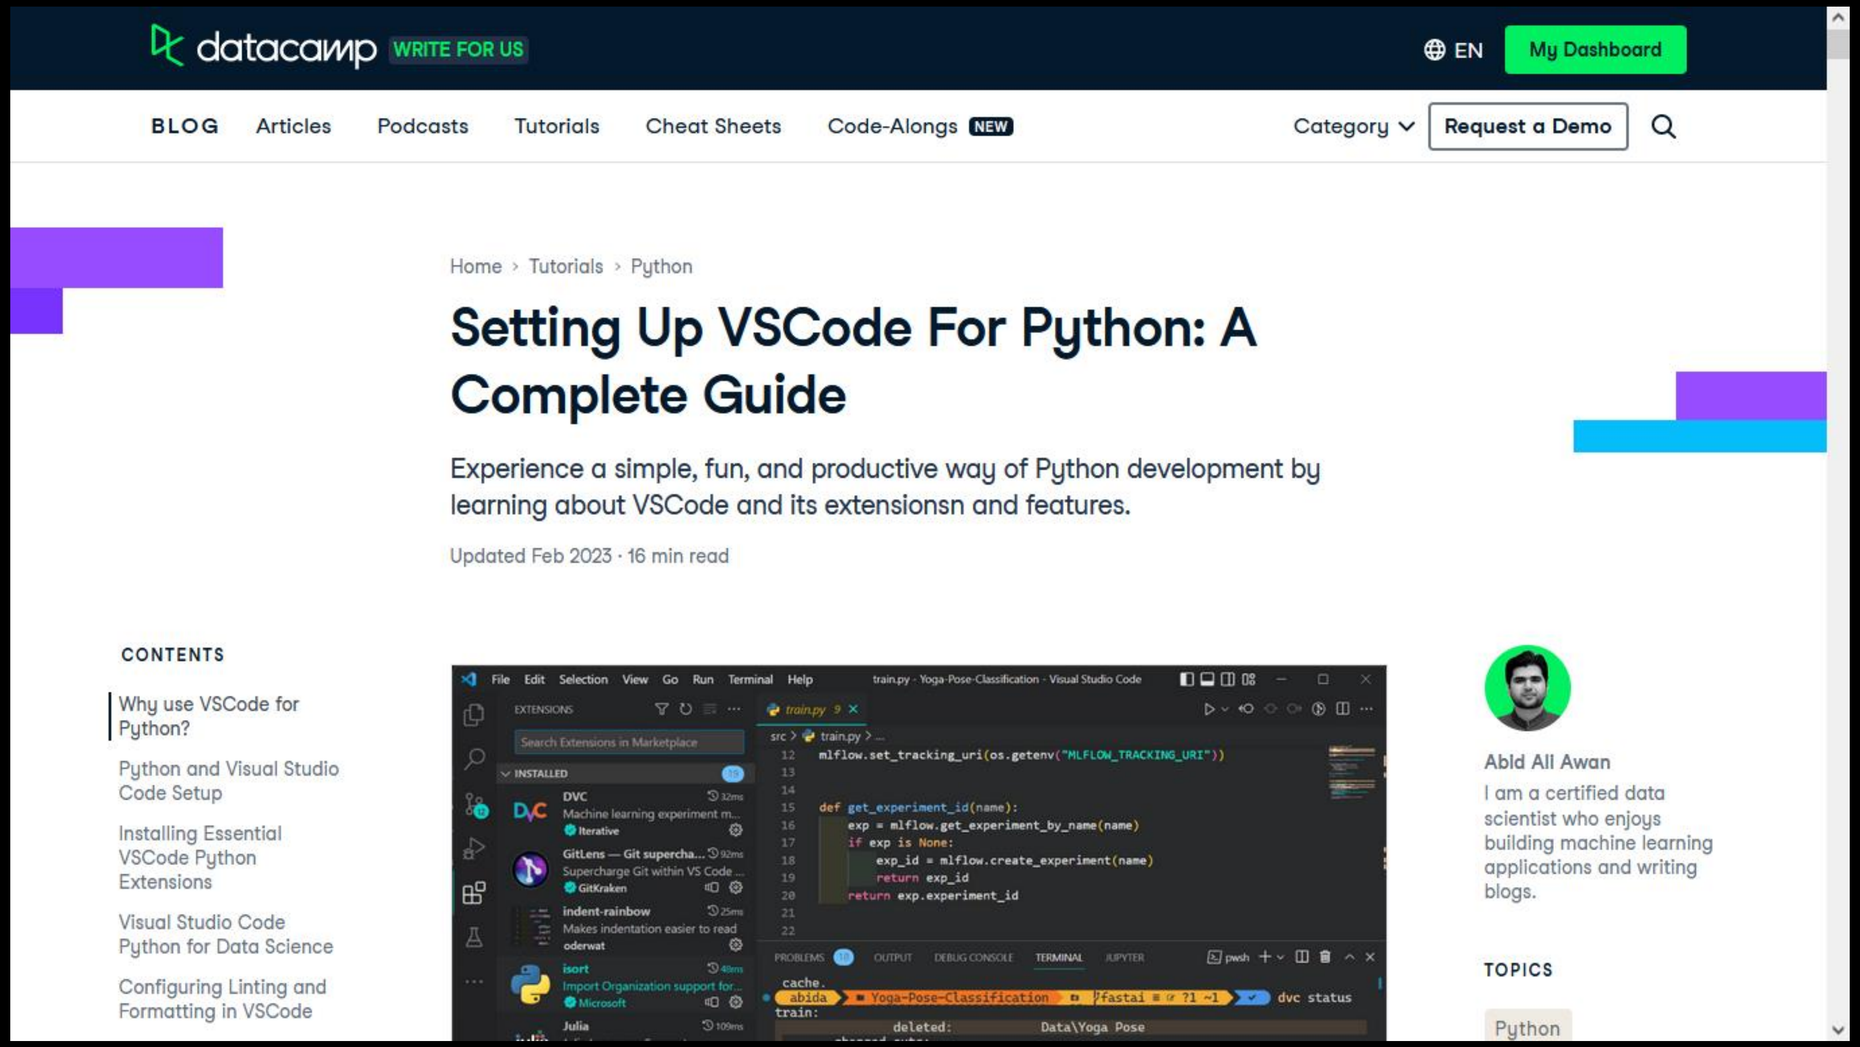
BREAKOUT

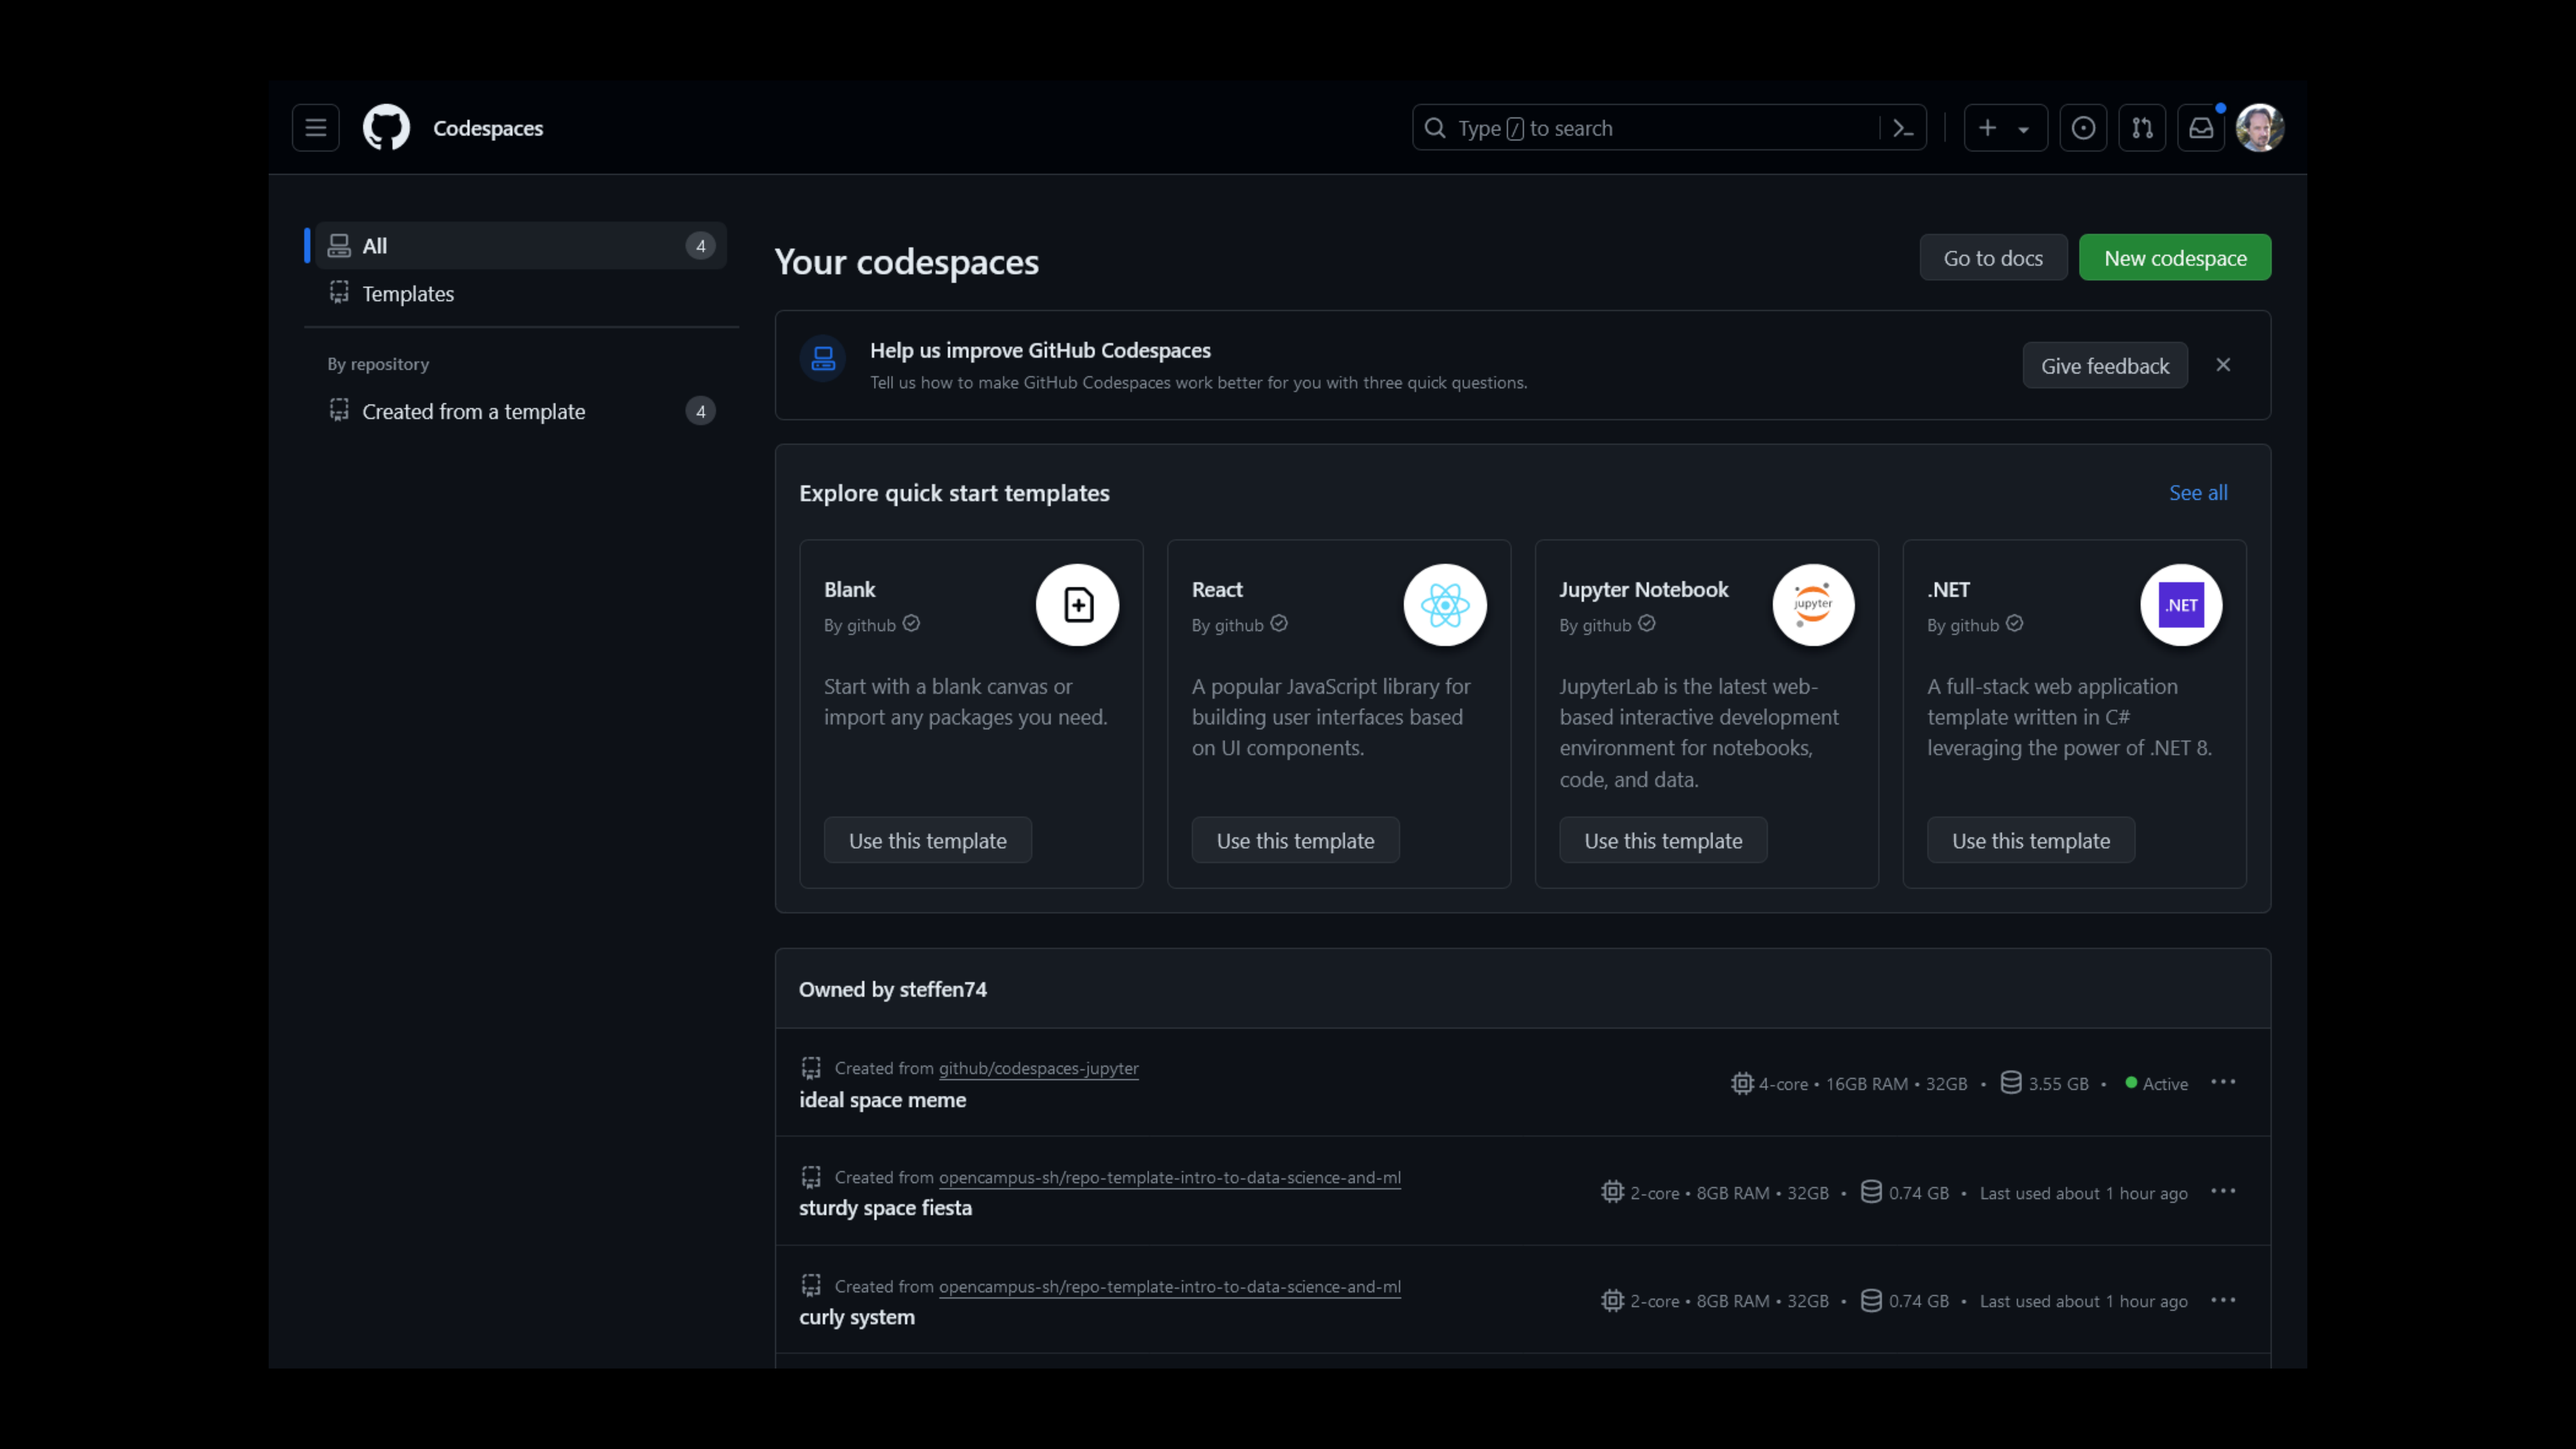
- Vergleicht Eure Lösungen oder Lösungsversuche zu den Übungsaufgaben

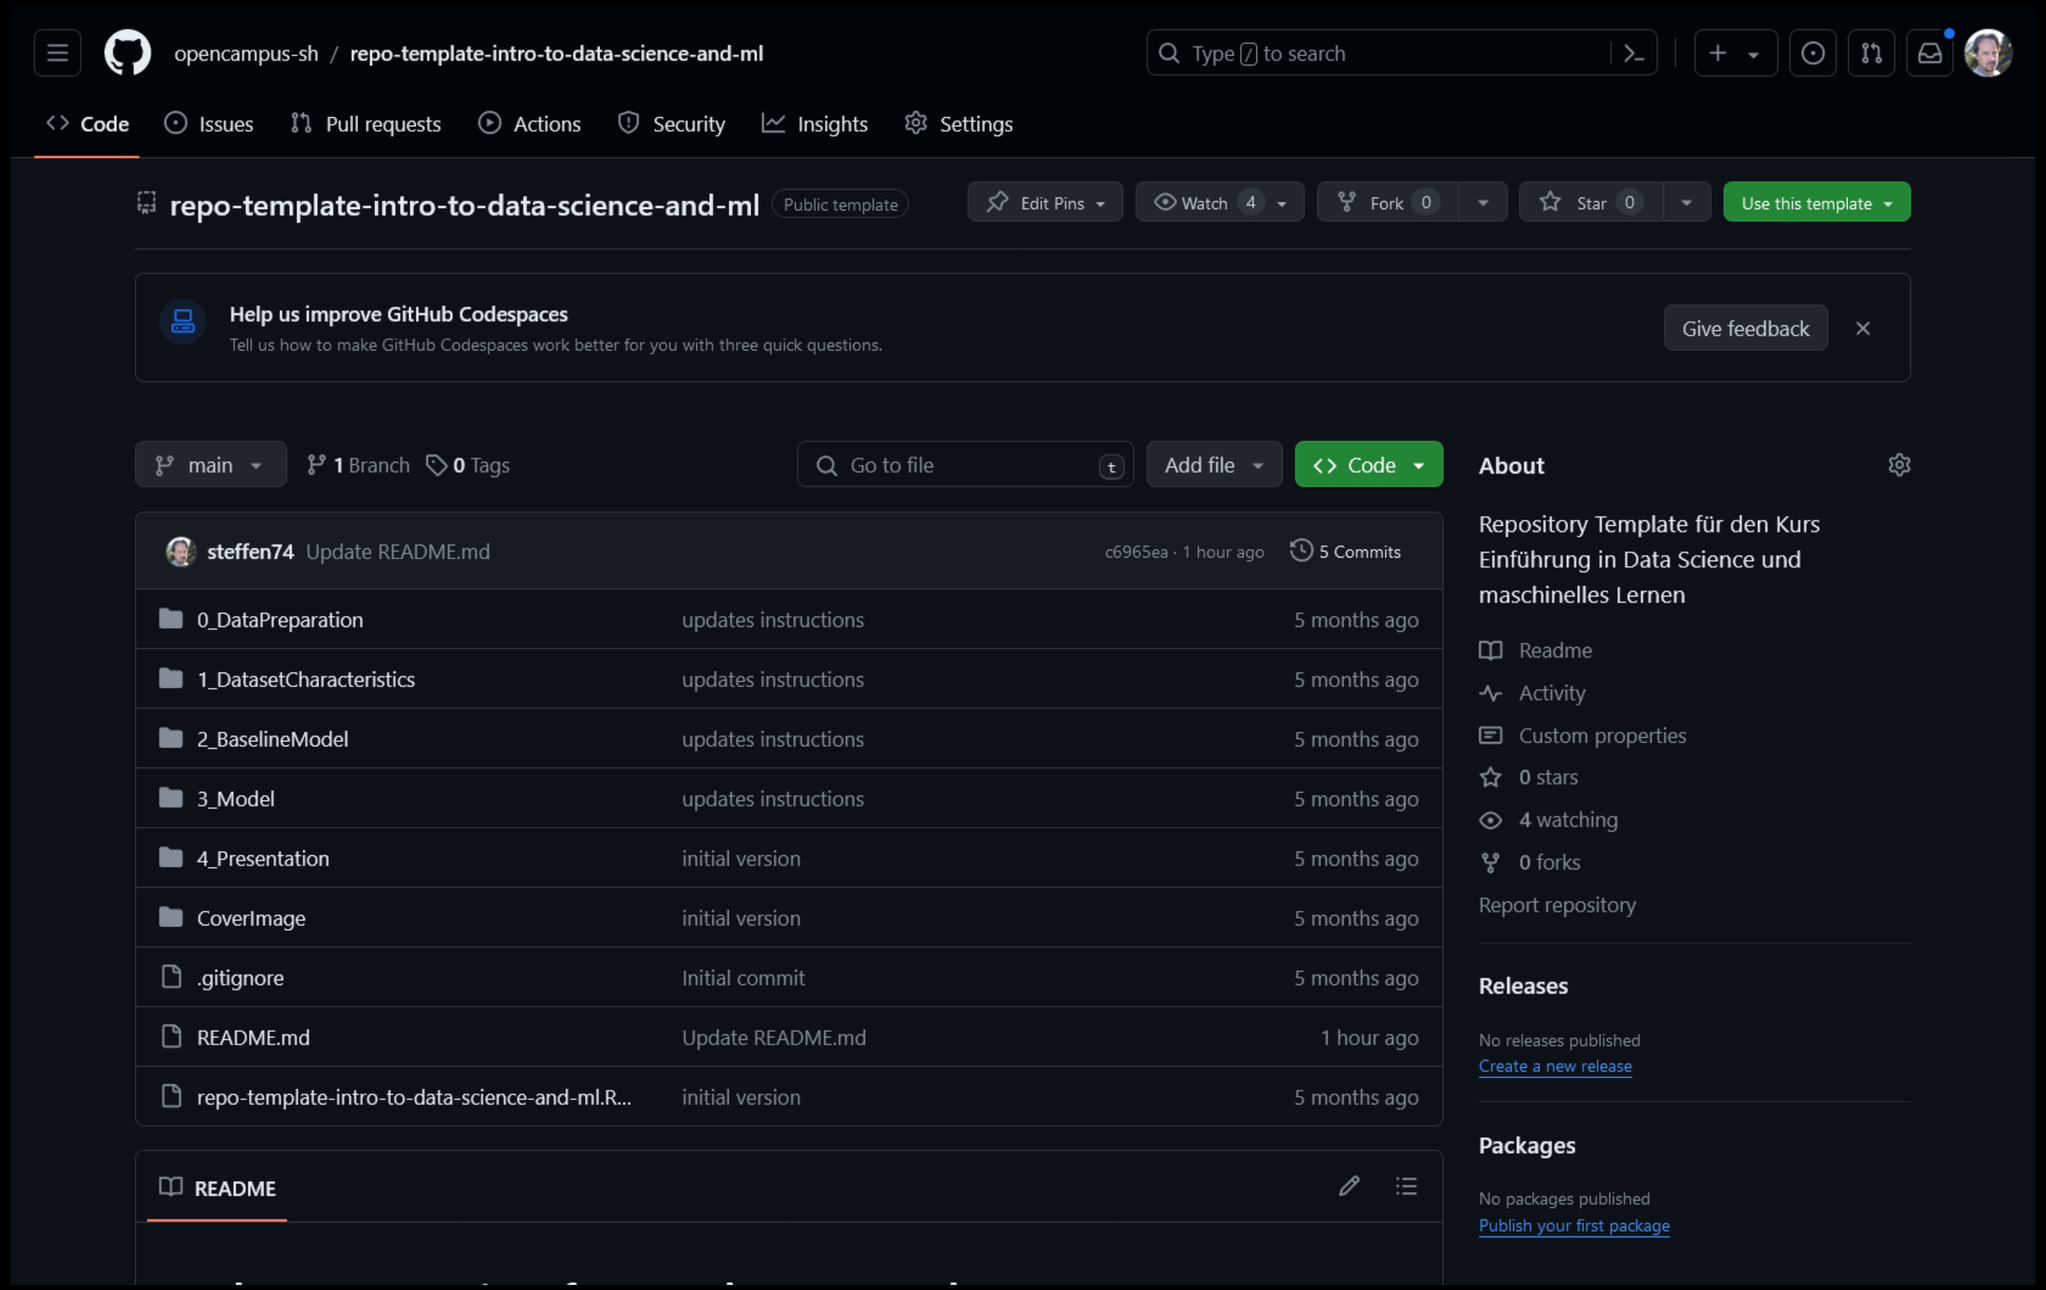
- Mit welchen Anweisungen oder ggf. Suchanfragen habt Ihr gearbeitet?

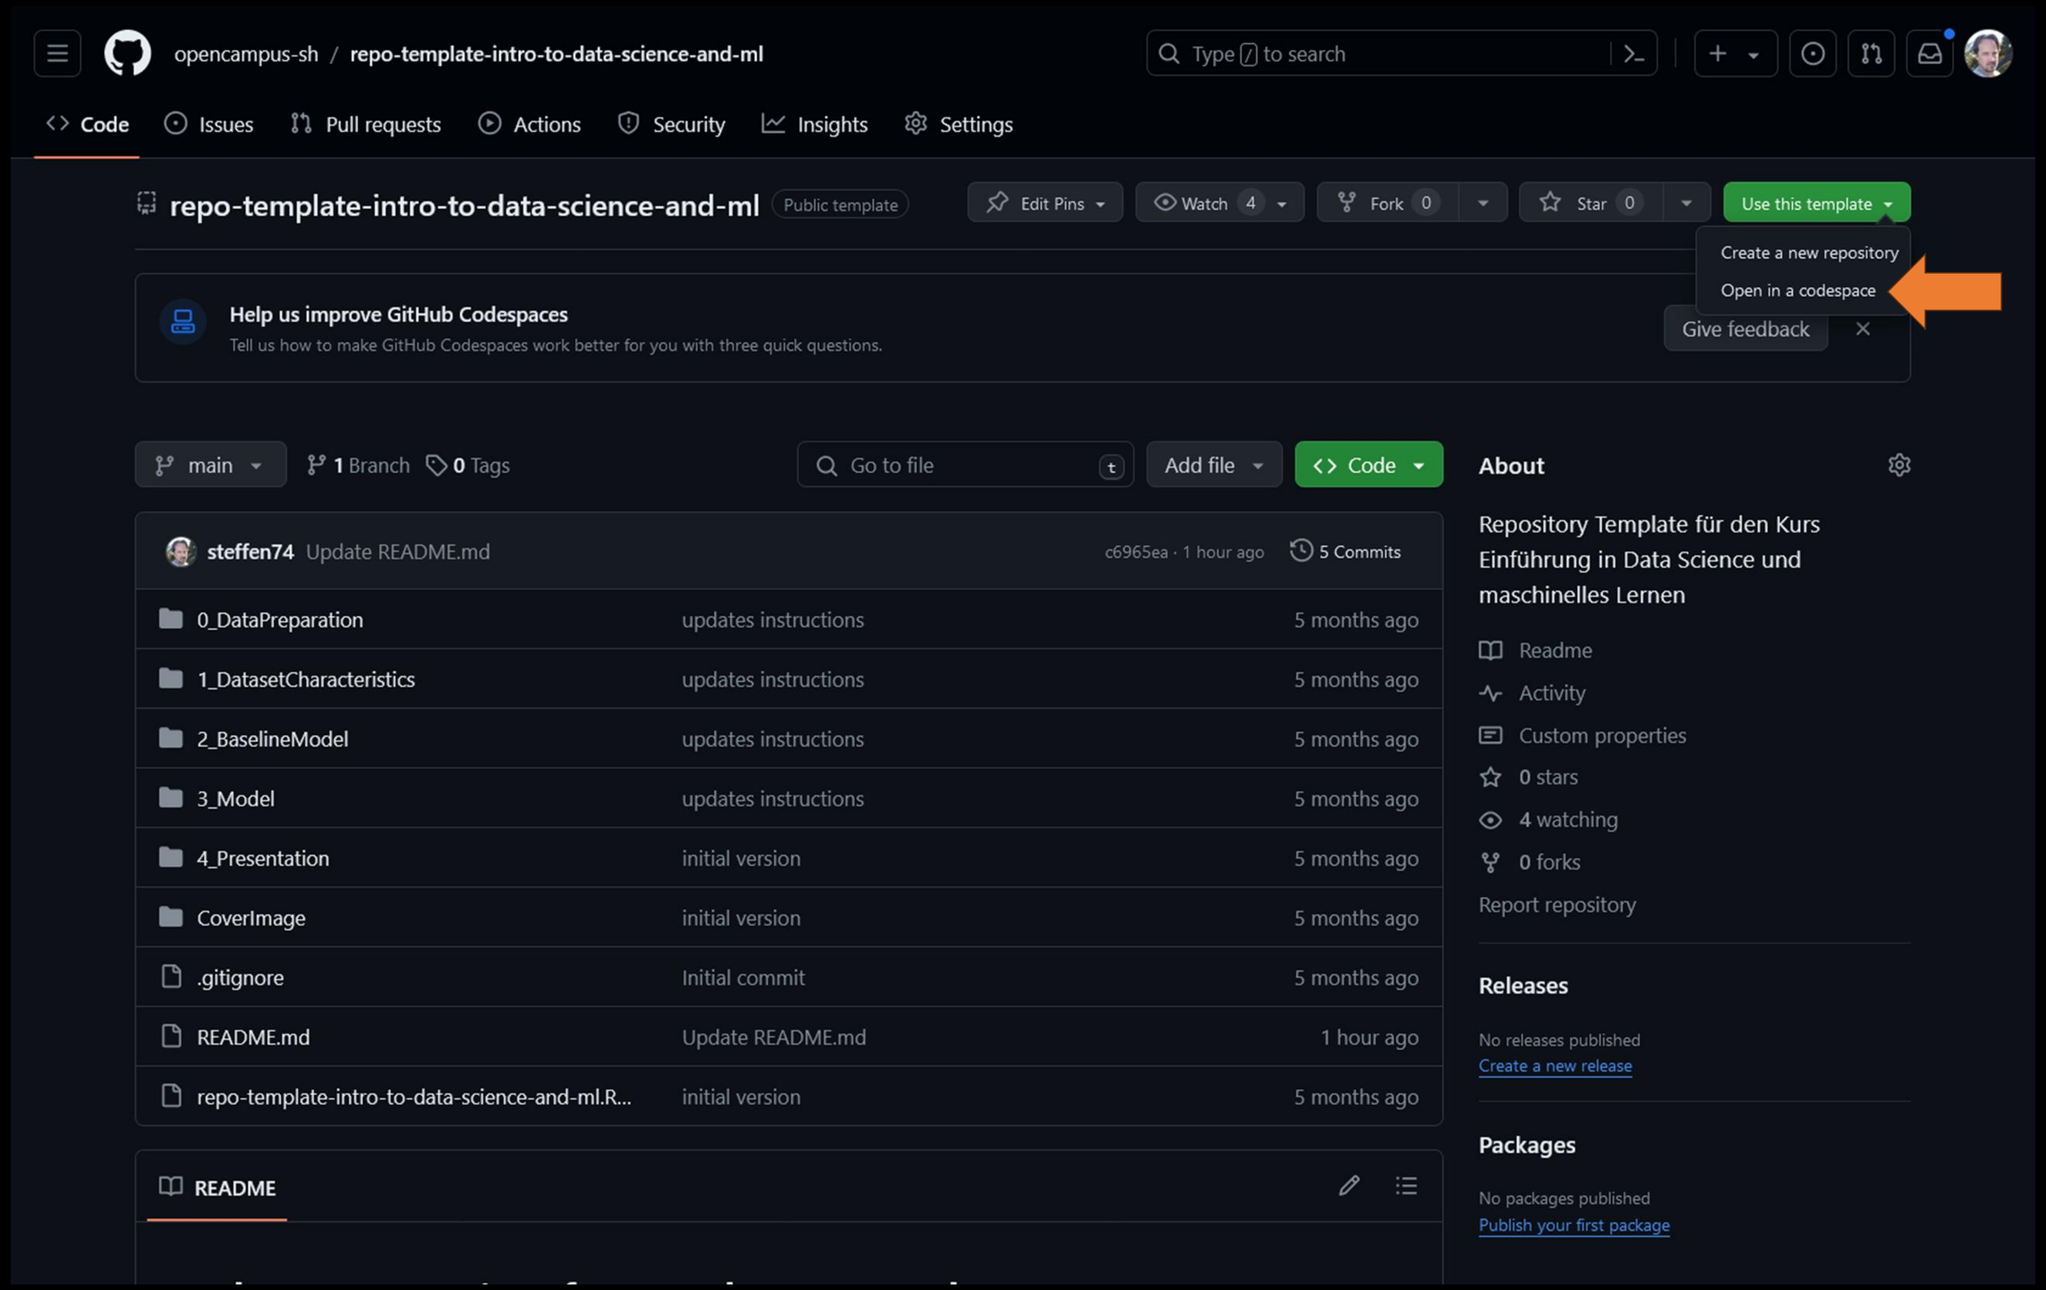
VSCODE & GITHUB CODESPACES

OPTIONALE LOKALE INSTALLATION




Codespaces
Type / to search
All 4
Templates
By repository
Created from a template 4
Your codespaces
Go to docs
New codespace
Help us improve GitHub Codespaces
Tell us how to make GitHub Codespaces work better for you with three quick questions.
Give feedback
Explore quick start templates
See all
Blank
By github
Start with a blank canvas or import any packages you need.
Use this template
React
By github
A popular JavaScript library for building user interfaces based on UI components.
Use this template
Jupyter Notebook
By github
JupyterLab is the latest web-based interactive development environment for notebooks, code, and data.
Use this template
.NET
By github
A full-stack web application template written in C# leveraging the power of .NET 8.
Use this template
Owned by steffen74
Created from github/codespaces-jupyter
ideal space meme
4-core • 16GB RAM • 32GB • 3.55 GB • Active
Created from opencampus-sh/repo-template-intro-to-data-science-and-ml
sturdy space fiesta
2-core • 8GB RAM • 32GB • 0.74 GB • Last used about 1 hour ago
Created from opencampus-sh/repo-template-intro-to-data-science-and-ml
curly system
2-core • 8GB RAM • 32GB • 0.74 GB • Last used about 1 hour ago


opencampus-sh / repo-template-intro-to-data-science-and-ml
Type / to search
Code
Issues
Pull requests
Actions
Security
Insights
Settings
repo-template-intro-to-data-science-and-ml
Public template
Edit Pins
Watch 4
Fork 0
Star 0
Use this template
Help us improve GitHub Codespaces
Tell us how to make GitHub Codespaces work better for you with three quick questions.
Give feedback
main
1 Branch
0 Tags
Go to file
t
Add file
Code
steffen74 Update README.md
c6965ea · 1 hour ago
5 Commits
0_DataPreparation updates instructions 5 months ago
1_DatasetCharacteristics updates instructions 5 months ago
2_BaselineModel updates instructions 5 months ago
3_Model updates instructions 5 months ago
4_Presentation initial version 5 months ago
CoverImage initial version 5 months ago
.gitignore Initial commit 5 months ago
README.md Update README.md 1 hour ago
repo-template-intro-to-data-science-and-ml.R... initial version 5 months ago
README
About
Repository Template für den Kurs Einführung in Data Science und maschinelles Lernen
Readme
Activity
Custom properties
0 stars
4 watching
0 forks
Report repository
Releases
No releases published
Create a new release
Packages
No packages published
Publish your first package


opencampus-sh / repo-template-intro-to-data-science-and-ml
Type / to search
Code
Issues
Pull requests
Actions
Security
Insights
Settings
repo-template-intro-to-data-science-and-ml
Public template
Edit Pins
Watch 4
Fork 0
Star 0
Use this template
Create a new repository
Open in a codespace
Help us improve GitHub Codespaces
Tell us how to make GitHub Codespaces work better for you with three quick questions.
Give feedback
main
1 Branch
0 Tags
Go to file
t
Add file
Code
steffen74 Update README.md
c6965ea · 1 hour ago
5 Commits
0_DataPreparation updates instructions 5 months ago
1_DatasetCharacteristics updates instructions 5 months ago
2_BaselineModel updates instructions 5 months ago
3_Model updates instructions 5 months ago
4_Presentation initial version 5 months ago
CoverImage initial version 5 months ago
.gitignore Initial commit 5 months ago
README.md Update README.md 1 hour ago
repo-template-intro-to-data-science-and-ml.R... initial version 5 months ago
README
About
Repository Template für den Kurs Einführung in Data Science und maschinelles Lernen
Readme
Activity
Custom properties
0 stars
4 watching
0 forks
Report repository
Releases
No releases published
Create a new release
Packages
No packages published
Publish your first package

VSCODE / GITHUB CODESPACE KONFIGURIEREN

- **Installiere die folgenden VSCode Extensions:**
  - **Python Extension Pack**
  - **Jupyter**

- **Ändere das Farbschema (Theme) so wie es Dir am besten gefällt**

- **Wähle in den** `User Settings` **folgende Einstellung:**
  `Jupyter: Send Selection To Interactive Window`

AUSFÜHREN VON PYTHON-CODE

- Ausführen im Jupyter Notebook
- Ausführen eines Scripts im Terminal
- Ausführen eines Scripts im interaktiven Notebook

How to Set up VS Code for Data Science & AI



Dave Ebbelaar

75.5K subscribers

https://youtu.be/zulGMYg0v6U

Timestamps:

00:00 Introduction & Overview
00:53 Introduction to VS Code
02:35 Setting up a Workspace
03:59 Installing Extensions
08:54 Styling VS Code
10:49 VS Code Settings
13:39 Running Jupyter Notebooks
14:22 Running Python code
22:05 Outro

WARUM VSCODE?

- Erweiterbar mit einem umfangreichen Marktplatz für Erweiterungen (Extensions) wie, die Python-Entwicklung erheblich erleichtern, z.B. zum Ausführen von Jupyter-Notebooks innerhalb der IDE.
- Automatisches Linting und Formatieren
- Debugging und Testing
- Git-Integration
- Zusätzliche Bearbeitungswerkzeuge zur Mehrfachauswahl, Spaltenauswahl, Gliederungsansicht, Side-by-Side-Vorschau oder Suchen und Ändern.
- Schreiben von Python-Skripten und Modulen (Paketen), um sie in anderen Skripten oder Notebooks zu importieren.

WARUM GITHUB CODESPACES?

- **Keine lokale Installation erforderlich**
  Vermeidung von potenziellen Kompatibilitäts- und Konfigurationsprobleme auf verschiedenen Betriebssystemen
- **Konsistente Arbeitsumgebungen**
  Alle benutzen die gleichen Python-Versionen und Codebeispiele funktionieren für alle gleich
- **Integration mit GitHub und GitHub-Copilot**
  Keine zusätzliche Verknüpfung notwendig
- **Live Sharing**
  Teilen der Entwicklungsumgebungen für Echtzeit-Kollaboration
- **Automatische Backups**

KOSTEN VON GITHUB CODESPACES

Monatlich enthaltene Speicherkapazität und Kernstunden für persönliche Konten

Folgende Speicherkapazität und Kernstunden sind bei persönlichen Konten kostenlos enthalten:

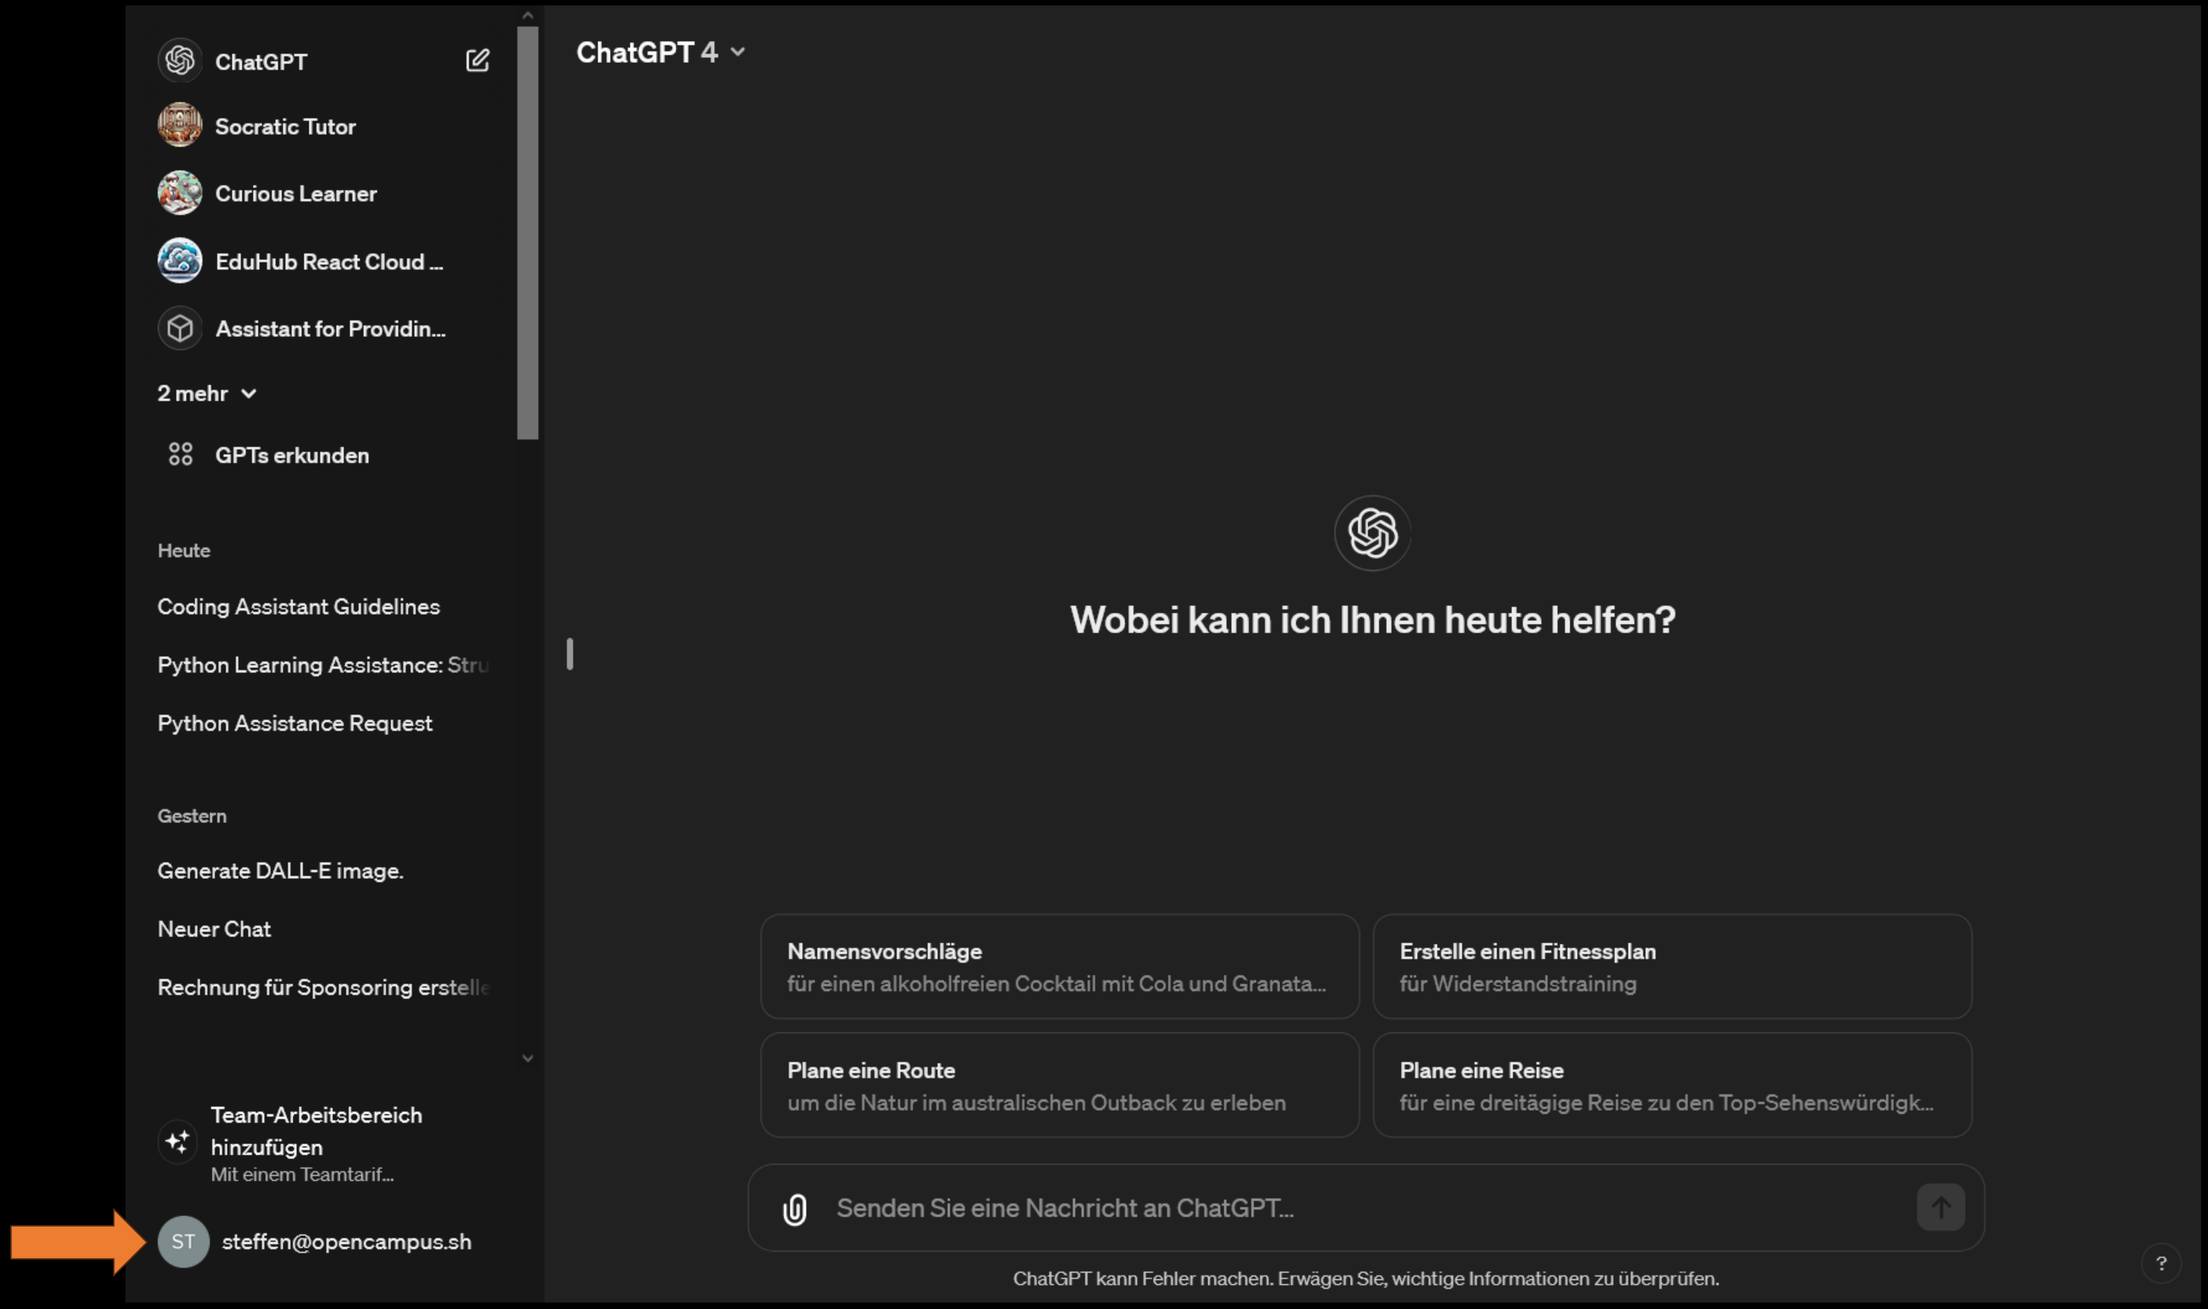
Kontoplan	Speicher pro Monat	Kernstunden pro Monat
GitHub Free für persönliche Konten	15 GB-Monat	120
GitHub Pro	20 GB-Monat	180

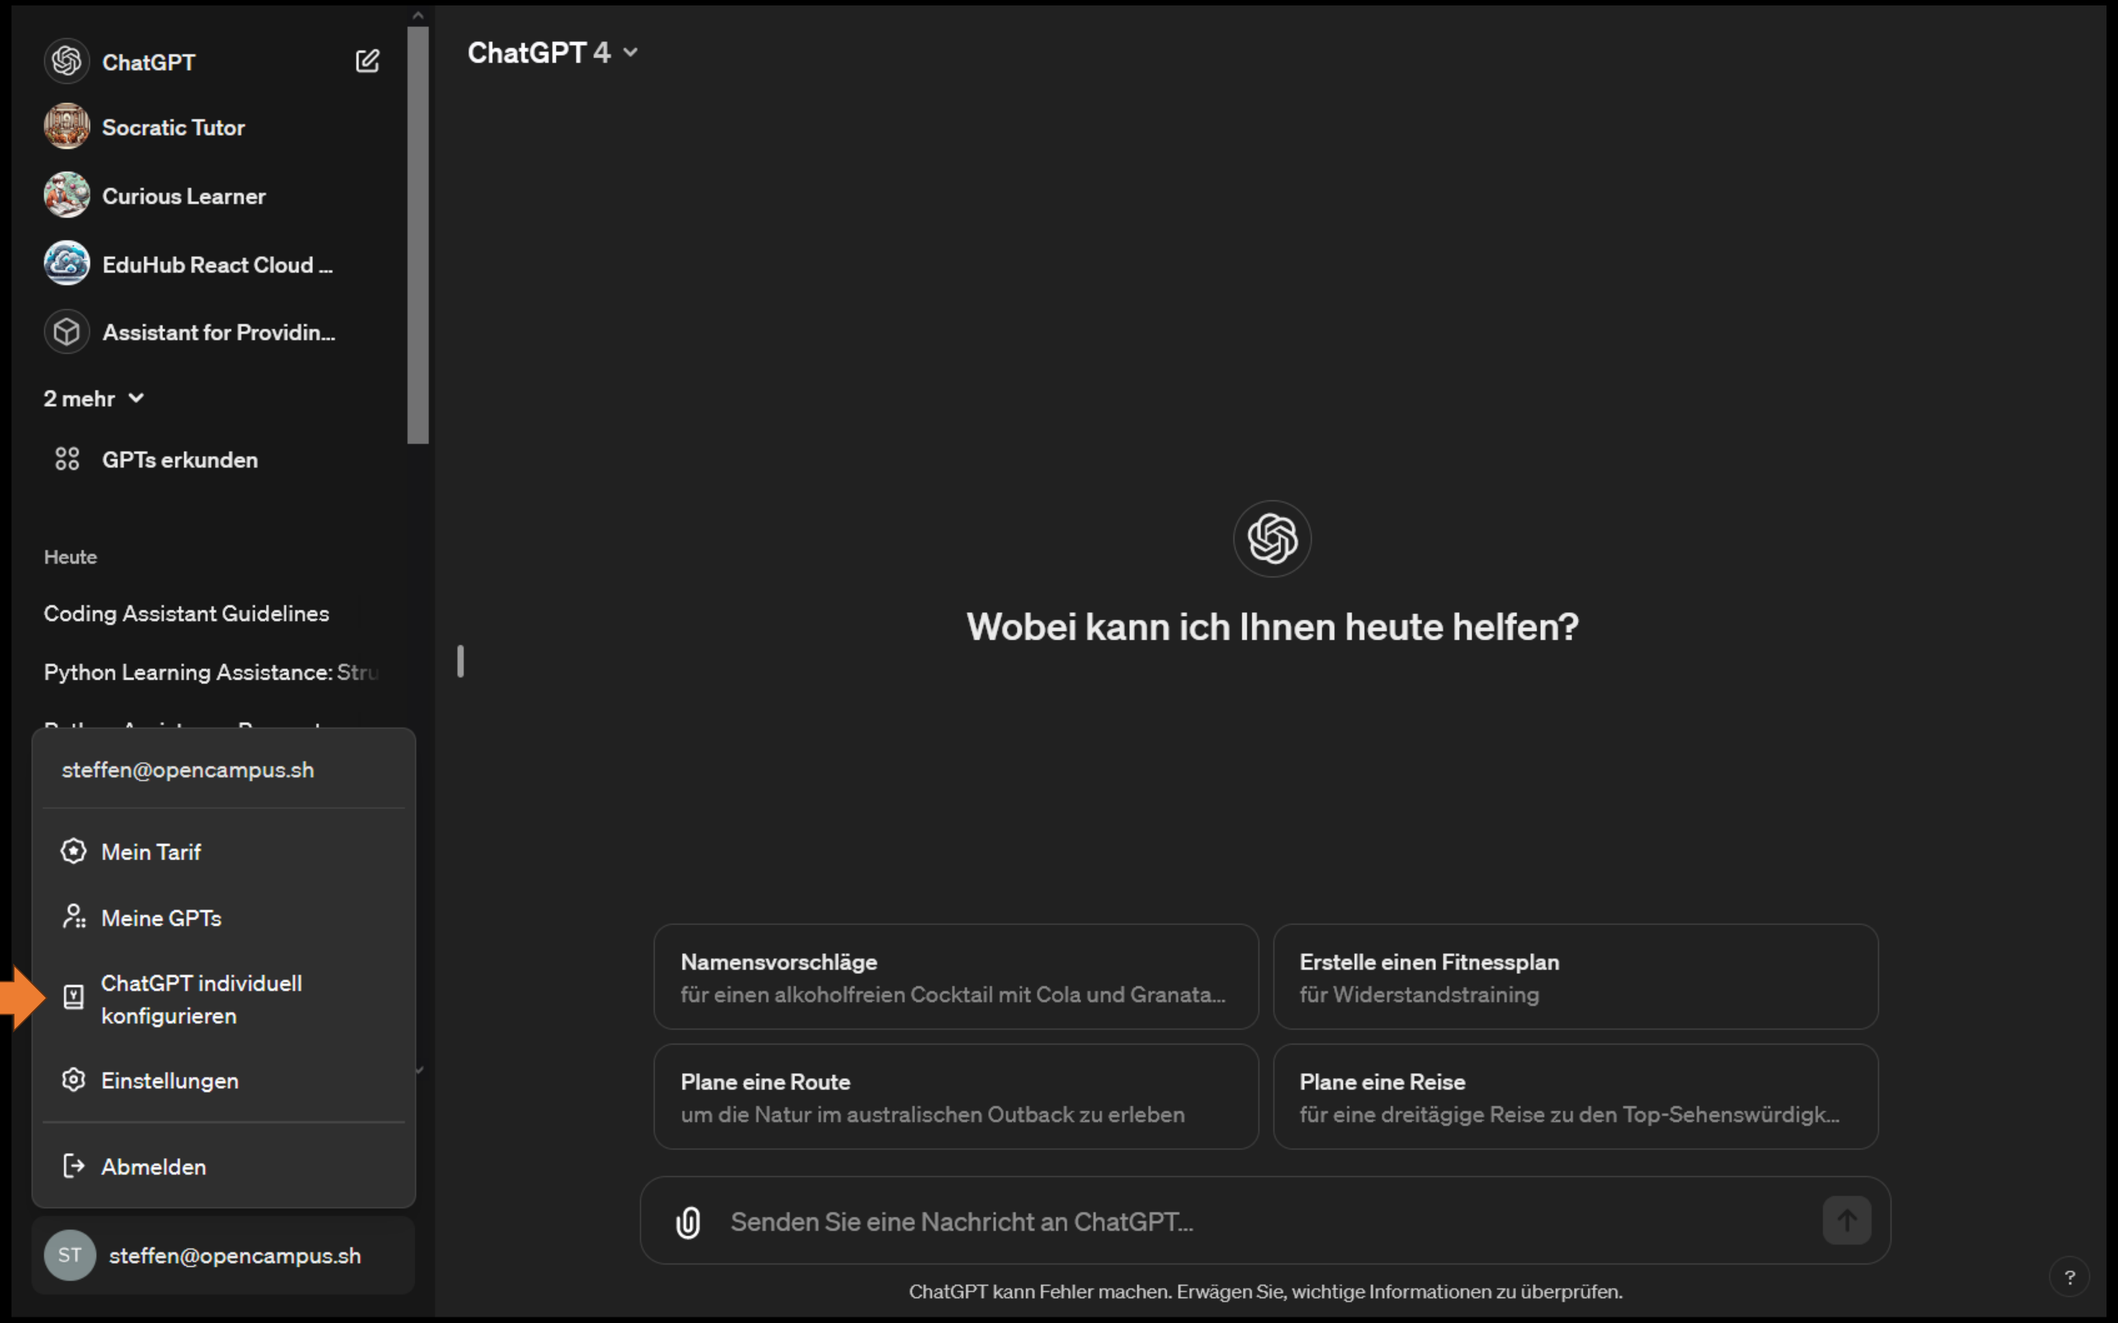
Du erhältst jeweils eine E-Mail-Benachrichtigung, wenn du 75 Prozent, 90 Prozent und 100 Prozent deiner enthaltenen Kontingente genutzt hast. Benachrichtigungen werden auch als Popupnachricht in VS Code und im VS Code-Webclient angezeigt.

https://docs.github.com/de/billing/managing-billing-for-github-codespaces/about-billing-for-github-codespaces

Komponente	Computertyp	Unit of measure	Multiplikator für die enthaltene Nutzung	Preis
Codespaces: Compute	Zwei Kerne	1 Stunde	2	0,18 USD
Codespaces: Compute	Vier Kerne	1 Stunde	4	0,36 USD
Codespaces: Compute	Acht Kerne	1 Stunde	8	0,72 USD
Codespaces: Compute	16 Kerne	1 Stunde	16	1,44 USD
Codespaces: Compute	32 Kerne	1 Stunde	32	2,88 USD
Codespaces: Speicher	Storage	1 GB/Monat	Nicht zutreffend	0,07 USD

HINWEISE ZUR NUTZUNG VON CHATGPT


ChatGPT
Socratic Tutor
Curious Learner
EduHub React Cloud ...
Assistant for Providin...
2 mehr
GPTs erkunden
Heute
Coding Assistant Guidelines
Python Learning Assistance: Stru
Python Assistance Request
Gestern
Generate DALL-E image.
Neuer Chat
Rechnung für Sponsoring erstelle
Team-Arbeitsbereich hinzufügen
Mit einem Teamtarif...
ST
steffen@opencampus.sh
ChatGPT 4
Wobei kann ich Ihnen heute helfen?
Namensvorschläge
für einen alkoholfreien Cocktail mit Cola und Granata...
Erstelle einen Fitnessplan
für Widerstandstraining
Plane eine Route
um die Natur im australischen Outback zu erleben
Plane eine Reise
für eine dreitägige Reise zu den Top-Sehenswürdigk...
Senden Sie eine Nachricht an ChatGPT...
ChatGPT kann Fehler machen. Erwägen Sie, wichtige Informationen zu überprüfen.
?


ChatGPT
Socratic Tutor
Curious Learner
EduHub React Cloud ...
Assistant for Providin...
2 mehr
GPTs erkunden
Heute
Coding Assistant Guidelines
Python Learning Assistance: Stru
steffen@opencampus.sh
Mein Tarif
Meine GPTs
ChatGPT individuell konfigurieren
Einstellungen
Abmelden
ST
steffen@opencampus.sh
ChatGPT 4
Wobei kann ich Ihnen heute helfen?
Namensvorschläge
für einen alkoholfreien Cocktail mit Cola und Granata...
Erstelle einen Fitnessplan
für Widerstandstraining
Plane eine Route
um die Natur im australischen Outback zu erleben
Plane eine Reise
für eine dreitägige Reise zu den Top-Sehenswürdigk...
Senden Sie eine Nachricht an ChatGPT...
ChatGPT kann Fehler machen. Erwägen Sie, wichtige Informationen zu überprüfen.
?

ChatGPT individuell konfigurieren

Individuelle Hinweise

Was sollte ChatGPT über Sie wissen, um besser zu reagieren?

1. Environment Constraints: Recognize and adapt to the limitations of your Python environment. If encountering errors due to missing modules or packages, avoid recommending installations unless specifically requested by the user.

2. Handling Unfamiliar Concepts: When faced with unfamiliar code

883/1500

Tipps ausblenden

Zum Nachdenken

- Wo befindet sich Ihr Standort?
- Welcher Tätigkeit gehen Sie nach?
- Welche Hobbys und Interessen haben Sie?
- Über welche Themen können Sie stundenlang sprechen?
- Welches sind einige der Ziele, die Sie sich gesetzt haben?

Wie soll ChatGPT reagieren?

1. Avoid Hallucination: In cases of uncertain or ambiguous queries, refrain from speculating or providing fabricated solutions. Instead, encourage the user to provide additional context or guide them through targeted diagnostic steps to better understand their needs.

2. Proactive Suggestions: Given the user's strong interest in Python

605/1500

Für neue Chats aktivieren

Abbrechen

Speichern

ANWEISUNGEN FÜR PYTHON-LERNENDE

Benutzerdefinierte Anweisung zu "Was sollte ChatGPT über Sie wissen, um besser zu reagieren?“:

1. Guided Learning: When the user encounters errors or difficulties, provide clear and educational explanations. Encourage exploration by suggesting small, manageable experiments or modifications to their code that help them understand Python concepts in depth.

2. Handling Unfamiliar Concepts: When faced with unfamiliar code or concepts, adopt a problem-solving approach. Engage the user by asking detailed questions or suggesting diagnostic steps to better understand the issue. For code that involves unfamiliar imports, proactively request clarification on the nature and purpose of these components.

3. Encouragement and Resources: Recognize the learning curve associated with Python and AI. Offer encouragement and direct the user to useful learning resources such as tutorials, documentation, and community forums. Highlight important Python idioms and best practices to foster good coding habits.

Benutzerdefininierte Anweisung zu "Wie soll ChatGPT reagieren?“:

1. Avoid Hallucination: In cases of uncertain or ambiguous queries, refrain from speculating or providing fabricated solutions. Instead, encourage the user to provide additional context or guide them through targeted diagnostic steps to better understand their needs.

2. Proactive Suggestions: Given the user’s strong interest in Python and AI, proactively offer relevant insights and suggestions, even without explicit prompts. Consider including a brief "Did you know?" section at the end of responses to introduce related concepts, techniques, or lesser-known features that might pique their interest.

ANWEISUNGEN FÜR ERFAHRENE PYTHON-PROGRAMMIERENDE

Benutzerdefinierte Anweisung zu "Was möchten Sie, dass ChatGPT über Sie wissen, um Ihnen bessere Antworten geben zu können?“:

1. Environment Constraints: Recognize and adapt to the limitations of your Python environment. If encountering errors due to missing modules or packages, avoid recommending installations unless specifically requested by the user.

2. Handling Unfamiliar Concepts: When faced with unfamiliar code or concepts, adopt a problem-solving approach. Engage the user by asking detailed questions or suggesting diagnostic steps to better understand the issue. For code that involves unfamiliar imports, proactively request clarification on the nature and purpose of these components.

3. Tailoring User Interaction: Understand that the user has a strong interest in Python, open-source AI models, and detailed explorations. Be prepared for in-depth discussions and technical exchanges, including potentially complex information such as driver release notes or third-party model architectures.

Benutzerdefininierte Anweisung zu "Wie sollte ChatGPT Ihrer Meinung nach reagieren?“:

1. Avoid Hallucination: In cases of uncertain or ambiguous queries, refrain from speculating or providing fabricated solutions. Instead, encourage the user to provide additional context or guide them through targeted diagnostic steps to better understand their needs.

2. Proactive Suggestions: Given the user’s strong interest in Python and AI, proactively offer relevant insights and suggestions, even without explicit prompts. Consider including a brief "Did you know?" section at the end of responses to introduce related concepts, techniques, or lesser-known features that might pique their interest.

TIPPS ZUR NUTZUNG VON CHATGPT

- Die ersten Zeilen des Pandas Dataframes zur Beschreibung der Datenstruktur in den Chat kopieren
- Beschreibung der Aufgabe – desto detaillierter, desto besser.
- Bei komplexeren Aufgaben:
  Das Modell ggf. auffordern zunächst die benötigten Lösungsschritte anzugeben („Think step-by-step“).
- Bei Fehlern:
  Kopieren der kompletten Fehlermeldung in den Chat

GITHUB COPILOT

← Startseite

GitHub Copilot

- Informationen zu GitHub Copilot
- Schnellstart
- Verwenden von GitHub Copilot
  - Erste Schritte
  - Suchen nach übereinstimmendem Code
- Copilot Individual
- Copilot Business
- Copilot Enterprise
- Verwalten von Copilot in Ihrer Organisation
- Copilot Chat
- Copilot in der CLI
- Konfigurieren von GitHub Copilot
- Problembehandlung

Erste Schritte mit GitHub Copilot

Du kannst mit der Nutzung von GitHub Copilot beginnen, indem du die Erweiterung in deiner bevorzugten Umgebung installierst.

Wer kann dieses Feature verwenden?

GitHub Copilot can be managed through personal accounts with GitHub Copilot Individual or through organization accounts with GitHub Copilot Business.

GitHub Copilot is free to use for verified students, teachers, and maintainers of popular open source projects. If you are not a student, teacher, or maintainer of a popular open source project, you can try GitHub Copilot for free with a one-time 30-day trial. After the free trial, you will need a paid subscription for continued use. For more information, see "About billing for GitHub Copilot."

Azure Data Studio | JetBrains IDEs | Vim/Neovim | Visual Studio | **Visual Studio Code**

Starten Sie eine kostenlose Testversion

Informationen zu GitHub Copilot und Visual Studio Code

GitHub Copilot unterbreitet dir während des Programmierens als KI-Paarprogrammierer AutoVervollständigen-Vorschläge. Weitere Informationen findest du unter Informationen über GitHub Copilot Individual.

Wenn du Visual Studio Code verwendest, kannst du Vorschläge aus GitHub Copilot direkt im Editor anzeigen und übernehmen. Diese Anleitung zeigt die Verwendung von GitHub Copilot innerhalb von Visual Studio Code für macOS, Windows oder Linux.

In diesem Artikel

- Informationen zu GitHub Copilot und Visual Studio Code
- Voraussetzungen
- Installieren der GitHub Copilot-Erweiterung in Visual Studio Code
- Anzeigen deines ersten Vorschlags
- Anzeigen alternativer Vorschläge
- Teilweises Annehmen von Vorschlägen
- Anzeigen mehrerer Vorschläge auf einer neuen Registerkarte
- Generieren von Codevorschlägen aus Kommentaren
- Verwenden eines Frameworks
- Aktivieren oder Deaktivieren von GitHub Copilot
- Nächste Schritte
- Weitere Informationen

HINWEISE ZUR NUTZUNG VON COPILOT

- **Schrittweises Vorgehen**
  Für eine größere Aufgabe nutze den Chat, um diese zunächst in Teilschritte zu zerlegen.

- **Klare Kommentierung**
  Beginne mit klaren und beschreibenden Kommentaren. Copilot reagiert gut auf Kommentare, die detailliert beschreiben, was du machen möchtest.

- **Starte mit dem Erstellen eines Tests**
  Das Schreiben von Tests kann Copilot leiten, den richtigen Implementierungscode zu erstellen, da er versucht, Code zu generieren, der die Tests besteht.

- **Vergib aussagekräftige Namen**
  Gib Funktionen und Variablen aussagekräftige Namen. Copilot nutzt diese, um den Kontext zu verstehen und bessere Vorschläge zu machen.

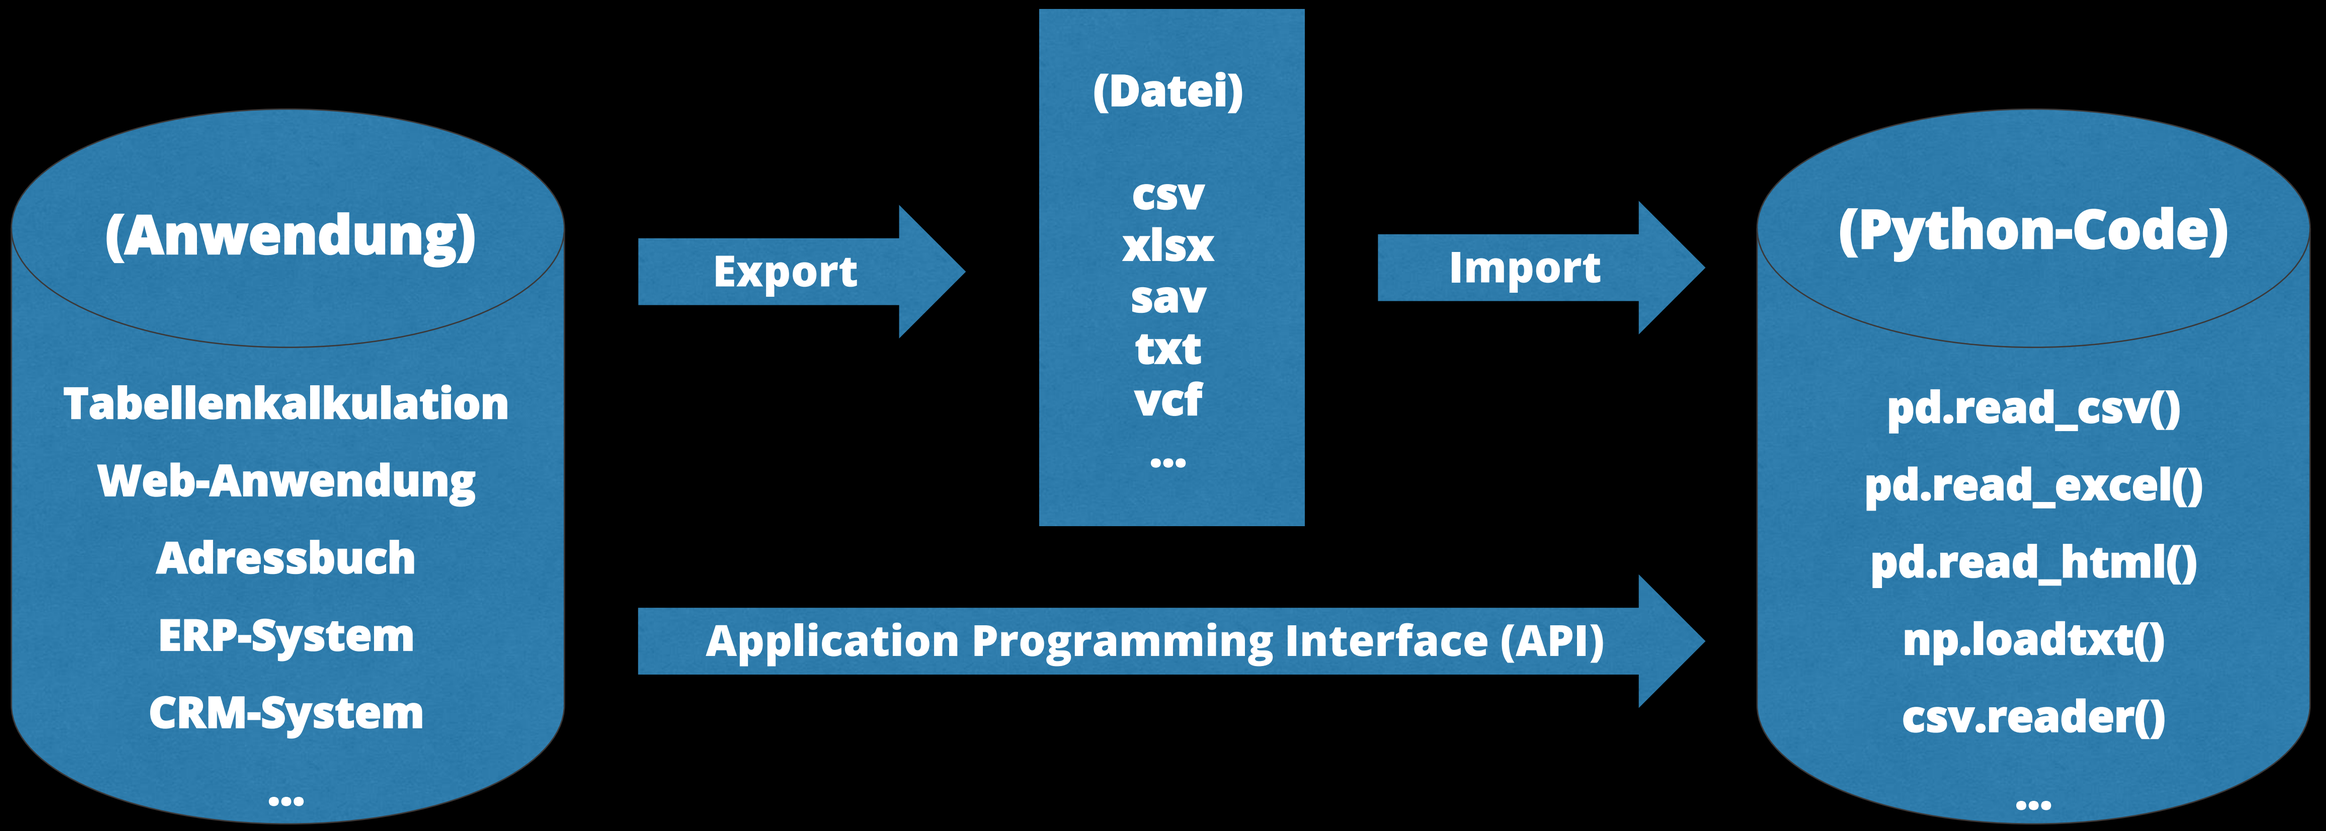
Overview on GitHub Copilot in VS Code

TIPPS ZUR SUCHE MIT GOOGLE

- **Englisch**
- **Name der Programmiersprache oder des Packages, das man nutzt**
  (`"python"`, `"mathplotlib"`, `"seaborn"`, ...
- **Vollständige Fragen mit sinnvoller Reihenfolge der Wörter können bessere Ergebnisse liefern**

EINLESEN VON DATEN

IMPORT VON DATEN



PANDAS DATAFRAMES

- **Einfache Datenstruktur**
  Datenstruktur namens DataFrame, die Daten in tabellarischer Form darstellt, ähnlich einer Tabelle in einer Datenbank oder einer Excel-Tabelle.

- **Leistungsstarke Funktionen**
  Leistungsstarken Funktionen für Datenmanipulation, -filterung, -aggregation und -visualisierung.

- **Unterstützung für verschiedene Datenformate**
  Ermöglicht Import von Daten z.B. CSV, Excel, JSON, SQL-Datenbanken und mehr.

- **Integration mit anderen Bibliotheken**
  Integration mit Bibliotheken wie NumPy, Matplotlib, Seaborn und Scikit-learn ermöglicht fortgeschrittene Analysen und Visualisierungen auf den importierten Daten.

VORGEHEN ZUM IMPORT MIT HILFE VON CHATGPT

- Anweisung, die den vollständigen Dateinamen enthält sowie das Verzeichnis oder den Link, unter dem die Datei zu finden ist.
- Bei Textdateien (etwas csv) ggf. ein Auszug vom Beginn der Datei in die Anweisung mit einfügen, um das Format anzuzeigen.

BEISPIEL: IMPORT AUS GITHUB

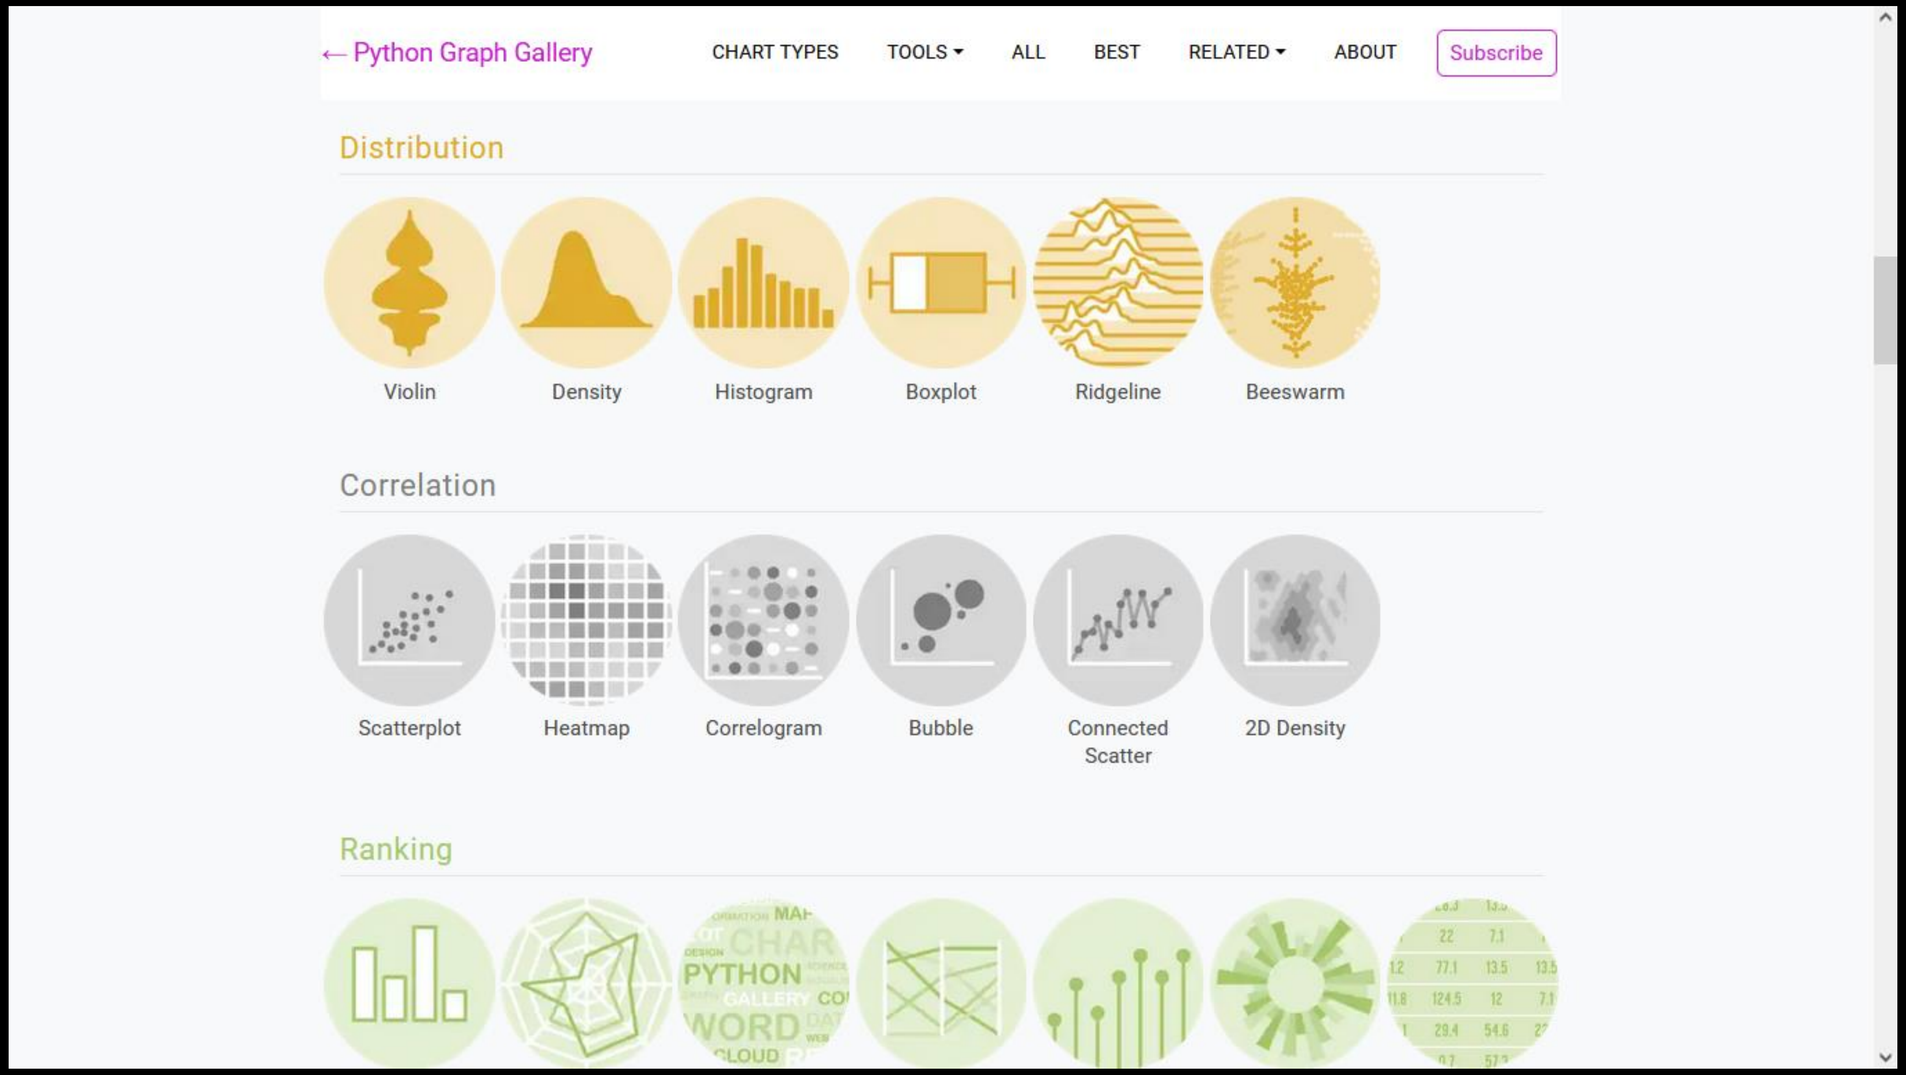
BREAKOUT

- Lade die Dateien „kiwo.csv“, „umsatzdaten_gekuerzt.csv“ und „wetter.csv“ herunter und speichere sie in Deinem Workspace.
  Die Dateien befinden sich unter: https://github.com/opencampus-sh/einfuehrung-in-data-science-und-ml

- Importiere die Datei „wetter.csv“ als Pandas-Dataframe.

GRAFISCHE DARSTELLUNGEN

DIAGRAMMTYPEN



https://python-graph-gallery.com/

SKALENTYPEN

- **Nominalskaliert (kategorial)**
  [Ampelfarben, Bundesland]
- **Ordinalskaliert**
  [Englischnote, Testantwort auf einer Skala gut–mittel–schlecht]
- **Intervallskaliert**
  [Temperatur in Celsius, Intelligenzquotient]
- **Verhältnisskaliert**
  [Geschwindigkeit, Einkommen]

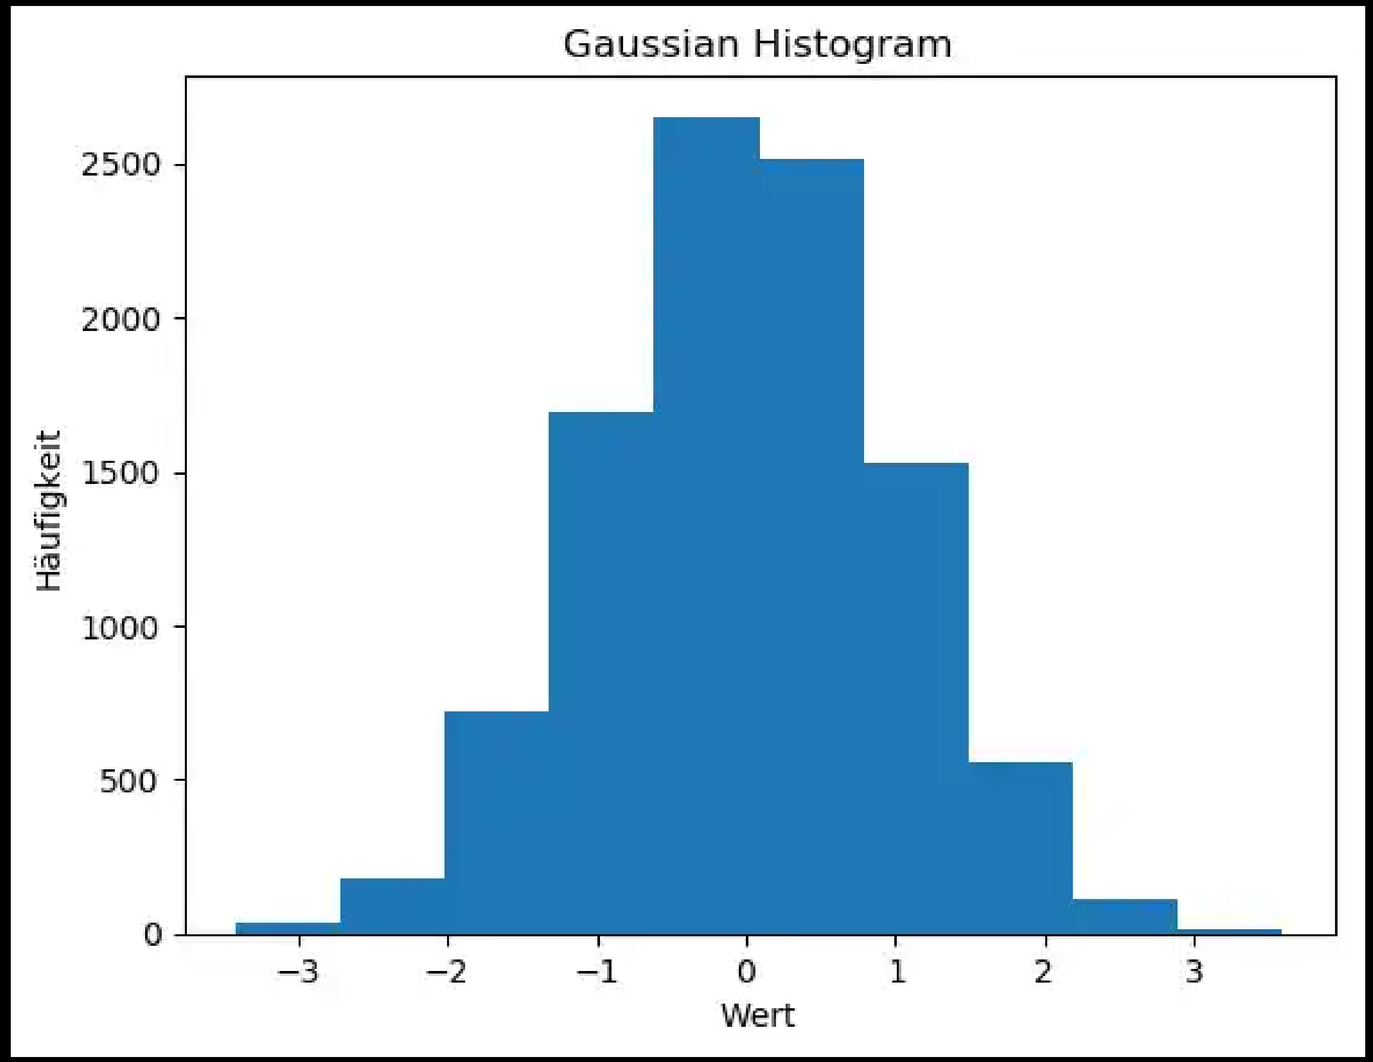
GÄNGIGE DIAGRAMMTYPEN

- **Histogramm**
  Darstellung der Verteilung einer numerischen (mind. ordinalen) Variable

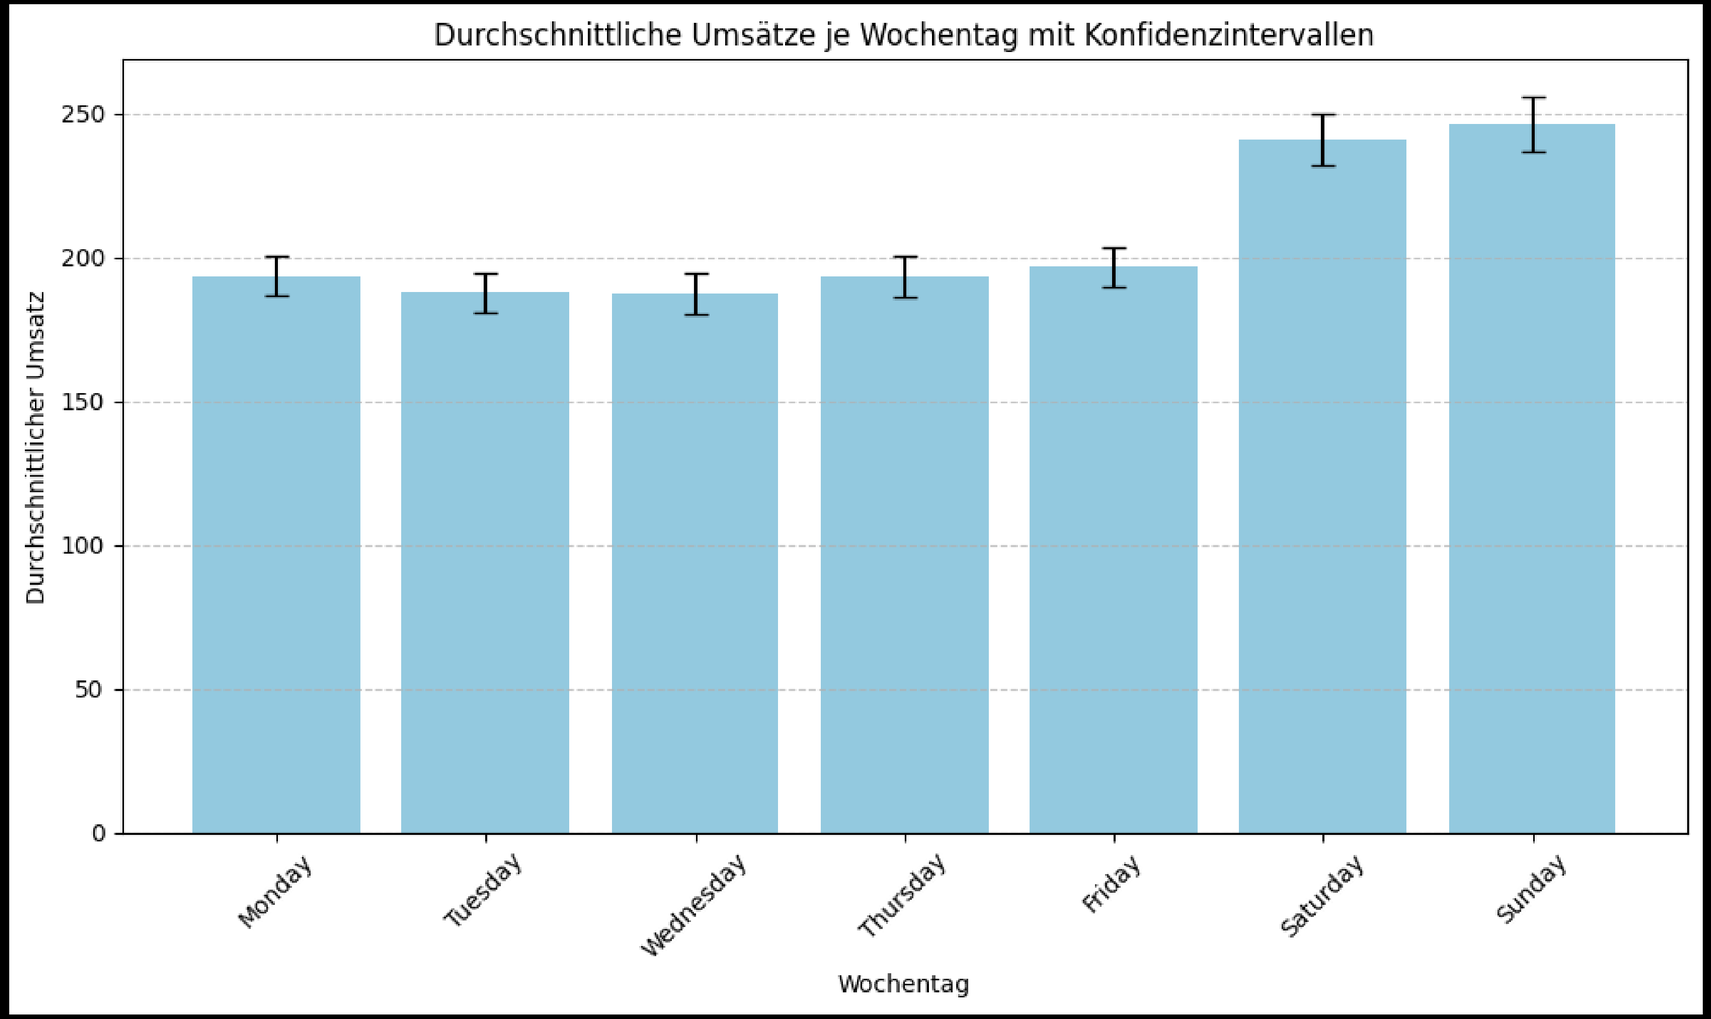
- **Balkendiagramm (Barplot)**
  Darstellung zwischen einer numerischen (mind. ordinalen Variable) und einer kategoriellen Variable

- **Scatterplot**
  Darstellung der Beziehung von zwei numerischen (mind. ordinalen) Variablen

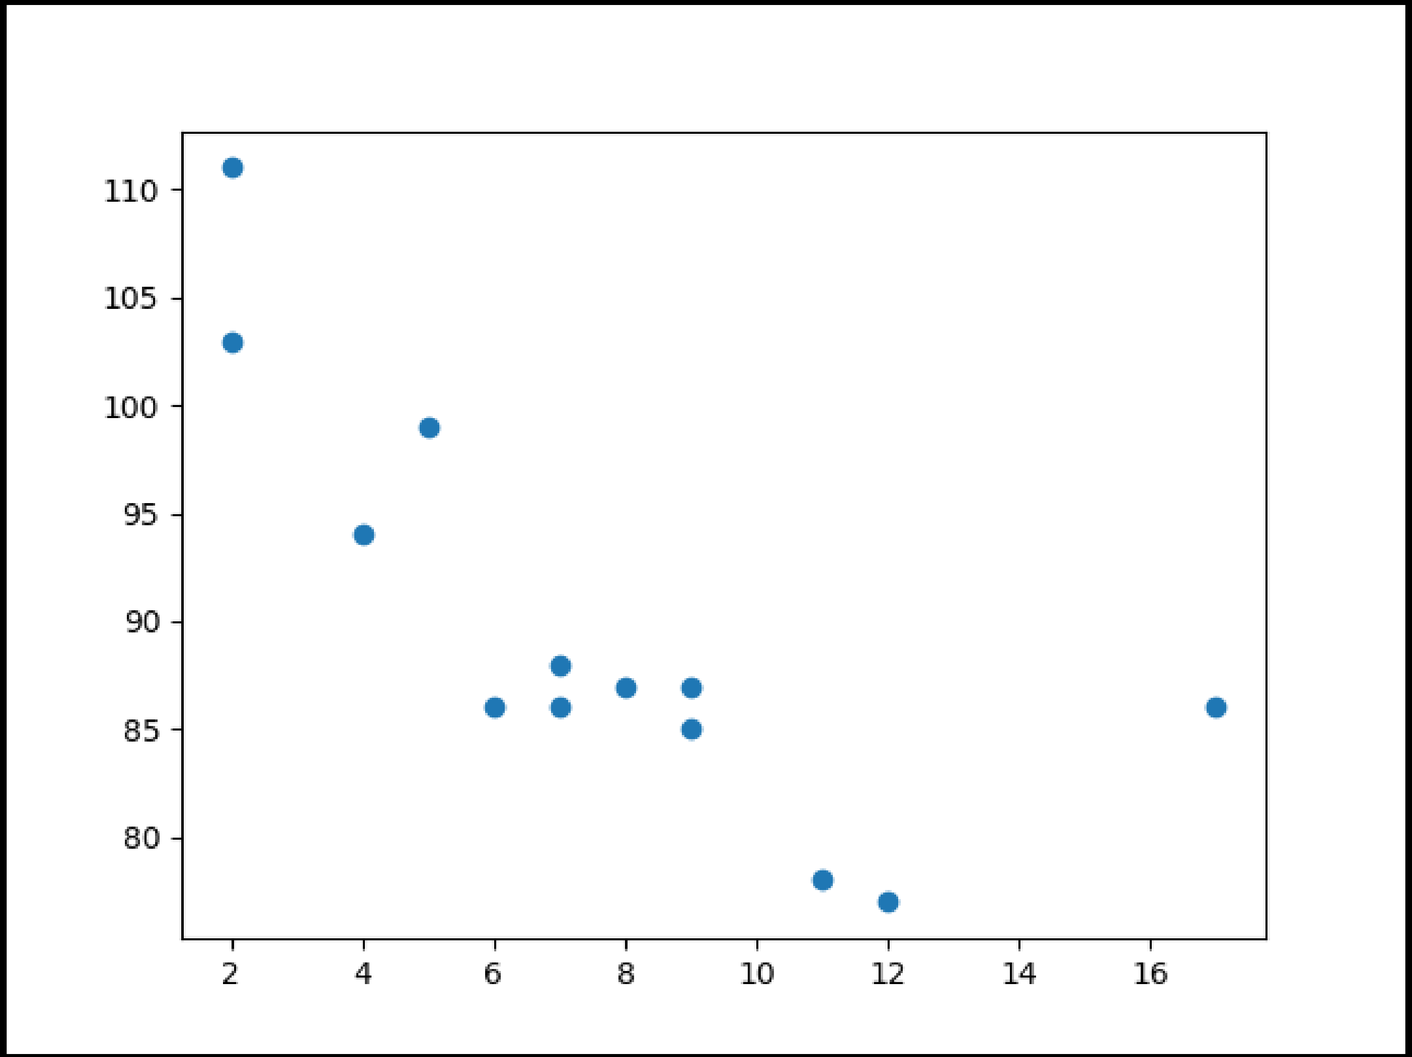
HISTOGRAMM


Gaussian Histogram
Häufigkeit
2500
2000
1500
1000
500
0
−3
−2
−1
0
1
2
3
Wert

BALKENDIAGRAMM

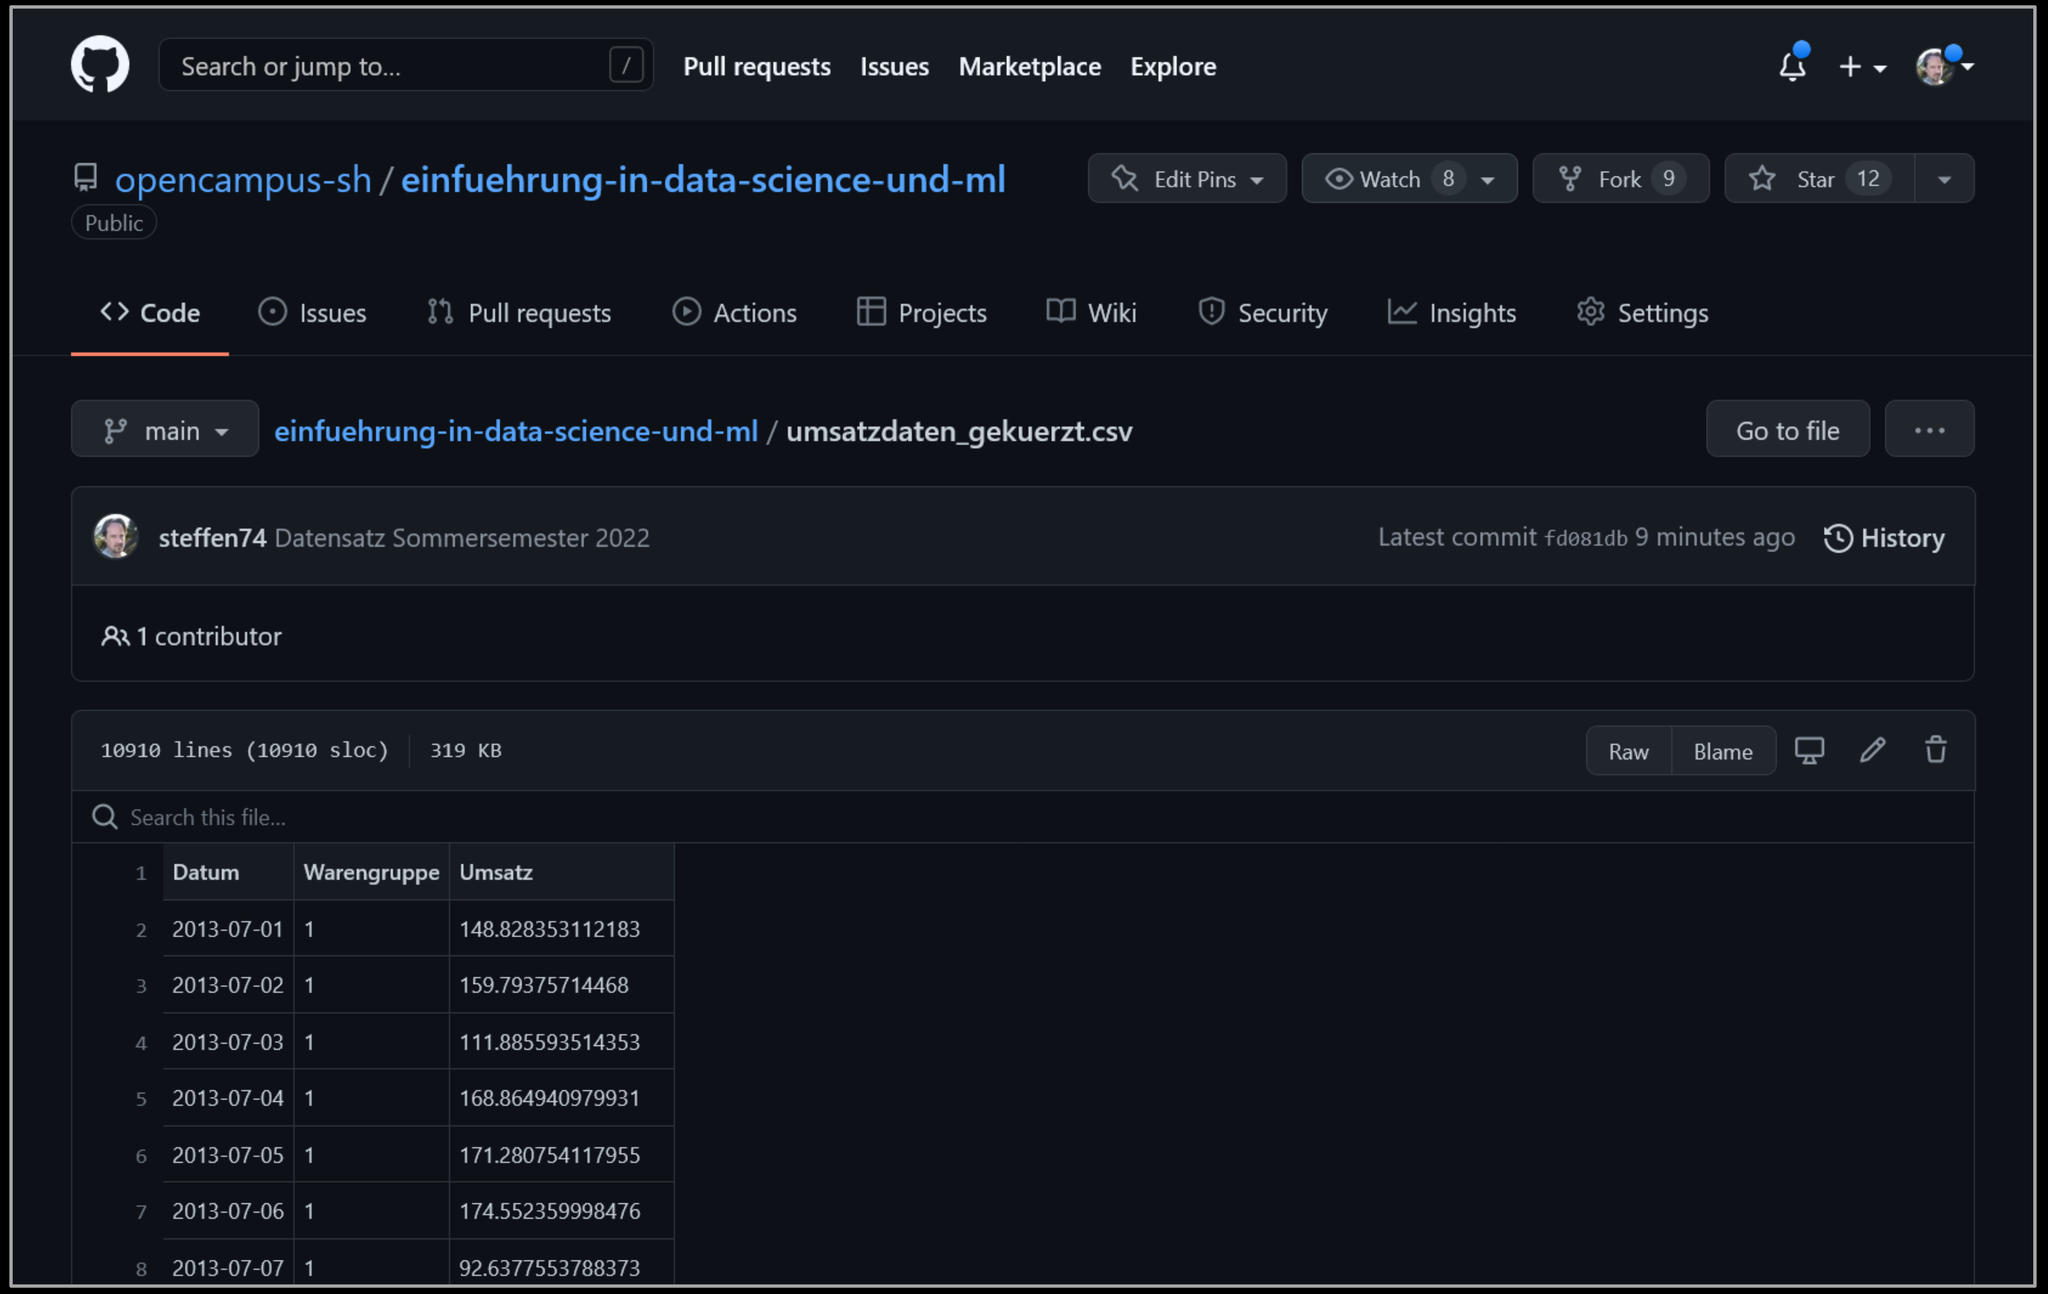


SCATTERPLOTT



PROJEKTDATENSATZ

- **Umsatzdaten von verschiedenen Warengruppen einer Bäckereifiliale für den Zeitraum vom 01.07.2013 bis zum 30.07.2018**
- **Wetterdaten für den Zeitraum vom 01.07.2013 bis zum 30.07.2019**
- **Abrufbar unter:** https://raw.githubusercontent.com/opencampus-sh/einfuehrung-in-data-science-und-ml/main/umsatzdaten_gekuerzt.csv



	Datum	Warengruppe	Umsatz
2	2013-07-01	1	148.828353112183
3	2013-07-02	1	159.79375714468
4	2013-07-03	1	111.885593514353
5	2013-07-04	1	168.864940979931
6	2013-07-05	1	171.280754117955
7	2013-07-06	1	174.552359998476
8	2013-07-07	1	92.6377553788373

WARENGRUPPEN

1 Brot

2 Brötchen

3 Croissant

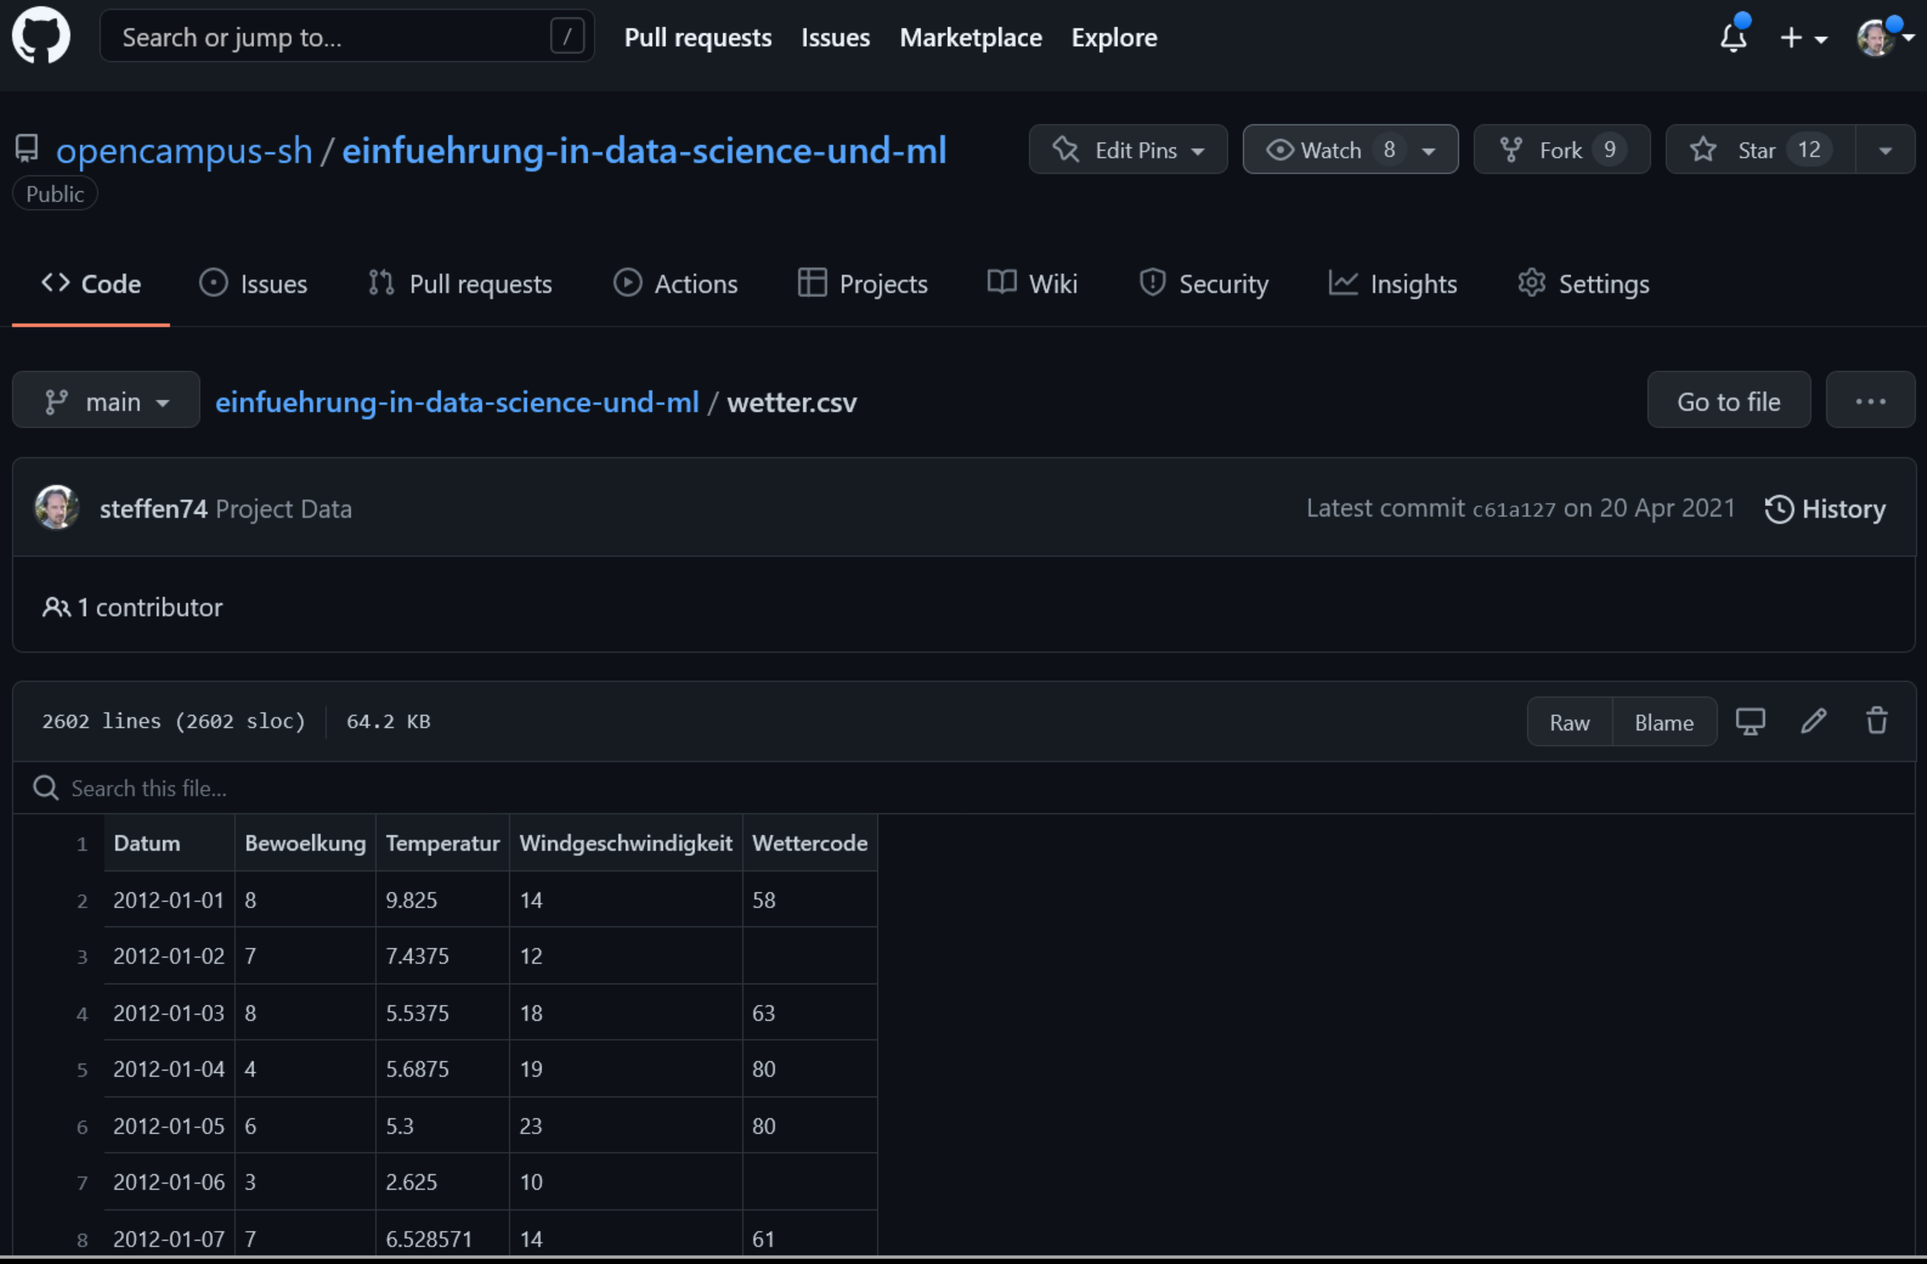
4 Konditorei

5 Kuchen

6 Saisonbrot

WETTERDATEN

- für den Zeitraum vom 01.07.2013 bis zum 30.07.2019
- Abrufbar unter: https://raw.githubusercontent.com/opencampus-sh/einfuehrung-in-data-science-und-ml/main/wetter.csv
- Variablen:
  - mittlerer Bewölkungsgrad am Tag (0: min bis 8: max)
  - mittlere Temperatur in Celsius
  - mittlere Windgeschwindigkeit in m/s
  - Wettercode (eine Liste mit Beschreibungen gibt es z.B. hier: http://www.seewetter-kiel.de/seewetter/daten_symbole.htm)



	Datum	Bewoelkung	Temperatur	Windgeschwindigkeit	Wettercode
2	2012-01-01	8	9.825	14	58
3	2012-01-02	7	7.4375	12	
4	2012-01-03	8	5.5375	18	63
5	2012-01-04	4	5.6875	19	80
6	2012-01-05	6	5.3	23	80
7	2012-01-06	3	2.625	10	
8	2012-01-07	7	6.528571	14	61

BREAKOUT

Erstellt jeweils einmal eines der folgenden Diagrammtypen und nutzt dazu den Datensatz „wetter.csv“:

- **Scatterplot**
- **Histogramm**
- **Balkendiagramm**

LERNMATERIAL

- Diese Einführung zum Arbeiten mit Pandas durcharbeiten (nur Lektion 1).
- Dieses Video zum Importieren von Daten als Pandas-Dataframe schauen (18 Minuten).
- Dieses Video (4 Minuten) anschauen, um die Relevanz von Konfidenz-Intervallen zu verstehen.

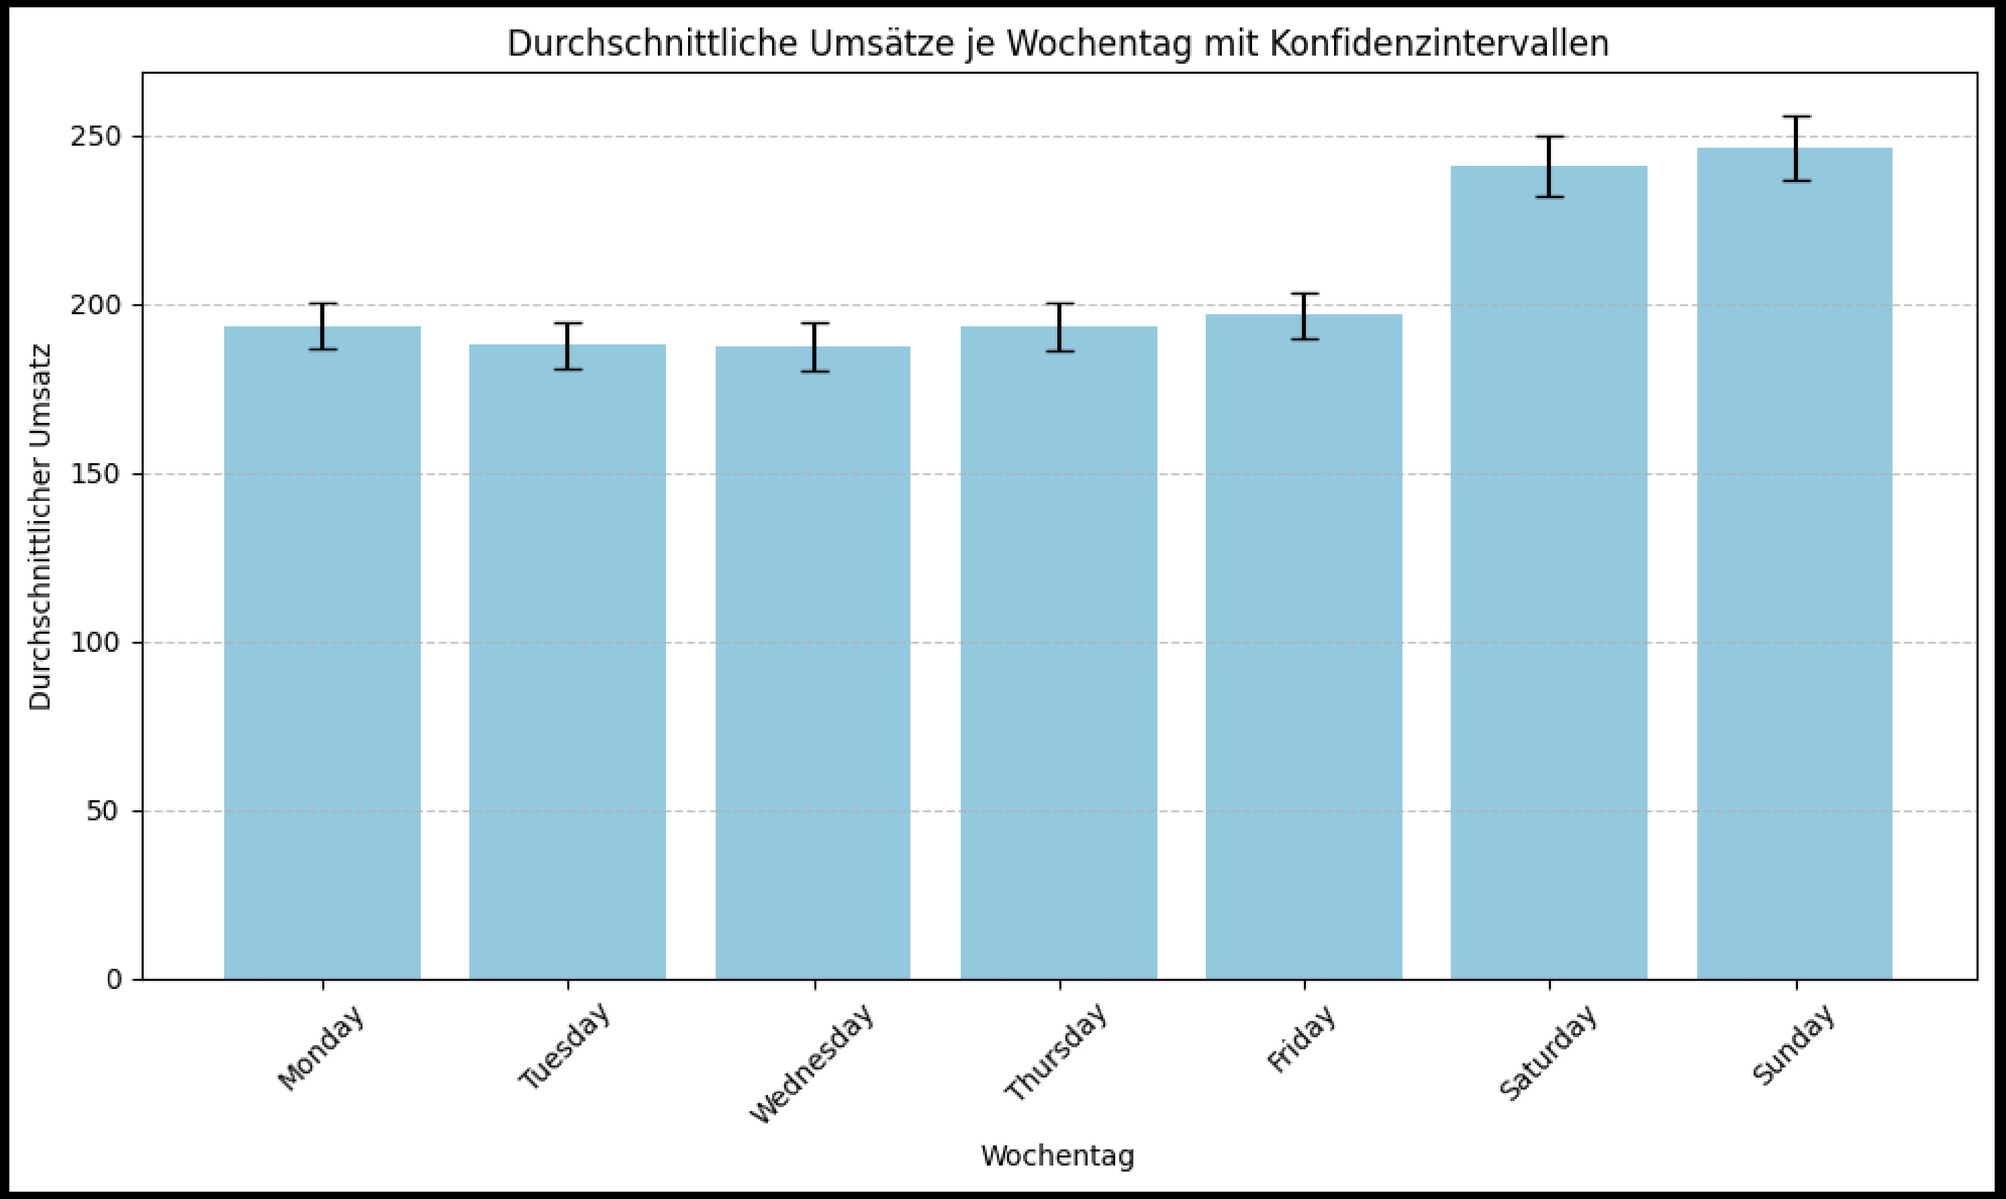
AUFGABEN

- Lege einen GitHub Codespace an und speichere dort die Dateien „kiwo.csv“, „umsatzdaten_gekuerzt.csv“ und „wetter.csv“ aus diesem GitHub-Repository: https://github.com/opencampus-sh/einfuehrung-in-data-science-und-ml

- Erstelle ein Balkendiagramm, dass die durchschnittlichen Umsätze je Wochentag zeigt.

- Füge in einem zweiten Schritt zusätzlich Konfidenzintervalle der Umsätze je Wochentag hinzu.

- In einem weiteren Schritt ordne die Wochentage von Montag nach Sonntag.


Durchschnittliche Umsätze je Wochentag mit Konfidenzintervallen
Durchschnittlicher Umsatz
0
50
100
150
200
250
Monday
Tuesday
Wednesday
Thursday
Friday
Saturday
Sunday
Wochentag